




دانشگاه خواجه نصیرالدین طوسی
دانشکده مهندسی کامپیوتر- گروه هوش مصنوعی

پایان نامه دوره کارشناسی ارشد

مهندسی کامپیوتر


تخمین عمق بدون نظارت با استفاده از پارامترهای کالیبراسیون داخلی به عنوان ورودی

محمدامین قاسم زاده

استاد راهنما

دکتر بهروز نصیحت کن

تابستان ۱۴۰۵



دانشگاه خواجه نصیرالدین طوسی
دانشکده مهندسی کامپیوتر- گروه هوش مصنوعی

پایان نامه دوره کارشناسی ارشد

مهندسی کامپیوتر

عنوان

تخمین عمق بدون نظارت با استفاده از پارامترهای
کالیبراسیون داخلی به عنوان ورودی

نگارش

محمدامین قاسم‌زاده

استاد راهنما

دکتر بهروز نصیحت کن

تابستان ۱۴۰۵



تقدیم به: مادر و پدر عزیزم

به آنان که با علم خود زندگی آزاد می سازند



تأییدیه هیئت داوران جلسه‌ی دفاع از پایان‌نامه کارشناسی ارشد

هیأت داوران پس از مطالعه‌ی پایان‌نامه و شرکت در جلسه‌ی دفاع از پایان‌نامه تهیه‌شده با عنوان «تخمین عمق بدون نظارت با استفاده از پارامترهای کالیبراسیون داخلی به عنوان ورودی» توسط آقای / خانم محمدمبین قاسم‌زاده صحت و کفایت تحقیق انجام شده را برای اخذ درجه‌ی کارشناسی ارشد در رشته‌ی مهندسی کامپیوتر در تاریخ تابستان ۱۴۰۵ مورد تأیید قرار دادند.

۱. استاد راهنما: دکتر بهروز نصیحت کن امضا

۲. استاد داور داخلی: دکتر حمید ابریشمی مقدم امضا

۳. استاد مدعو: دکتر محمدرضا محمدی امضا



دانشگاه صنعتی خواجه نصیرالدین طوسی

اظهارنامه دانشجو

اینجانب محمدامین قاسم‌زاده به شماره دانشجویی ۴۰۲۰۹۶۴۴ دانشجوی کارشناسی ارشد رشته‌ی مهندسی کامپیوتر دانشکده دانشکده مهندسی کامپیوتر دانشگاه خواجه نصیرالدین طوسی گواهی می‌نمایم که تحقیقات ارائه شده در این پایان‌نامه با عنوان:

تخمین عمق بدون نظارت با استفاده از پارامترهای کالبراسیون داخلی به عنوان ورودی

توسط اینجانب انجام و بدون هرگونه دخل و تصرف است و موارد نسخه برداری شده از آثار دیگران را با ذکر کامل مشخصات منبع ذکر کرده‌ام. در صورت اثبات خلاف مندرجات فوق، به تشخیص دانشگاه مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انضباطی و غیره) با اینجانب رفتار خواهد شد. در ضمن، مسئولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذی صلاح (اعم از اداری و قضایی) به عهده‌ی اینجانب خواهد بود و دانشگاه هیچ‌گونه مسئولیتی در این خصوص نخواهد داشت.

نام و نام خانوادگی دانشجو: محمدامین قاسم‌زاده

تاریخ و امضای دانشجو:



حق طبع، نشر و مالکیت نتایج

حق چاپ و تکثیر این پایان نامه متعلق به نویسندگان آن می باشد. بهره برداری از این پایان نامه در چهارچوب مقررات کتابخانه و با توجه به محدودیتی که توسط استاد راهنما به شرح زیر تعیین می گردد، بلامانع است:

☐ بهره برداری از این پایان نامه برای همگان و با ذکر منبع، بلامانع است.

☐ بهره برداری از این پایان نامه با اخذ مجوز از استاد راهنما و با ذکر منبع، بلامانع است.

☐ بهره برداری از این پایان نامه تا تاریخ _____ ممنوع است.

استاد راهنما: دکتر بهروز نصیحت کن امضا

قدردانی

اکنون که به یاری پروردگار و یاری و راهنمایی اساتید بزرگ موفق به پایان این رساله شده‌ام وظیفه خود دانسته که نهایت سپاسگزاری را از تمامی عزیزانی که در این راه به من کمک کرده‌اند را به عمل آورم: در آغاز از استاد بزرگ و دانشمند جناب آقا دکتر نصیحت‌کن که راهنمایی این پایان‌نامه را به عهده داشته‌اند کمال تشکر را دارم. از داوران گرامی دکتر حمید ابریشمی مقدم و دکتر محمدرضا محمدی که زحمت داوری و تصحیح این پایان‌نامه را به عهده داشتند کمال سپاس را دارم. خالصانه از تمامی اساتید و معلمان و مدرسانی که در مقاطع مختلف تحصیلی به من علم آموخته و مرا از سرچشمه دانایی سیراب کرده‌اند متشکرم. از کلیه هم‌دانشگاهیان و همراهان عزیز، دوستان خوبم نهایت سپاس را دارم.

و در پایان این پایان‌نامه را تقدیم می‌کنم به مادر و پدر مهربانم که با حضور و همراهی شان در دوران تحصیل، همیشه راه را به من نشان داده و مرا در این راه استوار و ثابت قدم نموده است.

محمدامین قاسم‌زاده

تابستان ۱۴۰۵

چکیده

تخمین عمق تک‌دورینه ذاتاً مسئله‌ای مبهم است، زیرا یک تصویر منفرد مقیاس متریک صحنه را به صورت یکتا تعیین نمی‌کند. در این پایان‌نامه بررسی می‌شود که آیا ورود صریح پارامترهای درونی دوربین می‌تواند این ابهام را در یک مدل بنیادین تخمین عمق کاهش دهد. برای این منظور، نسخه‌ای آگاه از دوربین از مدل Depth Anything V2 توسعه داده شده است که در آن یک توصیف گر نه‌بعدی نرمال شده از ماتریس مشخصه دوربین، به توکنی دروازه‌بانی شده تبدیل و به انکودر DINOv2 تزریق می‌شود. روش تجربی طی مجموعه‌ای از آزمایش‌های کنترل شده تکامل یافت و در این مسیر، نت داده در تفکیک NYUv2، ناهم‌خوانی خاموش میان فضای خروجی دیسپاریتی و هدف عمق مستقیم، به‌روزرسانی نشدن K هنگام برش تصویر و ناهم‌خوانی خاموش سر خروجی مدل متریک در ارزیابی شناسایی و اصلاح شد.

تمام مقایسه‌های نهایی بر مجموعه‌آزمون بدون نت ۶۵۴ تصویری Eigen و میان دو بازوی آموزشی همسان، یکی آگاه از K و دیگری فاقد آن، انجام شده‌اند. در پروتکل نسبی، مدل پیشنهادی ViT-S از مدل منتشرشده و کنترل هم‌داده بهتر است؛ با این حال، در ViT-L سهم خالص K معنادار نیست، زیرا تراز مقیاس و جابجایی به‌ازای هر تصویر، مهم‌ترین اطلاعات حاصل از فاصله کانونی را حذف می‌کند. در ارزیابی متریک بدون تراز، مدل آگاه از دوربین به‌طور پایدار از کنترل بهتر عمل می‌کند و با افزایش تنوع میدان دید، اندازه اثر نیز افزایش می‌یابد. سپس افزونه‌سازی هندسی «لرزش کانونی» پیشنهاد می‌شود که بازایی مقیاس را تنها از روی پیکسل‌ها ناممکن می‌سازد. در این تنظیم، مدل آگاه از K به AbsRel برابر ۰/۸۴۹ در برابر ۰/۱۰۳۰ برای کنترل می‌رسد و در همه معیارهای گزارش شده با $10^{-24} \leq p$ برتری دارد.

آزمون‌های سازوکاری و علی نشان می‌دهند که این بهبود واقعاً ناشی از استفاده از ماتریس مشخصه است. شیب لگاریتمی پاسخ عمق پیش‌بینی شده به مقیاس فاصله کانونی، پس از لرزش کانونی از ۰/۰۶ به ۰/۹۳ تا ۰/۹۷ می‌رسد که به مقدار ایده‌آل یک در مدل روزنه‌ای نزدیک است. حذف K خطای AbsRel را ۰/۵۹ درصد افزایش می‌دهد و تحریف عمودی فاصله کانونی، خطایی هم‌اندازه با پیش‌بینی هندسه تصویربرداری ایجاد می‌کند. بنابراین، پارامترهای درونی دوربین می‌توانند سیگنالی معنادار و از نظر علی ضروری برای بازایی مقیاس فراهم کنند؛ هرچند این اتکا، حساسیت به دقت کالیبراسیون را نیز افزایش می‌دهد و تعمیم آن به داده‌های واقعی چنددورینه و محیط‌های بیرونی نیازمند بررسی‌های آینده است.

واژگان کلیدی تخمین عمق تک‌دوربین، یادگیری عمیق بدون نظارت، عمق متریک، پارامترهای درونی
دوربین، هندسهٔ تصویربرداری، ۲V Anything Depth

فهرست مطالب

چ	فهرست تصاویر
خ	فهرست جداول
ذ	فهرست الگوریتم‌ها
ر	فهرست برنامه‌ها
ز	فهرست اختصارات
۱	فصل ۱: مقدمه
۱	۱.۱ بیان مسئله و اهمیت آن
۲	۲.۱ چالش‌های عمق متریک در مدل‌های یادگیری عمیق
۳	۳.۱ خلا پژوهشی
۴	۴.۱ اهداف و سوالات تحقیق
۴	۵.۱ ساختار پایان‌نامه
۷	فصل ۲: مروری بر مطالعات انجام شده
۷	۱.۲ مقدمه
۸	۲.۲ روش‌های کلاسیک تخمین عمق تک‌دوربین
۸	۳.۲ روش‌های مبتنی بر یادگیری عمیق
۹	۴.۲ تخمین عمق متریک و غیرمتریک

۵.۲	نقش هندسه دوربین و اطلاعات درونی	۱۰
۱۱	فصل ۳: روش تحقیق	۱۱
۱.۳	مقدمه	۱۱
۲.۳	صورت‌بندی مسئله تخمین عمق تک‌دوربین	۱۲
۳.۳	هندسه دوربین و نقش پارامترهای درونی	۱۴
۱.۳.۳	مدل دوربین سوراخ‌سوزنی	۱۴
۲.۳.۳	ماتریس مشخصه دوربین	۱۵
۳.۳.۳	نقش پارامترهای درونی در تخمین عمق	۱۶
۴.۳	معماری پایه: مدل Depth Anything V2	۱۷
۱.۴.۳	ساختار کلی شبکه encoder-decoder	۱۷
۲.۴.۳	بخش encoder مبتنی بر Transformer Vision	۱۷
۳.۴.۳	بخش decoder و راهبرد بازسازی نگاشت عمق	۱۸
۵.۳	انگیزه‌ی صریح برای لحاظ پارامترهای درونی دوربین	۱۹
۱.۵.۳	شواهد تجربی از تاثیر پارامترهای دوربین در معیارهای متریک	۱۹
۲.۵.۳	عدم کفایت رویکرد ضمنی نسبت به مشخصه‌های دوربین	۲۰
۳.۵.۳	کاربردهای عملی و انتقال‌پذیری به داده‌های جهان واقعی	۲۲
۴.۵.۳	لزوم طراحی مدل با ورود صریح پارامترهای درونی	۲۲
۶.۳	طراحی روش پیشنهادی: ادغام صریح ماتریس مشخصه دوربین	۲۲
۱.۶.۳	اصل طراحی: تفکیک اطلاعات تصویری و هندسی	۲۳
۲.۶.۳	نمایش و پیش‌پردازش ماتریس مشخصه دوربین	۲۳
۳.۶.۳	راهبرد ادغام اطلاعات دوربین با معماری Depth Anything V2	۲۴
۴.۶.۳	مزایای مورد انتظار از ادغام صریح پارامترهای درونی	۲۶
۷.۳	راهبرد آموزش مدل پیشنهادی	۲۶
۱.۷.۳	مجموعه داده‌های مورد استفاده	۲۷
۲.۷.۳	تفکیک صحیح مجموعه‌های آموزش و آزمون در NYUv۲	۲۷

۳.۷.۳	مدل پایه و راهبرد فاین تیون	۲۸
۴.۷.۳	فعال سازی پشتیبانی از پارامترهای دوربین	۲۸
۵.۷.۳	تنظیمات آموزش و بهینه سازی	۲۹
۶.۷.۳	فضای هدف آموزش برای مدل های نسبی: عمق معکوس	۲۹
۷.۷.۳	افزونه سازی هندسی آگاه از پارامترهای دوربین	۳۰
۸.۷.۳	افزونه سازی لرزش کانونی: غیرقابل حل کردن مقیاس بدون K	۳۲
۹.۷.۳	استفاده از تقطیر دانش	۳۳
۱۰.۷.۳	جمع بندی فرآیند آموزش	۳۳
۸.۳	توابع هزینه و معیارهای بهینه سازی	۳۵
۱.۸.۳	هزینه SiLog برای مدل های متریک	۳۵
۲.۸.۳	هزینه تغییرناپذیر نسبت به مقیاس و جابجایی برای مدل های نسبی	۳۶
۳.۸.۳	تمایز میان توابع هزینه آموزش و معیارهای ارزیابی	۳۶
۱.۳.۸.۳	توابع هزینه در آموزش	۳۶
۲.۳.۸.۳	معیارهای ارزیابی	۳۷
۴.۸.۳	نقش پارامترهای درونی دوربین در آموزش	۳۷
۵.۸.۳	حساسیت RMSE به پارامترهای دوربین و کاربرد آن در ارزیابی	۳۸
۶.۸.۳	جمع بندی	۳۸
۹.۳	جزئیات پیاده سازی	۳۹
۱.۹.۳	چارچوب نرم افزاری و زیرساخت محاسباتی	۳۹
۲.۹.۳	پیش پردازش داده ها	۳۹
۳.۹.۳	مدیریت و نرمال سازی پارامترهای درونی دوربین	۴۰
۴.۹.۳	تنظیمات آموزش و راهبرد بهینه سازی	۴۱
۵.۹.۳	دیتاست های مورد استفاده در پیاده سازی	۴۲
۶.۹.۳	ساختار کد و اسکرپت های اصلی	۴۲
۷.۹.۳	ملاحظات عملی و محدودیت ها	۴۴
۸.۹.۳	اشکال زدایی و درس های پیاده سازی	۴۵

۴۶	۹.۹.۳ جمع‌بندی	۴۶
۴۶	۱۰.۳ جمع‌بندی فصل	۴۶
۴۹	فصل ۴: نتایج	۴۹
۴۹	۱.۴ مقدمه	۴۹
۵۰	۲.۴ سوالات تحقیق و فرضیات تجربی	۵۰
۵۰	۱.۲.۴ بازگویی سوالات تحقیق	۵۰
۵۱	۲.۲.۴ فرضیات تجربی	۵۱
۵۱	۳.۲.۴ ارتباط فرضیات با بخش‌های فصل	۵۱
۵۲	۳.۴ تنظیمات آزمایش و پروتکل ارزیابی	۵۲
۵۲	۱.۳.۴ دیتاست‌های مورد استفاده	۵۲
۵۳	۲.۳.۴ نوع محیط‌ها و سناریوهای ارزیابی	۵۳
۵۳	۳.۳.۴ معیارهای ارزیابی	۵۳
۵۳	۱.۳.۳.۴ معیارهای غیر متریک	۵۳
۵۳	۲.۳.۳.۴ معیارهای متریک	۵۳
۵۴	۴.۳.۴ آزمون‌های آماری	۵۴
۵۴	۴.۴ نتایج کمی: مقایسه عددی مدل‌ها	۵۴
۵۵	۱.۴.۴ عملکرد مدل پایه در دیتاست‌های مختلف	۵۵
۵۵	۲.۴.۴ مقایسه مدل پایه و مدل پیشنهادی	۵۵
۵۶	۳.۴.۴ تحلیل پایداری بین‌دیتاستی مدل پیشنهادی	۵۶
۵۷	۵.۴ مطالعه کنترل‌شده بر روی پروتکل استاندارد NYUv2	۵۷
۵۸	۱.۵.۴ ممیزی نقاط واریسی و مسیر رسیدن به آزمایش نهایی	۵۸
۵۹	۲.۵.۴ راستی‌آزمایی زنجیره ارزیابی: بازتولید نتایج مدل پایه	۵۹
۵۹	۳.۵.۴ ناکارآمدی فاین‌تیون برای ارزیابی برون‌دامنه‌ای	۵۹
۶۰	۴.۵.۴ نتایج پروتکل نسبی: مقایسه چهارگانه	۶۰
۶۲	۵.۵.۴ اثر افزونه‌سازی هندسی و یک نتیجه منفی آموزنده	۶۲

۶۲	ارزیابی متریک: آشکارشدن سهم پارامترهای درونی دوربین	۶.۵.۴
۶۴	دور سوم — افزونه‌سازی لرزش کانونی: جهش سهم پارامترهای دوربین	۷.۵.۴
۶۵	مطالعه فروکاست: تفکیک اثر لرزش کانونی از ضریب λ	۸.۵.۴
۶۵	جمع‌بندی مطالعه کنترل‌شده و گزارش کوشش‌های تجربی	۹.۵.۴
۶۶	تحلیل حساسیت نسبت به پارامترهای دوربین	۶.۴
۶۶	آزمون جاروی K : آیا مدل واقعاً فاصله کانونی را می‌خواند؟	۱.۶.۴
۶۷	آزمون حذف و تحریف K : اثبات اتکای علی	۲.۶.۴
۶۹	رفتار متفاوت معیارهای AbsRel و RMSE	۳.۶.۴
۶۹	ارتباط با تحلیل هندسی فصل سوم	۴.۶.۴
۶۹	ملاحظات کیفی و حدود شواهد بصری	۷.۴
۷۰	تحلیل موردی دیتاست CityScapes	۸.۴
۷۰	ماهیت و ویژگی‌های خاص دیتاست CityScapes	۱.۸.۴
۷۰	تحلیل کیفیت عمق مرجع	۲.۸.۴
۷۱	دلیل رفتار متفاوت خطاها	۳.۸.۴
۷۱	محدودیت همسان‌سازی نتایج با سایر دیتاست‌ها	۴.۸.۴
۷۱	بحث و تفسیر نتایج	۹.۴
۷۲	جمع‌بندی تحلیلی نتایج کمی و کیفی	۱.۹.۴
۷۲	پاسخ به سوالات تحقیق	۲.۹.۴
۷۳	وابستگی سهم پارامترهای دوربین به پروتکل ارزیابی و ظرفیت مدل	۳.۹.۴
۷۳	مقایسه غیرمستقیم با ادبیات موضوع	۴.۹.۴
۷۴	تفسیر نتایج در چارچوب هندسه تصویربرداری	۵.۹.۴
۷۴	جمع‌بندی فصل نتایج	۱۰.۴

فصل ۵: بحث و نتیجه‌گیری

۷۷	مقدمه	۱.۵
۷۸	جمع‌بندی یافته‌های اصلی پژوهش	۲.۵

۷۹	تفسیر نهایی نتایج در چارچوب هندسه تصویربرداری	۳.۵
۸۰	نوآوری‌های تحقیق	۴.۵
۸۱	نوآوری تنوریک	۱.۴.۵
۸۱	نوآوری عملی	۲.۴.۵
۸۲	دستاوردهای روش شناختی و تشخیصی	۳.۴.۵
۸۳	محدودیت‌ها و چالش‌های پژوهش	۵.۵
۸۴	پیشنهادهایی برای تحقیقات آینده	۶.۵
۸۶	جمع‌بندی نهایی فصل	۷.۵

۸۷

کتاب‌نامه

اول

واژه‌نامه فارسی به انگلیسی

سوم

واژه‌نامه انگلیسی به فارسی

فهرست تصاویر

- ۱.۳ مدل هندسی دوربین سوراخ سوزنی: نگاشت یک نقطه سه بعدی X به نقطه دو بعدی x روی صفحه تصویر با توجه به فاصله کانونی f ۱۵
- ۲.۳ مقایسه زوجی دو سمت دوربین در Middlebury پس از میانگین گیری دو نسخه تصحیح هر یک از ۲۳ محتوای صحنه. ردیف بالا مقادیر هر صحنه و میانگین کل (لوزی سیاه) و ردیف پایین اختلاف مرتب شده دوربین ° منهای دوربین ۱ را نشان می دهد. خط چین قرمز میانگین اختلاف است. ۲۱
- ۳.۳ معماری مدل پیشنهادی: اطلاعات تصویر توسط انکودر از پیش آموزش دیده استخراج می شود. ماتریس مشخصه دوربین K پس از نرمال سازی، توسط واحد کدگذار دوربین به یک توکن نهان تبدیل شده و همراه با یک دروازه خروجی صفر مقدار اولیه، به دنباله توکن های انکودر تزریق می گردد تا سازوکار توجه بتواند اطلاعات هندسی را با بازنمایی های بصری ترکیب کند. ۲۵
- ۱.۴ مقایسه عملکرد متریک (معیار SiLog) بین مدل پایه و پیشنهادی در دیتاست های مختلف. همان طور که مشاهده می شود مدل پیشنهادی در تمامی موارد خطای بسیار کمتری دارد. . . ۵۶
- ۲.۴ آزمون جاروی K : میانه عمق پیش بینی شده (نرمال شده به حالت ضریب ۱، میانگین هندسی روی ۲۰ تصویر آزمون) در برابر ضریب مقیاس مصنوعی فاصله کانونی؛ محورها لگاریتمی اند. مدل پیشنهادی دور ۳ تقریباً به طور کامل بر خط ایده آل شیب ۱ منطبق است (در ضریب ۶/۱ دقیقاً عمق ۶/۱ برابر پیش بینی می کند)، همان معماری در دور ۲ تقریباً تخت است، و مدل کنترل طبق تعریف هیچ پاسخی به K ندارد. داده ها حاصل اجرای واقعی آزمون بر نقاط واریسی آموزش دیده اند. ۶۸

- ۱.۵ نمای کلی از فرآیند پژوهش: حرکت از شناسایی یک محدودیت ذاتی در مدل‌های موجود
تا ارائه راهکار هندسه‌آگاه و در نهایت دستیابی به پایداری متریک در تخمین عمق. . . . ۷۹

فهرست جداول

۱.۳	ممیزی بازتولیدپذیر تفاوت دو سمت دوربین در Middlebury. اختلاف به صورت دوربین
۲۰	• منهای دوربین ۱ و بازه ها به صورت بوت استرپ زوجی ۹۵ درصد گزارش شده اند ($n = ۲۳$). ۲۰
۱.۴	مقایسه معیار SiLog مدل پایه Depth Anything V2 در دیتاست های مختلف ۵۵
۲.۴	مقایسه عملکرد مدل پایه و مدل پیشنهادی بر اساس معیار SiLog ۵۶
۳.۴	مسیر تجربی رسیدن از نقاط واری واری اولیه به مدل نهایی آگاه از دوربین. ۵۸
۴.۴	راستی آزمایی زنجیره ارزیابی: بازتولید نتایج مدل منتشر شده Depth Anything V2
۵۹	(نسخه نسبی) بر روی پروتکل استاندارد. مقادیر به صورت $\delta_1 \uparrow / \downarrow \text{AbsRel}$ گزارش شده اند. ۵۹
۵.۴	ارزیابی بدون نشت نقاط واری چند مجموعه ای در حالت صفر نمونه؛ مقادیر به صورت
۵۹	$\delta_1 \uparrow / \downarrow \text{AbsRel}$ هستند. ۵۹
۶.۴	مقایسه چهارگانه بر روی مجموعه آزمون استاندارد NYUv2 (۶۵۴ تصویر، مرجع عمق
۶۰	خام)، انکودر ViT-S، پروتکل نسبی با تراز مقیاس و جابجایی. ۶۰
۷.۴	مقایسه چهارگانه بر روی مجموعه آزمون استاندارد NYUv2، انکودر ViT-L، پروتکل نسبی. ۶۰
۸.۴	اندازه اثر زوجی مدل پیشنهادی ViT-S بر ۶۵۴ تصویر NYUv2. ۶۱
۹.۴	آزمون های زوجی معناداری بر روی ۶۵۴ تصویر آزمون NYUv2 (پروتکل نسبی)؛ مقایسه
۶۱	مدل پیشنهادی با مدل منتشر شده و مدل کنترل. ۶۱
۱۰.۴	اثر افزونه سازی هندسی آگاه از دوربین بر زوج مدل ViT-L در پروتکل نسبی NYUv2. ۶۲
۱۱.۴	ارزیابی متریک (عمق مطلق، بدون تراز) بر روی مجموعه آزمون استاندارد NYUv2،
۶۳	انکودر ViT-L. دور ۱: افزونه سازی با میدان دید ۴۱-۶۳ درجه؛ دور ۲: ۳۳-۶۳ درجه. . . ۶۳

- ۱۲.۴ آزمون‌های زوجی معناداری در ارزیابی متریک ($n = ۶۵۴$)؛ مقایسه مدل پیشنهادی با
 ۶۳ مدل متریک منتشرشده و مدل کنترل.
- ۱۳.۴ دور ۳ (لرزش کانونی): ارزیابی متریک (عمق مطلق، بدون تراز) بر مجموعه آزمون
 استاندارد NYUv2، انکودر ViT-L، به همراه آزمون زوجی ویلکاکسون ($n = ۶۵۴$) و
 ۶۴ بازه اطمینان ۹۵٪ بوت استرپ تفاضل زوجی.
- ۱۴.۴ مطالعه فروکاست (لرزش کانونی با $\lambda = ۰/۵$ بدون تغییر): ارزیابی متریک بر مجموعه
 ۶۵ آزمون استاندارد NYUv2 ($n = ۶۵۴$).
- ۱۵.۴ شیب لگاریتمی جاروی K (میانگین $\pm$ انحراف معیار روی ۲۰ تصویر آزمون): پاسخ عمق
 پیش‌بینی شده به مقیاس دهی مصنوعی فاصله کانونی. شیب ایده‌آل برای مدل آگاه از هندسه
 ۶۷ ۱ است.
- ۱۶.۴ آزمون حذف و تحریف K بر مدل پیشنهادی دور ۳ (ViT-L متریک، $n = ۶۵۴$ ، بدون
 تراز). پیش‌بینی نظری: با شیب جاروی $s = ۰/۹۳$ ، تحریف f در ضریب X باید Ab-
 ۶۸ sRel را به حدود $|X^s - ۱|$ برساند.

فهرست الگوریتم‌ها

۱.۳	روند آموزش مدل با پارامترهای هندسی	۳۴
-----	------------------------------------	----

فهرست برنامه‌ها

فهرست اختصارات

فصل ۱

مقدمه

۱.۱ بیان مسئله و اهمیت آن

تخمین عمق صحنه از روی یک تصویر تک‌دوربین یکی از مسائل بنیادی و در عین حال چالش‌برانگیز در بینایی ماشین به شمار می‌رود [۱، ۲]. این مسئله در کاربردهای متنوعی از جمله رباتیک متحرک، ناوبری خودکار، بازسازی سه‌بعدی، واقعیت افزوده و سیستم‌های کمک‌راننده نقش کلیدی ایفا می‌کند [۳]. برخلاف روش‌های مبتنی بر چند نما یا حسگرهای فعال، تخمین عمق تک‌دوربین تنها بر اطلاعات یک تصویر دوبعدی متکی است و از این رو ذاتاً با ابهام‌های هندسی متعددی مواجه می‌شود [۴].

ببا پیشرفت روش‌های یادگیری عمیق، به‌ویژه شبکه‌های عصبی کانولوشنی و مدل‌های مبتنی بر ترنسفورمر، کیفیت تخمین عمق تک‌دوربین به‌طور قابل توجهی بهبود یافته است [۵، ۶]. بسیاری از مدل‌های مدرن قادرند ساختار نسبی صحنه را با دقت بالا بازسازی کنند و روابط عمقی میان اجسام را به‌خوبی بیاموزند. با این حال، خروجی این مدل‌ها در اغلب موارد فاقد مقیاس فیزیکی واقعی بوده و به‌صورت عمق نسبی یا *non-metric depth* بیان می‌شود. این محدودیت باعث می‌شود که استفاده مستقیم از چنین مدل‌هایی در کاربردهایی که نیازمند اندازه‌گیری‌های متریک دقیق هستند، با چالش مواجه شود.

مسئله اصلی در این میان، ابهام مقیاس ذاتی در تخمین عمق تک‌دوربین است. در غیاب اطلاعات هندسی صریح درباره دوربین تصویربرداری، بازیابی عمق متریک تنها بر اساس شدت پیکسل‌ها ذاتاً نامعین است [۳]. اگرچه برخی روش‌ها با اعمال نرمال‌سازی یا استفاده از معیارهای نسبی، عملکرد مناسبی در سنجش‌های غیرمتریک نشان می‌دهند، اما این رویکردها تضمینی برای پایداری مقیاس فیزیکی عمق فراهم نمی‌کنند. در نتیجه، تغییر شرایط تصویربرداری، از جمله تفاوت در نوع دوربین یا پارامترهای آن، می‌تواند منجر به تغییرات

معنادار در کیفیت تخمین عمق شود.

از این منظر، دستیابی به تخمین عمق متریک پایدار و قابل تعمیم، همچنان یکی از چالش‌های باز در حوزه بینایی ماشین محسوب می‌شود. پرداختن به این مسئله نه تنها از دیدگاه نظری اهمیت دارد، بلکه از منظر عملی نیز برای توسعه سیستم‌های قابل اعتماد در محیط‌های واقعی ضروری است. این پژوهش با تمرکز بر این چالش اساسی، به بررسی راهکارهایی برای ارتقای مدل‌های تخمین عمق تک‌دورینه از خروجی‌های غیرمتریک به عمق متریک پایدار می‌پردازد.

۲.۱ چالش‌های عمق متریک در مدل‌های یادگیری عمیق

اگرچه مدل‌های یادگیری عمیق در سال‌های اخیر پیشرفت چشمگیری در تخمین عمق تک‌دورینه داشته‌اند، اما اغلب این مدل‌ها به‌طور ضمنی برای یادگیری ساختار نسبی صحنه طراحی شده‌اند [۲]. بسیاری از معیارهای ارزیابی رایج نیز بر سنجش خطاهای نرمال شده یا نسبی تمرکز دارند و به جای مقیاس فیزیکی مطلق، همبستگی ساختاری عمق را مورد توجه قرار می‌دهند [۶]. این موضوع سبب شده است که بهبود عملکرد در این معیارها لزوماً به معنای دستیابی به عمق متریک دقیق نباشد.

یکی از چالش‌های مهم در این زمینه، وابستگی مدل‌ها به توزیع داده‌های آموزشی است. مدل‌هایی که بر روی یک یا چند دیتاست خاص آموزش داده می‌شوند، معمولاً فرض ضمنی ثبات شرایط تصویربرداری را در خود دارند. در عمل، در عمل، تغییر نوع دوربین، فاصله کانونی یا میدان دید می‌تواند توزیع نگاهت تصویر به عمق را تغییر دهد و باعث افت عملکرد مدل شود [۷]. این مسئله به‌ویژه در معیارهای متریک که نسبت به مقیاس فیزیکی حساس هستند، نمود بیشتری پیدا می‌کند.

چالش دیگر، فقدان استفاده صریح از اطلاعات هندسی دوربین در بسیاری از مدل‌های موجود است [۸]. در حالی که فرآیند تصویربرداری به‌طور مستقیم تحت تأثیر پارامترهای درونی دوربین قرار دارد، اغلب روش‌های یادگیری عمیق این اطلاعات را نادیده می‌گیرند یا به صورت ضمنی در داده‌ها مستتر فرض می‌کنند. این رویکرد می‌تواند منجر به یادگیری روابطی شود که تنها در شرایط خاص معتبر بوده و قابلیت تعمیم به سناریوهای متفاوت را ندارند.

در مجموع، این چالش‌ها نشان می‌دهند که برای دستیابی به تخمین عمق متریک پایدار، صرف بهبود معماری شبکه یا افزایش حجم داده‌های آموزشی کافی نیست. بلکه لازم است به صورت آگاهانه به نقش هندسه تصویربرداری و اطلاعات دوربین در فرآیند تخمین عمق توجه شود. این ضرورت، انگیزه اصلی پژوهش حاضر را شکل می‌دهد و زمینه را برای ارائه رویکردی فراهم می‌کند که بتواند پایداری عمق متریک را در مواجهه با

تغییرات شرایط تصویربرداری بهبود بخشد.

۳.۱ خلا پژوهشی

بخش عمده‌ای از پژوهش‌های پیشین بر بهبود دقت تخمین عمق نسبی تمرکز داشته‌اند [۲، ۹]. و موفق شده‌اند ساختار کلی صحنه و روابط عمقی میان اجسام را با کیفیت مناسبی بازسازی کنند. با این حال، در بسیاری از این مطالعات، مسئله مقیاس فیزیکی عمق یا به صورت ضمنی نادیده گرفته شده و یا به عنوان یک چالش ثانویه تلقی شده است.

از سوی دیگر، روش‌هایی که به تخمین عمق متریک پرداخته‌اند، غالباً متکی بر فرض‌های محدودکننده‌ای نظیر ثبات نوع دوربین یا شرایط تصویربرداری کنترل شده [۶] یا دسترسی به داده‌های کالیبره شده خاص بوده‌اند. این فرض‌ها موجب می‌شود که قابلیت تعمیم چنین مدل‌هایی به سناریوهای واقعی و متنوع کاهش یابد. به ویژه، تأثیر تغییر پارامترهای درونی دوربین بر عملکرد مدل‌ها در بسیاری از این کارها به صورت نظام‌مند مورد مطالعه قرار نگرفته است.

نکته قابل توجه دیگر آن است که در اغلب پژوهش‌های موجود، ارزیابی مدل‌ها عمدتاً بر اساس معیارهای غیر متریک یا نرمال شده انجام شده است [۵]. این معیارها اگرچه برای سنجش کیفیت نسبی عمق مناسب هستند، اما قادر به آشکارسازی ناپایداری‌های مرتبط با مقیاس فیزیکی و تغییر شرایط تصویربرداری نیستند. در نتیجه، ممکن است مدلی از نظر این معیارها عملکرد مطلوبی داشته باشد، در حالی که در کاربردهای متریک و واقعی دچار خطای قابل توجه شود.

علاوه بر این، اگرچه نقش هندسه دوربین در فرآیند تصویربرداری به خوبی شناخته شده است، استفاده صریح از اطلاعات درونی دوربین در مدل‌های یادگیری عمیق تخمین عمق، کمتر مورد توجه قرار گرفته است [۳، ۸]. در بسیاری از رویکردها، این اطلاعات یا کاملاً نادیده گرفته می‌شوند یا فرض می‌شود که شبکه می‌تواند به طور ضمنی اثر آن‌ها را از داده‌ها بیاموزد. فقدان بررسی صریح این فرض، یکی از خلأهای اساسی در ادبیات این حوزه محسوب می‌شود.

بر این اساس، می‌توان نتیجه گرفت که تاکنون مطالعه‌ای جامع که به طور هم‌زمان به مسئله تخمین عمق متریک، پایداری نسبت به تغییر پارامترهای دوربین و ارزیابی مبتنی بر معیارهای حساس به مقیاس فیزیکی بپردازد، به صورت منسجم ارائه نشده است. پژوهش حاضر با تمرکز بر این خلأ، تلاش می‌کند گامی در جهت پر کردن این شکاف برداشته و چارچوبی برای تحلیل و بهبود پایداری عمق متریک در تخمین عمق تک‌دوربین ارائه دهد.

۴.۱ اهداف و سوالات تحقیق

با توجه به خلأهای شناسایی شده در ادبیات موضوع و چالش‌های موجود در تخمین عمق تک‌دوربین، پژوهش حاضر با هدف بررسی امکان دستیابی به تخمین عمق متریک پایدار در چارچوب یادگیری عمیق انجام شده است. تمرکز اصلی این تحقیق بر تحلیل نقش هندسه دوربین در فرآیند تخمین عمق و ارزیابی تأثیر لحاظ کردن اطلاعات درونی دوربین بر پایداری و دقت خروجی مدل‌ها است.

هدف کلی این پژوهش، بررسی این مسئله است که آیا می‌توان با استفاده از اطلاعات صریح مربوط به مشخصات درونی دوربین، محدودیت‌های ذاتی تخمین عمق غیرمتریک را کاهش داد و به تخمینی دست یافت که نسبت به تغییر شرایط تصویربرداری پایدارتر باشد. در راستای این هدف کلی، اهداف جزئی زیر دنبال می‌شوند:

- بررسی میزان وابستگی مدل‌های تخمین عمق تک‌دوربین به نوع دیتاست و پارامترهای دوربین؛
- تحلیل تفاوت رفتار معیارهای ارزیابی غیرمتریک و متریک در مواجهه با تغییرات شرایط تصویربرداری؛
- ارزیابی امکان بهبود دقت و پایداری تخمین عمق متریک با استفاده از اطلاعات هندسی صریح.

بر این اساس، سوالات اصلی تحقیق به صورت زیر مطرح می‌شوند:

۱. آیا مدل‌های رایج تخمین عمق تک‌دوربین در برابر تغییر دیتاست و پارامترهای درونی دوربین رفتار پایداری از خود نشان می‌دهند؟

۲. آیا استفاده از معیارهای غیرمتریک می‌تواند ناپایداری‌های مرتبط با مقیاس فیزیکی عمق را پنهان کند؟

۳. آیا لحاظ کردن اطلاعات درونی دوربین می‌تواند به بهبود تخمین عمق متریک و کاهش حساسیت مدل نسبت به تغییرات دوربین منجر شود؟

پاسخ به این سوالات، چارچوب اصلی تحلیل‌های تجربی ارائه شده در فصل چهارم را تشکیل می‌دهد و مبنای نتیجه‌گیری‌های نهایی پژوهش حاضر قرار می‌گیرد.

۵.۱ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل سازمان‌دهی شده است که هر فصل به بخش مشخصی از فرآیند پژوهش اختصاص دارد.

در فصل اول، مقدمه‌ای بر مسئله تخمین عمق تک‌دورینه ارائه شد و با تبیین اهمیت موضوع، چالش‌های موجود و خلأهای پژوهشی، اهداف و سوالات تحقیق مطرح گردید.

فصل دوم به مرور ادبیات موضوع اختصاص دارد. در این فصل، پژوهش‌های پیشین در حوزه تخمین عمق تک‌دورینه، روش‌های متریک و غیرمتریک، نقش هندسه دوربین و معیارهای ارزیابی مورد بررسی و تحلیل قرار می‌گیرند و جایگاه پژوهش حاضر نسبت به کارهای موجود مشخص می‌شود.

در فصل سوم، روش پیشنهادی تحقیق به صورت جامع تشریح می‌شود. این فصل شامل صورت‌بندی مسئله، تحلیل هندسی فرآیند تصویربرداری، معرفی معماری پایه، انگیزه و چارچوب روش پیشنهادی، راهبرد آموزش، توابع هزینه و جزئیات پیاده‌سازی است.

فصل چهارم به ارائه تنظیمات آزمایشی، نتایج کمی و کیفی و تحلیل آن‌ها اختصاص دارد. در این فصل، عملکرد مدل‌ها بر روی دیتاست‌های مختلف بررسی شده و پایداری تخمین عمق نسبت به تغییر پارامترهای دوربین به صورت تجربی تحلیل می‌شود.

در نهایت، فصل پنجم به بحث و نتیجه‌گیری اختصاص دارد. در این فصل، یافته‌های اصلی پژوهش جمع‌بندی شده، نوآوری‌های نظری و عملی تحقیق بیان می‌شود و پیشنهادهایی برای پژوهش‌های آتی ارائه می‌گردد.

فصل ۲

مروری بر مطالعات انجام شده

۱.۲ مقدمه

تخمین عمق از تصاویر دوبعدی یکی از مسائل بنیادی در بینایی ماشین^۱ و ادراک صحنه محسوب می شود که کاربردهای گسترده ای در حوزه هایی نظیر رباتیک، رانندگی خودکار، واقعیت افزوده و بازسازی سه بعدی دارد [۱، ۳]. در میان شاخه های مختلف این مسئله، تخمین عمق تک دوربینه^۲ به دلیل نیاز حداقلی به تجهیزات تصویربرداری، بیشترین توجه را به خود جلب کرده است.

با این حال، تخمین عمق از یک تصویر منفرد ذاتاً یک مسئله ill-posed^۳ محسوب می شود، زیرا نداشتن از فضای دوبعدی تصویر به فضای سه بعدی صحنه فاقد یکتایی ذاتی است [۴]. به همین دلیل، پژوهش های پیشین همواره تلاش کرده اند با اعمال قیود هندسی، آماری یا یادگیری از داده، این ابهام را کاهش دهند.

هدف از این فصل، ارائه مروری ساختارمند بر پژوهش های انجام شده در حوزه تخمین عمق تک دوربینه است. بدین منظور، ابتدا رویکردهای کلاسیک و سپس روش های مبتنی بر یادگیری عمیق مورد بررسی قرار می گیرند. در ادامه، تفاوت میان تخمین عمق متریک و غیرمتریک و نقش هندسه دوربین در این مسئله مرور می شود تا جایگاه پژوهش حاضر نسبت به ادبیات موجود به روشنی مشخص گردد.

^۱Computer Vision

^۲Monocular Depth Estimation

^۳بد حال

۲.۲ روش‌های کلاسیک تخمین عمق تک‌دورینه

پیش از گسترش روش‌های مبتنی بر یادگیری عمیق، تخمین عمق تک‌دورینه عمدتاً بر پایه روش‌های کلاسیک و استفاده از قیود هندسی و آماری انجام می‌شد [۱۰]. این روش‌ها معمولاً از نشانه‌های تصویری^۱ مانند پرسپکتیو، انسداد، اندازه نسبی اشیاء، و تغییرات بافت برای استنتاج عمق استفاده می‌کردند. برخی از رویکردها تلاش می‌کردند با مدل‌سازی صریح صحنه و اعمال فرض‌هایی درباره ساختار محیط، عمق نسبی نواحی مختلف تصویر را تخمین بزنند [۱]. در این روش‌ها، اطلاعاتی مانند خطوط همگرا، سطوح تخت، یا موقعیت افق نقش کلیدی ایفا می‌کردند. با وجود کارایی محدود در سناریوهای خاص، این روش‌ها به‌شدت به مفروضات اولیه وابسته بودند و قابلیت تعمیم پایینی داشتند. دسته دیگری از روش‌های کلاسیک بر یادگیری مبتنی بر ویژگی‌های دستی^۲ تکیه داشتند. در این رویکردها، ابتدا ویژگی‌هایی از تصویر استخراج می‌شد و سپس با استفاده از مدل‌های آماری، نگاشتی بین این ویژگی‌ها و عمق تخمینی برقرار می‌گردید. اگرچه این روش‌ها نسبت به رویکردهای کاملاً هندسی انعطاف‌پذیرتر بودند، اما همچنان در مواجهه با صحنه‌های پیچیده و متنوع با محدودیت‌های جدی روبه‌رو بودند. به‌طور کلی، روش‌های کلاسیک تخمین عمق تک‌دورینه به‌دلیل وابستگی شدید به فرضیات صحنه و ناتوانی در بهره‌گیری مؤثر از داده‌های بزرگ، نتوانستند پاسخ‌گوی نیازهای کاربردهای مدرن باشند. این محدودیت‌ها زمینه‌ساز ظهور روش‌های مبتنی بر یادگیری عمیق در این حوزه شد.

۳.۲ روش‌های مبتنی بر یادگیری عمیق

با پیشرفت شبکه‌های عصبی عمیق^۳ و در دسترس قرار گرفتن دیتاست‌های بزرگ، روش‌های مبتنی بر یادگیری عمیق به رویکرد غالب در تخمین عمق تک‌دورینه تبدیل شدند [۲]. بخش قابل توجهی از این پژوهش‌ها از چارچوب‌های نظارت‌شده^۴ استفاده می‌کنند [۵]. مدل با بهره‌گیری از نقشه‌های عمق مرجع آموزش داده می‌شود. این رویکردها معمولاً دقت بالایی در دیتاست‌های خاص ارائه می‌دهند، اما به‌شدت به کیفیت و دامنه داده‌های آموزشی وابسته هستند و در سناریوهای خارج از توزیع آموزش، با افت عملکرد مواجه می‌شوند.

^۱Visual Cues

^۲Hand-crafted Features

^۳Deep Neural Networks

^۴Supervised Learning

در مقابل، روش‌های بدون نظارت^۱ تلاش می‌کنند با استفاده از قیود بازسازی تصویری و روابط هندسی ضمنی، مدل را بدون نیاز به داده‌های عمق مرجع آموزش دهند. این دسته از روش‌ها به‌ویژه در تخمین عمق تک‌دوربین مورد توجه قرار گرفته‌اند، زیرا امکان آموزش مدل‌ها بر روی داده‌های واقعی و متنوع را فراهم می‌کنند. با وجود موفقیت‌های قابل توجه، بیشتر روش‌های مبتنی بر یادگیری عمیق بر تخمین عمق نسبی تمرکز دارند و خروجی آن‌ها فاقد مقیاس فیزیکی مشخص است. در بسیاری از این مدل‌ها، فرض می‌شود که شبکه می‌تواند به‌طور ضمنی اطلاعات مربوط به هندسه تصویربرداری را از داده‌ها بیاموزد. این فرض، اگرچه در برخی معیارهای ارزیابی پذیرفتنی به نظر می‌رسد، اما در کاربردهای نیازمند عمق متریک با چالش‌های جدی همراه است.

۴.۲ تخمین عمق متریک و غیرمتریک

یکی از تمایزهای اساسی در تخمین عمق تک‌دوربین، تفاوت میان عمق غیرمتریک^۲ و عمق متریک^۳ است. در تخمین عمق غیرمتریک، مدل تنها قادر به بازیابی روابط نسبی میان نواحی مختلف صحنه است و مقیاس فیزیکی واقعی عمق به‌صورت ذاتی مبهم باقی می‌ماند. این ابهام مقیاس یکی از ویژگی‌های بنیادین مسئله تخمین عمق تک‌دوربین محسوب می‌شود.

بخش قابل توجهی از روش‌های اولیه مبتنی بر یادگیری عمیق، از جمله کارهای پیشگامانه Eigen و همکاران [۲] و Fergus و [۵] بر تخمین عمق نسبی تمرکز داشتند. در این روش‌ها، اگرچه ساختار کلی صحنه با دقت مناسبی بازسازی می‌شد، اما خروجی مدل فاقد مقیاس فیزیکی پایدار بود و برای کاربردهای متریک نیازمند نرمال‌سازی یا کالیبراسیون پس‌پردازشی بود.

در ادامه، برخی پژوهش‌ها تلاش کردند با استفاده از قیود هندسی یا داده‌های اضافی، تخمین عمق متریک را ممکن سازند. برای مثال، روش‌های مبتنی بر یادگیری خودنظارتی که از بازسازی دیدگاه^۴ استفاده می‌کنند، مانند کار Godard و همکاران [۹]، توانستند بدون استفاده از داده عمق مرجع، مدل‌هایی برای تخمین عمق آموزش دهند. با این حال، این روش‌ها نیز به‌طور معمول تنها به عمق نسبی دست می‌یابند و مقیاس خروجی آن‌ها وابسته به شرایط تصویربرداری و داده آموزشی است.

برخی مطالعات نشان داده‌اند که مدل‌های آموزش‌دیده با معیارهای غیرمتریک ممکن است در معیارهای نرمال‌شده عملکرد مطلوبی داشته باشند، اما در معیارهای حساس به مقیاس فیزیکی، مانند خطای جذر میانگین

¹Self-supervised / Unsupervised

²Non-metric Depth

³Metric Depth

⁴View Synthesis

مربعات^۱ افت قابل توجهی از خود نشان دهند [۶]. این مسئله به‌ویژه در هنگام تغییر نوع دوربین یا پارامترهای تصویربرداری بیشتر نمایان می‌شود.

در مجموع، می‌توان گفت که اگرچه تخمین عمق غیرمتریک برای بسیاری از کاربردهای ادراکی کافی است، اما برای کاربردهایی که نیازمند مقیاس واقعی هستند، مانند رباتیک و رانندگی خودکار، تخمین عمق متریک پایدار همچنان یک چالش حل‌نشده باقی مانده است.

۵.۲ نقش هندسهٔ دوربین و اطلاعات درونی

هندسهٔ تصویربرداری نقش بنیادینی در نگاشت فضای سه‌بعدی صحنه به تصویر دوبعدی ایفا می‌کند. مدل‌های کلاسیک تصویربرداری، مانند مدل دوربین سوراخ‌سوزنی، به‌روشنی نشان می‌دهند که پارامترهای درونی دوربین^۲ نظیر فاصلهٔ کانونی و مرکز تصویر، به‌طور مستقیم بر رابطهٔ بین مختصات تصویری و عمق فیزیکی تأثیر می‌گذارند [۳].

با وجود این واقعیت هندسی، بخش عمده‌ای از روش‌های مبتنی بر یادگیری عمیق اطلاعات درونی دوربین را یا به‌طور کامل نادیده می‌گیرند و یا فرض می‌کنند که شبکه می‌تواند اثر آن‌ها را به‌صورت ضمنی از داده‌ها بیاموزد. این فرض به‌ویژه در روش‌هایی که بر داده‌های متنوع با دوربین‌های متفاوت آموزش داده می‌شوند، چالش‌برانگیز است.

برخی مطالعات نشان داده‌اند که تغییر پارامترهای درونی دوربین، به‌ویژه فاصلهٔ کانونی، می‌تواند منجر به تغییرات معنادار در مقیاس عمق تخمینی شود، حتی زمانی که صحنهٔ تصویربرداری ثابت باقی می‌ماند [۷]. این پدیده بیانگر آن است که نادیده‌گرفتن اطلاعات هندسی صریح می‌تواند به ناپایداری خروجی مدل‌ها منجر شود. در سال‌های اخیر، تلاش‌هایی برای ترکیب دانش هندسی با مدل‌های یادگیری عمیق صورت گرفته است. برای نمونه، برخی روش‌ها از پارامترهای کالیبراسیون در مراحل آموزش یا ارزیابی استفاده کرده‌اند [۸]. با این حال، استفادهٔ نظام‌مند و صریح از ماتریس مشخصهٔ دوربین به‌عنوان ورودی مدل تخمین عمق هنوز به‌طور گسترده مورد بررسی قرار نگرفته است.

این مشاهدات نشان می‌دهد که نادیده‌گرفتن هندسهٔ دوربین یکی از عوامل اصلی ناپایداری عمق متریک در روش‌های موجود است. از این‌رو، تحلیل نقش اطلاعات درونی دوربین و بررسی تأثیر آن بر پایداری تخمین عمق می‌تواند مسیر روشنی برای بهبود مدل‌های تخمین عمق تک‌دوربین فراهم کند.

^۱Root Mean Squared Error

^۲Camera Intrinsics

فصل ۳

روش تحقیق

۱.۳ مقدمه

در این فصل، روش پیشنهادی برای شرطی‌سازی یک مدل بنیادین تخمین عمق تک‌چشمی با پارامترهای درونی دوربین تشریح می‌شود. تمرکز اصلی بر معماری، نحوه ادغام اطلاعات هندسی و فرآیند واقعی آموزش و ارزیابی است. مدل پایه از ادبیات یادگیری خودنظارتی و تقطیر بهره می‌گیرد، اما فاین‌تیون نهایی این پژوهش با عمق مرجع انجام شده است؛ از این رو، در سراسر فصل میان پیش‌آموزش مدل پایه، طرح اختیاری تقطیر و آموزش نظارتی آزمایش‌های نهایی تمایز گذاشته می‌شود.

مدل پایه مورد استفاده در این پژوهش، Depth Anything V2 است که یک معماری encoder-decoder مبتنی بر Transformer Vision را برای تخمین عمق چگال از تصاویر تک‌چشمی ارائه می‌دهد [۱۱]. اگرچه این مدل در حالت پایه عملکرد قابل‌توجهی در سناریوهای مختلف نشان می‌دهد، اما همانند بسیاری از روش‌های موجود، اطلاعات درونی دوربین به صورت صریح در ورودی مدل لحاظ نمی‌شود [۲، ۹، ۶]. این موضوع می‌تواند منجر به ناپایداری تخمین عمق در مواجهه با تغییر پارامترهای دوربین، به‌ویژه در داده‌های چندمنبعه یا تنظیمات دنیای واقعی، شود.

بر این اساس، در روش پیشنهادی این پژوهش، ماتریس مشخصه دوربین به عنوان یک ورودی اضافی و ساختاریافته به بخش encoder مدل افزوده شده است. هدف از این کار، فراهم کردن امکان استفاده مستقیم از اطلاعات هندسی دوربین در فرآیند یادگیری و تأثیرگذاری آن بر مکانیزم attention در لایه‌های Transformer است. بدین ترتیب، مدل قادر خواهد بود نداشت تصویر به عمق را نه تنها بر اساس محتوای بصری صحنه، بلکه با در نظر گرفتن ویژگی‌های تصویربرداری دوربین انجام دهد.

در ادامه این فصل، ابتدا فرمول‌بندی دقیق مسئله و مدل هندسی دوربین ارائه می‌شود. سپس معماری Depth Anything V2 به صورت جزئی بررسی شده و تغییرات اعمال شده برای ادغام ماتریس مشخصه دوربین توضیح داده می‌شود. در بخش‌های پایانی، جزئیات مربوط به فرآیند آموزش، توابع هزینه مورد استفاده و ملاحظات پیاده‌سازی بیان خواهد شد.

۲.۳ صورت‌بندی مسئله تخمین عمق تک‌دورینه

مسئله تخمین عمق تک‌دورینه^۱ به فرایند برآورد فاصله هر نقطه از صحنه نسبت به مرکز دوربین، تنها با استفاده از یک تصویر دوبعدی اطلاق می‌شود. در این مسئله، ورودی سیستم یک تصویر رنگی دوبعدی تعریف می‌شود و خروجی آن یک نگاشت عمق چگال است که به هر پیکسل تصویر، یک مقدار اسکالر متناظر با عمق نسبت داده می‌شود. با وجود ظاهر ساده این تعریف، تخمین عمق تک‌دورینه ذاتاً یک مسئله بدوضعیت محسوب می‌شود [۱، ۳] زیرا نگاشت از فضای دوبعدی تصویر به فضای سه‌بعدی صحنه، یکتا نبوده و چندین پیکربندی هندسی متفاوت می‌توانند تصویر یکسانی را ایجاد کنند.

در چارچوب یادگیری عمیق، این مسئله به صورت یادگیری یک تابع غیرخطی پارامتری‌شده با پارامترهای θ مدل‌سازی می‌شود که نگاشت زیر را تقریب می‌زند:

$$f_{\theta} : \mathbb{R}^{H \times W \times 3} \rightarrow \mathbb{R}^{H \times W}, \quad (1.3)$$

که در آن، H و W به ترتیب ارتفاع و عرض تصویر ورودی بوده و خروجی، نگاشت عمق چگال متناظر با تصویر ورودی است. مقدار عمق پیش‌بینی‌شده در هر پیکسل، فاصله آن نقطه از مرکز اپتیکی دوربین را در راستای محور دید نمایش می‌دهد.

در روش‌های بدون نظارت یا خودنظارتی، برخلاف روش‌های نظارت‌شده، برچسب عمق صریح در دسترس نیست و یادگیری معمولاً بر قیود هندسی، سازگاری تصویری و بازسازی میان نماهای متوالی تکیه دارد [۷، ۹]. این پیشینه انگیزه عنوان و صورت‌بندی هندسی پژوهش است. با این حال، آزمایش کنترل‌شده نهایی برای اندازه‌گیری دقیق سهم ماتریس مشخصه، از عمق مرجع استفاده می‌کند و بنابراین باید یک مرحله فاین‌تیون نظارتی تلقی شود. به صورت صوری، اگر I_t تصویر ورودی در زمان t باشد، هدف یادگیری تابعی است که نگاشت عمق D_t را به گونه‌ای تولید کند که با استفاده از آن و با در نظر گرفتن حرکت دوربین، تصویر I_{t+1} قابل بازسازی از I_t باشد.

¹Monocular Depth Estimation

این بازسازی مبتنی بر هندسهٔ تصویربرداری و مدل دوربین بوده و به‌طور مستقیم به پارامترهای درونی دوربین وابسته است [۳]. با این حال، بخش قابل توجهی از روش‌های موجود، یا به‌صورت ضمنی این پارامترها را نادیده می‌گیرند یا فرض می‌کنند که تمامی تصاویر با یک دوربین ایده‌آل و یکسان ثبت شده‌اند.

یکی از تمایزهای اساسی در مسئلهٔ تخمین عمق تک‌دوربین، تفاوت میان عمق نسبی و عمق مطلق است. بسیاری از روش‌های بدون نظارت قادر به پیش‌بینی عمق تنها تا یک ضریب مقیاس نامشخص هستند؛ بدین معنا که ساختار نسبی صحنه حفظ می‌شود، اما مقادیر عمق از نظر متریک معنا ندارند. این مسئله به‌ویژه در کاربردهایی که نیازمند دقت عددی در واحدهای فیزیکی هستند، نظیر ناوبری رباتیک یا بازسازی سه‌بعدی، یک محدودیت جدی محسوب می‌شود.

در مقابل، تخمین عمق مطلق یا متریک مستلزم آن است که نگاشت عمق خروجی، مستقیماً قابل تفسیر در واحدهای فیزیکی نظیر متر باشد. تحقق این هدف بدون در نظر گرفتن مشخصات هندسی دوربین عملاً امکان‌پذیر نیست، زیرا تبدیل میان مختصات تصویری و مختصات سه‌بعدی جهان، به‌طور مستقیم به پارامترهای درونی دوربین وابسته است. این وابستگی از طریق ماتریس مشخصهٔ دوربین مدل‌سازی می‌شود که نقش کلیدی در تعیین مقیاس و اعوجاج هندسی تصویر دارد.

در این پژوهش، مسئله به‌صورت زیر تعریف می‌شود: هدف، یادگیری تابعی است که علاوه بر تصویر ورودی، پارامترهای درونی دوربین را نیز دریافت کرده و نگاشت عمقی سازگار با هندسهٔ تصویربرداری تولید کند. این تعریف به نوع سیگنال نظارتی وابسته نیست و می‌تواند در آموزش نظارتی، خودنظارتی یا تقطیری به‌کار رود؛ پیاده‌سازی نهایی حاضر از حالت نظارتی استفاده می‌کند. به‌صورت نمادین:

$$f_{\theta} : (I, K) \rightarrow D, \quad (2.3)$$

که در آن، I تصویر ورودی، K ماتریس مشخصهٔ دوربین، و D نگاشت عمق خروجی است. در این صورت‌بندی، ماتریس مشخصه به‌عنوان بخشی از ورودی مدل در نظر گرفته می‌شود و مدل می‌آموزد که چگونه اطلاعات هندسی دوربین را در فرآیند استنتاج عمق لحاظ کند.

این بازفرمول‌بندی، امکان تحلیل صریح اثر تغییرات دوربین بر خروجی مدل را فراهم می‌سازد و زمینه را برای تبیین تفاوت رفتار معیارهای ارزیابی متریک و غیرمتریک مهیا می‌کند. به‌ویژه، معیارهایی نظیر خطای میانگین مربعات ریشه^۱ که به مقیاس فیزیکی حساس هستند، مستقیماً از نحوهٔ مدل‌سازی پارامترهای دوربین تأثیر می‌پذیرند، در حالی که معیارهای نسبی تر نظیر خطای نسبی مطلق^۲ کمتر به این تغییرات واکنش نشان می‌دهند.

^۱Root Mean Square Error

^۲Absolute Relative Error

این تمایز، در فصول بعدی و به‌ویژه در تحلیل نتایج تجربی، نقش محوری ایفا خواهد کرد.

۳.۳ هندسه دوربین و نقش پارامترهای درونی


مسئله تخمین عمق، به‌طور بنیادین ریشه در هندسه تصویربرداری دارد و هرگونه نگاشت میان فضای دوبعدی تصویر و ساختار سه‌بعدی صحنه، ناگزیر وابسته به مدل دوربین مورد استفاده است. در تخمین عمق تک‌دوربین، این وابستگی حتی پررنگ‌تر می‌شود، زیرا تمام اطلاعات مربوط به ساختار فضایی صحنه باید از روی یک تصویر و با اتکا به قیود هندسی استنتاج شود. از این رو، درک دقیق هندسه دوربین و نقش پارامترهای درونی آن، برای تحلیل رفتار مدل‌های تخمین عمق، به‌ویژه در تنظیمات بدون نظارت، ضروری است.

در این بخش، ابتدا مدل هندسی دوربین مورد استفاده معرفی می‌شود، سپس ماتریس مشخصه دوربین به‌صورت صوری تعریف شده و در ادامه، تأثیر مستقیم پارامترهای درونی بر مقیاس و پایداری تخمین عمق مورد بررسی قرار می‌گیرد.

۱.۳.۳ مدل دوربین سوراخ‌سوزنی

در اغلب روش‌های بینایی ماشین، از مدل دوربین سوراخ‌سوزنی به‌عنوان یک تقریب هندسی استاندارد برای فرآیند تصویربرداری استفاده می‌شود [۳]. در این مدل، فرض می‌شود که تمام پرتوهای نوری از یک نقطه واحد، موسوم به مرکز اپتیکی، عبور کرده و بر روی صفحه تصویر نگاشت می‌شوند. اگرچه این مدل بسیاری از پدیده‌های فیزیکی نظیر اعوجاج لنز را نادیده می‌گیرد، اما برای تحلیل هندسی و فرمول‌بندی ریاضی مسئله تخمین عمق، کفایت لازم را دارد.

در چارچوب این مدل، یک نقطه سه‌بعدی در مختصات جهان به‌صورت $\mathbf{X} = (X, Y, Z)^T$ نمایش داده می‌شود. این نقطه پس از تبدیل به دستگاه مختصات دوربین و انجام عمل تصویرسازی، به یک نقطه دوبعدی روی صفحه تصویر با مختصات پیکسلی (u, v) نگاشت می‌شود. این نگاشت، تحت فرضیات مدل سوراخ‌سوزنی، یک نگاشت پرسپکتیو بوده و ذاتاً غیرخطی است.



شکل ۱.۳: مدل هندسی دوربین سوراخ سوزنی: نگاشت یک نقطه سه بعدی X به نقطه دوبعدی x روی صفحه تصویر با توجه به فاصله کانونی f .

۲.۳.۳ ماتریس مشخصه دوربین

رابطه میان مختصات سه بعدی یک نقطه در دستگاه مختصات دوربین و مختصات دوبعدی آن روی تصویر، به وسیله ماتریس مشخصه دوربین مدل سازی می شود. این ماتریس که معمولاً با نماد K نمایش داده می شود، پارامترهای درونی دوربین را در بر می گیرد و به صورت زیر تعریف می شود:

$$K = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \quad (۳.۳)$$

که در آن، f_x و f_y فاصله کانونی مؤثر دوربین در راستاهای افقی و عمودی بر حسب پیکسل هستند و (c_x, c_y) مختصات نقطه اصلی تصویر را مشخص می کنند. این پارامترها به ویژگی های فیزیکی دوربین، نظیر فاصله کانونی، لنز، اندازه سنسور، و رزولوشن تصویر وابسته اند.

با استفاده از این ماتریس، رابطه میان یک نقطه سه بعدی X و تصویر دوبعدی آن را می توان به شکل زیر نوشت:

$$\lambda \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \begin{bmatrix} X \\ Y \\ Z \end{bmatrix}, \quad (۴.۳)$$

که در آن، λ یک ضریب مقیاس است که به عمق نقطه، یعنی مؤلفه Z ، وابسته است. این رابطه به وضوح نشان می‌دهد که مختصات تصویری هر پیکسل، نه تنها به موقعیت سه بعدی نقطه، بلکه به پارامترهای درونی دوربین نیز وابسته است [۳].

۳.۳.۳ نقش پارامترهای درونی در تخمین عمق

در مسئله تخمین عمق، هدف اصلی برآورد مؤلفه Z برای هر پیکسل تصویر است. با توجه به رابطه هندسی فوق، روشن است که تبدیل میان مختصات تصویری و عمق واقعی صحنه، بدون اطلاع از ماتریس مشخصه دوربین، به طور کامل قابل تعیین نیست. در غیاب این اطلاعات، مدل تنها قادر به یادگیری روابط نسبی میان پیکسل‌ها خواهد بود و عمق به دست آمده فاقد مقیاس متریک مشخص خواهد بود.

این مسئله در روش‌های بدون نظارت، که یادگیری بر پایه بازسازی تصویری انجام می‌شود، اهمیت دوچندان می‌یابد. در این روش‌ها، بازسازی یک تصویر از روی تصویر دیگر مستلزم انجام عملیات پروجکشن معکوس و نگاشت نقاط از یک نما به نمای دیگر است. این عملیات به طور مستقیم از ماتریس مشخصه دوربین استفاده می‌کند و هرگونه خطا یا فرض نادرست درباره پارامترهای درونی، منجر به بازسازی نادرست و در نتیجه یادگیری عمق ناپایدار می‌شود.

در بسیاری از روش‌های پیشین، یا فرض شده است که تمام تصاویر با یک دوربین ثابت و با پارامترهای درونی یکسان ثبت شده‌اند، یا اطلاعات مربوط به دوربین به صورت ضمنی در وزن‌های شبکه جذب شده است. این فرضیات، در عمل و به ویژه در تنظیمات چنددوربین یا داده‌های جمع‌آوری شده در شرایط واقعی، معتبر نیستند. تغییر در فاصله کانونی یا نقطه اصلی تصویر می‌تواند نگاشت میان پیکسل و عمق را به طور معناداری تغییر دهد، حتی اگر محتوای صحنه ثابت باقی بماند.

پیامد مستقیم این موضوع، ناپایداری تخمین عمق متریک در مواجهه با داده‌های ناهمگن از نظر مشخصات دوربین است. معیارهایی که به مقیاس فیزیکی عمق حساس هستند، نظیر خطای میانگین مربعات ریشه، بیش از سایر معیارها تحت تأثیر این ناپایداری قرار می‌گیرند. در مقابل، معیارهای مبتنی بر روابط نسبی میان پیکسل‌ها، که به مقیاس مطلق وابسته نیستند، رفتار پایدارتری از خود نشان می‌دهند.

بر این اساس، لحاظ صریح پارامترهای درونی دوربین در فرآیند تخمین عمق، نه تنها از منظر هندسی موجه است، بلکه برای دستیابی به عمق متریک پایدار و قابل تعمیم، امری ضروری به نظر می‌رسد. این مشاهده، مبنای نظری روش پیشنهادی این پژوهش را تشکیل می‌دهد که در آن، ماتریس مشخصه دوربین به عنوان بخشی از ورودی مدل در نظر گرفته شده و نقش آن در فرآیند استنتاج عمق به صورت ساخت یافته مدل سازی می‌شود.

۴.۳ معماری پایه: مدل Depth Anything V2

مدل Depth Anything V2 یکی از جدیدترین چارچوب‌های ارائه‌شده برای تخمین عمق تک‌دوربینه یادگیری خودنظارتی مبتنی بر تقطیر است [۱۱]. و با بهره‌گیری از معماری‌های مبتنی بر ترنسفورمر و به‌کارگیری راهبردهای بازنمایی چندمقیاسی، قادر است نداشت‌های عمق باکیفیت و سازگار با جزئیات ساختاری تصویر تولید کند. در این مدل، ساختار اصلی شبکه بر مبنای یک معماری encoder-decoder بنا شده است که در آن، بخش encoder مسئول استخراج بازنمایی‌های سطح‌بالا و چندمقیاسی از تصویر ورودی بوده و بخش decoder وظیفه بازگردانی این بازنمایی‌ها به یک نداشت عمق چگال را بر عهده دارد. این معماری، به‌ویژه در نسخه دوم مدل، با بهبودهای ساختاری مهمی همراه شده است که موجب افزایش دقت تخمین عمق در هر دو محیط درونی و بیرونی و نیز بهبود رفتار مدل در داده‌های ناهمگن شده است.

۱.۴.۳ ساختار کلی شبکه encoder-decoder

در معماری Depth Anything V2، تصویر ورودی پس از اعمال پیش‌پردازش مناسب، به بخش encoder تغذیه می‌شود. خروجی این بخش مجموعه‌ای از بازنمایی‌های نهان در سطوح مختلف است که در ادامه توسط بخش decoder برای تولید نقشه عمق استفاده می‌شوند. این ساختار دو مرحله‌ای به مدل اجازه می‌دهد تا از یک سو، توصیف‌های سطح‌بالای مبتنی بر محتوای معنایی تصویر را استخراج کند و از سوی دیگر، با بهره‌گیری از ساختارهای چندمقیاسی، جزئیات مکانی لازم برای تولید عمق دقیق را حفظ نماید. در این معماری، جریان اطلاعات میان encoder و decoder از طریق مسیرهای میان‌بری برقرار است تا ویژگی‌های مکانی که ممکن است در تغییر مقیاس‌های مکرر از دست بروند، در فرآیند بازسازی نقشه عمق حفظ شوند.

۲.۴.۳ بخش encoder مبتنی بر Transformer Vision

بخش encoder در این مدل بر پایه معماری Transformer Vision طراحی شده است [۱۲]. که در سال‌های اخیر به‌عنوان یکی از مؤثرترین ساختارها در بازنمایی‌های بصری مطرح شده است. در این بخش، تصویر ورودی به مجموعه‌ای از قطعه‌های منظم تقسیم شده و سپس هر قطعه به یک بردار نهان با ابعاد ثابت نگاشت می‌شود. این بردارها در ادامه وارد لایه‌های خودتوجهی چندسری^۱ شده و وابستگی‌های غیرمحلی میان^۱ منظور از خودتوجهی چندسری همان Multi-Head Self-Attention است که در معماری ترنسفورمر معرفی شده و با استفاده از چندین سر توجه به‌صورت موازی، روابط متفاوتی میان ویژگی‌ها را مدل می‌کند.

بخش‌های مختلف تصویر را مدل‌سازی می‌کنند. استفاده از سازوکار^۱ توجه به مدل اجازه می‌دهد تا روابط بلندبرد میان اجزای تصویر به‌طور مستقیم در بازنمایی نهان لحاظ شود، امری که به‌ویژه در تخمین عمق تک‌دوربین اهمیت اساسی دارد؛ زیرا رابطه میان هندسه صحنه و محتوای تصویری، اغلب به وابستگی‌های گسترده مکانی متکی است.

در نسخه دوم Depth Anything، بخش encoder علاوه بر بهبود در ساختار توجه و افزایش ظرفیت مدل، با به‌کارگیری دانش انتقالی از مدل‌های از پیش آموزش‌دیده بزرگ، نظیر مدل‌های مبتنی بر داده‌های گسترده طبقه‌بندی و بخش‌بندی، قادر شده است بازنمایی‌های بصری دقیق‌تری را تولید کند. این رویکرد موجب افزایش تعمیم‌پذیری مدل در صحنه‌های جدید و شرایط نوری متفاوت شده است.

۳.۴.۳ بخش decoder و راهبرد بازسازی نگاشت عمق

بخش decoder در Depth Anything V2 بر پایه ساختاری از خانواده DPT طراحی شده است [۶]. ساختاری که به‌طور خاص برای بازسازی نگاشت‌های چگال، نظیر عمق یا نرمال سطح، توسعه یافته است. این بخش با ترکیب بازنمایی‌های چندمقیاسی استخراج‌شده از encoder و انجام فرآیندهای ادغام مکانی، نگاشت عمق نهایی را تولید می‌کند. در این فرآیند، لایه‌های افزایش تفکیک‌پذیری، همراه با سازوکارهای ادغام ویژگی‌ها، نقشی اساسی در بازگردانی جزئیات محلی ایفا می‌کنند. از آنجا که بخش encoder به‌سبب تغییر مقیاس‌های متعدد، بخشی از اطلاعات مکانی صحنه را از دست می‌دهد، وجود مسیرهای ادغام میان‌بُری که بازنمایی‌های سطح پایین‌تر را با سطوح بالاتر ترکیب می‌کنند، برای تولید عمق دقیق و دارای مرزبندی روشن ضروری است. در نسخه دوم این مدل، decoder به‌گونه‌ای بازطراحی شده است که بتواند به شیوه‌ای کارآمد با رزولوشن‌های بالاتر نیز سازگار شود. به‌طور خاص، شبکه قادر است ورودی‌هایی با ابعاد تا چند صد پیکسل در هر ضلع را پردازش کرده و در عین حال، پایداری خود را در تخمین عمق حفظ کند. این ویژگی به‌طور مستقیم از نیازهای کاربردهای بازسازی سه‌بعدی با وضوح بالا الهام گرفته است، کاربردهایی که در مطالعات اخیر، از جمله روش‌های افزایش وضوح تا حد 4K، اهمیت زیادی پیدا کرده‌اند.

در مجموع، ترکیب یک encoder مبتنی بر ترنسفورمر با یک decoder مبتنی بر ساختارهای بازسازی چگال، موجب شده است Depth Anything V2 بتواند میان بازنمایی سطح‌بالا و جزئیات مکانی تعادل مناسبی برقرار کند. این ویژگی، آن را به مدلی مناسب برای استفاده به‌عنوان معماری پایه در این پژوهش بدل می‌کند. در بخش‌های بعدی، نحوه ادغام صریح ماتریس مشخصه دوربین در این معماری، و نیز تأثیر آن بر کیفیت تخمین عمق متریک، به تفصیل بررسی می‌شود.

¹Attention

۵.۳ انگیزه‌ی صریح برای لحاظ پارامترهای درونی دوربین

در فرآیند تخمین عمق تک‌دوربین^۱، رابطه بنیادین میان تصویربرداری و هندسه صحنه، مستقیماً به چگونگی بازنمایی پارامترهای درونی دوربین^۲ وابسته است. اغلب مطالعات پیشین، با فرض یکسان بودن مشخصات اپتیکی و هندسی در تمام تصاویر مجموعه داده، یا با اتکا به دانش از پیش آموزش یافته مدل نسبت به ساختار معمول دوربین‌ها، از لحاظ صریح و صوری این پارامترها در چرخه فرایند یادگیری صرف نظر کرده‌اند. [۷، ۹] این رویکرد، هرچند روی مجموعه‌های همگن (مانند دیتاست‌های کنترل شده آزمایشگاهی) می‌تواند به نتایج قابل اتکاء منجر شود، اما به شدت نسبت به ناهمگونی‌های اپتیکی و تفاوت‌های ساختاری میان نمونه‌های تصویری حساس است؛ عاملی که در کاربردهای دنیای واقعی و نیز در انتقال مدل به مجموعه داده‌های ناهمگن، موجب ناپایداری و کاهش دقت تخمین عمق می‌شود.

۱.۵.۳ شواهد تجربی از تاثیر پارامترهای دوربین در معیارهای متریک

تحلیل ارائه شده در ادامه نشان می‌دهد که تغییر سمت دوربین در یک جفت استریو، با وجود شباهت محتوایی دو تصویر، می‌تواند در معیارهای وابسته به مقیاس اثر متفاوتی ایجاد کند. برای سنجش این موضوع، شاخص خطای مطلق نسبی^۳ و ریشه میانگین مربعات^۴ برای خروجی مدل متریک Depth Anything V2 (انکودر ViT-S و نقطه واریسی Hypersim) روی هر دو نمای مجموعه Middlebury محاسبه شد. واحد استنباط آماری، محتوای صحنه بود: نتایج دو نسخه تصحیح شده perfect و imperfect هر صحنه ابتدا میانگین‌گیری شد و سپس آزمون زوجی دوسویه روی ۲۳ صحنه مستقل انجام گرفت.

بازبینی فایل‌های کالیبراسیون یک نکته مهم را نیز روشن کرد: در هر جفت استریو، مقادیر f_x و f_y دو دوربین دقیقاً برابرند و c_y نیز تغییری ندارد؛ تفاوت نظام مند ماتریس‌ها در c_x است (اختلاف دوربین ۱ منهای دوربین ۰ در بازه ۲۱۵/۷۷ تا ۱۹۵/۸۰۹ پیکسل). بنابراین این آزمایش را نباید آزمون علی تغییر f_y دانست، بلکه مقایسه زوجی دو سمت دوربین با دیدگاه‌ها و نقاط اصلی متفاوت است.

مطابق جدول ۱.۳، میانگین اختلاف RMSE برابر ۰/۳۷۰ متر بود و آزمون t زوجی این اختلاف را در آستانه ۰/۰۵ معنادار نشان داد ($t(22) = 2/093$ ، $p = 0/048$ ، بازه اطمینان بوت‌استرپ ۹۵ درصد: $[0/00054, 0/0727]$). در مقابل، اختلاف AbsRel معنادار نبود ($t(22) = 1/493$ ، $p = 0/150$).

¹Monocular Depth Estimation

²Camera Intrinsic Parameters

³Absolute Relative Error (AbsRel)

⁴Root Mean Squared Error (RMSE)

بازه اطمینان: $[-0.0032, 0.0232]$). آزمون ناپارامتری ویلکاکسون نیز نتیجه RMSE را تأیید کرد ($p = 0.196$)، در حالی که نتیجه AbsRel مرزی بود ($p = 0.052$). شکل ۲.۳ مقادیر زوجی و جهت ناهمگن اختلاف‌ها را نشان می‌دهد.

جدول ۱.۳: ممیزی بازتولیدپذیر تفاوت دو سمت دوربین در Middlebury. اختلاف به صورت دوربین ° منهای دوربین ۱ و بازه‌ها به صورت بوت‌استرپ زوجی ۹۵ درصد گزارش شده‌اند ($n = 23$).

معیار	دوربین ° (میانگین $\pm$ انحراف معیار)	دوربین ۱ (میانگین $\pm$ انحراف معیار)	اختلاف میانگین [بازه اطمینان]	$t(22)$	p
↓AbsRel	0.3459 ± 0.1648	0.3356 ± 0.1634	$[-0.0032, 0.0232]$	۱/۴۹۳	۰/۱۵۰
↓RMSE (متر)	1.1012 ± 0.7598	1.0642 ± 0.7607	$[0.0054, 0.0727]$	۲/۰۹۳	۰/۰۴۸


این نتیجه از حساسیت بیشتر RMSE به تفاوت نظام‌مند میان دو سمت تصویربرداری پشتیبانی می‌کند، اما به‌تنهایی اثر علی یک مؤلفه مشخص از K را اثبات نمی‌کند؛ زیرا دو ورودی، دیدگاه و محتوای پیکسلی کاملاً یکسانی ندارند و مدل پایه نیز K را به صورت صریح دریافت نمی‌کند. شواهد علی مصرف K در فصل بعد با کنترل تصویر و تغییر مستقیم ورودی K ارائه می‌شود.

۲.۵.۳ عدم کفایت رویکرد ضمنی نسبت به مشخصه‌های دوربین

روش‌هایی که بدون لحاظ صریح ماتریس مشخصه دوربین^۱ توسعه یافته‌اند، اغلب متکی بر راهبردهای یادگیری روابط نسبی یا بازسازی بر مبنای هندسه ضمنی هستند؛ به این معنا که مدل، صرفاً براساس روابط داخلی پیکسل‌های تصویر، بدون آگاهی از مقیاس مطلق صحنه یا فواصل کانونی واقعی، اقدام به بازسازی عمق می‌کند. این سیاست، علاوه بر ایجاد وابستگی پنهان مدل نسبت به توزیع دوربین‌های موجود در مرحله آموزش، در عمل منجر به آن می‌شود که مدل به محض مواجهه با تصاویر ثبت‌شده توسط دوربینی با پارامترهای متفاوت، دیگر قادر به تولید تخمین‌های متریک دقیق نیست.

این موضوع به‌ویژه در کاربردهای عملی، که تصاویر ورودی ممکن است مجموعه‌ای ناهمگن از لحاظ نوع، رزولوشن، و پارامترهای اپتیکی باشند، مصداق می‌یابد و موجب کاهش جدی قابلیت اعتماد مدل در محیط‌های واقعی می‌شود. افزون بر آن، تضعیف ارزیابی مدل با معیارهای متریک (همانند RMSE) نه تنها مانعی برای ارتقاء کیفی سیستم‌های بینایی ماشینی محسوب می‌شود، بلکه حتی قابلیت رقابت مدل با سنسورهای عمق‌سنج فیزیکی را نیز با چالش جدی مواجه می‌سازد.

^۱Camera Intrinsic Matrix (K)



شکل ۲.۳: مقایسه زوجی دو سمت دوربین در Middlebury پس از میانگین‌گیری دو نسخه تصحیح هر یک از ۲۳ محتوای صحنه. ردیف بالا مقادیر هر صحنه و میانگین کل (لوزی سیاه) و ردیف پایین اختلاف مرتب‌شده دوربین ° منهای دوربین ۱ را نشان می‌دهد. خط چین قرمز میانگین اختلاف است.

۳.۵.۳ کاربردهای عملی و انتقال‌پذیری به داده‌های جهان واقعی

در بسیاری از کاربردهای کلیدی تخمین عمق تک‌دوربین، از جمله رباتیک، هدایت خودکار وسایل نقلیه، نقشه‌برداری سه‌بعدی، و واقعیت افزوده، داده‌های تصویری از منابع و دوربین‌های متعددی تأمین می‌شوند که هریک دارای ویژگی‌های اپتیکی منحصر به فردی هستند. انتقال موفق مدل از شرایط آزمایشگاهی به محیط‌های عملی، مستلزم آن است که سامانه بتواند برای هر تصویر ورودی، با استفاده از ماتریس مشخصه دوربین متناظر آن، عمل تخمین عمق را به صورت سازگار و قابل اطمینانی انجام دهد. پژوهش‌هایی که اخیراً حول موضوع جبران و بهبود رفتار مدل نسبت به زاویه دید (FOV) و کالیبراسیون دوربین در مجموعه داده‌های مختلف منتشر شده است [۱۳]، بر همین نکته تأکید دارند: لحاظ صریح مشخصات دوربین، کلید دستیابی به یک تخمین عمق متریک باکیفیت و مقاوم در کاربردهای واقعی است.

۴.۵.۳ لزوم طراحی مدل با ورود صریح پارامترهای درونی

برآیند این شواهد نظری و تجربی، این ضرورت را آشکار می‌کند که طراحی مدل‌هایی که به دنبال تخمین عمق متریک هستند، باید به طور ساختاری از اطلاعات پارامترهای دوربین (و به طور ویژه ماتریس K) بهره گیرند. لحاظ K ، چه به صورت ورودی صریح به شبکه، چه از طریق تطبیق ساختار لایه‌های مدل با قیود فیزیکی تصویربرداری، می‌تواند پایداری و دقت تخمین عمق را در مواجهه با تنوع عملی داده‌ها تضمین کند. رویکرد پیشنهادی ما در این پژوهش، مبتنی بر ورود ساخت یافته اطلاعات ماتریس مشخصه دوربین در جریان یادگیری و استنتاج مدل است؛ رویکردی که شواهد ریاضی و تجربی، برتری آن را به ویژه در ارزیابی عمق متریک ثابت کرده‌اند. جزئیات پیاده‌سازی این ایده و ادغام K با معماری پایه، در بخش‌های بعدی ارائه خواهد شد.

۶.۳ طراحی روش پیشنهادی: ادغام صریح ماتریس مشخصه دوربین

بر اساس مباحث نظری ارائه شده در بخش‌های پیشین و شواهد تجربی حاصل از تحلیل حساسیت معیارهای متریک نسبت به پارامترهای درونی دوربین، در این پژوهش روشی برای ادغام صریح ماتریس مشخصه دوربین در معماری Depth Anything V2 پیشنهاد می‌شود. ایده اصلی این روش، فراهم کردن امکان دسترسی مستقیم مدل به اطلاعات هندسی فرآیند تصویربرداری است، به گونه‌ای که شبکه به جای استنتاج ضمنی و ناپایدار این اطلاعات از روی داده، بتواند از قیود فیزیکی دوربین به صورت ساخت یافته بهره‌مند شود [۷، ۱۴].

در این بخش، ابتدا اصول کلی طراحی روش پیشنهادی تشریح می‌شود، سپس نحوه نمایش و نرمال‌سازی ماتریس مشخصه دوربین توضیح داده شده و در ادامه، راهبرد ادغام این اطلاعات با معماری encoder-decoder مدل پایه مورد بررسی قرار می‌گیرد.

۱.۶.۳ اصل طراحی: تفکیک اطلاعات تصویری و هندسی

در اغلب مدل‌های تخمین عمق تک‌دوربین بدون نظارت، تصویر ورودی تنها منبع اطلاعاتی شبکه محسوب می‌شود و تمام قیود هندسی، اعم از فاصله کانونی یا میدان دید، به‌صورت ضمنی در وزن‌های مدل جذب می‌شوند [۱۵، ۶]. این رویکرد باعث می‌شود که مدل به توزیع دوربین‌های موجود در داده آموزشی وابسته شود و در مواجهه با داده‌هایی که از نظر پارامترهای درونی تفاوت دارند، عملکرد ناپایداری از خود نشان دهد. روش پیشنهادی این پژوهش بر اصل تفکیک میان اطلاعات تصویری و اطلاعات هندسی استوار است. در این چارچوب، تصویر ورودی همچنان به‌عنوان منبع اطلاعات ظاهری و معنایی صحنه مورد استفاده قرار می‌گیرد، در حالی که ماتریس مشخصه دوربین به‌عنوان توصیف‌گر هندسه تصویربرداری، به‌صورت یک ورودی مستقل و مکمل در اختیار مدل قرار داده می‌شود. این تفکیک، به مدل اجازه می‌دهد تا نداشت میان پیکسل و عمق را نه تنها بر اساس الگوهای بصری، بلکه با در نظر گرفتن مقیاس و هندسه واقعی دوربین انجام دهد [۱۶، ۱۷].

۲.۶.۳ نمایش و پیش‌پردازش ماتریس مشخصه دوربین

ماتریس مشخصه دوربین به‌صورت زیر تعریف می‌شود:

$$K = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}. \quad (5.3)$$

از آنجا که مقادیر این ماتریس به رزولوشن تصویر و تنظیمات فیزیکی دوربین وابسته‌اند، استفاده مستقیم از مقادیر خام می‌تواند موجب ناپایداری عددی در فرآیند یادگیری شود [۷، ۱۸]. به همین دلیل، در روش پیشنهادی، پارامترهای درونی دوربین پیش از ورود به شبکه نرمال‌سازی می‌شوند. به‌طور خاص، مؤلفه‌های فاصله کانونی و

مختصات نقطه اصلی بر حسب ابعاد تصویری که ماتریس K در آن بیان شده است نرمال می‌شوند:

$$\tilde{f}_x = \frac{f_x}{W}, \quad \tilde{f}_y = \frac{f_y}{H}, \quad \tilde{c}_x = \frac{c_x}{W}, \quad \tilde{c}_y = \frac{c_y}{H}, \quad (۶.۳)$$

که در آن H و W به ترتیب عرض و ارتفاع چارچوب مرجع پارامترهای دوربین هستند. این بازنمایی نرمال شده، امکان استفاده پایدار از اطلاعات دوربین در مجموعه داده‌هایی با رزولوشن‌های متفاوت را فراهم می‌کند [۱۹، ۲۰]. افزون بر مؤلفه‌های نرمال شده فوق، برای آنکه بازنمایی ورودی به صورت مستقیم در بردارنده مفهوم فیزیکی میدان دید^۱ باشد، زوایای میدان دید افقی و عمودی نیز به صورت

$$\text{fov}_w = 2 \arctan\left(\frac{W}{2f_x}\right), \quad \text{fov}_h = 2 \arctan\left(\frac{H}{2f_y}\right) \quad (۷.۳)$$

محاسبه می‌شوند. مطابق پیاده‌سازی نهایی، زاویه‌ها بر π ، میانگین فاصله کانونی بر بزرگ‌ترین بُعد تصویر و مساحت تصویر بر مساحت مرجع 1080×1920 تقسیم می‌شوند. بنابراین، بردار توصیف‌گر هندسی دوربین دقیقاً به صورت

$$\mathbf{k} = \left[\frac{f_x}{W}, \frac{f_y}{H}, \frac{c_x}{W}, \frac{c_y}{H}, \frac{\text{fov}_h}{\pi}, \frac{\text{fov}_w}{\pi}, \frac{W}{H}, \frac{f_x + f_y}{2 \max(H, W)}, \frac{HW}{1920 \times 1080} \right] \quad (۸.۳)$$

تعریف می‌شود و به عنوان ورودی هندسی مدل مورد استفاده قرار می‌گیرد. نکته اساسی در این بازنمایی آن است که ماتریس K و ابعاد (H, W) باید هر دو در یک چارچوب مختصات یکسان بیان شوند؛ در غیر این صورت، کدگذاری حاصل از منظر هندسی نادرست خواهد بود. اهمیت عملی این نکته در بخش جزئیات پیاده‌سازی و در تحلیل اشکال‌زدایی فصل چهارم آشکار می‌شود.

۳.۶.۳ راهبرد ادغام اطلاعات دوربین با معماری Depth Anything V2

برای ادغام بردار پارامترهای درونی دوربین با معماری پایه، در این پژوهش از یک واحد کدگذار دوربین^۲ استفاده می‌شود که وظیفه آن، تبدیل بردار کم بعد $\mathbf{k}$ به یک توکن دوربین سازگار با فضای بازنمایی ترنسفورمر است. این واحد شامل یک شبکه تمام متصل دولایه برای نگاشت اولیه و سپس چند بلوک ترنسفورمر برای پالایش

^۱Field of View (FoV)

^۲Camera Encoder


بازنمایی است که خروجی آن یک توکن با ابعاد برابر با بعد نهان انکودر بینایی است:

$$\mathbf{z}_k = \phi(\mathbf{k}), \quad (9.3)$$

که در آن $\phi(\cdot)$ تابع نگاشت پارامتری قابل یادگیری است.

توکن دوربین $\mathbf{z}_k$ سپس در کنار توکن‌های تصویری، به دنباله توکن‌های انکودر مبتنی بر DINOv2 تزریق می‌شود؛ به گونه‌ای که سازوکار خودتوجهی بتواند در تمامی لایه‌های پس از نقطه تزریق، اطلاعات هندسی دوربین را با بازنمایی‌های بصری ترکیب کند. لایه تزریق از طریق پارامتر قابل تنظیم `--cam-token-inject-` layer کنترل می‌شود و در تنظیمات پیش‌فرض، تزریق از نخستین لایه انکودر انجام می‌گیرد. این راهبرد با روش‌های شرطی‌سازی مبتنی بر توکن در معماری‌های ترنسفورمری و نیز رویکردهای تنظیم ویژگی به کمک بردارهای شرطی نظیر FiLM هم‌خانواده است [۲۱]؛ با این تفاوت که در اینجا، شرطی‌سازی از طریق سازوکار توجه انجام می‌شود و نیازی به دستکاری مستقیم نگاشت‌های ویژگی نیست.

نکته طراحی مهم در این ادغام، استفاده از یک دروازه خروجی با مقداردهی اولیه صفر^۱ است: خروجی کدگذار دوربین در ابتدای آموزش در یک ضریب قابل یادگیری با مقدار اولیه صفر ضرب می‌شود. در نتیجه، در گام‌های نخست آموزش، توکن دوربین عملاً برداری صفر است و رفتار مدل دقیقاً با مدل از پیش آموزش دیده پایه یکسان باقی می‌ماند؛ سپس در طول آموزش، شبکه به تدریج و تنها در صورتی که اطلاعات دوربین برای کاهش خطا مفید باشد، این دروازه را باز می‌کند. این سازوکار، از آسیب رساندن به بازنمایی‌های از پیش آموخته در آغاز فاین‌تیون جلوگیری کرده و پایداری فرآیند آموزش را تضمین می‌کند [۱۶، ۲۲].



شکل ۳.۳: معماری مدل پیشنهادی: اطلاعات تصویر توسط انکودر از پیش آموزش دیده استخراج می‌شود. ماتریس مشخصه دوربین K پس از نرمال‌سازی، توسط واحد کدگذار دوربین به یک توکن نهان تبدیل شده و همراه با یک دروازه خروجی صفر مقدار اولیه، به دنباله توکن‌های انکودر تزریق می‌گردد تا سازوکار توجه بتواند اطلاعات هندسی را با بازنمایی‌های بصری ترکیب کند.

¹Zero-initialized Output Gate

۴.۶.۳ مزایای مورد انتظار از ادغام صریح پارامترهای درونی

ادغام صریح ماتریس مشخصه دوربین، چند مزیت کلیدی را به همراه دارد. نخست آنکه مدل قادر خواهد بود نگاشت میان پیکسل و عمق را با در نظر گرفتن مقیاس واقعی دوربین انجام دهد و از این طریق، دقت تخمین عمق متریک افزایش یابد. دوم آنکه وابستگی مدل به توزیع خاصی از دوربین‌ها در داده آموزشی کاهش می‌یابد و تعمیم‌پذیری آن در مواجهه با داده‌های چنددوربین به‌یود پیدا می‌کند. این موضوع به‌ویژه با توجه به نتایج تجربی ارائه‌شده در تحلیل RMSE در بخش پیشین، اهمیت ویژه‌ای دارد. در نهایت، این طراحی امکان توسعه مدل به سناریوهای پیشرفته‌تر، نظیر یادگیری انتقالی میان مجموعه داده‌های با میدان دید متفاوت، را نیز فراهم می‌کند.

در بخش‌های بعدی، نحوه آموزش این مدل، تابع هزینه مورد استفاده، و تنظیمات تجربی برای ارزیابی اثر ادغام پارامترهای درونی دوربین به تفصیل تشریح خواهد شد.

۷.۳ راهبرد آموزش مدل پیشنهادی

در این پژوهش، آموزش مدل پیشنهادی به صورت فاین تیون^۱ یک مدل از پیش آموزش یافته انجام شده است. به طور خاص، از نسخه non-metric مدل Depth Anything V2 با وزن‌های اولیه مدل Large به عنوان نقطه شروع استفاده شده و فرآیند آموزش با هدف تبدیل آن به یک مدل متریک پایدار، با لحاظ صریح پارامترهای درونی دوربین، طراحی شده است. این راهبرد، ضمن بهره‌گیری از دانش غنی مدل معلم، امکان انطباق مدل با تنظیمات هندسی جدید را بدون نیاز به آموزش از ابتدا فراهم می‌کند.

برای رفع ابهام اصطلاح‌شناختی، عنوان کلی پژوهش به تخمین عمق بدون نظارت و استفاده از یک مدل بنیادین از پیش آموخته اشاره دارد، اما مرحله نهایی فاین تیون کنترل شده در این پایان‌نامه نظارتی است و از نگاشت‌های عمق مرجع NYUV2 استفاده می‌کند. تقطیر دانش در زیرساخت پیاده‌سازی شده، ولی در آزمایش‌های نهایی غیرفعال است. این تفکیک ضروری است تا بهبود مشاهده‌شده به ورودی K و برنامه فاین تیون نسبت داده شود، نه به یک سیگنال آموزشی جانبی.

¹Fine-tuning

۱.۷.۳ مجموعه داده‌های مورد استفاده

در مرحله اکتشافی، ترکیب‌هایی از Virtual KITTI^۱، NYUv2^۲، DIODE^۳، Cityscapes و Middlebury آزموده شد. این داده‌ها از نظر نوع صحنه، شرایط تصویربرداری و مشخصات دوربین متنوع‌اند [۲۳، ۲۴، ۲۵]؛ با این حال، نتایج فصل چهارم نشان داد که فاین تیون چندمجموعه‌ای محدود، تعمیم صفرنمونه مدل بنیادین را تخریب می‌کند. از این رو، مطالعه نهایی برای جداسازی علی سهم K به NYUv2 محدود شد و هر زوج پیشنهادی/کنترل دقیقاً داده‌ها و برنامه آموزشی یکسانی دریافت کرد.

داده‌های مورد استفاده عمدتاً به صورت تک‌تصویر یا توالی‌های کوتاه از تصاویر ثبت شده‌اند، با این تفاوت که در فرآیند آموزش حاضر، هر تصویر به صورت مستقل پردازش شده و هیچ گونه قید زمانی یا وابستگی صریح میان فریم‌های متوالی اعمال نشده است. این انتخاب، با هدف تمرکز بر مسئله تخمین عمق تک‌تصویر و حذف اثرات جانبی ناشی از حرکت دوربین یا برآورد ژست صورت گرفته است.

در مواردی که اطلاعات ماتریس مشخصه دوربین به صورت صریح در داده‌ها موجود بوده، این اطلاعات مستقیماً مورد استفاده قرار گرفته و در سایر موارد، پارامترهای دوربین مطابق با تنظیمات مرجع هر مجموعه داده استخراج یا بازسازی شده‌اند.

۲.۷.۳ تفکیک صحیح مجموعه‌های آموزش و آزمون در NYUv2

نکته روش‌شناختی مهمی که در جریان این پژوهش شناسایی و اصلاح شد، نحوه تفکیک داده‌های آموزش و آزمون در مجموعه داده NYUv2 است. پروتکل استاندارد ارزیابی در ادبیات این حوزه، زیرمجموعه آزمون ۶۵۴ تصویری موسوم به تقسیم‌بندی Eigen است [۲] که مدل Depth Anything V2 نیز نتایج خود را بر همین مبنا گزارش می‌کند [۱۱]. در نسخه اولیه زیرساخت آموزش این پژوهش، تقسیم‌بندی آموزش/اعتبارسنجی به صورت تصادفی بر روی کل ۱۴۴۹ تصویر مجموعه برچسب‌دار انجام می‌شد؛ بررسی دقیق نشان داد که با این رویه، ۵۲۷ تصویر از ۶۵۴ تصویر آزمون استاندارد (معادل ۸۰/۶ درصد) در مجموعه آموزش قرار می‌گیرند و در نتیجه هرگونه ارزیابی روی مجموعه آزمون، دچار نشت داده^۴ و به صورت مصنوعی خوش‌بینانه خواهد بود.

برای رفع این مشکل، فرآیند تقسیم‌بندی به گونه‌ای اصلاح شد که ابتدا تمامی ۶۵۴ تصویر آزمون استاندارد به طور کامل کنار گذاشته شوند و سپس تقسیم ۸۰/۲۰ آموزش/اعتبارسنجی تنها بر روی ۷۹۵ تصویر باقی‌مانده انجام گیرد (۶۳۶ تصویر آموزش و ۱۵۹ تصویر اعتبارسنجی). عدم هم‌پوشانی سه مجموعه نیز با آزمون خودکار

^۱Virtual KITTI

^۲NYUv2

^۳DIODE

^۴Data Leakage

راستی آزمایی شده است. تمامی نتایج نهایی گزارش شده در فصل چهارم بر مبنای این تفکیک بدون نشت به دست آمده‌اند.

۳.۷.۳ مدل پایه و راهبرد فاین تیون

مدل پایه مورد استفاده، نسخه Depth Anything V2 non-metric است که به صورت teacher-student distillation^۱ آموزش دیده و دارای توانایی بالایی در استخراج ویژگی‌های معنایی و هندسی تصویر است. در این پژوهش، این مدل به عنوان دانش اولیه در نظر گرفته شده و فرآیند فاین تیون با هدف افزودن قابلیت تخمین عمق متریک و تطبیق با اطلاعات دوربین انجام شده است.

برای حفظ پایداری آموزش و جلوگیری از بیش‌برازش، بخش encoder مبتنی بر DINOv2^۲ در طول آموزش فریز شده است. این تصمیم مبتنی بر این فرض است که ویژگی‌های استخراج شده توسط DINOv2، پیشاپیش از غنای کافی برای نمایش محتوای تصویری برخوردارند و نیازی به بازآموزی در این مرحله ندارند [۲۶]. در مقابل، بخش decoder و همچنین ماژول‌های مرتبط با تخمین عمق و پردازش پارامترهای دوربین، به صورت کامل قابل یادگیری باقی مانده‌اند.

۴.۷.۳ فعال‌سازی پشتیبانی از پارامترهای دوربین

گزینه `--use-camera-intrinsics` در اسکریپت آموزش، استفاده از ماتریس مشخصه دوربین را در فرآیند آموزش فعال می‌کند. با فعال‌سازی این گزینه، بردار نرمال‌سازی شده پارامترهای دوربین مطابق با توضیحات بخش ۳-۶ استخراج شده و از طریق یک encoder اختصاصی به فضای نهان مدل نگاشت می‌شود. علاوه بر این، امکان کنترل محل تزریق اطلاعات دوربین در معماری شبکه از طریق پارامتر `--cam-token-inject-layer` فراهم شده است. این پارامتر لایه تزریق توکن به انکودر DINOv2 را تعیین می‌کند. در تمام آزمایش‌های گزارش شده مقدار پیش‌فرض، یعنی لایه نخست انکودر، استفاده شده است؛ حساسیت نسبت به محل تزریق و تزریق چندلایه در این پژوهش پیمایش نشده و به عنوان مسیر کار آینده گزارش می‌شود.

^۱Teacher-Student Distillation

^۲DINOv2

۵.۷.۳ تنظیمات آموزش و بهینه‌سازی

فرآیند آموزش با اسکریپت `train.py` و در دو حالت انجام شده است: `--model-type basic` برای خروجی نسبی در فضای عمق معکوس، و `--model-type metric` برای عمق مطلق بر حسب متر. حالت نسبی برای بازتولید پروتکل استاندارد و تشخیص محدودیت تراز مقیاس به کار رفت؛ حالت متریک، بستر اصلی آزمون فرضیه نقش K در بازیابی مقیاس بود.

به منظور سازگاری بهتر فرآیند فاین تیون با وزن‌های از پیش آموزش یافته، نرخ یادگیری بخش‌های مختلف شبکه به صورت ناهمسان تنظیم شده است. به طور خاص، برای لایه‌های مربوط به تخمین عمق و `encoder` پارامترهای دوربین، از ضریب تقویت نرخ یادگیری استفاده شده است:

$$-head-lr-multiplier \quad (۱۰.۳)$$

این راهبرد باعث می‌شود که لایه‌های جدید یا تغییر یافته، سریع‌تر با هدف متریک آموزش تطبیق یابند، در حالی که سایر بخش‌های شبکه دچار نوسان شدید نشوند.

همچنین، برای افزایش پایداری عددی آموزش، از برش گرادیان^۱ و در برخی تنظیمات از `warm-up` تدریجی نرخ یادگیری استفاده شده است. این تنظیمات به‌ویژه در مراحل ابتدایی آموزش، از واگرایی گرادیان‌ها جلوگیری کرده و همگرایی نرم‌تری را فراهم می‌کنند.

۶.۷.۳ فضای هدف آموزش برای مدل‌های نسبی: عمق معکوس

یکی از یافته‌های روش شناختی مهم این پژوهش، اهمیت هم‌خوانی فضای هدف آموزش با فضای خروجی مدل از پیش آموزش دیده است. مدل پایه نسبی `Depth Anything V2`، مطابق با سنت روش‌های خانواده `MiDaS [۱۴]`، در فضای عمق معکوس (دیسپاریتی)^۲ آموزش دیده و خروجی آن با عمق رابطه وارون دارد: نقاط نزدیک مقادیر بزرگ و نقاط دور مقادیر کوچک دریافت می‌کنند.

در نسخه اولیه زیرساخت آموزش این پژوهش، مقادیر عمق مستقیم به عنوان هدف آموزشی مدل نسبی به کار می‌رفت. تحلیل دقیق این تنظیم نشان داد که ترکیب آن با تابع هزینه تغییرناپذیر نسبت به مقیاس و جابجایی، به یک شکست خاموش^۳ منجر می‌شود: از یک سو، محدودسازی ضریب مقیاس s به مقادیر مثبت در پیاده‌سازی

^۱Gradient Clipping

^۲Inverse Depth / Disparity

^۳Silent Failure

تابع هزینه، برازش رابطه وارون میان خروجی دیسپاریتی و هدف عمق مستقیم را ناممکن می‌سازد؛ و از سوی دیگر، مؤلفه تطابق گرادیان که بر روی مقادیر تراز نشده محاسبه می‌شود، دامنه خروجی مدل را به شدت به سمت صفر سوق می‌دهد. برآیند این دو عامل آن است که بهینه عملی تابع هزینه، خروجی ثابت صفر است و تابع فعال‌سازی ReLU در انتهای سر شبکه، این حالت را برگشت‌ناپذیر می‌کند (گرادیان صفر). آزمایش کنترل‌شده ابزارگذاری شده نشان داد که مدل ViT-L تنها در حدود ۱۸ گام آموزشی به‌طور کامل به این حالت فرو می‌ریزد؛ این در حالی است که منحنی هزینه آموزش ظاهری کاملاً طبیعی دارد، زیرا با خروجی ثابت، مقدار هزینه صرفاً تابع آماره‌های داده در هر دسته است. جزئیات تجربی این پدیده و فرآیند تشخیص آن در فصل چهارم گزارش شده است.

بر این اساس، در چارچوب نهایی آموزش، هدف مدل‌های نسبی به فضای عمق معکوس منتقل شد:

$$T_{\text{disp}} = \frac{1}{\max(DGT, d_{\min})}, \quad (11.3)$$

که در آن $d_{\min}$ کران پایین عمق معتبر است. با این تغییر، فضای هدف با فضای خروجی مدل ازپیش آموزش دیده هم‌راستا شده و فرآیند فاین‌تیون بدون فروریزش و با پایداری کامل انجام می‌گیرد. متناظر با آن، ارزیابی اعتبارسنجی حین آموزش نیز با ترازکردن مقیاس و جابجایی در فضای عمق معکوس و سپس وارون‌سازی به فضای عمق انجام می‌شود و نوع فضای هدف در فراداده‌های ذخیره‌شده هر نقطه واریسی^۱ ثبت می‌گردد تا زنجیره ارزیابی به‌صورت خودکار رفتار صحیح را اتخاذ کند.

۷.۷.۳ افزونه‌سازی هندسی آگاه از پارامترهای دوربین

چالش بنیادی در آموزش مدل آگاه از پارامترهای دوربین بر روی یک مجموعه داده تک‌دوربین (نظیر NYUv2 که تمامی تصاویر آن با یک حسگر Kinect ثبت شده‌اند) آن است که بردار k برای تمامی نمونه‌ها ثابت است و در نتیجه هیچ سیگنال تمایزبخشی برای واحد کدگذار دوربین فراهم نمی‌کند. افزون بر این، بررسی زیرساخت اولیه آموزش نشان داد که برش تصادفی^۲ متداول در خط لوله پیش‌پردازش، مرکز تصویر مؤثر را جابه‌جا می‌کند بدون آنکه ماتریس K متناظراً به‌روزرسانی شود؛ در نتیجه، کدگذار دوربین در عمل اطلاعاتی ثابت و از منظر هندسی نادرست دریافت می‌کرد.

برای رفع هم‌زمان هر دو مشکل، در این پژوهش یک راهبرد افزونه‌سازی هندسی دقیق طراحی و پیاده‌سازی

^۱Checkpoint

^۲Random Crop

شد که در آن، برای هر نمونه آموزشی، پنجره‌ای تصادفی با نسبت ابعادی ثابت ۳:۴ و ضریب بزرگ‌نمایی s (در بازه ۱ تا حداکثر ۷/۱ یا ۲/۲ بسته به تنظیم آزمایش، و با احتمال ۲۰ درصد دقیقاً قاب کامل) از تصویر بریده می‌شود و ماتریس K به صورت دقیق در تمامی مراحل هندسی به‌روزرسانی می‌گردد: جابه‌جایی نقطه اصلی متناسب با مبدأ پنجره برش،

$$c'_x = c_x - x_0, \quad c'_y = c_y - y_0, \quad (12.3)$$

و مقیاس‌دهی فاصله کانونی و نقطه اصلی متناسب با تغییر اندازه پنجره به چارچوب ثابت ورودی شبکه:

$$\begin{aligned} f'_x &= f_x \frac{W_{\text{net}}}{w_{\text{win}}}, & c'_x &= (c_x - x_0) \frac{W_{\text{net}}}{w_{\text{win}}}, \\ f'_y &= f_y \frac{H_{\text{net}}}{h_{\text{win}}}, & c'_y &= (c_y - y_0) \frac{H_{\text{net}}}{h_{\text{win}}}. \end{aligned} \quad (13.3)$$

که در آن $(H_{\text{net}}, W_{\text{net}})$ ابعاد ثابت چارچوب ورودی شبکه (در پیاده‌سازی حاضر 686×518 ، مضرب اندازه وصله‌های ترنسفورمر) است. مقادیر عمق در این تبدیل تغییر نمی‌کنند، زیرا نقاط صحنه همان نقاط پیشین هستند.

وارونه‌سازی افقی نیز هم‌زمان بر تصویر، نگاشت عمق، ماسک اعتبار و ماتریس مشخصه اعمال می‌شود. در این حالت، مختصه افقی نقطه اصلی مطابق $c'_x = W - c_x$ اصلاح می‌گردد. همچنین ابعاد چارچوبی که K در آن تعریف شده است همراه هر نمونه نگهداری می‌شود تا نرمال‌سازی مؤلفه‌های دوربین در آموزش و استنتاج دقیقاً در یک دستگاه مختصات انجام شود. این کنترل‌ها ضروری‌اند، زیرا تغییر تصویر بدون تبدیل متناظر K ، حتی در صورت اجرای بی‌خطای برنامه، ورودی هندسی ناسازگار تولید می‌کند.

از منظر هندسی، این افزونه‌سازی معادل شبیه‌سازی دوربین‌هایی با میدان دید متفاوت از یک صحنه واحد است: بزرگ‌نمایی s میدان دید مؤثر را از حدود ۶۳ درجه (قاب کامل NYUV2) تا حدود ۳۳ درجه تغییر می‌دهد. بدین ترتیب، مدل آگاه از پارامترهای دوربین در طول آموزش با زوج‌های (K, s) مواجه می‌شود که در آن‌ها ابهام میان مقیاس صحنه و میدان دید به صورت واقعی وجود دارد و تنها از طریق اطلاعات K قابل رفع است؛ در حالی که مدل کنترل بدون پارامترهای دوربین، دقیقاً همین تصاویر افزونه‌سازی شده را بدون اطلاعات K دریافت می‌کند. این طراحی، مبنای مطالعه کنترل‌شده فصل چهارم برای سنجش سهم واقعی پارامترهای درونی دوربین است.

۸.۷.۳ افزونه‌سازی لرزش کانونی: غیرقابل حل کردن مقیاس بدون K

افزونه‌سازی زوم‌برش زیربخش قبل، میدان دید را متنوع می‌کند، اما یک محدودیت بنیادی دارد: در تصاویر معمولی، نشانه‌های معنایی صحنه (ابعاد آشنای اشیاء، مبلمان، درها) به‌تنهایی برای بازیابی مقیاس تقریبی کافی‌اند و شبکه می‌تواند بدون مراجعه به K نیز پاسخ قابل قبولی بدهد. برای آنکه اتکای مدل به پارامترهای درونی دوربین به یک ضرورت تبدیل شود، در این پژوهش افزونه‌سازی مکملی با عنوان «لرزش کانونی»^۱ طراحی شد که مستقیماً از معادله تصویربرداری روزنه‌ای الهام می‌گیرد. طبق این معادله، $u = f \cdot X/Z$ ، اگر فاصله کانونی در ضریب α و هم‌زمان تمام عمق‌های صحنه نیز در همان α ضرب شوند، تصویر حاصل دقیقاً یکسان باقی می‌ماند. بر همین اساس، برای هر نمونه آموزشی ضریبی به‌صورت لگاریتمی-یکنواخت از بازه

$$\alpha \sim \exp(\mathcal{U}(-\ln m, +\ln m)), \quad m = 1/6, \quad (14.3)$$

نمونه‌برداری شده و تبدیل

$$f_x \mapsto \alpha f_x, \quad f_y \mapsto \alpha f_y, \quad Z \mapsto \alpha Z \quad (15.3)$$

اعمال می‌شود؛ پیکسل‌های تصویر و مختصات نقطه اصلی (c_x, c_y) دست‌نخورده می‌مانند. این تبدیل از منظر هندسی دقیق است (برخلاف بازنمونه‌برداری، هیچ خطای درونیابی ایجاد نمی‌کند) و هیچ نشی اطلاعاتی ندارد، زیرا تصویر ورودی تغییری نمی‌کند.

پیامد این طراحی برای دو بازوی مطالعه کنترل‌شده متقارن نیست: مدل بدون K با تصاویری مواجه می‌شود که پیکسل‌های یکسان دارند اما برچسب‌های عمق متناقض؛ بهترین کاری که از آن برمی‌آید رگرسیون به میانگین توزیع α است و بخشی از خطا برای آن کاهش ناپذیر می‌شود. در مقابل، مدل آگاه از K می‌تواند α را مستقیماً از مقدار فاصله کانونی بخواند و ابهام را به‌طور کامل رفع کند. به بیان دیگر، لرزش کانونی مسئله بازیابی مقیاس را برای مدل کور نسبت به دوربین به مسئله‌ای بدساخت^۲ تبدیل می‌کند و بدین ترتیب فشار آموزشی صریحی برای بهره‌گیری از ورودی K ایجاد می‌نماید.

دو نکته پیاده‌سازی اهمیت اساسی دارد. نخست، ماسک اعتبار پیکسل‌ها ویژگی حسگر و متعلق به عمق مقیاس نشده است؛ بنابراین آستانه سقف عمق در ماسک نیز باید در α ضرب شود، وگرنه دقیقاً نقاط دوری که α در آن‌ها بیشترین اطلاعات را دارد از آموزش حذف می‌شوند. دوم، برای آنکه مقایسه زوجی مدل پیشنهادی

¹Focal Jitter

²Ill-posed

و کنترل کاملاً منصفانه باشد، سازوکار قفل بذر تصادفی^۱ به زیرساخت آموزش افزوده شد که ترتیب داده‌ها، وارونه‌سازی‌های افقی، پنجره‌های زوم‌برش و نمونه‌های α را میان دو اجرا یکسان می‌کند؛ صحت این سازوکار با برابری بیت‌به‌بیت مقدار تابع هزینه در گام صفر هر دو بازو راستی‌آزمایی شد. همچنین در آزمایش متناظر، ضریب λ در تابع هزینه SiLog (بخش ۳-۸) از $5/0$ به $3/0$ کاهش یافت تا مؤلفه خطای مقیاس سراسری — که دقیقاً همان اطلاعاتی است که K فراهم می‌کند — کمتر بخشوده شود.

۹.۷.۳ استفاده از تقطیر دانش

زیرساخت آموزش برای بررسی تقطیر دانش به‌عنوان یک قید نظارتی ضعیف توسعه یافته است. در این طرح اختیاری، مدل غیرمتریک Depth Anything V2 نقش معلم را دارد و پارامترهای `--use-distillation` و `--teacher-checkpoint` بارگذاری معلم را کنترل می‌کنند. این مسیر در مرحله‌های اکتشافی در نظر گرفته شد، اما جزئی از دستورالعمل نهایی تولید نتایج فصل چهارم نیست.

شایان ذکر است که در مجموعه آزمایش‌های نهایی گزارش‌شده در فصل چهارم، به‌منظور جداسازی دقیق اثر پارامترهای درونی دوربین از سایر عوامل، سازوکار تقطیر دانش غیرفعال بوده و آموزش هر دو مدل (پیشنهادی و کنترل) صرفاً با نظارت مستقیم بر مبنای نقشه‌های عمق مرجع انجام شده است. قابلیت تقطیر دانش به‌عنوان بخشی از زیرساخت پیاده‌سازی حفظ شده و می‌تواند در پژوهش‌های آتی به‌کار گرفته شود.

۱۰.۷.۳ جمع‌بندی فرآیند آموزش

در مجموع، راهبرد نهایی بر فاین‌تیون نظارتی و کنترل‌شده یک مدل قدرتمند از پیش‌آموزش‌یافته، فریزکردن انکودر، آموزش سر عمق و کدگذار دوربین، و زوج‌سازی کامل مدل پیشنهادی با کنترل فاقد K استوار است. تقطیر دانش در اجرای نهایی غیرفعال ماند تا اثر پارامترهای دوربین از سایر سیگنال‌های آموزشی جدا شود. در بخش بعدی، توابع هزینه مورد استفاده در این فرآیند آموزش و نقش هر یک در هدایت مدل به‌سوی تخمین عمق متریک دقیق، به‌صورت رسمی و ریاضی تشریح خواهد شد.

¹Seed Locking

الگوریتم ۱.۳: روند آموزش مدل با پارامترهای هندسی

- ورودی:** مجموعه داده آموزش $\{(I_i, K_i, D_i^{GT})\}_{i=1}^N$ ، مدل پایه با وزنهای θ_{enc} (فریز شده)، θ_{dec} (قابل آموزش)، θ_{cam} (شبکه کدگذار دوربین)
- خروجی:** مدل نهایی آموزش دیده
- ۱: برای هر epoch از آموزش انجام بده
 - ۲: برای هر دسته داده (batch) از D انجام بده
 - ۳: تصویر $I \leftarrow$
 - ۴: ماتریس درونی دوربین $K \leftarrow$
 - ۵: نقشه عمق مرجع $D^{GT} \leftarrow$
 - ۶: {پیش پردازش و کدگذاری پارامترهای دوربین}
 - ۷: $\mathbf{k} \leftarrow (K, W, H)$ نرمال سازی
 - ۸: $\mathbf{z}_k \leftarrow MLP(\mathbf{k}, \theta_{cam})$
 - ۹: {استخراج ویژگی های بصری با تزریق توکن دوربین در انکودر}
 - ۱۰: $F \leftarrow Encoder(I, \mathbf{z}_k, \theta_{enc})$
 - ۱۱: {تخمین عمق}
 - ۱۲: $D^{pred} \leftarrow Decoder(F, \theta_{dec})$
 - ۱۳: {محاسبه تابع هزینه متریک}
 - ۱۴: $\mathcal{L} \leftarrow \mathcal{L}_{SiLog}(D^{pred}, D^{GT})$
 - ۱۵: {بهروزرسانی وزن ها}
 - ۱۶: $\theta_{dec}, \theta_{cam} \leftarrow Optimizer.step(\nabla \mathcal{L})$
 - ۱۷: پایان حلقه برای
 - ۱۸: پایان حلقه برای
-

۸.۳ توابع هزینه و معیارهای بهینه‌سازی

طراحی تابع هزینه در مسئله تخمین عمق تک‌دوربین، نقش تعیین‌کننده‌ای در نوع اطلاعاتی دارد که مدل در فرآیند آموزش فرا می‌گیرد. از آنجا که هدف این پژوهش، دستیابی به تخمین عمق متریک پایدار و ناوابسته به تغییر پارامترهای درونی دوربین است، انتخاب تابع هزینه به گونه‌ای انجام شده که مدل بتواند مقیاس مطلق عمق را یاد بگیرد و در عین حال نسبت به تغییرات پارامترهای دوربین پایدار باشد.

در این پژوهش، بسته به نوع مدل (متریک یا نسبی)، از توابع هزینه مناسبی استفاده شده است که در ادامه تشریح می‌شوند.

۱.۸.۳ هزینه SiLog برای مدل‌های متریک

برای آموزش مدل متریک که هدف آن تولید تخمین عمق مطلق بر حسب متر است، از تابع هزینه لگاریتمی تغییرناپذیر نسبت به مقیاس^۱ استفاده می‌شود. این تابع هزینه که به اختصار SiLog نامیده می‌شود، به گونه‌ای طراحی شده که به جای تفاوت مستقیم مقادیر عمق، بر تفاوت لگاریتمی آن‌ها تمرکز دارد:

$$\mathcal{L}_{\text{SiLog}} = \sqrt{\frac{1}{N} \sum_{i=1}^N d_i^2 - \frac{\lambda}{N^2} \left(\sum_{i=1}^N d_i \right)^2}, \quad (16.3)$$

که در آن N تعداد پیکسل‌های دارای برچسب معتبر، $d_i = \log D_i^{GT} - \log D_i^{pred}$ تفاوت لگاریتمی بین مقدار واقعی و مقدار پیش‌بینی شده در پیکسل i -ام است. ضریب λ معمولاً برابر ۰/۵ در نظر گرفته می‌شود تا تعادلی بین خطای مطلق و خطای نسبی برقرار گردد.

ویژگی مهم SiLog آن است که ضمن حفظ حساسیت به مقیاس مطلق عمق، باعث می‌شود خطا در فواصل دور و نزدیک به صورت متعادل‌تری در نظر گرفته شود. استفاده از فضای لگاریتمی، مدل را نسبت به خطاهای بزرگ در عمق‌های دور مقاوم‌تر می‌کند و از تمرکز بیش از حد بر خطاهای نقطه‌ای بسیار بزرگ جلوگیری می‌نماید.

¹Scale-Invariant Logarithmic Loss

۲.۸.۳ هزینه تغییرناپذیر نسبت به مقیاس و جابجایی برای مدل‌های نسبی

برای آموزش مدل در حالت نسبی (basic mode) که خروجی آن دارای ابهام مقیاس است، از تابع هزینه تغییرناپذیر نسبت به مقیاس و جابجایی^۱ استفاده می‌شود. این تابع هزینه ابتدا پیش‌بینی مدل را با استفاده از روش کمترین مربعات بر مقدار واقعی منطبق می‌کند:

$$D_{pred}^* = s \cdot D_{pred} + t, \quad (۱۷.۳)$$

که در آن s و t مقیاس و جابجایی بهینه هستند که به صورت تحلیلی از طریق کمینه‌سازی خطای پیکسل به-پیکسل محاسبه می‌شوند. تابع هزینه نهایی ترکیبی از خطای مطلق پیکسل‌ها (L_1) و خطای تطابق گرادیان است:

$$\mathcal{L}_{SSI} = (1 - \alpha)\mathcal{L}_{pixel} + \alpha\mathcal{L}_{grad}, \quad (۱۸.۳)$$

که در آن $\mathcal{L}_{pixel}$ خطای L_1 میان تخمین منطبق‌شده و عمق واقعی است و $\mathcal{L}_{grad}$ خطای تطابق گرادیان در چند مقیاس را اندازه می‌گیرد. پارامتر α (معمولاً 0.5) وزن نسبی این دو مؤلفه را تعیین می‌کند. هزینه گرادیان باعث می‌شود که لبه‌های عمق و ناپیوستگی‌ها در تصویر با دقت بیشتری بازسازی شوند.

۳.۸.۳ تمایز میان توابع هزینه آموزش و معیارهای ارزیابی

نکته‌ای حائز اهمیت در این پژوهش، تمایز آگاهانه میان توابع هزینه مورد استفاده در آموزش و معیارهای به‌کاررفته در ارزیابی مدل است. این تمایز از آن جهت ضروری است که اهداف آموزش و ارزیابی لزوماً یکسان نیستند.

۱.۳.۸.۳ توابع هزینه در آموزش

در مرحله آموزش:

¹Scale-Shift Invariant Loss

- برای مدل‌های متریک از **SiLog** استفاده می‌شود
- برای مدل‌های نسبی از **Loss Invariant Scale-Shift** استفاده می‌شود

۲.۳.۸.۳ معیارهای ارزیابی

در مرحله ارزیابی، از معیارهای متنوع‌تری بسته به نوع مدل استفاده می‌شود:
برای مدل‌های متریک، از معیارهای استاندارد تخمین عمق استفاده می‌گردد:

- خطای مطلق نسبی: **(AbsRel)**

$$\text{AbsRel} = \frac{1}{N} \sum_{i=1}^N \frac{|D_i^{\text{pred}} - D_i^{\text{GT}}|}{D_i^{\text{GT}}} \quad (۱۹.۳)$$

- **RMSE:**

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (D_i^{\text{pred}} - D_i^{\text{GT}})^2} \quad (۲۰.۳)$$

- معیارهای دقت آستانه‌ای (δ_i): درصد پیکسل‌هایی که $\max \left(\frac{D^{\text{pred}}}{D^{\text{GT}}}, \frac{D^{\text{GT}}}{D^{\text{pred}}} \right) < 1.25^i$ برای $i \in \{1, 2, 3\}$

برای مدل‌های نسبی که دارای ابهام مقیاس هستند، ابتدا یک تراز مقیاس (معمولاً از طریق میانه) اعمال شده و سپس معیارهای فوق محاسبه می‌شوند. همچنین معیار SiLog که ذاتاً تغییرناپذیر نسبت به مقیاس است، برای مقایسه این نوع مدل‌ها مناسب‌تر است.

۴.۸.۳ نقش پارامترهای درونی دوربین در آموزش

نقش ماتریس مشخصه دوربین در این چارچوب، نه از طریق افزودن یک مؤلفه مستقیم به تابع هزینه، بلکه از طریق تزریق اطلاعات هندسی به معماری مدل ایفا می‌شود. با در اختیار داشتن اطلاعات صریح پارامترهای درونی، مدل قادر است تخمین‌های متریک خود را با هندسه واقعی تصویربرداری تطبیق دهد.

در مدل پیشنهادی، پارامترهای درونی دوربین از طریق یک واحد کدگذار مجزا پردازش شده و به صورت توکن دوربین به لایه‌های میانی Transformer Vision تزریق می‌شوند. این اطلاعات به مدل امکان می‌دهد تا در فرآیند یادگیری، رابطه میان ویژگی‌های تصویری و مقیاس واقعی عمق را با در نظر گرفتن مشخصات هندسی دوربین یاد بگیرد.

به این ترتیب، تابع هزینه SiLog که ذاتاً به مقیاس مطلق عمق حساس است، می‌تواند به درستی مدل را برای تولید تخمین‌های متریک پایدار هدایت کند. این پایداری در مواجهه با داده‌هایی که تنها در پارامترهای درونی دوربین تفاوت دارند، در آزمایش‌های تجربی به وضوح مشاهده می‌شود.

۵.۸.۳ حساسیت RMSE به پارامترهای دوربین و کاربرد آن در ارزیابی

معیار RMSE که در این پژوهش برای ارزیابی مدل‌های متریک استفاده شده، به صورت مستقیم به مقیاس عمق وابسته است:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (D_i^{\text{pred}} - D_i^{\text{GT}})^2}. \quad (21.3)$$

این وابستگی باعث می‌شود RMSE نسبت به تغییر پارامترهای درونی دوربین، به ویژه فاصله کانونی، حساس باشد. این ویژگی، هرچند در نگاه اول یک محدودیت به نظر می‌رسد، اما در واقع ابزار مناسبی برای آشکارسازی ناپایداری متریک مدل‌های عمق محسوب می‌شود.

در این پژوهش، از این حساسیت به عنوان معیاری برای سنجش پایداری مدل استفاده شده است. مدلی که نسبت به تغییر پارامترهای دوربین پایدار باشد، باید تغییرات کمی در RMSE از خود نشان دهد، حتی زمانی که تصاویر با مشخصات هندسی متفاوت تصویربرداری شده باشند.

۶.۸.۳ جمع‌بندی

در این بخش، توابع هزینه مورد استفاده در آموزش مدل‌های متریک و نسبی تشریح شد. استفاده از SiLog برای مدل‌های متریک، ضمن حفظ حساسیت به مقیاس مطلق عمق، مدل را نسبت به خطاهای بزرگ مقاوم می‌کند. تزریق پارامترهای درونی دوربین به معماری مدل، امکان یادگیری رابطه صحیح میان ویژگی‌های تصویری

و عمق واقعی را فراهم می‌آورد. در فصل بعد، نتایج تجربی حاصل از این طراحی و تحلیل آماری پایداری مدل نسبت به تغییر مشخصات دوربین ارائه خواهد شد.

۹.۳ جزئیات پیاده‌سازی

در این بخش، جزئیات فنی مربوط به پیاده‌سازی مدل پیشنهادی، تنظیمات آموزش، پیش‌پردازش داده‌ها، ساختار کد و ملاحظات عملی لازم برای بازتولید نتایج ارائه می‌شود. هدف از این بخش، مستندسازی دقیق تمامی تصمیمات پیاده‌سازی است تا امکان تکرار آزمایش‌ها و تحلیل نتایج برای پژوهشگران دیگر فراهم شود.

۱.۹.۳ چارچوب نرم‌افزاری و زیرساخت محاسباتی

تمامی پیاده‌سازی‌ها در چارچوب PyTorch (نسخه 1.12 و بالاتر) انجام شده و کد پایه بر اساس مخزن رسمی Depth Anything V2 توسعه داده شده است. معماری کلی شامل یک انکودر مبتنی بر DINOv2 Vision Transformer و یک دیکودر از خانواده Dense Prediction Transformer (DPT) است. آموزش مدل‌ها بر روی پردازنده‌های گرافیکی NVIDIA با معماری Ampere یا جدیدتر انجام شده و تمامی آزمایش‌ها به صورت تک‌کارت گرافیک و با دقت ممیز شناور ۳۲ بیتی اجرا شده‌اند. برای تضمین تکرارپذیری، بذر تصادفی^۱ برای کتابخانه‌های NumPy، PyTorch و Python در ابتدای هر آزمایش ثابت (معمولاً بر روی مقدار ۴۲) تنظیم شده است.

۲.۹.۳ پیش‌پردازش داده‌ها

تمامی تصاویر ورودی پیش از ورود به شبکه، به صورت یکنواخت پیش‌پردازش می‌شوند. در تنظیم پایه، تصاویر با حفظ نسبت ابعاد به کران پایین ۵۱۸ پیکسل تغییر اندازه داده شده و سپس برش‌های تصادفی 518×518 برای یکسان‌سازی ابعاد دسته در مرحله آموزش اعمال می‌گردد؛ راهبردی مطابق با تنظیمات مدل پایه Depth Anything V2 [۱۱]. در آزمایش‌های نهایی مبتنی بر افزونه‌سازی هندسی (بخش ۷.۷.۳)، این برش تصادفی ساده ناآگاه از K کنار گذاشته شده و کل زنجیره برش و تغییر اندازه به صورت آگاه از پارامترهای دوربین و با

¹Random Seed

به روزرسانی دقیق ماتریس K انجام می‌شود؛ در این حالت، چارچوب ورودی شبکه به صورت ثابت 518×686 (قاب کامل ۳:۴ در کران پایین ۵۱۸ و مضرب ۱۴) انتخاب شده است.

مقادیر پیکسل تصاویر به بازه $[0, 1]$ نرمال‌سازی شده و سپس با استفاده از میانگین و واریانس داده‌های ImageNet استانداردسازی می‌شوند:

$$I_{norm} = \frac{I - \mu_{ImageNet}}{\sigma_{ImageNet}}, \quad (22.3)$$

که در آن $\mu_{ImageNet} = [0.485, 0.456, 0.406]$ و $\sigma_{ImageNet} = [0.229, 0.224, 0.225]$ هستند. این مرحله به‌ویژه برای سازگاری با وزن‌های از پیش‌آموزش‌دیده انکودر DINOv2 ضروری است.

۳.۹.۳ مدیریت و نرمال‌سازی پارامترهای درونی دوربین

برای هر تصویر ورودی، ماتریس مشخصه دوربین K استخراج شده و پارامترهای اصلی آن شامل فاصله کانونی در راستاهای افقی و عمودی (f_x, f_y) و مختصات نقطه اصلی (c_x, c_y) مورد استفاده قرار می‌گیرند. به منظور جلوگیری از ناپایداری عددی و تسهیل فرآیند یادگیری، این پارامترها پیش از ورود به شبکه نرمال‌سازی می‌شوند:

$$\tilde{f}_x = \frac{f_x}{W}, \quad \tilde{f}_y = \frac{f_y}{H}, \quad \tilde{c}_x = \frac{c_x}{W}, \quad \tilde{c}_y = \frac{c_y}{H}, \quad (23.3)$$

که در آن H و W به ترتیب عرض و ارتفاع تصویر ورودی هستند. بردار نهایی پارامترهای دوربین به صورت

$$\mathbf{k} = [\tilde{f}_x, \tilde{f}_y, \tilde{c}_x, \tilde{c}_y] \quad (24.3)$$

تعریف شده و همراه با مؤلفه‌های میدان دید و نسبت ابعاد (مطابق بخش ۳-۶)، یک بردار توصیف‌گر نه‌بعدی را تشکیل می‌دهد. این بردار از طریق یک شبکه تمام‌متصل دولایه (با تابع فعال‌سازی GELU) به فضایی هم‌بعد

با بازنمایی نهان انکودر (برای ViT-L برابر ۱۰۲۴) نگاشت شده و سپس توسط چهار بلوک ترنسفورمر پالایش می‌شود. خروجی این واحد، پس از اعمال دروازه خروجی صفرمقدار اولیه، به‌عنوان توکن دوربین z_k به دنباله توکن‌های انکودر تزریق می‌گردد.

۴.۹.۳ تنظیمات آموزش و راهبرد بهینه‌سازی

مدل پیشنهادی با استفاده از بهینه‌ساز AdamW [۲۷] آموزش داده شده است. نرخ یادگیری پایه برای انکودر DINOv2 برابر با $10^{-6} \times 5$ در نظر گرفته شده، در حالی که برای دیکودر و لایه‌های افزوده شده (شامل کدگذار دوربین و سر تخمین عمق)، از یک ضریب تقویتی (معمولاً 10^2 برابر) استفاده شده که نرخ یادگیری این بخش‌ها را به $10^{-5} \times 5$ می‌رساند.

پارامترهای بهینه‌ساز به‌صورت زیر تنظیم شده‌اند:

- ضرایب ممنتوم: $\beta_1 = 0.9$, $\beta_2 = 0.999$

- ضریب کاهش وزن (Weight Decay): 0.01

- پارامتر ϵ برای پایداری عددی: 10^{-8}

در راستای جلوگیری از بیش‌برازش و حفظ دانش از پیش‌آموخته‌شده، وزن‌های انکودر DINOv2 در طول آموزش فریز شده‌اند. این تنظیم، مطابق با گزینه پیش‌فرض freeze-dinov2-- در اسکریپت آموزش اعمال شده است. فریز کردن انکودر باعث می‌شود تنها لایه‌های سر شبکه^۱ و واحد کدگذار دوربین آموزش ببینند، که این امر از واگرایی نمایش‌های ویژگی جلوگیری کرده و همگرایی سریع‌تر را تضمین می‌کند.

برای زمان‌بندی نرخ یادگیری، از یک استراتژی ترکیبی شامل warmup خطی در ابتدای آموزش و سپس کاهش چندجمله‌ای (Polynomial Decay) با توان 0.9 استفاده شده است. تعداد دوره‌های آموزش معمولاً بین ۲۰ تا ۴۰ epoch بوده و اندازه دسته بسته به حافظه موجود بین ۲ تا ۸ تنظیم شده است. در صورت محدودیت حافظه، از تجمع گرادیان^۲ برای افزایش اندازه دسته مؤثر استفاده شده است.

¹Head Layers

²Gradient Accumulation

۵.۹.۳ دیتاست‌های مورد استفاده در پیاده‌سازی

پیاده‌سازی مدل بر روی مجموعه‌ای متنوع از دیتاست‌های داخلی و خارجی انجام شده است که شامل صحنه‌های indoor و outdoor با مشخصات تصویربرداری متفاوت هستند. از جمله دیتاست‌های مورد استفاده می‌توان به موارد زیر اشاره کرد:

- **VKITTI2**: دیتاست شبیه‌سازی شده برای صحنه‌های رانندگی با truth ground دقیق عمق و پارامترهای دوربین

- **KITTI**: دیتاست واقعی رانندگی خودکار با اطلاعات عمق از لایدار

- **NYUv2**: دیتاست صحنه‌های داخلی با عمق حاصل از سنسور Kinect

- **Hypersim**: دیتاست سنتتیک با تنوع بالا در صحنه‌های داخلی و کنترل کامل بر پارامترهای دوربین

این تنوع داده در مرحله اکتشافی برای سنجش پایداری بین‌دیتاستی به کار رفت. قالب دقیق فهرست و کالبراسیون به مجموعه داده وابسته است: پارامترها ممکن است در فایل `.npz`، فایل متنی کالبراسیون یا مستندات رسمی مجموعه داده موجود باشند. مطالعه کنترل شده نهایی، همان گونه که پیش تر بیان شد، تنها از تقسیم بدون نشت NYUv2 استفاده می‌کند.

۶.۹.۳ ساختار کد و اسکرپت‌های اصلی

ساختار کد به گونه‌ای طراحی شده که اجزای اصلی شامل ماژول‌های بارگذاری داده، تعریف مدل، آموزش و ارزیابی به صورت مجزا پیاده‌سازی شوند. ساختار کلی پروژه به شرح زیر است:

```
project_root/
|-- models/
|   |-- raw_models/
|   |   |-- DepthAnythingV2/
|   |   |-- DepthAnythingV2-revised/
|   |   |-- Depth-Anything-3/
|   |-- base.py
```

```
|-- datasets/
|   |-- base.py
|   `-- training_datasets.py
|-- src/
|   |-- pipeline.py
|   |-- metrics.py
|   `-- visualization.py
|-- train.py
|-- evaluate.py
`-- compare_models.py
```

اسکرپت `train.py` مسئول اجرای فرآیند آموزش بوده و از طریق آرگومان‌های ورودی، امکان تنظیم پارامترهای زیر را فراهم می‌کند:

- `--use-camera-intrinsics`: فعال‌سازی استفاده از پارامترهای دوربین
 - `--model-type`: انتخاب نوع مدل (basic یا metric)
 - `--encoder`: انتخاب اندازه انکودر (vits, vitb, vitl, vitg)
 - `--use-distillation`: فعال‌سازی تقطیر دانش
 - `--freeze-dinov2`: فریز کردن وزن‌های انکودر
 - `--focal-jitter` و `--silog-lambda`: تنظیم لرنش کانونی و ضریب مقیاس در هزینه SiLog
 - `--seed`: قفل کردن ترتیب داده و جریان‌های تصادفی برای زوج‌های کنترل‌شده
 - `--accumulate-grad`: تجمع گرادیان برای دستیابی به اندازه دسته مؤثر بزرگ‌تر
- علاوه بر اسکرپت آموزش، ابزارهای اصلی به شرح زیر هستند:
- `evaluate_paper.py` برای بازتولید پروتکل ارزیابی مقاله؛
 - `tools/paired_stats.py` برای آزمون زوجی، ویلکاکسون و بوت‌استرپ ده‌هزارباره؛

• `tools/k_sweep.py` و `tools/k_knockout.py` برای آزمون‌های سازوکاری و علی؛

• `tools/eval_fov_varied.py` برای سنجش تعمیم به میدان دیدهای متفاوت.

صحت تبدیل لرزش کانونی، منطق ماسک اعتبار و اعتبارسنجی آرگومان‌ها نیز با ده آزمون واحد در فایل `tests/test_focal_jitter.py` پوشش داده شده است.

دستورالعمل مدل نهایی فروکاست — مدلی که قوی‌ترین شاهد استفاده از K را با $\lambda = 0.5$ ارائه می‌کند — به صورت زیر است. برای بازوی کنترل، دو گزینه پایانی با `--model-variant base` جایگزین می‌شوند؛ سایر آرگومان‌ها بدون تغییر می‌مانند.

```
python train.py --encoder vitl --datasets nyu --model-type metric \
  --min-depth 0.001 --max-depth 20 --epochs 40 --bs 2 \
  --accumulate-grad 2 --lr 5e-6 --freeze-dinov2 \
  --head-lr-multiplier 10 --grad-clip 1 --focal-jitter 1.6 \
  --silog-lambda 0.5 --seed 42 --pretrained-from <basic_vitl.pth> \
  --save-path <output_dir> --model-variant revised \
  --use-camera-intrinsics
```

این مدل با AbsRel برابر 0.834 و شیب جاروی K برابر 0.3 ± 0.97 ، بهترین مدل دارای لرزش کانونی است. اگر تنها کمینه کردن خطای خام روی هندسه استاندارد NYUv2 هدف باشد، مدل متریک دور نخست بدون لرزش کانونی با AbsRel برابر 0.791 بهتر است؛ اما برای ادعای اصلی پایان‌نامه درباره مصرف علی K ، مدل فروکاست نهایی انتخاب مناسب‌تری است.

۷.۹.۳ ملاحظات عملی و محدودیت‌ها

در پیاده‌سازی عملی، برخی محدودیت‌ها و چالش‌ها شناسایی و مدیریت شده‌اند:

- **محدودیت حافظه GPU:** با توجه به حجم بالای مدل‌های Vision، Transformer، از تجمع گرادیان استفاده شده است. به طور مشخص، آموزش ViT-L در چارچوب ورودی 686×518 با اندازه دسته ۴ از حافظه ۲۴ گیگابایتی کارت گرافیک فراتر می‌رفت؛ از این رو، اندازه دسته ۲ همراه با تجمع گرادیان با گام ۲ (اندازه دسته مؤثر ۴) به کار گرفته شد.

- **عدم دسترسی به پارامترهای دقیق دوربین:** برای برخی دیتاست‌ها، پارامترهای دوربین از روی اطلاعات EXIF تصاویر یا مستندات دیتاست استخراج یا تخمین زده شده است. در مواردی که اطلاعات دقیق در دسترس نبوده، از مقادیر نموذج (مانند $f = W$ برای تصاویر با FoV استاندارد) استفاده شده است.
- **تنوع در کیفیت truth: ground** دیتاست‌های مختلف دارای سطوح متفاوتی از دقت در نقشه‌های عمق مرجع هستند. برای رفع این مسئله، در فرآیند ارزیابی از masking برای حذف پیکسل‌های نامعتبر استفاده شده است. در ارزیابی استاندارد NYUv2، مطابق پروتکل مرجع، از نقشه‌های عمق خام ثبت شده^۱ (و نه نسخه‌های درونیابی شده) به عنوان مرجع استفاده شده است.
- **تکرارپذیری و استنباط آماری:** علی‌رغم ثابت نگه داشتن بذره‌های تصادفی، برخی عملیات GPU ذاتاً غیرقطعی هستند. برای استنباط آماری معتبر، به جای اتکا به مقایسه میانگین‌های کل، از آزمون‌های زوجی در سطح تک‌تصویر (آزمون t زوجی و آزمون علامت‌دار ویلکاکسون بر روی ۶۵۴ تصویر آزمون) به همراه بازه‌های اطمینان بوت‌استرپ استفاده شده است. آموزش با چند بذر مستقل تکرار نشده است؛ از این رو، برآورد و گزارش انحراف معیار میان اجراها یکی از محدودیت‌ها و پیشنهادهای پژوهش آینده است.

۸.۹.۳ اشکال‌زدایی و درس‌های پیاده‌سازی

در مسیر رسیدن به پیکربندی نهایی، سه اشکال اساسی در زنجیره آموزش و ارزیابی شناسایی، ریشه‌یابی و برطرف شد که مستندسازی آن‌ها هم برای تکرارپذیری پژوهش و هم به عنوان درس‌های روش‌شناختی حائز اهمیت است:

۱. **ناهم‌خوانی فضای هدف و فروریزش خاموش سر شبکه:** همان‌گونه که در بخش ۶.۷.۳ تشریح شد، آموزش مدل نسبی با هدف عمق مستقیم، به فروریزش خروجی به مقدار ثابت صفر منجر می‌شد؛ شکستی که در منحنی هزینه آموزش قابل مشاهده نبود و تنها از طریق پایش معیارهای اعتبارسنجی (که در مقداری ثابت منجمد می‌شدند) و سپس بازتولید کنترل‌شده گام‌به‌گام با ثبت آماره‌های خروجی و گرادیان در هر گام، ریشه‌یابی شد. راه‌حل، انتقال هدف آموزش به فضای عمق معکوس بود.

۲. **به‌روزشدن ماتریس K در افزونه‌سازی داده:** برش تصادفی متداول، نقطه اصلی مؤثر تصویر را تغییر می‌داد بدون آنکه K اصلاح شود؛ در نتیجه کدگذار دوربین ورودی هندسی نادرست دریافت می‌کرد.

¹Raw Depth

راه حل، طراحی زنجیره افزونه سازی هندسی دقیق (بخش ۷.۷.۳) بود که صحت آن با راستی آزمایی عددی میدان دید نمونه های تولیدی تأیید شد.

۳. **ناهم خوانی معماری سر شبکه در ارزیابی مدل های متریک:** نقاط واریسی متریک آموزش دیده در این پژوهش دارای سر خروجی مبتنی بر ReLU هستند، در حالی که بارگذار ارزیابی، به طور پیش فرض معماری سر سیگموئیدی ضرب در عمق-بیشینه نقاط واریسی رسمی را می ساخت. از آنجا که نام و ابعاد پارامترها در هر دو معماری یکسان است، بارگذاری وزن ها بدون هیچ خطایی انجام می شد اما خروجی عمق حدود چهار برابر بیش برآورد می گردید (AbsRel) ظاهری حدود $97/2$ در برابر مقدار صحیح نزدیک 0.08 . راه حل، ثبت نشانگر `from_train_py` در فراداده نقطه واریسی و انتخاب خودکار معماری صحیح در زمان ارزیابی بود.

درس مشترک هر سه مورد آن است که در زنجیره های یادگیری عمیق، شکست ها می توانند کاملاً خاموش باشند: منحنی هزینه طبیعی به نظر می رسد، بارگذاری وزن ها بدون خطا انجام می شود، و تنها راستی آزمایی های مستقل انتها-به-انتها (بازتولید نتایج مرجع منتشر شده، پایش انجماد معیارهای اعتبارسنجی، و بررسی آماره های خروجی مدل) قادر به آشکارسازی آن ها هستند. بر همین اساس، پیش از اجرای آزمایش های اصلی، صحت کل زنجیره ارزیابی این پژوهش از طریق بازتولید نتایج گزارش شده مقاله Depth Anything V2 روی پروتکل استاندارد راستی آزمایی شد (فصل چهارم).

۹.۹.۳ جمع بندی

در این بخش، جزئیات پیاده سازی مدل پیشنهادی شامل چارچوب نرم افزاری، پیش پردازش داده ها، مدیریت پارامترهای درونی دورین، تنظیمات آموزش، دیتاست های مورد استفاده و ساختار کد تشریح شد. این توضیحات، مبنای فنی لازم برای درک و تحلیل نتایج تجربی ارائه شده در فصل بعد را فراهم می کنند و امکان بازتولید آزمایش ها توسط سایر پژوهشگران را تسهیل می نمایند.

۱۰.۳ جمع بندی فصل

در این فصل، چارچوب روش شناختی پژوهش حاضر برای استفاده از یک مدل بنیادین تخمین عمق تک دورینه و فاین تیون نظارتی آن با هدف دستیابی به عمق متریک پایدار ارائه شد. تمرکز اصلی فصل بر تحلیل

نقش هندسهٔ تصویربرداری و به‌ویژه ماتریس مشخصهٔ دوربین در فرآیند یادگیری عمق، و ارائهٔ یک راهکار عملی برای ادغام صریح این اطلاعات در مدل بود.

در ابتدا، مسئلهٔ تخمین عمق به‌صورت یک نگاشت تابعی از تصویر ورودی و پارامترهای درونی دوربین صورت‌بندی شد و تفاوت مفهومی میان عمق غیرمتریک و عمق متریک مورد بررسی قرار گرفت. نشان داده شد که در غیاب اطلاعات هندسی دوربین، مدل‌های تک‌دوربینه—حتی در صورت عملکرد مناسب از منظر معیارهای نرمال‌شده—قادر به تولید تخمین‌هایی با مقیاس فیزیکی پایدار نیستند.

سپس، با تکیه بر مدل هندسی سوراخ‌سوزنی، نقش پارامترهای فاصلهٔ کانونی و نقطهٔ اصلی تصویر در تبدیل مختصات تصویری به عمق متریک تشریح شد. این تحلیل هندسی، مبنای نظری لازم برای انگیزه‌بخشی به روش پیشنهادی را فراهم کرد و روشن ساخت که نادیده گرفتن ماتریس مشخصهٔ دوربین می‌تواند به ناپایداری قابل توجه در معیارهای حساس به مقیاس، به‌ویژه RMSE، منجر شود.

در ادامه، معماری پایهٔ Depth Anything V2 به‌عنوان یک مدل بنیادین قدرتمند در تخمین عمق تک‌تصویری معرفی شد. این معماری، با وجود تعمیم‌پذیری بالا در سناریوهای صفرنمونه، ذاتاً برای تولید عمق غیرمتریک طراحی شده است. بر همین اساس، روش پیشنهادی این پژوهش بر افزودن یک مسیر صریح برای پردازش پارامترهای درونی دوربین و ادغام آن‌ها به‌صورت توکن دوربین در دنبالهٔ توکن‌های انکودر متمرکز شد، به‌گونه‌ای که اطلاعات هندسی از اطلاعات صرفاً تصویری تفکیک شده و از طریق سازوکار توجه، به‌صورت کنترل‌شده در فرآیند استنتاج عمق وارد شوند.

راهبرد پیشنهادی شامل نرمال‌سازی پارامترهای ماتریس مشخصهٔ دوربین، نگاشت آن‌ها به یک توکن نهان، و تزریق دروازه‌بانی‌شدهٔ این بازنمایی هندسی به انکودر مدل بود. این طراحی، به‌واسطهٔ دروازهٔ خروجی صفرمقدار اولیه، بدون ایجاد اختلال در رفتار اولیهٔ انکودر ازپیش‌آموزش‌دیده، امکان یادگیری تدریجی وابستگی‌های متریک را فراهم می‌کند. در آزمایش‌های نهایی، آموزش با نگاشت عمق مرجع و بدون تقطیر انجام شد تا سهم خالص K در مقایسه با کنترل هم‌داده قابل اندازه‌گیری باشد.

در بخش‌های پایانی فصل، توابع هزینه، معیارهای ارزیابی و جزئیات پیاده‌سازی به‌صورت کامل تشریح شدند. تمایز میان معیارهای نرمال‌شده مانند AbsRel و SiLog، در مقابل معیارهای حساس به واحد فیزیکی مانند RMSE، به‌عنوان یک نکتهٔ کلیدی در تحلیل عملکرد مدل‌های متریک برجسته شد. این تمایز، چارچوب مفهومی لازم برای تفسیر نتایج تجربی را فراهم می‌کند [۲، ۱۵].

در مجموع، این فصل یک چارچوب منسجم نظری و عملی برای ادغام اطلاعات درونی دوربین در تخمین عمق تک‌دوربینه ارائه داد. فصل بعد هم نتایج اکتشافی بین‌دیتاستی و هم مطالعهٔ نهایی کنترل‌شدهٔ NYUV2 را گزارش می‌کند و تأثیر افزودن ماتریس مشخصهٔ دوربین بر مقیاس متریک، دقت عددی و رفتار علی مدل را تحلیل می‌نماید.

فصل ۴

نتایج

۱.۴ مقدمه

این فصل به ارائه، تحلیل و تفسیر نتایج تجربی حاصل از پیاده‌سازی و ارزیابی روش پیشنهادی در این پژوهش اختصاص دارد. در حالی که فصل سوم به تشریح چارچوب نظری، معماری مدل و راهبردهای آموزش پرداخته است، تمرکز فصل حاضر بر پاسخ‌گویی عملی و داده‌محور به سوالات تحقیق و بررسی میزان تحقق اهداف پژوهش از طریق آزمایش‌های کنترل‌شده و قابل تکرار است. بدین منظور، نتایج حاصل از اجرای مدل‌ها بر روی مجموعه‌ای متنوع از دیتاست‌های استاندارد ارائه شده و با استفاده از معیارهای کمی و تحلیل‌های آماری مورد ارزیابی قرار می‌گیرند.

هدف اصلی این پژوهش، ارتقای مدل Depth Anything V2 از یک مدل تخمین عمق غیرمتریک^۱ به مدلی با خروجی عمق متریک پایدار^۲ و کاهش حساسیت آن نسبت به تغییر پارامترهای دوربین، به‌ویژه ماتریس مشخصه دوربین^۳ بوده است. از این رو، در این فصل به‌طور خاص بررسی می‌شود که آیا ادغام صریح اطلاعات هندسی دوربین در فرآیند تخمین عمق، می‌تواند ناپایداری مقیاس و وابستگی به نوع دوربین را که در مدل‌های تک‌دوربین مرسوم مشاهده می‌شود، کاهش دهد یا خیر.

برای ارزیابی جامع عملکرد مدل پیشنهادی، مجموعه‌ای از آزمایش‌های کمی بر روی دیتاست‌های متنوع شامل محیط‌های داخلی، خارجی، واقعی و مصنوعی انجام شده است. در این آزمایش‌ها، مدل پیشنهادی با

^۱Non-metric Depth

^۲Metric Depth

^۳Camera Intrinsics

مدل پایه مقایسه شده و عملکرد آن با استفاده از معیارهای متداول ارزیابی عمق، از جمله معیارهای غیرمتریک و متریک، سنجیده می‌شود. همچنین، به منظور بررسی پایداری نتایج، از آزمون‌های آماری و بازه‌های اطمینان استفاده شده تا معناداری تفاوت‌های مشاهده شده به صورت دقیق تحلیل گردد. نتایج ارائه شده در این فصل، مبنای قضاوت نهایی در خصوص کارایی و اعتبار روش پیشنهادی را فراهم می‌کنند.

۲.۴ سوالات تحقیق و فرضیات تجربی

در فصل نخست این پژوهش، مجموعه‌ای از سوالات تحقیق با هدف بررسی امکان دستیابی به عمق متریک پایدار در چارچوب تخمین عمق تک‌دوربین و نقش اطلاعات هندسی دوربین در این فرآیند مطرح شد. در این فصل، این سوالات بر اساس نتایج تجربی به دست آمده مورد ارزیابی و پاسخ‌گویی قرار می‌گیرند.

۱.۲.۴ بازگویی سوالات تحقیق

سوالات اصلی تحقیق به صورت زیر قابل باز بیان هستند:

- آیا مدل Depth Anything V2 در حالت پایه، قادر به تولید عمق متریک پایدار در دیتاست‌هایی با دوربین‌ها و پارامترهای تصویربرداری متفاوت است؟
- آیا ادغام صریح ماتریس مشخصه دوربین^۱ در ورودی مدل، می‌تواند وابستگی خروجی عمق به پارامترهای دوربین را کاهش داده و پایداری مقیاس فیزیکی را بهبود بخشد؟
- آیا بهبود عملکرد مدل در معیارهای متریک، بدون تخریب ساختار نسبی عمق و معیارهای غیرمتریک قابل دستیابی است؟

این سوالات، به طور مستقیم از محدودیت‌های مدل‌های تخمین عمق تک‌دوربین متداول ناشی می‌شوند که عموماً خروجی‌هایی با ابهام مقیاس^۲ تولید می‌کنند و نسبت به تغییر پارامترهای دوربین حساس هستند.

^۱Camera Intrinsic

^۲Scale Ambiguity

۲.۲.۴ فرضیات تجربی

به منظور پاسخ‌گویی نظام‌مند به سوالات فوق، فرضیات تجربی زیر در این پژوهش تعریف و مورد آزمون قرار گرفته‌اند:

- **فرضیه اول:** مدل پایه Depth Anything V2 در معیارهای متریک، نسبت به نوع دیتاست و پارامترهای دوربین حساس بوده و تفاوت عملکرد معنادار آماری بین دیتاست‌های مختلف نشان می‌دهد.
- **فرضیه دوم:** ادغام صریح ماتریس مشخصه دوربین K در مدل پیشنهادی، منجر به کاهش معنادار خطا در معیارهای متریک و بهبود پایداری مقیاس فیزیکی خروجی عمق می‌شود.
- **فرضیه سوم:** بهبود عملکرد متریک مدل پیشنهادی، بدون افت محسوس در معیارهای غیرمتریک و ساختار نسبی نقشه عمق حاصل می‌شود.

۳.۲.۴ ارتباط فرضیات با بخش‌های فصل

برای شفافیت در روند ارزیابی، هر یک از فرضیات فوق در بخش مشخصی از این فصل مورد بررسی قرار می‌گیرد:

- **فرضیه اول** در بخش ۴.۴ و به‌طور خاص در تحلیل عملکرد مدل پایه در دیتاست‌های مختلف بررسی می‌شود.
- **فرضیه دوم** در بخش‌های مقایسه کمی بین مدل پایه و مدل پیشنهادی و همچنین در تحلیل پایداری بین دیتاستی مدل پیشنهادی مورد ارزیابی قرار می‌گیرد.
- **فرضیه سوم** در بخش تحلیل معیارهای غیرمتریک و نتایج کیفی، از طریق مقایسه بصری نقشه‌های عمق بررسی خواهد شد.

بدین ترتیب، ساختار فصل به‌گونه‌ای طراحی شده است که پاسخ‌گویی به سوالات تحقیق و آزمون فرضیات به‌صورت مرحله‌به‌مرحله و مبتنی بر شواهد تجربی انجام گیرد.

۳.۴ تنظیمات آزمایش و پروتکل ارزیابی

در این بخش، تنظیمات آزمایش‌ها، دیتاست‌های مورد استفاده و پروتکل ارزیابی مدل‌ها تشریح می‌شود. هدف از این بخش، ایجاد یک پل منطقی میان چارچوب روش‌شناختی ارائه‌شده در فصل سوم و نتایج تجربی گزارش‌شده در ادامه این فصل است، به گونه‌ای که تفسیر نتایج بر مبنای شرایط آزمایش‌ها به صورت شفاف و قابل بازتولید انجام گیرد.

۱.۳.۴ دیتاست‌های مورد استفاده

به منظور ارزیابی جامع عملکرد مدل‌ها در شرایط متنوع، از مجموعه‌ای از دیتاست‌های استاندارد و پرکاربرد در حوزه تخمین عمق تک‌دوربین استفاده شده است. این دیتاست‌ها از نظر نوع محیط، منبع داده و پارامترهای دوربین تنوع بالایی دارند و امکان بررسی پایداری مدل نسبت به تغییر شرایط تصویربرداری را فراهم می‌کنند.

- **VKITTI:** دیتاستی مصنوعی^۱ شامل صحنه‌های بیرونی، تولیدشده بر پایه دیتاست KITTI با عمق مرجع دقیق و چگال.
- **NYUv2:** دیتاستی واقعی از محیط‌های داخلی^۲، ثبت‌شده با دوربین RGB که عمق مرجع آن با استفاده از حسگرهای فعال به دست آمده است.
- **DIODE:** دیتاستی ترکیبی شامل صحنه‌های داخلی و خارجی، با تنوع بالا در نوع دوربین و شرایط تصویربرداری.
- **DrivingStereo:** دیتاستی واقعی از محیط‌های بیرونی^۳ با عمق مرجع متراکم، استخراج‌شده از داده‌های استریو با کالیبراسیون دقیق دوربین.
- **CityScapes:** دیتاستی شهری و واقعی، که عمق مرجع آن از طریق تطبیق استریو و الگوریتم‌های بازسازی سه‌بعدی به دست آمده و دارای چگالی و کیفیت ناهمگن در نواحی مختلف تصویر است.

این تنوع دیتاست‌ها امکان بررسی رفتار مدل‌ها در شرایط مختلف تصویربرداری، تفاوت میدان دید، و تغییر پارامترهای هندسی دوربین را فراهم می‌سازد.

^۱Synthetic Dataset

^۲Indoor

^۳Outdoor

۲.۳.۴ نوع محیط‌ها و سناریوهای ارزیابی

دیتاست‌های مورد استفاده را می‌توان از منظر نوع محیط به سه دسته اصلی تقسیم کرد:

- محیط‌های داخلی (NYUv2 و بخشی از DIODE)
- محیط‌های خارجی (CityScapes، DrivingStereo و بخشی از DIODE)
- داده‌های مصنوعی (VKITTI)

این تقسیم‌بندی امکان تحلیل پایداری مدل‌ها در سناریوهای مختلف، از فضاهای بسته با مقیاس محدود تا صحنه‌های باز شهری با عمق‌های بزرگ، را فراهم می‌کند.

۳.۳.۴ معیارهای ارزیابی

برای ارزیابی عملکرد مدل‌ها، از ترکیبی از معیارهای غیرمتریک و متریک استفاده شده است تا هم ساختار نسبی عمق و هم مقیاس فیزیکی خروجی مورد بررسی قرار گیرد.

۱.۳.۳.۴ معیارهای غیرمتریک

معیارهای غیرمتریک^۱ برای ارزیابی صحت نسبی عمق و ترتیب اجسام در صحنه به کار می‌روند و نسبت به مقیاس فیزیکی مطلق حساس نیستند. در این پژوهش، معیار AbsRel به عنوان نماینده این دسته استفاده شده است.

۲.۳.۳.۴ معیارهای متریک

معیارهای متریک^۲ برای سنجش دقت عمق بر حسب واحدهای فیزیکی واقعی (مانند متر) به کار می‌روند و نسبت به خطاهای مقیاس حساس هستند. در این پژوهش، معیار SiLog به عنوان معیار اصلی ارزیابی عمق متریک استفاده شده و در برخی تحلیل‌ها، معیار RMSE نیز گزارش می‌شود.

^۱Non-metric Metrics

^۲Metric Metrics

۴.۳.۴ آزمون‌های آماری

به منظور بررسی معناداری تفاوت‌های مشاهده شده بین مدل‌ها و دیتاست‌ها، از آزمون‌های آماری استفاده شده است. در مقایسه‌های بین دیتاستی این فصل، آزمون t دو نمونه‌ای^۱ برای مقایسه میانگین خطاها به کار رفته و سطح معناداری برابر با ۰/۰۵ در نظر گرفته شده است.

در مطالعه کنترل شده بخش ۵.۴ که در آن مدل‌های مختلف بر روی مجموعه آزمون یکسانی ارزیابی می‌شوند، از آزمون‌های زوجی در سطح تک‌تصویر استفاده شده است: برای هر تصویر آزمون، خطای دو مدل به صورت زوجی محاسبه شده و معناداری تفاوت میانگین‌ها با آزمون t زوجی^۲ سنجیده می‌شود. از آنجا که توزیع خطاهای تک‌تصویری لزوماً نرمال نیست، آزمون ناپارامتری علامت‌دار ویلکاکسون^۳ نیز به عنوان سنجۀ استحکام در کنار آن گزارش می‌شود. طرح زوجی، واریانس ناشی از دشواری متفاوت تصاویر را حذف کرده و توان آماری آزمون را به طور قابل توجهی افزایش می‌دهد.

علاوه بر این، به منظور برآورد پایداری نتایج و کاهش وابستگی به فرضیات توزیعی، از بازنمونه‌گیری بوت‌استرپ^۴ (با ده هزار بازنمونه بر روی تفاضل‌های زوجی خطا) برای محاسبه بازه‌های اطمینان ۹۵٪ استفاده شده است. ترکیب این رویکردهای آماری امکان تحلیل دقیق‌تر تفاوت عملکرد مدل‌ها و اطمینان از اعتبار نتایج تجربی را فراهم می‌کند.

۴.۴ نتایج کمی: مقایسه عددی مدل‌ها

در این بخش، نتایج کمی حاصل از ارزیابی مدل‌ها ارائه و تحلیل می‌شود. هدف اصلی، بررسی پایداری مدل پایه Depth Anything V2 در دیتاست‌های مختلف و مقایسه آن با مدل پیشنهادی از منظر معیارهای متریک و غیرمتریک است. تمامی نتایج گزارش شده در این بخش بر اساس اجرای یکسان پروتکل ارزیابی و با استفاده از آزمون‌های آماری ارائه شده در بخش ۳.۴ به دست آمده‌اند.

لازم به توضیح است که آزمایش‌های این بخش، مرحله نخست مطالعات تجربی این پژوهش را تشکیل می‌دهند و پیش از اصلاح تفکیک مجموعه‌های آموزش و آزمون NYUv2 (بخش ۷-۳) انجام شده‌اند؛ از این رو، مقادیر مطلق گزارش شده برای NYUv2 در این بخش باید صرفاً به عنوان مقایسه نسبی میان مدل‌ها تفسیر شوند. مجموعه نهایی و بدون نشت آزمایش‌ها، شامل مقایسه کنترل شده با مدل پایه و مدل هم داده و تحلیل آماری

¹Two-sample t-test

²Paired t-test

³Wilcoxon Signed-rank Test

⁴Bootstrap Resampling

زوجی کامل، در بخش ۵.۴ ارائه می شود.

۱.۴.۴ عملکرد مدل پایه در دیتاست های مختلف

در گام نخست، عملکرد مدل پایه Depth Anything V2 در دیتاست های مختلف مورد بررسی قرار می گیرد تا میزان پایداری آن نسبت به نوع دیتاست و پارامترهای دوربین ارزیابی شود. برای این منظور، معیار SiLog به عنوان معیار متریک اصلی استفاده شده است. نتایج مقایسه بین دیتاستی مدل پایه در جدول ۱.۴ ارائه شده است.

جدول ۱.۴: مقایسه معیار SiLog مدل پایه Depth Anything V2 در دیتاست های مختلف

نتیجه	p -value	اختلاف میانگین	مقایسه دیتاست ها
معنادار	< 0.05	۳۹.۰	VKITTI vs DrivingStereo
معنادار	< 0.05	۱۰۱.۰	NYUv2 vs DrivingStereo
معنادار	< 0.05	۴۵۰.۰	NYUv2 vs DIODE

همان طور که مشاهده می شود، مدل پایه در تمامی مقایسه های انجام شده تفاوت عملکرد معنادار آماری بین دیتاست ها نشان می دهد ($p < 0.05$). این رفتار بیانگر آن است که خروجی عمق مدل پایه به نوع دیتاست و در نتیجه به پارامترهای دوربین و شرایط تصویربرداری وابسته است. در نتیجه، می توان نتیجه گرفت که مدل Depth Anything V2 در حالت پایه قادر به تولید عمق متریک پایدار در شرایط مختلف نیست. این ناپایداری، حتی در مواردی که مدل از نظر ساختار نسبی عمق عملکرد مناسبی دارد، در معیارهای متریک به صورت اختلاف های قابل توجه در مقدار خطا ظاهر می شود.


۲.۴.۴ مقایسه مدل پایه و مدل پیشنهادی

در ادامه، عملکرد مدل پایه با مدل پیشنهادی که در آن ماتریس مشخصه دوربین K به صورت صریح در فرآیند تخمین عمق ادغام شده است، مقایسه می شود. تمرکز اصلی این مقایسه بر معیارهای متریک و به ویژه SiLog است.

جدول ۲.۴ نتایج مقایسه مستقیم دو مدل در دیتاست های مختلف را نشان می دهد. نتایج نشان می دهد که مدل پیشنهادی در تمامی دیتاست ها کاهش چشمگیر و معنادار آماری در مقدار خطای SiLog نسبت به مدل پایه دارد. درصد بهبود مشاهده شده بین حدود ۵۵ تا ۷۴ درصد متغیر بوده که بیانگر تأثیر قابل توجه ادغام اطلاعات هندسی دوربین بر تخمین عمق متریک است.

جدول ۲.۴: مقایسه عملکرد مدل پایه و مدل پیشنهادی بر اساس معیار SiLog

دیتاست	مدل پایه	مدل پیشنهادی	بهبود (%)	-valuep
NYUv2	۲۸۴.۱	۳۲۹.۰	۳۸.۷۴	$\ll 0.05$
DIODE	۸۳۳.۰	۳۷۷.۰	۷۸.۵۴	$\ll 0.05$
CityScapes	۸۳۵.۱	۶۶۲.۰	۹۰.۶۳	$\ll 0.05$
DrivingStereo	۳۹۹.۱	۴۱۴.۰	۴۲.۷۰	$\ll 0.05$



شکل ۱.۴: مقایسه عملکرد متریک (معیار SiLog) بین مدل پایه و پیشنهادی در دیتاست‌های مختلف. همان‌طور که مشاهده می‌شود مدل پیشنهادی در تمامی موارد خطای بسیار کمتری دارد.

این بهبود یکنواخت در دیتاست‌های داخلی، خارجی و مصنوعی نشان می‌دهد که مدل پیشنهادی قادر است وابستگی به توزیع داده و نوع دوربین را به‌طور مؤثری کاهش دهد.

۳.۴.۴ تحلیل پایداری بین دیتاستی مدل پیشنهادی

در این بخش، پایداری مدل پیشنهادی نسبت به تغییر دیتاست و دوربین بررسی می‌شود. برای این منظور، عملکرد مدل پیشنهادی بین جفت دیتاست‌های مختلف با استفاده از آزمون t و بازه‌های اطمینان بوت‌استرپ مقایسه شده است.

نتایج نشان می‌دهد که برخلاف مدل پایه، تفاوت عملکرد مدل پیشنهادی در بسیاری از مقایسه‌های بین دیتاستی از نظر آماری معنادار نیست ($p > 0.05$) و بازه‌های اطمینان محاسبه‌شده شامل مقدار صفر هستند. این رفتار بیانگر آن است که مدل پیشنهادی توانسته است وابستگی خروجی عمق به پارامترهای دوربین را تا

حد زیادی کاهش دهد و به عمق متریک پایدار دست یابد. بدین ترتیب، می‌توان نتیجه گرفت که ادغام صریح ماتریس مشخصه دوربین نقش کلیدی در بهبود پایداری مقیاس در تخمین عمق تک‌دوربینه ایفا می‌کند و پاسخ مثبت و مستقیمی به سوال اصلی پژوهش در خصوص امکان دستیابی به عمق متریک پایدار ارائه می‌دهد.

۵.۴ مطالعه کنترل‌شده بر روی پروتکل استاندارد NYUv2

در مرحله دوم مطالعات تجربی این پژوهش، به منظور ارائه مقایسه‌ای کاملاً منصفانه، بدون نشت داده و قابل انطباق با ادبیات موضوع، مجموعه‌ای از آزمایش‌های کنترل‌شده بر روی پروتکل استاندارد ارزیابی NYUv2 طراحی و اجرا شد. در این پروتکل که در اغلب پژوهش‌های مرجع از جمله Depth Anything V2 به‌کار می‌رود [۲، ۱۱]، ارزیابی بر روی زیرمجموعه‌ای از ۶۵۴ تصویر Eigen با نقشه‌های عمق خام حسگر به‌عنوان مرجع، برش استاندارد Eigen، و محدوده عمق ۰/۰۱ تا ۱۰ متر انجام می‌شود. برای مدل‌های نسبی، پیش از محاسبه معیارها، تراز مقیاس و جابجایی به‌ازای هر تصویر در فضای عمق معکوس اعمال می‌گردد و سپس پیش‌بینی ترازشده به بازه معتبر ارزیابی محدود می‌شود؛ برای مدل‌های متریک، خروجی مدل بدون هیچ‌گونه تراز مستقیماً با مرجع مقایسه می‌شود. در بازتولید KITTI نیز مطابق جدول ۲ مقاله مرجع از ۶۵۲ تصویر تقسیم Eigen و حالت بدون برش استفاده شد.

برای هر اندازه‌انگودر، چهار مدل در شرایط یکسان مقایسه می‌شوند:

۱. مقادیر گزارش‌شده در مقاله مرجع Depth Anything V2 (جدول ۲ مقاله)؛
 ۲. مدل منتشرشده Depth Anything V2، ارزیابی‌شده با زنجیره ارزیابی این پژوهش؛
 ۳. مدل کنترل: معماری پایه بدون پارامترهای دوربین، فاین‌تیون‌شده بر روی همان داده آموزشی بدون نشت، با ابرپارامترها و برنامه آموزشی کاملاً یکسان با مدل پیشنهادی؛
 ۴. مدل پیشنهادی: همان تنظیمات، به‌علاوه ورودی صریح ماتریس مشخصه دوربین.
- مقایسه (۴) با (۲) میزان بهبود نسبت به مدل پایه منتشرشده را می‌سنجد و مقایسه (۴) با (۳) — که تنها در دسترسی به K تفاوت دارند — سهم خالص پارامترهای درونی دوربین را جدا می‌کند.

۱.۵.۴ ممیزی نقاط واریسی و مسیر رسیدن به آزمایش نهایی

پیش از آغاز آموزش‌های جدید، حدود بیست نقطه واریسی پیشین در اندازه‌های ViT-S و ViT-L، دو حالت نسبی و متریک، و ترکیب‌های گوناگون داده ممیزی شد. بیشتر اجراها در اعتبارسنجی درون‌دامنه‌ای به AbsRel حدود ۵/۰ تا ۷/۰ رسیده بودند، اما دو اجرا در تمام دوره‌ها روی مقدار ثابت ۳۶۹۸/۰ متوقف شده و دو نقطه واریسی نسبی ViT-L نیز برای همه تصاویر خروجی نامعتبر تولید می‌کردند. این ممیزی نشان داد که پایین بودن خطای اعتبارسنجی به تنهایی شاهد تعمیم نیست و سلامت نقطه واریسی باید با ارزیابی مستقل و بررسی آماره‌های خروجی تأیید شود.

جدول ۳.۴ توالی تصمیم‌های اصلی را نشان می‌دهد. این توالی بخشی از نتیجه پژوهش است، زیرا مدل نهایی حاصل یک تغییر منفرد نبود؛ هر مرحله، یک فرض یا اشکال مرحله قبل را آزمود و مسیر آزمایش بعدی را تعیین کرد.

جدول ۳.۴: مسیر تجربی رسیدن از نقاط واریسی اولیه به مدل نهایی آگاه از دوربین.

مرحله	مسئله یا مشاهده	تصمیم و پیامد
ممیزی اولیه	فروریزش یا خروجی نامعتبر در چند نقطه واریسی و اتکای بیش‌ازحد به اعتبارسنجی درون‌دامنه‌ای	بازتولید خط مبنای منتشرشده و ارزیابی مستقل همه ادعاها
ارزیابی صفرنمونه	افت شدید تعمیم پس از فاین‌تیون چندمجموعه‌ای محدود	کنارگذاشتن این مسیر و انتخاب پروتکل درون‌دامنه‌ای استاندارد
پاک‌سازی داده	حضور ۵۲۷ تصویر آزمون در آموزش اولیه NYUv2	حذف کامل تقسیم Eigen پیش از ساخت آموزش/اعتبارسنجی
آموزش نسبی ViT-S	نخستین برتری بدون نشت نسبت به مدل منتشرشده و کنترل	تکرار در مقیاس ViT-L
فروریزش ViT-L	خروجی ثابت صفر با منحنی هزینه ظاهراً طبیعی	انتقال هدف از عمق مستقیم به عمق معکوس و ثبت فضای هدف در نقطه واریسی
زوم‌برش هندسی	ثابت و نادرست بودن K تحت برش معمولی	تولید میدان دید متنوع با به‌روزرسانی دقیق K ؛ بهبود هر دو بازو ولی نبود برتری K در پروتکل نسبی
ارزیابی متریک	حذف شدن اطلاعات مقیاس در تراز نسبی	ارزیابی بدون تراز؛ ظهور الگوی پاسخ به دوز با افزایش تنوع میدان دید
لرزش کانونی	شیب جاروی K تنها ۶/۰ و استفاده ضعیف مدل از ورودی دوربین	ناممکن کردن ارزیابی مقیاس بدون K ؛ شیب ۹۳/۰-۹۷/۰ و برتری قاطع همه معیارها
فروکاست و حذف K	هم‌زمانی تغییر لرزش کانونی و λ و نیاز به شاهد علی	اثبات اینکه لرزش کانونی عامل اثر است و صحت پیش‌بینی به K صحیح وابستگی علی دارد

۲.۵.۴ راستی آزمایی زنجیره ارزیابی: بازتولید نتایج مدل پایه

پیش از هرگونه مقایسه، صحت زنجیره ارزیابی از طریق بازتولید نتایج گزارش شده مقاله مرجع راستی آزمایی شد. جدول ۴.۴ نشان می‌دهد که نتایج به دست آمده با زنجیره ارزیابی این پژوهش، با دقت مطلوبی بر مقادیر مقاله منطبق است؛ اختلاف‌های جزئی در محدوده تلورانس متعارف بازتولید این محک قرار دارند.

جدول ۴.۴: راستی آزمایی زنجیره ارزیابی: بازتولید نتایج مدل منتشر شده Depth Anything V2 (نسخه نسبی) بر روی پروتکل استاندارد. مقادیر به صورت $\downarrow/\uparrow$ AbsRel δ_1 گزارش شده‌اند.

محک و انکودر	مقاله مرجع	ارزیابی این پژوهش
NYUv2, ViT-S	۹۷۳.۰ / ۰.۵۳.۰	۹۷۳.۰ / ۰.۵۱.۰
NYUv2, ViT-L	۹۷۹.۰ / ۰.۴۵.۰	۹۷۹.۰ / ۰.۴۳.۰
KITTI, ViT-S	۹۳۶.۰ / ۰.۷۸.۰	۹۳۴.۰ / ۰.۸۳.۰
KITTI, ViT-L	۹۴۶.۰ / ۰.۷۴.۰	۹۴۸.۰ / ۰.۷۶.۰

۳.۵.۴ ناکارآمدی فاین تیون برای ارزیابی برون دامنه‌ای

نخستین یافته این مرحله، نتیجه‌ای منفی اما تعیین کننده در طراحی ادامه آزمایش‌ها بود: فاین تیون مدل پایه بر روی ترکیب مجموعه داده‌های محدود (نظیر NYUv2 و DIODE, Cityscapes, VKITTI2)، توانایی تعمیم صفر نمونه مدل را به شدت تخریب می‌کند. نتایج دقیق در جدول ۵.۴ آمده است.

جدول ۵.۴: ارزیابی بدون نشت نقاط واریسی چند مجموعه‌ای در حالت صفر نمونه؛ مقادیر به صورت $\downarrow$ AbsRel δ_1 $\uparrow$ هستند.

محک و مدل	نقطه واریسی فاین تیون شده	مدل منتشر شده
KITTI, ViT-S، مدل پیشنهادی	۶۱۸۹.۰ / ۲۱۳۹.۰	۹۳۴۱.۰ / ۰.۸۲۹.۰
KITTI, ViT-S، کنترل فاقد K	۶۱۷۹.۰ / ۲۱۳۲.۰	۹۳۴۱.۰ / ۰.۸۲۹.۰
NYUv2, ViT-S، مدل پیشنهادی بدون داده NYU	۹۵۷۸.۰ / ۰.۶۵۷.۰	۹۷۳۳.۰ / ۰.۵۰۸.۰

افزایش KITTI AbsRel از حدود ۰.۸۳ به ۰.۲۱۴ هم در مدل پیشنهادی و هم در کنترل رخ می‌دهد؛ اختلاف ۰.۲۱۳۹ و ۰.۲۱۳۲ در حد نوفه است. بنابراین، پارامترهای دوربین نه علت این افت‌اند و نه راه‌حل آن. این مشاهده نشان می‌دهد که مدل بنیادین آموزش دیده بر ده‌ها میلیون تصویر، با فاین تیون بر چند هزار تصویر کوچک یا مصنوعی از بازنمایی عمومی خود فاصله می‌گیرد. بر همین اساس، مطابق رویه مقاله مرجع، ادامه مطالعه به فاین تیون بر بخش آموزشی یک محک و ارزیابی بر بخش آزمون همان محک منتقل شد.

۴.۵.۴ نتایج پروتکل نسبی: مقایسه چهارگانه

جدول‌های ۶.۴ و ۷.۴ نتایج مقایسه چهارگانه را برای دو اندازه انکودر نشان می‌دهند. هر دو مدل فاین‌تیون‌شده بر روی تفکیک بدون نشت (۶۳۶ تصویر آموزش) و با دستورالعمل یکسان (۴۰ دوره، نرخ یادگیری $10^{-6} \times 5$ ، انکودر فریزشده، هدف عمق معکوس مطابق بخش ۷-۳) آموزش دیده‌اند.

جدول ۶.۴: مقایسه چهارگانه بر روی مجموعه آزمون استاندارد NYUv2 (۶۵۴ تصویر، مرجع عمق خام)، انکودر ViT-S، پروتکل نسبی با تراز مقیاس و جابجایی.

مدل	$\downarrow \text{AbsRel}$	$\delta_1 \uparrow$	$\downarrow \text{RMSE}$	$\downarrow \text{SqRel}$	$\log_{10} \downarrow$
مقاله مرجع (جدول ۲)	۰.۵۳.۰	۹۷۳.۰	—	—	—
DA2 منتشرشده (ارزیابی این پژوهش)	۰.۵۰۸.۰	۹۷۳۳.۰	۲۴۱۴.۰	۰.۲۴۵.۰	۰.۲۲۲.۰
مدل کنترل (فاین‌تیون بدون K)	۰.۵۰۷.۰	۹۷۴۱.۰	۲۰۸۸.۰	۰.۱۸۶.۰	۰.۲۱۸.۰
مدل پیشنهادی (فاین‌تیون با K)	۰.۵۰۱.۰	۹۷۴۵.۰	۲۰۶۴.۰	۰.۱۸۲.۰	۰.۲۱۶.۰

پیش از دستیابی به نتیجه ViT-L جدول بعد، دو اجرای پیشنهادی و کنترل با همان دستورالعمل اولیه فروریختند: AbsRel اعتبارسنجی از دوره نخست روی حدود ۳۴۶/۰ ثابت ماند و خروجی شبکه در تمام پیکسل‌ها دقیقاً صفر شد. کاهش ضریب نرخ یادگیری سر شبکه از ۱۰ به ۱ و افزودن گرم‌سازی نیز مشکل را رفع نکرد. بازتولید ایزارگذاری‌شده نشان داد سهم پیکسل‌های مرده در تنها ۱۸ گام از حدود ۰.۰۱/۰ به ۱ رسید. پس از انتقال هدف به عمق معکوس، یک اجرای آزمایشی ۱۵۰ گامی هیچ پیکسل مرده‌ای نداشت و هزینه آن ۲۰ تا ۵۰ برابر کمتر بود؛ سپس آموزش کامل تکرار شد. بنابراین نتیجه ViT-L زیر مربوط به نسخه اصلاح‌شده فضای هدف است، نه اجرای فروریخته.

جدول ۷.۴: مقایسه چهارگانه بر روی مجموعه آزمون استاندارد NYUv2، انکودر ViT-L، پروتکل نسبی.

مدل	$\downarrow \text{AbsRel}$	$\delta_1 \uparrow$	$\downarrow \text{RMSE}$
مقاله مرجع (جدول ۲)	۰.۴۵.۰	۹۷۹.۰	—
DA2 منتشرشده (ارزیابی این پژوهش)	۰.۴۲۵.۰	۹۷۸۹.۰	۲۱۱۹.۰
مدل کنترل (فاین‌تیون بدون K)	۰.۳۷۸.۰	۹۸۶۲.۰	۱۹۲۲.۰
مدل پیشنهادی (فاین‌تیون با K)	۰.۳۷۷.۰	۹۸۶۱.۰	۱۹۱۳.۰

برای تکمیل گزارش اندازه اثر، جدول ۸.۴ تفاضل زوجی و بازه اطمینان بوت‌استرپ چهار مقایسه اصلی ViT-S را ارائه می‌کند. علامت مثبت به معنای خطای بیشتر مدل مرجع یا کنترل نسبت به مدل پیشنهادی است. برای سنجش معناداری آماری تفاوت‌ها، از آزمون‌های زوجی در سطح تک‌تصویر (آزمون t زوجی و آزمون علامت‌دار ویلکاکسون بر روی $n = 654$ زوج) استفاده شده است؛ نتایج در جدول ۹.۴ آمده است.

جدول ۸.۴: اندازه اثر زوجی مدل پیشنهادی ViT-S بر ۶۵۴ تصویر NYUv2.

مقایسه	معیار	میانگین تفاضل	بازه اطمینان ۹۵٪
در برابر DA2 منتشرشده	RMSE	+۰/۰۳۵۰	[+۰/۰۲۷۰, +۰/۰۴۳۸]
در برابر DA2 منتشرشده	AbsRel	+۰/۰۰۰۷	[-۰/۰۰۰۰۸, +۰/۰۰۰۲۲]
در برابر کنترل فاقد K	RMSE	+۰/۰۰۰۲۴	[+۰/۰۰۰۱۳, +۰/۰۰۰۳۴]
در برابر کنترل فاقد K	AbsRel	+۰/۰۰۰۰۶	[+۰/۰۰۰۰۲, +۰/۰۰۰۱۰]

جدول ۹.۴: آزمون‌های زوجی معناداری بر روی ۶۵۴ تصویر آزمون NYUv2 (پروتکل نسبی)؛ مقایسه مدل پیشنهادی با مدل منتشرشده و مدل کنترل.

انکودر	مقایسه	معیار	p (زوجی)	p (ویلکاکسون)
ViT-S	در برابر DA2	AbsRel	۴۰.۰	۰.۹.۰
ViT-S	در برابر DA2	RMSE	$۲/۸ \times ۱۰^{-۱۵}$	۵×۱۰^{-۱۸}
ViT-S	در برابر DA2	δ_1	۳۴.۰	۰.۵.۰
ViT-S	در برابر کنترل	AbsRel	$۱/۳ \times ۱۰^{-۳}$	$۵/۰ \times ۱۰^{-۳}$
ViT-S	در برابر کنترل	RMSE	$۱/۱ \times ۱۰^{-۵}$	$۳/۵ \times ۱۰^{-۵}$
ViT-S	در برابر کنترل	δ_1	۲۹.۰	۰.۶.۰
ViT-L	در برابر DA2	AbsRel	$۲/۵ \times ۱۰^{-۸}$	$۸/۹ \times ۱۰^{-۶}$
ViT-L	در برابر DA2	RMSE	$۱/۰ \times ۱۰^{-۷}$	$۱/۱ \times ۱۰^{-۹}$
ViT-L	در برابر DA2	δ_1	$۴/۱ \times ۱۰^{-۶}$	$۱/۲ \times ۱۰^{-۱۲}$
ViT-L	در برابر کنترل	AbsRel	۷۷.۰	۱۸.۰
ViT-L	در برابر کنترل	RMSE	۲۹.۰	۵۰.۰
ViT-L	در برابر کنترل	δ_1	۸۱.۰	۰.۴.۰

سه نتیجه اصلی از این جدول‌ها قابل استخراج است. نخست، مدل پیشنهادی ViT-L در هر سه معیار، به‌صورت معنادار آماری از مدل منتشرشده Depth Anything V2 بهتر است (کاهش AbsRel از ۰/۴۲۵ به ۰/۳۷۷ و کاهش ۷/۹ درصدی RMSE، همگی با $p < ۱۰^{-۵}$). دوم، در اندازه ViT-S، سهم خالص پارامترهای دوربین در برابر مدل کنترل هم‌داده، کوچک اما از نظر آماری معنادار است (AbsRel با $p = ۱/۳ \times ۱۰^{-۳}$ و RMSE با $p = ۱/۱ \times ۱۰^{-۵}$). سوم — و از منظر علمی آموزنده — در اندازه ViT-L تفاوت مدل پیشنهادی و مدل کنترل در پروتکل نسبی از نظر آماری معنادار نیست؛ تحلیل این پدیده در ادامه همین بخش و در بخش بحث ارائه می‌شود.

اندازه اثر ViT-L در برابر مدل منتشرشده نیز روشن است. برای AbsRel میانگین تفاضل زوجی و بازه اطمینان ۹۵٪ به ترتیب +۰/۰۰۴۸ و [۰/۰۰۰۳۲, +۰/۰۰۰۶۶] است. برای RMSE مقادیر متناظر برابر +۰/۰۲۰۵ و [۰/۰۱۳۳, +۰/۰۲۸۲] هستند. در مقابل، آزمون‌های مدل پیشنهادی و کنترل برای AbsRel و RMSE به ترتیب $p = ۰/۱۸$ و $p = ۰/۵۰$ در ویلکاکسون هستند و تفاوت معناداری میان دو بازو در این پروتکل نشان نمی‌دهند.

۵.۵.۴ اثر افزونه‌سازی هندسی و یک نتیجه منفی آموزنده

فرضیهٔ محتمل برای عدم مشاهدهٔ سهم پارامترهای دوربین در ViT-L، ثابت بودن بردار k در مجموعه دادهٔ تک دوربین NYUv2 بود. برای آزمون این فرضیه، زوج مدل ViT-L با افزونه‌سازی هندسی آگاه از دوربین (بخش ۷-۳، بازهٔ میدان دید ۴۱ تا ۶۳ درجه) بازآموزی شد. نتایج (جدول ۱۰.۴) دو یافته به همراه داشت: نخست، خود افزونه‌سازی هندسی برای هر دو مدل سودمندی چشمگیری دارد (کاهش AbsRel مدل کنترل از ۰.۳۷۸ به ۰.۳۵۹ با $p = ۱/۲ \times ۱۰^{-۱۳}$ و مدل پیشنهادی از ۰.۳۷۷ به ۰.۳۶۲ با $p = ۱/۲ \times ۱۰^{-۸}$) و بهترین نتایج این پژوهش در پروتکل نسبی را رقم می‌زند. دوم، حتی با وجود سیگنال هندسی متنوع و صحیح، مدل پیشنهادی در پروتکل نسبی بر مدل کنترل برتری نیافت (و در AbsRel با اختلاف بسیار جزئی ۰.۰۰۳ ولی معنادار، $p = ۸/۱ \times ۱۰^{-۳}$ ، پشت سر آن قرار گرفت).

جدول ۱۰.۴: اثر افزونه‌سازی هندسی آگاه از دوربین بر زوج مدل ViT-L در پروتکل نسبی NYUv2.

مدل	↓AbsRel	$\delta_1 \uparrow$	↓RMSE
مدل کنترل + افزونه‌سازی	۰.۳۵۹.۰	۹۸۷۲.۰	۱۸۴۹.۰
مدل پیشنهادی + افزونه‌سازی	۰.۳۶۲.۰	۹۸۶۹.۰	۱۸۸۱.۰

این نتیجهٔ منفی، تبیینی اصولی دارد که یکی از یافته‌های مفهومی این پژوهش محسوب می‌شود: در پروتکل ارزیابی نسبی، پیش از محاسبهٔ هر معیار، یک تراز مقیاس و جابجایی به‌ازای هر تصویر میان پیش‌بینی و مرجع اعمال می‌شود. اطلاعات اصلی که میدان دید و فاصلهٔ کانونی در اختیار مدل قرار می‌دهند، دقیقاً همان مقیاس مطلق صحنه است؛ کمیتی که سازوکار تراز، آن را از ارزیابی حذف می‌کند. به بیان دیگر، پروتکل نسبی به‌صورت ساختاری نسبت به سهم اصلی پارامترهای درونی دوربین «کور» است. این تحلیل پیش‌بینی می‌کند که سهم پارامترهای دوربین باید در ارزیابی متریک (بدون تراز) آشکار شود؛ پیش‌بینی‌ای که در زیربخش بعد به‌صورت تجربی آزموده می‌شود.

۶.۵.۴ ارزیابی متریک: آشکارشدن سهم پارامترهای درونی دوربین

در این مرحله، زوج مدل ViT-L در حالت متریک (تابع هزینهٔ SiLog بر عمق مطلق، مطابق فصل سوم) و با افزونه‌سازی هندسی آموزش دیده و بر روی مجموعهٔ آزمون استاندارد، بدون هیچ‌گونه تراز مقیاس، ارزیابی شد. مرجع مقایسه در این حالت، مدل متریک منتشرشدهٔ Depth Anything V2 (فاین تیون شده بر Hypersim برای صحنه‌های داخلی) است. آزمایش در دو دور با دو شدت افزونه‌سازی انجام شد: دور نخست با بازهٔ میدان دید ۴۱ تا ۶۳ درجه و دور دوم با بازهٔ وسیع‌تر ۳۳ تا ۶۳ درجه.

جدول ۱۱.۴: ارزیابی متریک (عمق مطلق، بدون تراز) بر روی مجموعه آزمون استاندارد NYUv2، انکودر ViT-L. دور ۱: افزونه سازی با میدان دید ۶۳-۴۱ درجه؛ دور ۲: ۶۳-۳۳ درجه.

مدل	$\downarrow$ AbsRel	$\delta_1 \uparrow$	$\downarrow$ RMSE
DA2 متریک منتشر شده (Hypersim)	۲۰۷۳.۰	۶۹۱۹.۰	۶۰۶۳.۰
دور ۱: مدل کنترل	۰۷۹۶.۰	۹۵۸۳.۰	۲۹۱۹.۰
دور ۱: مدل پیشنهادی	۰۷۹۱.۰	۹۵۹۳.۰	۲۸۸۲.۰
دور ۲: مدل کنترل	۰۸۲۶.۰	۹۵۴۶.۰	۲۹۹۸.۰
دور ۲: مدل پیشنهادی	۰۸۱۷.۰	۹۵۶۹.۰	۲۹۴۴.۰

نتایج جدول ۱۱.۴ و آزمون های زوجی متناظر (جدول ۱۲.۴) سه یافته کلیدی دارند:

جدول ۱۲.۴: آزمون های زوجی معناداری در ارزیابی متریک ($n = ۶۵۴$)؛ مقایسه مدل پیشنهادی با مدل متریک منتشر شده و مدل کنترل.

دور	مقایسه	معیار	p (ویلیکاکسون)	p (زوجی) ($t p$)
۱	در برابر DA2 متریک	AbsRel	$۸/۴ \times ۱۰^{-۹۶}$	$۴/۸ \times ۱۰^{-۱۳۳}$
۱	در برابر DA2 متریک	RMSE	$۵/۶ \times ۱۰^{-۸۷}$	$۶/۷ \times ۱۰^{-۱۰۰}$
۱	در برابر کنترل	AbsRel	۵۳.۰	۲۶.۰
۱	در برابر کنترل	RMSE	$۹/۳ \times ۱۰^{-۳}$	$۴/۹ \times ۱۰^{-۳}$
۲	در برابر کنترل	AbsRel	۰۴۰.۰	۰۸۹.۰
۲	در برابر کنترل	RMSE	$۱/۲ \times ۱۰^{-۴}$	$۶/۵ \times ۱۰^{-۵}$

نخست، هر دو مدل فاین تیون شده، مدل متریک منتشر شده را با فاصله بسیار زیاد پشت سر می گذارند (کاهش AbsRel از $۲۰۷/۰$ به حدود $۰۸/۰$ ، معادل بهبود $۶/۲$ برابری، با p در مرتبه $۱۰^{-۱۳۳}$)؛ این نتیجه هم راستا با گزارش خود مقاله مرجع است که مقیاس متریک مدل Hypersim به صحنه های واقعی به خوبی منتقل نمی شود. دوم، برخلاف پروتکل نسبی، در ارزیابی متریک مدل پیشنهادی در هر دو دور و در تمامی معیارها از مدل کنترل هم داده پیشی می گیرد و این برتری در معیار RMSE در هر دو دور معنادار آماری است ($p = ۴/۹ \times ۱۰^{-۳}$ در دور ۱ و $p = ۶/۵ \times ۱۰^{-۵}$ در دور ۲). سوم — و مهم تر — با افزایش شدت تنوع میدان دید از دور ۱ به دور ۲، فاصله مدل پیشنهادی از مدل کنترل در همه معیارها افزایش می یابد و معناداری AbsRel نیز به آستانه تصمیم می رسد (ویلیکاکسون $p = ۰/۰۴۰$). این الگوی پاسخ به دوز^۱ — یعنی رشد سهم پارامترهای دور بین متناسب با میزان ابهام هندسی موجود در داده — که در دو اجرای مستقل آموزش تکرار شده است، شاهد تجربی مهمی بر سودمندی واقعی ورودی پارامترهای درونی دور بین است. زیربخش بعد نشان می دهد که با رساندن ابهام هندسی به حد نهایی خود، این سهم از یک برتری آماری مرزی به یک اثر قاطع و همه جانبه تبدیل می شود.

¹Dose-Response Pattern

۷.۵.۴ دور سوم — افزونه‌سازی لرزش کانونی: جهش سهم پارامترهای دورین

نقطه اوج الگوی پاسخ به دوز، به کارگیری افزونه‌سازی لرزش کانونی (بخش ۸.۷.۳) است که مقیاس مطلق صحنه را بدون دسترسی به K اساساً غیرقابل بازیابی می‌کند. زوج مدل ViT-L متریک با دستور آموزشی یکسان با دور ۲، به علاوه لرزش کانونی ($m = 1/6$)، ضریب $\lambda = 0.3$ در هزینه، SiLog و قفل بذر تصادفی بازآموزی شد؛ قفل بذر تضمین می‌کند که هر دو بازو دقیقاً همان دنباله‌ی داده، وارونه‌سازی و ضرایب α را دیده باشند (تابع هزینه گام صفر هر دو اجرا تا آخرین رقم اعشار برابر بود: $1/725$).

جدول ۱۳.۴: دور ۳ (لرزش کانونی): ارزیابی متریک (عمق مطلق، بدون تراز) بر مجموعه آزمون استاندارد NYUv2، انکودر ViT-L، به همراه آزمون زوجی ویلکاکسون ($n = 654$) و بازه اطمینان ۹۵٪ بوت استرپ تفاضل زوجی.

معیار	مدل پیشنهادی	مدل کنترل	تفاضل [بازه اطمینان ۹۵٪]	p (ویلکاکسون)
AbsRel ↓	۰.۸۴۹.۰	۱.۰۳۰.۰	$[-0.0153, -0.0210]$	$4/0 \times 10^{-31}$
RMSE ↓	۳۰۷۱.۰	۳۴۳۱.۰	$[-0.0289, -0.0432]$	$1/0 \times 10^{-24}$
δ_1 ↑	۹۵۲۰.۰	۹۲۲۶.۰	$[+0.0224, +0.0367]$	$2/5 \times 10^{-24}$
SiLog ↓	۰.۹۴۲.۰	۱.۰۴۵.۰	$[-0.0118, -0.0102]$	$1/5 \times 10^{-34}$
$\log_{10}$ ↓	۰.۳۶۳.۰	۰.۴۲۷.۰	$[-0.0053, -0.0076]$	$2/8 \times 10^{-27}$

نتایج (جدول ۱۳.۴) جهشی کیفی نسبت به دوره‌های قبل نشان می‌دهد: مدل پیشنهادی در تمامی معیارها با معناداری در مرتبه $10^{-24} \leq p$ از مدل کنترل هم‌داده و هم‌بذر پیشی می‌گیرد؛ در حالی که بهترین معناداری AbsRel در دور ۲ تنها $p = 0.04$ بود. توزیع نسبت مقیاس هر تصویر (میانۀ پیش‌بینی تقسیم بر میانۀ مرجع) سازوکار این برتری را آشکار می‌کند: مدل پیشنهادی حول $1/14$ متمرکز است، در حالی که نوفه کاهش‌ناپذیر α مدل کنترل را اریب و پراکنده کرده است (میانۀ $1/81$). به بیان دیگر، مدل کنترل — که ناچار است به میانگین توزیع α رگرسیون کند — دقیقاً همان رفتاری را نشان می‌دهد که تحلیل بدساختی مسئله در بخش ۸.۷.۳ پیش‌بینی می‌کرد.

سنجش تعمیم به میدان دیدهای متفاوت نیز همین برتری را تأیید می‌کند: در ارزیابی با برش‌های مرکزی قطعی (زوم $1/4$ و $1/8$ با به‌روزرسانی دقیق K ، هر 654 تصویر)، AbsRel مدل پیشنهادی به‌ترتیب 0.092 ، 0.097 و 0.107 و مدل کنترل 0.110 ، 0.110 و 0.115 است — برتری در تمام سطوح زوم. دو ملاحظه صادقانه ضروری است. نخست، این برتری قاطع نسبت به کنترل، با بهای اندکی در کیفیت مطلق همراه است: AbsRel مدل پیشنهادی دور ۳ (0.849) اندکی بالاتر از بهترین مدل خام پژوهش (دور ۱، 0.0791) است؛ ادامه همان مصالحه‌ای که از دور ۱ به دور ۲ نیز مشاهده شد: وظیفه آموزشی دشوارتر، کیفیت مطلق را اندکی می‌کاهد اما شواهد سازوکاری را به‌شدت تقویت می‌کند. دوم، دور ۳ نسبت به دور ۲ دو متغیر را هم‌زمان تغییر می‌دهد (افزونه‌سازی لرزش کانونی و λ)؛ آزمایش تفکیک این دو عامل در زیربخش ۸.۵.۴

گزارش می‌شود.

۸.۵.۴ مطالعه فروکاست: تفکیک اثر لرزش کانونی از ضریب λ

برای انتساب دقیق اثر مشاهده‌شده در دور ۳، زوج مدل چهارمی با تنها یک متغیر تغییر یافته نسبت به دور ۲ آموزش داده شد: لرزش کانونی فعال ($m = 1/6$) اما $\lambda = 0/5$ بدون تغییر (به همراه همان قفل بذر تصادفی).

جدول ۱۴.۴: مطالعه فروکاست (لرزش کانونی با $\lambda = 0/5$ بدون تغییر): ارزیابی متریک بر مجموعه آزمون استاندارد NYUv2 ($n = 654$).

معیار	مدل پیشنهادی	مدل کنترل	تفاضل [بازه اطمینان ۹۵٪]	p (ویلیکاکسون)
↓AbsRel	۰.۸۳۴.۰	۱.۰۶۵.۰	$[-0/0260, -0/0202]$	$3/4 \times 10^{-45}$
↓RMSE	۲۹۸۷.۰	۳۴۹۷.۰	$[-0/0583, -0/0437]$	$7/5 \times 10^{-40}$
$\delta_1 \uparrow$	۹۵۵۴.۰	۹۱۷۳.۰	$[+0/0310, +0/0453]$	$1/2 \times 10^{-39}$
↓SILog	۰.۹۱۸.۰	۱.۰۵۶.۰	$[-0/0155, -0/0123]$	$2/2 \times 10^{-50}$

نتیجه فروکاست (جدول ۱۴.۴) از دو جهت تعیین‌کننده است. نخست، کل اثر دور ۳ با لرزش کانونی به‌تنهایی بازتولید — و حتی تقویت — می‌شود: برتری مدل پیشنهادی در تمامی معیارها به مرتبه $p \leq 10^{-39}$ می‌رسد و شیب جاروی K به $0/97 \pm 0/03$ — نزدیک‌تر به مقدار ایده‌آل ۱ نسبت به دور ۳. بنابراین عامل علی، خود افزونه‌سازی لرزش کانونی است و کاهش λ نه‌تنها ضروری نیست، بلکه اندکی هم زیان‌بار بوده است (AbsRel) مدل پیشنهادی با $\lambda = 0/5$: $0/834$ در برابر $0/849$ با $\lambda = 0/3$. دوم، این چهارمین زوج آموزشی مستقلی است که برتری مدل آگاه از K را تکرار می‌کند و در کنار دوره‌های ۱ تا ۳، الگوی پاسخ به دوز را به‌صورت یکنواخت کامل می‌سازد: هرچه بازیابی مقیاس بدون K دشوارتر، سهم پارامترهای دوربین بزرگ‌تر و معنادارتر.

۹.۵.۴ جمع‌بندی مطالعه کنترل‌شده و گزارش کوشش‌های تجربی

برای شفافیت علمی، گستره کوشش‌های تجربی این مرحله به‌اختصار گزارش می‌شود. در مجموع بیش از بیست اجرای آموزش مستقل (شامل زوج‌های پیشنهادی/کنترل در دو اندازه انکودر، دو نوع مدل نسبی و متریک، و دوشدت افزونه‌سازی) و ممیزی کامل نقاط واریسی پیشین پروژه انجام شد. در جریان این ممیزی، تعدادی از نقاط واریسی قدیمی ViT-L به‌دلیل فروریزش خاموش توصیف‌شده در بخش ۳-۷ عملاً بلااستفاده تشخیص داده شدند و سه اشکال زیرساختی (نشت تقسیم‌بندی NYUv2، ناهم‌خوانی فضای هدف آموزش، و ناهم‌خوانی معماری

سر شبکه در ارزیابی متریک) شناسایی و رفع گردید (بخش ۳-۹). رویکردهای آزموده شده و کنار گذاشته شده نیز مستند شده اند: فاین تیون چندمجموعه ای برای ارزیابی صفر نمونه (به دلیل تخریب تعمیم)، و کاهش نرخ یادگیری سر شبکه به عنوان راه حل فرو ریزش (که مؤثر نبود و نشان داد ریشه مشکل در فضای هدف است، نه نرخ یادگیری). خلاصه یافته های این مطالعه کنترل شده چنین است: (۱) مدل پیشنهادی در هر دو اندازه انکودر و در هر دو پروتکل، از مدل پایه منتشر شده Depth Anything V2 به صورت معنادار بهتر است؛ (۲) سهم خالص پارامترهای درونی دوربین در پروتکل نسبی تنها در اندازه کوچک معنادار است، زیرا سازوکار تراز، اطلاعات مقیاس را حذف می کند؛ (۳) در ارزیابی متریک — که مقیاس مطلق اهمیت دارد — سهم پارامترهای دوربین آشکار، معنادار و متناسب با میزان تنوع هندسی داده است؛ و (۴) هنگامی که افزونه سازی لرزش کانونی مقیاس را بدون K غیرقابل بازیابی می کند، این سهم به برتری قاطع در تمامی معیارها ($p \leq 10^{-24}$) می رسد.

۶.۴ تحلیل حساسیت نسبت به پارامترهای دوربین

یکی از اهداف اصلی این پژوهش، کاهش حساسیت تخمین عمق نسبت به پارامترهای هندسی دوربین، به ویژه ماتریس مشخصه دوربین K ، بوده است. در این بخش، رفتار مدل ها تحت تغییر این پارامترها به صورت کمی مورد تحلیل قرار می گیرد تا ارتباط عملی میان تحلیل های هندسی ارائه شده در فصل سوم و نتایج تجربی برقرار شود.

۱.۶.۴ آزمون جاروی K : آیا مدل واقعاً فاصله کانونی را می خواند؟

معیارهای تجمیعی مانند AbsRel نشان می دهند که ورودی K «سودمند» است، اما به این پرسش سازوکاری پاسخ نمی دهند که آیا مدل واقعاً مقدار فاصله کانونی را می خواند و مطابق هندسه تصویربرداری از آن استفاده می کند یا خیر. برای پاسخ، آزمونی طراحی شد که در این پژوهش «جاروی K »^۱ نامیده می شود: تصویر ورودی ثابت نگه داشته می شود و تنها مؤلفه های f_x, f_y در ماتریس K ورودی، در ضرایب $\{0/6, 0/8, 1/0, 1/25, 1/6\}$ ضرب می شوند. طبق معادله روزنه ای $u = fX/Z$ ، تصویری یکسان با فاصله کانونی α برابر، تنها با صفحه ای α برابر دورتر سازگار است؛ بنابراین مدلی که K را به درستی مصرف می کند باید عمق پیش بینی شده خود را متناسب با f باز مقیاس کند. سنجش کمی این رفتار، شیب رگرسیون

¹K-Sweep

(عمق پیش‌بینی شده) $\log$ بر حسب $\log(f)$ است: مقدار ایده‌آل ۱ (پیروی کامل از هندسه) و مقدار ۰ به معنای نادیده گرفتن کامل K است.

جدول ۱۵.۴: شیب لگاریتمی جاروی K (میانگین $\pm$ انحراف معیار روی ۲۰ تصویر آزمون): پاسخ عمق پیش‌بینی شده به مقیاس دهی مصنوعی فاصله کانونی. شیب ایده‌آل برای مدل آگاه از هندسه ۱ است.

زوج آموزشی	مدل پیشنهادی	مدل کنترل
دور ۲ (افزونه‌سازی هندسی)	0.06 ± 0.01	۰/۰۰
دور ۳ (+ لرزش کانونی)	0.93 ± 0.03	۰/۰۰


نتیجه این آزمون (جدول ۱۵.۴ و شکل ۲.۴) صریح‌ترین یافته سازوکاری این پژوهش است. مدل پیشنهادی دور ۲ — با وجود برتری آماری بر کنترل — شیب تنها ۰/۰۶ دارد؛ یعنی عملاً K را نمی‌خواند و برتری‌اش از نشانه‌های غیرمستقیم می‌آید. اما پس از آموزش با لرزش کانونی، شیب به ۰/۹۳ می‌جهد: خروجی مدل تقریباً دقیقاً همان‌گونه با f مقیاس می‌شود که معادله $u = fX/Z$ ایجاب می‌کند. جالب آنکه پارامتر دروازه اسکالر کدگذار دوربین در همین مدل همچنان کوچک است (۰/۲۴-); یعنی اندازه دروازه به‌تنهایی سنجۀ مناسبی برای میزان مصرف K نیست و بزرگی سیگنال آموخته‌شده در پشت دروازه است که تعیین‌کننده است.

لازم است تأکید شود که تفسیر درست این رفتار برای مدل متریک، «پاسخ‌گویی صحیح» به K است، نه «حساسیت نامطلوب»: هنگامی که فاصله کانونی واقعاً تغییر کند (مثلاً دوربینی با لنز متفاوت)، تصویر یکسان به‌واقع با صحنه‌ای در مقیاس متفاوت سازگار است و مدل باید پیش‌بینی خود را تغییر دهد؛ مدل کنترل که به هر K پاسخ یکسان می‌دهد، در چنین شرایطی به‌طور سیستماتیک خطا خواهد کرد. این همان پدیده‌ای است که در ارزیابی میدان دید متغیر زیربخش ۷.۵.۴ به‌صورت افت دقت مدل کنترل مشاهده شد.

۲.۶.۴ آزمون حذف و تحریف K : اثبات اتکای علی

آزمون جاروی K نشان داد که خروجی مدل با K حرکت می‌کند؛ آزمون مکملی لازم است تا نشان دهد دقت مدل نیز به K وابسته است و اطلاعات درست دوربین، جزء ضروری عملکرد آن است. برای این منظور، مدل پیشنهادی دور ۳ بر کل مجموعه آزمون در چهار شرایط ارزیابی شد: با K صحیح؛ با حذف کامل ورودی K ؛ و با K عمداً تحریف‌شده (f_x, f_y در ۷/۰ یا ۴/۱ ضرب‌شده، تصویر بدون تغییر).

نتایج (جدول ۱۶.۴) اتکای علی را از دو جهت اثبات می‌کند. نخست، حذف K دقت را به‌شدت تخریب می‌کند (AbsRel از ۰/۹۲ به ۱۴۷/۰، افت ۵۹ درصدی): مسیر پارامترهای دوربین در این مدل تزئینی نیست و بخش اساسی محاسبه مقیاس از آن عبور می‌کند. دوم — و از منظر سازوکاری مهم‌تر — بزرگی خطا تحت تحریف f به‌صورت کمی با پیش‌بینی هندسی سازگار است: با شیب جاروی ۰/۹۳، انتظار می‌رود تحریف



شکل ۲.۴: آزمون جاروی K : میانه عمق پیش‌بینی‌شده (نرمال‌شده به حالت ضریب ۱، میانگین هندسی روی ۲۰ تصویر آزمون) در برابر ضریب مقیاس مصنوعی فاصله کانونی؛ محورهای لگاریتمی‌اند. مدل پیشنهادی دور ۳ تقریباً به‌طور کامل بر خط ایده‌آل شیب ۱ منطبق است (در ضریب ۶/۱ دقیقاً عمق ۶/۱ برابر پیش‌بینی می‌کند)، همان معماری در دور ۲ تقریباً تخت است، و مدل کنترل طبق تعریف هیچ پاسخی به K ندارد. داده‌ها حاصل اجرای واقعی آزمون بر نقاط واریسی آموزش‌دیده‌اند.

جدول ۱۶.۴: آزمون حذف و تحریف K بر مدل پیشنهادی دور ۳ (ViT-L متریک، $n = ۶۵۴$ بدون تراز). پیش‌بینی نظری: با شیب جاروی $s = ۰/۹۳$ ، تحریف f در ضریب X باید AbsRel را به حدود $|X^s - ۱|$ برساند.

شرایط ورودی K	$\downarrow$ AbsRel	$\delta_1 \uparrow$	$\downarrow$ RMSE
K صحیح	۰۹۲۴.۰	۹۳۳۹.۰	۳۴۵۵.۰
K حذف‌شده	۱۴۶۷.۰	۸۴۴۹.۰	۴۸۲۶.۰
$f \times ۰/۷$	۲۸۸۷.۰	۱۳۱۰.۰	۹۱۵۳.۰
$f \times ۱/۴$	۴۲۷۴.۰	۱۲۰۹.۰	۲۱۱۸.۱

$f \times ۰/۷$ خطای مقیاسی حدود $۰/۲۸ \approx |۰/۷^{۰/۹۳} - ۱|$ و تحریف $f \times ۱/۴$ حدود $۰/۳۷ \approx |۱/۴^{۰/۹۳} - ۱|$ ایجاد کند؛ مقادیر مشاهده‌شده (۲۸۹/۰ و ۴۲۷/۰، شامل خطای پایه مدل) دقیقاً در همین مرتبه‌اند و سقوط δ_1 به حدود $۱۳/۰$ نشان می‌دهد تقریباً تمام پیکسل‌ها به اندازه همین ضریب مقیاس جابه‌جا شده‌اند. به بیان دیگر، مدل نه‌تنها از K استفاده می‌کند، بلکه به همان شکلی استفاده می‌کند که معادله تصویربرداری روزنه‌ای تجویز می‌کند — تصادف یا هم‌پستگی جانبی نمی‌تواند چنین انطباق کمی‌ای تولید کند.

این یافته یک پیامد کاربردی نیز دارد که در بخش محدودیت‌ها (فصل پنجم) بازتاب یافته است: مدلی که به K اتکای علی دارد، به صحت K نیز حساس است؛ در کاربردهایی که کالبراسیون نادقیق است، این حساسیت باید در طراحی سامانه لحاظ شود.

۳.۶.۴ رفتار متفاوت معیارهای AbsRel و RMSE

برای تحلیل دقیق‌تر حساسیت مدل‌ها، از دو معیار AbsRel و RMSE به صورت هم‌زمان استفاده شده است. نتایج نشان می‌دهد که این دو معیار رفتارهای متفاوتی نسبت به تغییر پارامترهای دوربین دارند. معیار AbsRel به دلیل نرمال‌سازی خطا نسبت به مقدار عمق مرجع، در بسیاری از موارد تغییرات ناشی از مقیاس را پنهان می‌کند. به عبارت دیگر، حتی در شرایطی که خروجی عمق دچار تغییر مقیاس قابل توجه شده است، مقدار AbsRel ممکن است تغییر اندکی را نشان دهد یا حتی تقریباً ثابت باقی بماند. در مقابل، معیار RMSE به طور مستقیم به مقدار مطلق عمق حساس است و تغییرات مقیاس ناشی از تغییر ماتریس K را به وضوح منعکس می‌کند. نتایج تجربی نشان می‌دهد که در شرایط تغییر پارامترهای دوربین، افزایش RMSE در مدل پایه به مراتب شدیدتر از مدل پیشنهادی است، که این موضوع بیانگر پایداری بیشتر مدل پیشنهادی از منظر هندسی است.

۴.۶.۴ ارتباط با تحلیل هندسی فصل سوم

یافته‌های این بخش به صورت مستقیم با تحلیل‌های هندسی ارائه شده در فصل سوم هم‌راستا هستند. در فصل سوم نشان داده شد که عدم لحاظ صریح ماتریس K در فرآیند تخمین عمق منجر به ابهام مقیاس و وابستگی خروجی به پارامترهای تصویربرداری می‌شود. نتایج تجربی این فصل تأیید می‌کنند که ادغام صریح ماتریس مشخصه دوربین می‌تواند این ابهام را کاهش دهد و تخمین عمق را از یک پیش‌بینی نسبی به تخمینی با مقیاس پایدار نزدیک کند. بدین ترتیب، تحلیل حساسیت انجام شده در این بخش نه تنها کارایی عملی مدل پیشنهادی را نشان می‌دهد، بلکه اعتبار تجربی چارچوب هندسی ارائه شده در فصل سوم را نیز تأیید می‌کند.

۷.۴ ملاحظات کیفی و حدود شواهد بصری

بازبینی نقشه‌های عمق در جریان توسعه برای یافتن خروجی صفر، پیکسل‌های مرده و شکست مقیاس به کار رفت؛ به‌ویژه همین بازرسی، فروپاشی دو اجرای اولیه ViT-L را آشکار کرد. با این حال، شبکه تصویری همسان و قابل بازتولیدی از خروجی تمام نقاط واریسی در مصنوعات نهایی آزمایش‌ها نگهداری نشده است. از این رو، درج یک شکل نمونه یا ادعای برتری بصری می‌توانست گزینشی و غیرقابل ممیزی باشد و آگاهانه از نسخه نهایی حذف شد.

شاهد اصلی برای تغییر رفتار خروجی، به جای قضاوت بصری، آزمون‌های عددی سطح تصویر است: جاروی K پاسخ تقریباً خطی مقیاس پیش‌بینی را نشان می‌دهد، آزمون حذف K افت ۵۹ درصدی ایجاد می‌کند و مقایسه زوجی روی ۶۵۴ تصویر، بهبود AbsRel و RMSE را اندازه‌گیری می‌کند. این شواهد مستقیماً به فرضیه مصرف اطلاعات دوربین مربوط‌اند و از انتخاب چند تصویر مطلوب مصون‌تر هستند.

برای بازتولید کیفی در کار آینده باید شناسه تصاویر پیش از مشاهده قفل شود و برای هر نمونه، تصویر ورودی، عمق مرجع، خروجی کنترل و خروجی مدل پیشنهادی با یک نگاشت رنگ و بازه عمق یکسان ذخیره گردد. تا زمان اجرای چنین پروتکلی، نتیجه‌گیری این پایان‌نامه به شواهد کمی و آزمون‌های علی گزارش شده محدود می‌ماند.

۸.۴ تحلیل موردی دیتاست CityScapes

در میان دیتاست‌های مورد استفاده در این پژوهش، دیتاست CityScapes دارای ویژگی‌هایی است که آن را از سایر مجموعه‌داده‌ها متمایز می‌کند. به همین دلیل، رفتار خطاها و نتایج حاصل از ارزیابی مدل‌ها بر روی این دیتاست نیازمند تحلیل مستقل و موردی است.

۱.۸.۴ ماهیت و ویژگی‌های خاص دیتاست CityScapes

CityScapes یک دیتاست واقعی شهری^۱ است که تصاویر آن در شرایط متنوع نوری، آب‌وهوایی و با سناریوهای پیچیده ترافیکی ثبت شده‌اند. صحنه‌ها شامل اجسام متعدد در فواصل بسیار متنوع از دوربین هستند، از خودروها و عابران نزدیک تا ساختمان‌ها و پس‌زمینه‌های بسیار دوردست.

برخلاف برخی دیتاست‌های دیگر، CityScapes به صورت ذاتی برای تخمین عمق تک‌دوربین طراحی نشده و عمق مرجع آن از طریق تطبیق استریو و بازسازی سه‌بعدی به دست آمده است. این موضوع منجر به تفاوت‌های ساختاری در کیفیت و یکنواختی داده‌های عمق مرجع می‌شود.

۲.۸.۴ تحلیل کیفیت عمق مرجع

عمق مرجع در CityScapes دارای چگالی و دقت یکنواخت در سراسر تصویر نیست. در نواحی نزدیک به دوربین و بر روی اجسام برجسته، عمق مرجع از کیفیت نسبتاً بالایی برخوردار است، اما در نواحی دوردست،

¹Real-world Urban Dataset

لبه‌ها و سطوح با بافت ضعیف، خطاها و ناپیوستگی‌های قابل توجهی مشاهده می‌شود. این ناهمگنی در کیفیت عمق مرجع باعث می‌شود که معیارهای متریک، به‌ویژه RMSE و SiLog نسبت به نویز و خطاهای محلی حساسیت بیشتری نشان دهند. در نتیجه، مقادیر خطای گزارش شده لزوماً بازتاب‌دهنده صرف عملکرد واقعی مدل نیستند، بلکه تا حدی تحت تأثیر محدودیت‌های داده مرجع قرار دارند.

۳.۸.۴ دلیل رفتار متفاوت خطاها

نتایج تجربی نشان می‌دهد که رفتار خطاها در CityScapes با برخی دیتاست‌های دیگر مانند NYUv2 یا VKITTI تفاوت معناداری دارد. یکی از دلایل اصلی این تفاوت، دامنه بسیار وسیع عمق در صحنه‌های شهری است، که از چند متر تا ده‌ها متر متغیر است. در چنین شرایطی، خطاهای کوچک نسبی می‌توانند به خطاهای مطلق بزرگ در معیارهای متریک منجر شوند. از سوی دیگر، وجود نواحی دوردست با عمق نامطمئن باعث می‌شود که مدل‌هایی با رفتار پایدارتر از نظر مقیاس الزاماً بهبود یکنواختی در تمامی معیارها نشان ندهند.

۴.۸.۴ محدودیت همسان‌سازی نتایج با سایر دیتاست‌ها

با توجه به ویژگی‌های ذکر شده، همسان‌سازی مستقیم مقادیر خطا بین CityScapes و سایر دیتاست‌ها دارای محدودیت‌های ذاتی است. تفاوت در نحوه تولید عمق مرجع، دامنه عمق صحنه، و کیفیت داده‌ها باعث می‌شود که مقایسه عددی ساده بدون در نظر گرفتن این عوامل می‌تواند منجر به برداشت نادرست شود. از این رو، در این پژوهش، نتایج CityScapes بیشتر به‌عنوان یک مطالعه موردی برای بررسی رفتار مدل‌ها در شرایط شهری واقعی و پیچیده مورد استفاده قرار گرفته است، نه به‌عنوان مرجع مطلق برای مقایسه کمی با سایر دیتاست‌ها. این رویکرد امکان تحلیل واقع‌بینانه‌تر و تفسیر دقیق‌تر نتایج را فراهم می‌کند.

۹.۴ بحث و تفسیر نتایج

در این بخش، نتایج کمی و کیفی ارائه شده در فصل حاضر به‌صورت یکپارچه مورد بحث و تفسیر قرار می‌گیرند. هدف اصلی این بخش، فراتر رفتن از گزارش صرف اعداد و نمودارها و پاسخ‌گویی صریح به سوالات

تحقیق، تبیین رفتار مدل‌ها، و تفسیر یافته‌ها در چارچوب هندسهٔ تصویربرداری و ادبیات موجود در حوزهٔ تخمین عمق تک‌دوربین است.

۱.۹.۴ جمع‌بندی تحلیلی نتایج کمی و کیفی

نتایج کمی نشان دادند که مدل پایه Depth Anything V2، اگرچه در معیارهای غیر متریک عملکرد رقابتی و قابل قبولی دارد، اما در معیارهای متریک، به‌ویژه SiLog و RMSE، رفتاری ناپایدار نسبت به تغییر دیتاست و پارامترهای دوربین از خود نشان می‌دهد. این ناپایداری به‌صورت اختلاف‌های معنادار آماری در مقایسهٔ بین‌دیتاستی آشکار شد.

در مقابل، مدل پیشنهادی که در آن ماتریس مشخصهٔ دوربین به‌صورت صریح لحاظ شده است، بهبود قابل توجهی در معیارهای متریک و کاهش معنادار حساسیت نسبت به تغییر دیتاست‌ها نشان داد. این بهبودها نه تنها از نظر آماری معنادار بودند، بلکه در تحلیل‌های کیفی نیز به‌صورت افزایش یکنواختی سطوح، پایداری مقیاس اجسام و بازنمایی واقع‌بینانه‌تر نواحی دوردست مشاهده شدند.

هم‌راستایی نتایج کمی و کیفی نشان می‌دهد که بهبودهای حاصل شده صرفاً نتیجهٔ بهینه‌سازی عددی معیارها نیستند، بلکه بیانگر تغییر معنادار در نحوهٔ درک مدل از ساختار هندسی صحنه هستند.

۲.۹.۴ پاسخ به سوالات تحقیق

یافته‌های این پژوهش امکان پاسخ‌گویی مستقیم به سوالات تحقیق مطرح شده در فصل اول را فراهم می‌کند. نخست، در پاسخ به این سوال که آیا می‌توان با تکیه بر یک مدل بنیادین تک‌دوربین به عمق متریک پایدار دست یافت، نتایج نشان می‌دهد که فاین‌تیون نظارتی مدل پایه دقت متریک را به‌طور چشمگیری بهبود می‌دهد؛ با این حال، وقتی مقیاس در داده عمداً مبهم شود، مدل فاقد K با یک کف خطای کاهش‌ناپذیر مواجه می‌شود. بنابراین، اطلاعات تصویر می‌تواند مقیاس تقریبی را از نشانه‌های معنایی بیاموزد، اما در حالت هندسی مبهم تضمینی برای بازیابی یکتای مقیاس ندارد.

دوم، در خصوص نقش ماتریس مشخصهٔ دوربین، نتایج به‌وضوح نشان می‌دهند که ادغام صریح K می‌تواند وابستگی خروجی عمق به پارامترهای تصویربرداری را کاهش داده و پایداری متریک مدل را به‌طور معناداری افزایش دهد.

در نهایت، پژوهش حاضر نشان می‌دهد که بهبود معیارهای متریک نه از طریق تغییرات پیچیده در معماری، بلکه با افزودن اطلاعات هندسی مناسب و هم‌راستا با فیزیک تصویربرداری قابل دستیابی است.

۳.۹.۴ وابستگی سهم پارامترهای دوربین به پروتکل ارزیابی و ظرفیت مدل

یافته‌های مطالعه کنترل‌شده بخش ۵.۴ تصویری دقیق‌تر و مشروط‌تر از سهم پارامترهای درونی دوربین ترسیم می‌کنند که شایسته بحث مستقل است.

نخست، سهم این پارامترها به پروتکل ارزیابی وابسته است. در پروتکل نسبی، تراز مقیاس و جابجایی به‌ازای هر تصویر، دقیقاً همان مؤلفه اطلاعاتی را از ارزیابی حذف می‌کند که میدان دید و فاصله کانونی در اختیار مدل می‌گذارند؛ یعنی مقیاس مطلق صحنه. از این رو، مشاهده برتری نیافتن مدل آگاه از K بر مدل کنترل در پروتکل نسبی ViT-L نه شاهدهی علیه فرضیه پژوهش، بلکه پیامد ساختاری سازوکار ارزیابی است. در مقابل، در ارزیابی متریک بدون تراز، برتری مدل پیشنهادی در تمامی معیارها ظاهر شده و در RMSE در هر دو دور آزمایش معنادار است. مهم‌تر آنکه الگوی پاسخ به دوز — رشد فاصله دو مدل با افزایش تنوع میدان دید در داده — نشان می‌دهد که این برتری، پیوند علی با اطلاعات هندسی دارد و صرفاً نوسان آماری نیست.

دوم، سهم پارامترهای دوربین به ظرفیت انکودر نیز وابسته است. در اندازه ViT-S، حتی در پروتکل نسبی، افزودن K بهبود کوچک اما معنادار ایجاد کرد؛ در حالی که در ViT-L چنین نبود. تبیین محتمل آن است که انکودر بزرگ‌تر، سرنخ‌های پرسپکتیوی و معنایی تصویر (نظیر اندازه ظاهری اجسام آشنا و هندسه خطوط گریز) را با دقتی استخراج می‌کند که برای بازسازی ساختار نسبی، اطلاعات مکمل چندانی از K باقی نمی‌ماند؛ حال آنکه انکودر کوچک‌تر از هر سیگنال کمکی بهره می‌برد. این مشاهده با یافته‌های مربوط به جبران میدان دید در ادبیات [۱۳] هم‌راستا است و مرزهای سودمندی رویکرد پیشنهادی را به‌صورت تجربی مشخص می‌کند.

سوم، نتایج نشان دادند که بخش قابل توجهی از بهبود مطلق نسبت به مدل منتشرشده، حاصل ترکیب فاین‌تیون درون‌دامنه‌ای بدون نشت و افزونه‌سازی هندسی صحیح است و سهم خالص ورودی K ، افزایشی و در مرتبه کوچک‌تری قرار دارد. گزارش شفاف این تفکیک، برای جلوگیری از بیش‌برآورد سهم هر مؤلفه ضروری است و اعتبار علمی ادعاهای پژوهش را تضمین می‌کند.

۴.۹.۴ مقایسه غیرمستقیم با ادبیات موضوع

در بسیاری از مطالعات پیشین در حوزه تخمین عمق تک‌دوربین، تمرکز اصلی بر بهبود معیارهای غیرمتریک یا استفاده از نرمال‌سازی‌های ضمنی برای کاهش اثر مقیاس بوده است. در این رویکردها، اطلاعات دوربین یا نادیده گرفته شده یا به‌صورت ضمنی در داده‌ها نهفته فرض شده است.

در مقابل، یافته‌های این پژوهش نشان می‌دهد که نادیده گرفتن صریح هندسه دوربین می‌تواند منجر به ارزیابی‌های همراه‌کننده در معیارهای نرمال‌شده شود، در حالی که خطاهای متریک واقعی پنهان باقی می‌مانند.

از این منظر، نتایج حاضر هم‌راستا با دیدگاه‌هایی است که بر لزوم بازگشت به مدل‌های فیزیکی تصویربرداری در طراحی شبکه‌های یادگیری عمیق تأکید دارند، هرچند مسیر پیاده‌سازی آن‌ها در این پژوهش متفاوت و ساده‌تر دنبال شده است.

۵.۹.۴ تفسیر نتایج در چارچوب هندسه تصویربرداری

از منظر هندسه تصویربرداری، عمق متریک به‌صورت مستقیم به پارامترهای کانونی و هندسه پروجکشن وابسته است. بنابراین، مدلی که تنها بر اطلاعات تصویری تکیه دارد، در بهترین حالت می‌تواند یک بازنمایی نسبی از عمق را بیاموزد.

نتایج این پژوهش تأیید می‌کنند که ادغام صریح ماتریس مشخصه دوربین در فرآیند تخمین عمق، در واقع محدودیت‌های فیزیکی سیستم تصویربرداری را به فضای یادگیری تحمیل می‌کند. این محدودیت‌ها باعث می‌شوند که مدل به جای اتکا به هم‌بستگی‌های آماری ناپایدار، وابستگی‌های هندسی معنادار میان تصویر و عمق را یاد بگیرد.

در نتیجه، بهبود پایداری متریک مشاهده‌شده را می‌توان به‌عنوان پیامد مستقیم هم‌راستا شدن معماری یادگیری با اصول هندسی مدل سوراخ‌سوزنی تفسیر کرد. این تفسیر نشان می‌دهد که ترکیب آگاهانه یادگیری عمیق و هندسه کلاسیک می‌تواند مسیر مؤثری برای پیشرفت در تخمین عمق تک‌دوربین فراهم کند.

۱۰.۴ جمع‌بندی فصل نتایج

در این فصل، نتایج حاصل از ارزیابی کمی و کیفی مدل پیشنهادی و مدل پایه در چارچوبی منسجم ارائه و تحلیل شد. هدف اصلی این فصل، پاسخ‌گویی تجربی به سوالات تحقیق و بررسی میزان تحقق اهداف پژوهش بر اساس داده‌ها و آزمایش‌های انجام‌شده بود.

نتایج کمی نشان دادند که مدل پایه Depth Anything V2، علی‌رغم عملکرد مناسب در معیارهای غیرمتریک، در معیارهای متریک رفتاری ناپایدار نسبت به تغییر دیتاست و پارامترهای دوربین دارد. این ناپایداری به‌صورت اختلاف‌های معنادار آماری در مقایسه‌های بین‌دیتاستی و حساسیت بالا در معیارهایی مانند RMSE و SiLog مشاهده شد.

در مقابل، مدل پیشنهادی که در آن ماتریس مشخصه دوربین به‌صورت صریح در فرآیند تخمین عمق لحاظ شده است، بهبود معناداری در معیارهای متریک نشان داد و حساسیت آن نسبت به تغییر شرایط تصویربرداری

به طور محسوسی کاهش یافت. این بهبودها نه تنها از نظر آماری معنادار بودند، بلکه در تحلیل‌های کیفی نیز به صورت پایداری مقیاس، یکنواختی بهتر سطوح و بازنمایی واقع‌بینانه‌تر نواحی دوردست قابل مشاهده بودند. تحلیل حساسیت نسبت به پارامترهای دوربین نشان داد که معیارهای نرمال‌شده‌ای مانند AbsRel توانایی محدودی در آشکارسازی خطاهای مقیاس دارند، در حالی که معیارهای متریک رفتار هندسی واقعی مدل‌ها را بهتر منعکس می‌کنند. این یافته به طور مستقیم تحلیل‌های نظری فصل سوم در خصوص نقش ماتریس K در بازیابی عمق متریک را تأیید می‌کند.

همچنین، تحلیل موردی دیتاست CityScapes نشان داد که تفاوت در ماهیت داده‌ها و کیفیت عمق مرجع می‌تواند بر رفتار معیارهای ارزیابی اثرگذار باشد و تفسیر نتایج نیازمند در نظر گرفتن محدودیت‌های ذاتی هر دیتاست است.

مطالعه کنترل‌شده بخش ۵.۴، که پس از اصلاح تفکیک آموزش/آزمون NYUv2 و راستی‌آزمایی زنجیره ارزیابی از طریق بازتولید نتایج مقاله مرجع انجام شد، دقیق‌ترین سنجش این پژوهش از سهم پارامترهای درونی دوربین را فراهم آورد. بر اساس این مطالعه، مدل پیشنهادی ViT-L در پروتکل استاندارد، از مدل منتشرشده Depth Anything V2 در تمامی معیارها به صورت معنادار آماری بهتر است (کاهش AbsRel از ۰/۴۲۵ به ۰/۳۷۷ در پروتکل نسبی و از ۲۰۷/۰ به ۰/۷۹ در ارزیابی متریک). سهم خالص ورودی K در برابر مدل کنترل هم‌داده، در پروتکل نسبی تنها برای انکودر کوچک معنادار بود، اما در ارزیابی متریک بدون تراز، در هر دو دور آزمایش و به صورت فزاینده با شدت تنوع میدان دید (الگوی پاسخ به دوز) آشکار شد. این نتایج، همراه با تحلیل توضیحی نقش سازوکار تراز در پنهان‌سازی اطلاعات مقیاس، درک دقیق‌تری از شرایط سودمندی اطلاعات هندسی دوربین به دست می‌دهند.

در مجموع، نتایج این فصل نشان می‌دهد که ادغام آگاهانه اطلاعات هندسی دوربین در مدل‌های تخمین عمق تک‌دوربین می‌تواند گامی مؤثر در جهت دستیابی به عمق متریک پایدار باشد. این فصل، با ارائه شواهد تجربی، زمینه را برای جمع‌بندی نهایی پژوهش و بیان دستاوردها، محدودیت‌ها و مسیرهای آینده تحقیق در فصل بعد فراهم می‌کند.

فصل ۵

بحث و نتیجه‌گیری

۱.۵ مقدمه

این فصل به جمع‌بندی نهایی پژوهش حاضر و تبیین برداشت‌های حاصل از یافته‌های آن اختصاص دارد. در فصل‌های پیشین، مسئله پژوهش، پیشینه علمی مرتبط، روش پیشنهادی و نتایج تجربی به صورت گام به گام ارائه و تحلیل شدند. در این مرحله، هدف اصلی پاسخ‌گویی به این پرسش بنیادین است که یافته‌های به دست آمده چه معنایی دارند و چه ارزش علمی و عملی برای حوزه تخمین عمق تک‌دوربین ایجاد می‌کنند.

در فصل نخست، ضرورت پرداختن به مسئله تخمین عمق متریک و چالش‌های ذاتی آن، به ویژه ابهام مقیاس و وابستگی به پارامترهای دوربین، مطرح شد. در ادامه، مرور ادبیات نشان داد که بخش عمده‌ای از روش‌های موجود، یا به عمق غیرمتریک بسنده کرده‌اند و یا نقش هندسه تصویربرداری را به صورت ضمنی و نادقیق در نظر گرفته‌اند. در فصل سوم، چارچوب روش شناختی پژوهش ارائه شد و نشان داده شد که چگونه می‌توان با ادغام صریح ماتریس مشخصه دوربین در معماری یک مدل یادگیری عمیق، رابطه میان تصویر، هندسه دوربین و عمق متریک را به صورت مستقیم مدل‌سازی کرد. در فصل چهارم نیز، نتایج کمی و کیفی حاصل از آزمایش‌ها برای ارزیابی صحت این رویکرد گزارش و تحلیل شدند.

اکنون در فصل حاضر، با تکیه بر نتایج عملی استخراج شده و بدون ارائه داده‌ها یا آزمایش‌های جدید، برداشت نهایی از یافته‌های پژوهش مطرح می‌شود. در این فصل، تلاش می‌شود ضمن جمع‌بندی دستاوردهای اصلی، میزان تحقق اهداف پژوهش مشخص شود، نوآوری‌های تئوریک و عملی کار تبیین گردد، و محدودیت‌ها و مسیرهای آتی پژوهش در چارچوب مسئله مورد مطالعه بیان شوند. بدین ترتیب، این فصل نقش حلقه پایانی تر را ایفا می‌کند و ارتباط منطقی میان مسئله اولیه، روش انجام تحقیق و نتایج به دست آمده را به صورت یکپارچه

روشن می‌سازد.

۲.۵ جمع‌بندی یافته‌های اصلی پژوهش

هدف اصلی این پژوهش، بررسی امکان دستیابی به تخمین عمق متریک پایدار با استفاده از یک مدل بنیادین تخمین عمق تک‌دوربین و تحلیل نقش اطلاعات هندسی دوربین در تحقق این هدف بود. یافته‌های به‌دست‌آمده در فصل‌های سوم و چهارم به‌صورت منسجم نشان می‌دهند که ابهام مقیاس، نه یک ضعف پیاده‌سازی، بلکه یک محدودیت ذاتی در مدل‌هایی است که صرفاً بر اطلاعات تصویری تکیه دارند.


نتایج نشان داد که مدل‌های متداول تخمین عمق تک‌دوربین، از جمله مدل پایه مورد بررسی در این پژوهش، توانایی یادگیری ساختار نسبی عمق صحنه را دارند، اما در غیاب اطلاعات صریح مربوط به هندسه دوربین، قادر به بازیابی مقیاس فیزیکی پایدار نیستند. این مسئله به‌صورت ناپایداری خروجی عمق در برابر تغییر دیتاست و پارامترهای تصویربرداری در معیارهای متریک آشکار شد، در حالی که معیارهای نرمال‌شده در بسیاری از موارد این ناپایداری را پنهان می‌کنند.

در مقابل، یافته‌های این پژوهش نشان می‌دهد که ادغام صریح ماتریس مشخصه دوربین در فرآیند تخمین عمق می‌تواند این محدودیت ذاتی را تا حد قابل توجهی کاهش دهد. مدل پیشنهادی با بهره‌گیری از اطلاعات هندسی دوربین، وابستگی خروجی عمق به شرایط تصویربرداری را کاهش داده و به تخمینی پایدارتر از نظر مقیاس فیزیکی دست یافته است. این بهبود نه تنها در ارزیابی‌های کمی، بلکه در تحلیل‌های کیفی نیز به‌صورت یکنواختی بهتر سطوح، حفظ مقیاس اجسام و بازنمایی واقع‌بینانه‌تر نواحی دوردست مشاهده شد.

مطالعه کنترل‌شده نهایی بر روی پروتکل استاندارد NYUV2 (بخش ۵.۴)، این یافته‌ها را با دقت آماری مشخص‌تری صورت‌بندی کرد. مدل پیشنهادی در پیکربندی ViT-L، مدل منتشرشده Depth Anything V2 را در تمامی معیارهای ارزیابی و با معناداری آماری بالا پشت سر گذاشت: در پروتکل نسبی، کاهش AbsRel از ۰/۴۲۵ به ۰/۳۷۷ ($p = 2/5 \times 10^{-8}$)، آزمون t زوجی، ($n = 654$) و در ارزیابی متریک بدون تراز، کاهش AbsRel از ۰/۲۰۷ به ۰/۱۷۹ (بهبود ۶/۲ برابری). در عین حال، مقایسه با مدل کنترل هم‌داده نشان داد که سهم خالص ورودی پارامترهای دوربین، وابسته به پروتکل ارزیابی است: در ارزیابی نسبی که تراز مقیاس به‌ازای هر تصویر، اطلاعات مقیاس را حذف می‌کند، این سهم تنها در انکودر کوچک معنادار بود؛ اما در ارزیابی متریک، برتری مدل آگاه از K در دو اجرای مستقل تکرار شد (RMSE) با $p = 4/9 \times 10^{-3}$ و $p = 6/5 \times 10^{-5}$ و با افزایش تنوع میدان دید در داده‌های آموزشی، به‌صورت نظام‌مند بزرگ‌تر گردید. نقطه اوج این الگوی پاسخ به دوز، آموزش با افزونه‌سازی لرش کانونی بود (زیربخش ۷.۵.۴) که مقیاس مطلق را بدون K اساساً غیرقابل بازیابی

می‌کند: در این پیکربندی، مدل آگاه از K در تمامی معیارها با معناداری در مرتبه $10^{-24} \leq p$ از مدل کنترل هم‌داده و هم‌بذر پیشی گرفت (AbsRel: 0.85% در برابر 1.03%) و آزمون سازوکاری جاروی K نشان داد که خروجی مدل تقریباً دقیقاً مطابق معادله روزنه‌ای با فاصله کانونی مقیاس می‌شود (شیب لگاریتمی 0.93% در برابر مقدار ایده‌آل ۱؛ مدل کنترل: صفر). مطالعه فروکاست، عامل علی را به‌طور قطعی به خود افزونه‌سازی لرزش کانونی منتسب کرد (بازتولید کامل اثر λ بدون تغییر: AbsRel: 0.83% در برابر 1.07% کنترل، $p \leq 10^{-39}$ ، شیب جاروی 0.97%) و آزمون حذف و تحریف K نشان داد که این اتکا علی است: حذف K دقت را 59% درصد تخریب می‌کند و تحریف عمده فاصله کانونی، خطا را دقیقاً به اندازه‌ای که هندسه روزنه‌ای پیش‌بینی می‌کند افزایش می‌دهد. مجموعه این شواهد — الگوی پاسخ به دوز در چهار زوج آموزشی مستقل، برتری همه‌جانبه آماری، و انطباق کمی رفتار مدل با هندسه تصویربرداری — سودمندی علی اطلاعات هندسی دوربین را به‌صورت هم‌گرا اثبات می‌کند.

همچنین، تحلیل بین‌دیتاستی نتایج نشان داد که پایداری متریک مدل پیشنهادی در محیط‌های متنوع داخلی و خارجی حفظ می‌شود، هرچند کیفیت و ماهیت داده‌های عمق مرجع می‌تواند بر مقادیر مطلق خطا اثرگذار باشد. مطالعه موردی دیتاست CityScapes نشان داد که تفسیر نتایج باید با در نظر گرفتن محدودیت‌های ذاتی هر دیتاست انجام شود و مقایسه مستقیم خطاها بدون توجه به کیفیت داده‌های مرجع می‌تواند گمراه‌کننده باشد. در مجموع، یافته‌های این پژوهش نشان می‌دهد که دستیابی به عمق متریک پایدار در تخمین عمق تک‌دوربین نه از طریق پیچیده‌تر کردن معماری شبکه، بلکه از طریق هم‌راستا کردن مدل یادگیری با اصول هندسه تصویربرداری امکان‌پذیر است. این نتیجه، چارچوب نظری و عملی ارائه‌شده در این پژوهش را تأیید می‌کند و مبنایی برای تفسیر نوآوری‌ها، محدودیت‌ها و مسیرهای آتی تحقیق در بخش‌های بعدی این فصل فراهم می‌سازد.



شکل ۱.۵: نمای کلی از فرآیند پژوهش: حرکت از شناسایی یک محدودیت ذاتی در مدل‌های موجود تا ارائه راهکار هندسه‌آگاه و در نهایت دستیابی به پایداری متریک در تخمین عمق.

۳.۵ تفسیر نهایی نتایج در چارچوب هندسه تصویربرداری

یافته‌های این پژوهش را می‌توان به‌صورت منسجم در چارچوب هندسه تصویربرداری و مدل فیزیکی دوربین تفسیر کرد. در مدل سوراخ‌سوزنی، رابطه میان مختصات تصویر و عمق صحنه به‌صورت مستقیم به پارامترهای

کانونی و هندسهٔ پروجکشن وابسته است. از این رو، عمق متریک ذاتاً یک کمیت هندسی است و بازیابی آن بدون اطلاع از پارامترهای دوربین به صورت یکتا امکان‌پذیر نیست.

نتایج تجربی این پژوهش نشان دادند که مدل‌هایی که تنها بر اطلاعات تصویری تکیه دارند، در بهترین حالت قادر به یادگیری ساختار نسبی عمق هستند. این رفتار با تحلیل‌های نظری فصل سوم هم‌خوانی دارد، زیرا در غیاب ماتریس مشخصهٔ دوربین، نداشت تصویر به عمق دارای درجه‌ای از آزادی مقیاس است که شبکهٔ یادگیری عمیق نمی‌تواند آن را صرفاً از دادهٔ تصویری حذف کند. به همین دلیل، پایداری مشاهده‌شده در معیارهای غیرمتریک لزوماً به معنای بازیابی صحیح عمق فیزیکی نیست.

در مقابل، زمانی که اطلاعات هندسی دوربین به صورت صریح در فرآیند تخمین عمق لحاظ می‌شود، مدل یادگیری با محدودیت‌های فیزیکی سیستم تصویربرداری هم‌راستا می‌گردد. نتایج این پژوهش نشان می‌دهد که ادغام صریح ماتریس مشخصهٔ دوربین در عمل نقش یک قید هندسی را ایفا می‌کند که فضای پاسخ‌های ممکن شبکه را محدود می‌سازد. این محدودسازی باعث می‌شود که مدل به جای اتکا به هم‌بستگی‌های آماری ناپایدار، وابستگی‌های هندسی معنادار میان تصویر و عمق را بیاموزد.

تحلیل رفتار معیارهای ارزیابی نیز از این تفسیر هندسی پشتیبانی می‌کند. معیارهای نرمال‌شده، به دلیل حذف ضمنی اثر مقیاس، نمی‌توانند تغییرات ناشی از پارامترهای دوربین را به خوبی منعکس کنند، در حالی که معیارهای متریک مستقیماً به روابط پروجکشن وابسته‌اند و نسبت به خطاهای هندسی حساس هستند. بهبود پایداری در این معیارها نشان‌دهندهٔ آن است که مدل پیشنهادی توانسته است وابستگی خروجی عمق به هندسهٔ تصویربرداری را به صورت سازگارتر مدل‌سازی کند.

از منظر هندسی، یافته‌های این پژوهش تأیید می‌کنند که یادگیری عمیق، بدون لحاظ صریح مدل تصویربرداری، نمی‌تواند جایگزین کامل قیود فیزیکی شود. در عوض، ترکیب آگاهانهٔ یادگیری داده‌محور با مدل‌های کلاسیک هندسی می‌تواند به تخمین‌هایی منجر شود که هم از نظر بصری معنادارند و هم از نظر فیزیکی پایدار. این تفسیر نشان می‌دهد که دستاورد اصلی پژوهش حاضر نه صرفاً بهبود یک مدل خاص، بلکه ارائهٔ شواهد تجربی برای اهمیت ادغام هندسهٔ تصویربرداری در طراحی مدل‌های تخمین عمق تک‌دوربین است.

۴.۵ نوآوری‌های تحقیق

بر اساس یافته‌های نظری و تجربی ارائه‌شده در این پژوهش، نوآوری‌های تحقیق حاضر را می‌توان در دو سطح تئوریک و عملی دسته‌بندی کرد. این نوآوری‌ها نه بر مبنای ادعاهای کلی، بلکه بر اساس نتایج عملی استخراج‌شده و تحلیل‌های انجام‌شده در فصل‌های سوم و چهارم تشریح می‌شوند.

۱.۴.۵ نوآوری تئوریک

نوآوری تئوریک اصلی این پژوهش در بازتعریف مسئله تخمین عمق تک‌دوربینه در چارچوب هندسه تصویربرداری نهفته است. در بسیاری از کارهای پیشین، تخمین عمق به‌عنوان یک مسئله صرفاً داده‌محور مدل‌سازی شده و نقش پارامترهای هندسی دوربین یا نادیده گرفته شده یا به‌صورت ضمنی در داده‌ها فرض شده است.

در این پژوهش نشان داده شد که ابهام مقیاس در تخمین عمق تک‌دوربینه یک محدودیت ذاتی هندسی است و نه صرفاً یک ضعف در معماری شبکه یا فرآیند آموزش. بر این اساس، نوآوری تئوریک تحقیق حاضر در این است که بازیابی عمق متریک پایدار تنها در صورتی امکان‌پذیر است که اطلاعات هندسی دوربین به‌صورت صریح وارد فرآیند یادگیری شود.

افزون بر این، پژوهش حاضر با تفکیک روشن میان معیارهای متریک و غیرمتریک و تحلیل رفتار متفاوت آن‌ها نشان می‌دهد که ارزیابی‌های متداول مبتنی بر معیارهای نرمال‌شده می‌توانند تصویری ناقص یا حتی گمراه‌کننده از عملکرد واقعی مدل‌ها ارائه دهند. این دیدگاه، چارچوبی مفهومی برای بازنگری در نحوه ارزیابی مدل‌های تخمین عمق در ادبیات موجود فراهم می‌کند.

۲.۴.۵ نوآوری عملی

در سطح عملی، نوآوری این پژوهش در ارائه یک راهکار ساده، قابل پیاده‌سازی و سازگار با معماری‌های موجود برای بهبود تخمین عمق متریک است. برخلاف بسیاری از روش‌ها که نیازمند تغییرات گسترده در معماری یا استفاده از داده‌های اضافی هستند، روش پیشنهادی با حفظ هسته معماری پایه و افزودن صریح اطلاعات ماتریس مشخصه دوربین در قالب یک توکن دروازه‌بانی شده به انکودر شبکه، توانسته است پایداری متریک خروجی عمق را افزایش دهد.

یافته‌های عملی این پژوهش نشان می‌دهد که حتی بدون تغییر انکودر و با ثابت نگه‌داشتن وزن‌های استخراج ویژگی، می‌توان با بهره‌گیری از اطلاعات هندسی مناسب، به بهبود معنادار در معیارهای متریک دست یافت. این نتیجه، توصیه‌ای عملی برای پژوهشگران و کاربردهای صنعتی است که نشان می‌دهد نادیده گرفتن اطلاعات دوربین می‌تواند منجر به نتایج ناپایدار در کاربردهایی شود که به مقیاس فیزیکی دقیق نیاز دارند.

در مجموع، نوآوری عملی این پژوهش در ارائه شواهد تجربی است که نشان می‌دهد ادغام آگاهانه هندسه دوربین در مدل‌های یادگیری عمیق می‌تواند بدون افزایش قابل توجه پیچیدگی سیستم، کیفیت و پایداری تخمین عمق متریک را بهبود بخشد.

۳.۴.۵ دستاوردهای روش شناختی و تشخیصی

در کنار نوآوری‌های فوق، این پژوهش مجموعه‌ای از دستاوردهای روش شناختی دارد که اعتبار نتایج را تضمین کرده و برای پژوهش‌های مشابه قابل استفاده‌اند:

- **شناسایی و رفع نشت داده در تقسیم‌بندی NYUv2:** نشان داده شد که تقسیم تصادفی متداول بر روی مجموعه برچسب‌دار، بیش از ۸۰ درصد تصاویر آزمون استاندارد را وارد آموزش می‌کند؛ اصلاح این نشت، پیش‌شرط هر مقایسه معتبر با ادبیات موضوع است.
- **تشخیص و تبیین یک شکست خاموش در فاین‌تیون مدل‌های نسبی:** نااهم خوانی فضای هدف آموزش (عمق مستقیم) با فضای خروجی مدل از پیش‌آموزش‌دیده (عمق معکوس)، در تعامل با جزئیات تابع هزینه تغییرناپذیر نسبت به مقیاس، به فروریزش برگشت‌ناپذیر شبکه می‌انجامد در حالی که منحنی هزینه طبیعی می‌نماید. ریشه‌یابی و رفع این پدیده، آموزش موفق مدل‌های بزرگ را ممکن ساخت.
- **افزونه‌سازی هندسی آگاه از دوربین:** راهبردی که با برش‌های مقیاس متغیر و به‌روزرسانی دقیق ماتریس K ، از یک مجموعه داده تک‌دوربین، داده‌هایی با میدان دید متنوع و برچسب هندسی صحیح می‌سازد. این راهبرد به‌تنهایی بهترین نتایج پروتکل نسبی این پژوهش را رقم زد و بستر آزمون علی سهم پارامترهای دوربین را فراهم کرد.
- **تحلیل وابستگی نتیجه‌گیری به پروتکل ارزیابی:** نشان داده شد که پروتکل ارزیابی نسبی، به‌صورت ساختاری نسبت به سهم اصلی پارامترهای دوربین (مقیاس مطلق) ناپیوسته و سنجش منصفانه این سهم، مستلزم ارزیابی متریک بدون تراز است. این یافته برای طراحی ارزیابی در پژوهش‌های آتی حوزه اهمیت دارد.
- **افزونه‌سازی لرزش کانونی:** تبدیل دقیق $(f, Z) \mapsto (\alpha f, \alpha Z)$ برگرفته از معادله روزنه‌ای که بدون هیچ بازنمونه‌برداری، بازیابی مقیاس را برای مدل فاقد K به مسئله‌ای بدساخت تبدیل می‌کند و اتکای مدل به پارامترهای دوربین را از یک گزینه به یک ضرورت آموزشی ارتقا می‌دهد (زیربخش ۸.۷.۳).
- **آزمون تشخیصی جاروی K :** سنجش‌ای سازوکاری (شیب لگاریتمی پاسخ عمق به مقیاس دهی مصنوعی فاصله کانونی) که مستقیماً اندازه می‌گیرد مدل چقدر K را «می‌خواند»، و نشان داد که معیارهای تجمیعی و حتی مقدار پارامتر دروازه کدگذار دوربین می‌توانند درباره میزان واقعی مصرف K گمراه‌کننده باشند (زیربخش ۱.۶.۴).

- زوج‌سازی کامل آزمایش‌ها با قفل بذر تصادفی: یکسان‌سازی ترتیب داده، وارونه‌سازی‌ها و نمونه‌های افزونه‌سازی میان بازوی پیشنهادی و کنترل، به‌گونه‌ای که تفاوت نتایج تنها به متغیر مورد مطالعه (ورودی K) قابل انتساب باشد؛ صحت آن با برابری بیت‌به‌بیت هزینه گام صفر دو بازو راستی آزمایی شد.

۵.۵ محدودیت‌ها و چالش‌های پژوهش

با وجود نتایج مثبت و معنادار حاصل از این پژوهش، لازم است محدودیت‌ها و چالش‌هایی که در مسیر انجام تحقیق وجود داشته‌اند به‌صورت شفاف بیان شوند. ذکر این موارد نه تنها به درک دقیق‌تر دامنه اعتبار یافته‌ها کمک می‌کند، بلکه مسیر توسعه و بهبود پژوهش‌های آتی در این حوزه را نیز روشن‌تر می‌سازد. نخستین محدودیت این پژوهش به وابستگی روش پیشنهادی به صحت ماتریس مشخصه دوربین بازمی‌گردد. در این تحقیق فرض شده است که پارامترهای درونی دوربین به‌صورت دقیق و بدون خطا در دسترس هستند. آزمون حذف و تحریف K (زیربخش ۲.۶.۴) ابعاد این وابستگی را کمی کرده است: حذف کامل K حدود ۵۹ درصد و تحریف ۳۰ تا ۴۰ درصدی فاصله کانونی، چند برابر خطای پایه به مدل تحمیل می‌کند. این رفتار، روی دیگر سکه اتکای علی مدل به K است: در عمل، به‌ویژه در کاربردهای واقعی که پارامترها ممکن است ناقص، تقریبی یا همراه با نویز باشند، حساسیت مدل به خطای کالیبراسیون باید در طراحی سامانه لحاظ شود؛ مطالعه نظام‌مند رفتار مدل تحت عدم قطعیت‌های واقع‌گرایانه کالیبراسیون (نه تحریف‌های عمدی بزرگ) موضوعی برای پژوهش‌های آتی است.

محدودیت دیگر به کیفیت و ماهیت داده‌های عمق مرجع در دیتاست‌های مختلف مربوط است. همان‌گونه که در فصل چهارم نشان داده شد، دیتاست‌ها از نظر نحوه تولید عمق مرجع، دامنه عمق و یکنواختی داده‌ها تفاوت‌های اساسی دارند. این ناهمگنی می‌تواند بر مقادیر مطلق خطاهای متریک اثرگذار باشد و تفسیر نتایج را تحت تأثیر قرار دهد. هرچند در این پژوهش تلاش شده است این مسئله از طریق تحلیل‌های آماری و بررسی‌های موردی کنترل شود، اما محدودیت‌های ذاتی داده‌های مرجع به‌طور کامل قابل حذف نیستند.

از منظر معماری، روش پیشنهادی بر پایه یک مدل خاص از خانواده Depth Anything V2 پیاده‌سازی و ارزیابی شده است. اگرچه چارچوب ارائه‌شده به‌صورت مفهومی مستقل از معماری خاص است، اما تعمیم تجربی نتایج به سایر معماری‌ها یا انکودرهای متفاوت در این پژوهش به‌صورت مستقیم بررسی نشده است. از این رو، نتایج ارائه‌شده بیشتر در چارچوب معماری مورد استفاده قابل تفسیر هستند.

در نهایت، این پژوهش تمرکز خود را بر تخمین عمق تک‌دوربین ایستا و تصاویر منفرد قرار داده است. اطلاعات زمانی یا چندنمایی که می‌توانند قیود هندسی مکملی فراهم کنند، در چارچوب این تحقیق مورد استفاده

قرار نگرفته‌اند. این انتخاب آگاهانه، برای تمرکز بر نقش ماتریس مشخصه دوربین در ساده‌ترین سناریوی ممکن انجام شده است، اما در عین حال دامنه کاربرد نتایج را به این سناریو محدود می‌کند.

سه محدودیت دیگر نیز که از مطالعه کنترل‌شده نهایی برمی‌خیزند باید به‌صراحت ذکر شوند. نخست، تنوع پارامترهای دوربین در آزمایش‌های نهایی از طریق افزونه‌سازی هندسی (برش‌های مقیاس متغیر با K اصلاح‌شده) شبیه‌سازی شده است، نه با داده‌های واقعی چنددوربین؛ اگرچه این شبیه‌سازی از منظر هندسی دقیق است، اثرات ثانویه دوربین‌های واقعی (نظیر اعوجاج لنز، عمق میدان و نویز حسگر) را پوشش نمی‌دهد. دوم، در دو دور متریک مبتنی بر زوم‌برش، برتری مدل آگاه از K در RMSE تثبیت شد، اما AbsRel دور دوم در آستانه معناداری بود (ویلاکسون $p = 0.040$ و آزمون t زوجی $p = 0.089$). این محدودیت مربوط به آن دو دور است؛ در آزمایش لرزش کانونی تمام معیارها با $p \leq 10^{-24}$ معنادار شدند. بنابراین قدرت شواهد به میزان ابهام هندسی ایجادشده در داده وابسته است. سوم، مقایسه‌های کنترل‌شده نهایی بر یک محک درون‌دامنه‌ای (NYUV2) متمرکز بوده‌اند؛ تعمیم سهم پارامترهای دوربین به فاین‌تیون بر محک‌های دیگر (به‌ویژه صحنه‌های بیرونی با دامنه عمق بزرگ) نیازمند آزمایش‌های تکمیلی است. در صورت دسترسی به داده آموزشی واقعی KITTI، تکرار مطالعه کنترل‌شده متریک بر روی آن می‌تواند تعمیم‌پذیری یافته‌ها را در محیط بیرونی و دامنه عمق بزرگ مستند کند.

چهارم، هر بازوی هر زوج آموزشی تنها یک بار آموزش داده شده است. قفل بذر، ترتیب داده و افزونه‌سازی را میان دو بازوی یکسان می‌کند و آزمون‌های زوجی عدم قطعیت در سطح تصویر را می‌سنجند، اما جایگزین تکرار کامل آموزش با چند بذر مستقل نیست. از این رو، استنباط علی درون هر زوج قوی است، ولی برآورد واریانس ناشی از تصادفی بودن کل فرآیند آموزش همچنان به آزمایش تکمیلی نیاز دارد.

با در نظر گرفتن این موارد، می‌توان گفت که محدودیت‌های مطرح‌شده نتایج اصلی پژوهش را نقض نمی‌کنند، بلکه چارچوب اعتبار آن‌ها را مشخص می‌سازند و زمینه‌ای مناسب برای توسعه و تکمیل پژوهش در مطالعات آینده فراهم می‌کنند.

۶.۵ پیشنهادهایی برای تحقیقات آینده

یافته‌ها و محدودیت‌های مطرح‌شده در این پژوهش، زمینه‌های روشنی را برای ادامه و توسعه تحقیقات آینده در حوزه تخمین عمق تک‌دوربین فراهم می‌کنند. پیشنهادهای ارائه‌شده در این بخش به‌طور مستقیم بر چارچوب مفهومی و عملی تحقیق حاضر استوار هستند و از طرح موضوعات کلی و خارج از دامنه پژوهش اجتناب شده است.

یکی از مسیرهای طبیعی برای توسعه این پژوهش، بررسی رفتار مدل پیشنهادی در شرایطی است که ماتریس

مشخصه دوربین به صورت دقیق در دسترس نیست. در بسیاری از کاربردهای واقعی، پارامترهای درونی دوربین ممکن است همراه با نویز یا به صورت تخمینی ارائه شوند. مطالعه پایداری مدل پیشنهادی در برابر خطاهای موجود در ماتریس K و یا طراحی سازوکارهایی برای مقابله با این عدم قطعیت، می‌تواند گام مهمی در جهت کاربردپذیری عملی تر روش ارائه شده باشد.

مسیر پژوهشی دیگر، یادگیری هم‌زمان عمق و پارامترهای دوربین است. در چارچوب تحقیق حاضر، ماتریس مشخصه دوربین به عنوان ورودی معلوم در نظر گرفته شده است. بررسی امکان تخمین یا اصلاح پارامترهای درونی دوربین به صورت هم‌زمان با تخمین عمق، می‌تواند منجر به مدل‌هایی شود که وابستگی کمتری به کالیبراسیون اولیه دارند و در سناریوهای متنوع‌تری قابل استفاده هستند.

مسیر مهم دیگری که مستقیماً از یافته‌های مطالعه کنترل‌شده برمی‌خیزد، آموزش بر روی داده‌های واقعاً چنددوربین است. الگوی پاسخ به دوز مشاهده شده نشان می‌دهد که سهم پارامترهای دوربین با میزان تنوع هندسی داده رشد می‌کند؛ بنابراین انتظار می‌رود آموزش بر ترکیبی از مجموعه داده‌هایی با دوربین‌ها و میدان‌های دید متفاوت (به جای شبیه‌سازی تنوع از طریق افزونه‌سازی) این سهم را بزرگ‌تر و پایدارتر آشکار کند. در همین راستا، مطالعه نظام‌مند محل تزریق توکن دوربین در عمق‌های مختلف انکودر (از طریق پارامتر `--cam-token-inject-layer`) و بررسی سازوکارهای تزریق چندلایه، می‌تواند اثرگذاری اطلاعات هندسی را افزایش دهد. از منظر استحکام آماری، تکرار هر زوج پیشنهادی/کنترل با چند بذر مستقل و گزارش میانگین و انحراف معیار میان اجراها ضروری است. این تکرار باید در کنار آزمون‌های زوجی سطح تصویر انجام شود تا دو منبع عدم قطعیت — تفاوت دشواری تصاویر و تصادفی بودن آموزش — به صورت جداگانه اندازه‌گیری شوند.

همچنین، تعمیم چارچوب پیشنهادی به سناریوهای چندتصویری یا ویدئویی می‌تواند زمینه پژوهشی ارزشمندی باشد. اطلاعات زمانی یا چندنمایی، قیود هندسی مکملی نسبت به اطلاعات تک‌تصویری فراهم می‌کنند و ترکیب آن‌ها با ادغام صریح ماتریس مشخصه دوربین می‌تواند به تخمین‌های پایدارتر و دقیق‌تر از عمق متریک منجر شود.

از منظر معماری، بررسی پیاده‌سازی روش پیشنهادی بر روی انکودرها و دیکودرهای متفاوت و تحلیل میزان وابستگی نتایج به انتخاب معماری پایه می‌تواند به تعمیم‌پذیری بهتر چارچوب ارائه شده کمک کند. چنین بررسی‌هایی امکان ارزیابی این موضوع را فراهم می‌کنند که آیا مزایای مشاهده شده یک ویژگی عمومی رویکرد هندسی پیشنهادی هستند یا به معماری خاصی وابسته‌اند.

در مجموع، پیشنهادها مطرح شده در این بخش نشان می‌دهند که پژوهش حاضر می‌تواند به عنوان نقطه آغاز برای مجموعه‌ای از مطالعات عمیق‌تر در زمینه ترکیب هندسه تصویربرداری و یادگیری عمیق در تخمین عمق تک‌دوربین مورد استفاده قرار گیرد.

۷.۵ جمع‌بندی نهایی فصل

در این فصل، جمع‌بندی نهایی پژوهش حاضر با تمرکز بر برداشت‌های حاصل از یافته‌ها ارائه شد. بر اساس نتایج نظری و تجربی به‌دست آمده، نشان داده شد که تخمین عمق متریک پایدار در چارچوب تک‌دوربین بدون لحاظ صریح هندسه دوربین به‌صورت ذاتی با محدودیت مواجه است. این برداشت، ریشه در اصول هندسه تصویربرداری دارد و با نتایج عملی گزارش شده در فصل‌های پیشین هم‌راستا است.

یافته‌های این پژوهش نشان می‌دهد که ادغام آگاهانه ماتریس مشخصه دوربین در فرآیند تخمین عمق می‌تواند نقش تعیین‌کننده‌ای در کاهش ابهام مقیاس و افزایش پایداری متریک خروجی ایفا کند. این بهبودها نه تنها در معیارهای ارزیابی، بلکه در کیفیت بصری نقشه‌های عمق و رفتار مدل در سناریوهای متنوع تصویربرداری قابل مشاهده بودند.

در مجموع، پژوهش حاضر نشان می‌دهد که ترکیب یادگیری عمیق با قیود هندسی کلاسیک، مسیر مؤثری برای ارتقای تخمین عمق تک‌دوربین است. نتایج ارائه شده می‌توانند به‌عنوان مبنایی برای توسعه مدل‌های آتی و بازنگری در شیوه ارزیابی روش‌های تخمین عمق مورد استفاده قرار گیرند. بدین ترتیب، این پایان‌نامه با ارائه یک چارچوب نظری و عملی منسجم، پاسخی روشن به مسئله مطرح شده در ابتدای تحقیق ارائه می‌دهد و زمینه را برای پژوهش‌های تکمیلی در این حوزه فراهم می‌سازد.

کتاب نامه

- [1] Saxena, Ashutosh, Sun, Min, and Ng, Andrew Y. Make3d: Learning 3d scene structure from a single still image. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31(5):824–840, 2009.
- [2] Eigen, David, Puhrsch, Christian, and Fergus, Rob. Depth map prediction from a single image using a multi-scale deep network. *Advances in Neural Information Processing Systems*, 2014.
- [3] Hartley, Richard and Zisserman, Andrew. *Multiple View Geometry in Computer Vision*. Cambridge University Press, 2004.
- [4] Koch, Reinhard. Dynamic 3-d scene analysis through synthesis feedback control. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1998.
- [5] Eigen, David and Fergus, Rob. Predicting depth, surface normals and semantic labels with a common multi-scale convolutional architecture. *IEEE International Conference on Computer Vision*, 2015.
- [6] Ranftl, René, Bochkovskiy, Alexey, and Koltun, Vladlen. Vision transformers for dense prediction. *IEEE International Conference on Computer Vision*, 2021.
- [7] Zhou, Tinghui, Brown, Matthew, Snavely, Noah, and Lowe, David. Unsupervised learning of depth and ego-motion from video. *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [8] Guizilini, Vitor et al. Semantically-guided representation learning for self-supervised monocular depth. *IEEE International Conference on Computer Vision*, 2020.
- [9] Godard, Clément, Mac Aodha, Oisín, and Brostow, Gabriel. Unsupervised monocular depth estimation with left-right consistency. *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [10] Hoiem, Derek, Efros, Alexei, and Hebert, Martial. Geometric context from a single image. *IEEE International Conference on Computer Vision*, 2005.

- [11] Yang, Lihe et al. Depth anything v2. *arXiv preprint*, 2024.
- [12] Dosovitskiy, Alexey et al. An image is worth 16x16 words: Transformers for image recognition at scale. *ICLR*, 2021.
- [13] Saxena, Shubham et al. Zero-shot metric depth with a field-of-view conditioned diffusion model. *arXiv preprint arXiv:2312.13252*, 2023.
- [14] Ranftl, Rene et al. Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer. *arXiv preprint*, 2019.
- [15] Godard, Clément, Aodha, Oisin Mac, Firman, Michael, and Brostow, Gabriel J. Digging into self-supervised monocular depth estimation. in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.
- [16] Casser, Vincent, Pirk, Soren, Mahjourian, Reza, and Angelova, Anelia. Depth prediction without the sensors: Leveraging structure for unsupervised learning from monocular videos. in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, 2019.
- [17] Sucar, Edgar, Liu, Shichen, Ortiz, Joseph, and Davison, Andrew J. Implicit representation of geometry for learning depth. in *Proceedings of the Conference on Robot Learning (CoRL)*, 2020.
- [18] Kendall, Alex and Cipolla, Roberto. Geometry-aware learning of maps for camera localization. in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015.
- [19] Chen, Rui et al. Camera-aware multi-view stereo via geometry-aware cost volume. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [20] Guizilini, Vitor, Ambrus, Rares, Pillai, Sudeep, and Gaidon, Adrien. Semantically-guided representation learning for self-supervised monocular depth. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [21] Perez, Ethan, Strub, Florian, de Vries, Harm, Dumoulin, Vincent, and Courville, Aaron. Film: Visual reasoning with a general conditioning layer. in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2018.
- [22] Li, Zhengqi et al. Neural scene flow fields for space-time view synthesis of dynamic scenes. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

- [23] Gaidon, Adrien, Wang, Qiao, Cabon, Yohann, and Vig, Eleonora. Virtual worlds as proxy for multi-object tracking analysis. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [24] Silberman, Nathan, Hoiem, Derek, Kohli, Pushmeet, and Fergus, Rob. Indoor segmentation and support inference from rgb-d images. *European Conference on Computer Vision (ECCV)*, 2012.
- [25] Vasiljevic, Igor and Koltun, Vladlen. Diode: A dense indoor and outdoor depth dataset. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [26] Oquab, Maxime et al. DINOv2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [27] Loshchilov, Ilya and Hutter, Frank. Decoupled weight decay regularization. in *International Conference on Learning Representations (ICLR)*, 2019.

*واژه‌نامه فارسی به انگلیسی

*واژه‌نامه انگلیسی به فارسی


Abstract

Monocular depth estimation is intrinsically ambiguous because a single image does not uniquely determine the metric scale of a scene. This thesis investigates whether supplying camera intrinsics explicitly can reduce that ambiguity in a foundation depth model. A camera-aware extension of Depth Anything V2 is developed in which a normalized nine-dimensional camera descriptor is encoded as a gated token and injected into the DI-NOv2 encoder. The experimental methodology was refined through a sequence of controlled investigations that exposed and corrected data leakage in the NYUv2 split, a silent disparity–depth target mismatch that collapsed ViT-L training, geometrically inconsistent crop augmentation, and a silent metric-head mismatch during evaluation.

All final comparisons use the leak-free 654-image NYUv2 Eigen test set and matched camera-aware and camera-blind training arms. Under relative evaluation, the proposed ViT-S model improves over both the released model and the matched control, while the ViT-L camera contribution is not significant because per-image scale-and-shift alignment removes the principal information supplied by the focal length. Under metric evaluation without alignment, the camera-aware ViT-L model consistently improves over its matched control, and the effect grows as field-of-view diversity increases. A geometrically exact focal-jitter augmentation is then introduced to make scale unrecoverable from image pixels alone. With this augmentation, the camera-aware model obtains AbsRel 0.0849 versus 0.1030 for the control and improves every reported metric with Wilcoxon significance of at least $p \leq 10^{-24}$.

Mechanistic and causal tests confirm that the improvement is genuinely attributable to the intrinsic matrix. The log–log slope of predicted depth versus injected focal scale rises from 0.06 before focal jitter to 0.93–0.97 afterward, close to the pinhole-model ideal of one. Withholding the intrinsic matrix increases AbsRel by 59 percent, while deliberately corrupting focal length produces errors of the magnitude predicted by projective geometry. These results show that camera intrinsics can provide a statistically significant and causally necessary scale signal, while also revealing sensitivity to calibration accuracy and the need for future evaluation on genuinely multi-camera and outdoor data.

Keywords Monocular Depth Estimation, Unsupervised Deep Learning, Metric Depth, Camera Intrinsics, Imaging Geometry, Depth Anything V2



K. N. Toosi University of Technology
Faculty of Computer Engineering- Artificial Intelligence Group

Thesis Submitted in Partial Fulfillment of the
Requirements for the Degree of Master of Science (M.Sc.)
in Computer Engineering

Unsupervised Depth Estimation Using Internal Calibration Parameters as Input

By:

Mohammad Amin Ghasemzadeh

Supervisor:

Dr. Behrouz Nasihatkon

Winter 2026