دانشگاه خواجه نصیرالدین طوسی
دانشکده مهندسی کامپیوتر- گروه هوش مصنوعی

پایان‌نامه دوره کارشناسی ارشد

مهندسی کامپیوتر

تخمین عمق بدون نظارت با استفاده از پارامترهای کالیبراسیون داخلی به عنوان ورودی

محمدامین قاسم‌زاده

استاد راهنما

دکتر بهروز نصیحت کن

پاییز ۱۴۰۵

دانشگاه خواجه نصیرالدین طوسی
دانشکده مهندسی کامپیوتر- گروه هوش مصنوعی

پایان‌نامه دوره کارشناسی ارشد

مهندسی کامپیوتر

عنوان

تخمین عمق بدون نظارت با استفاده از پارامترهای کالیبراسیون داخلی به عنوان ورودی

نگارش

محمدامین قاسم‌زاده

استاد راهنما

دکتر بهروز نصیحت کن

پاییز ۱۴۰۵



تقدیم به: مادر و پدر عزیزم

به آنان که با علم خود زندگی آزاد می‌سازند

دانشگاه صنعتی خواجه نصیرالدین طوسی

تأییدیهٔ هیئت داوران جلسه‌ی دفاع از پایان‌نامهٔ کارشناسی ارشد

هیأت داوران پس از مطالعه‌ی پایان‌نامهٔ و شرکت در جلسه‌ی دفاع از پایان‌نامهٔ تهیه‌شده با عنوان «تخمین عمق بدون نظارت با استفاده از پارامترهای کالیبراسیون داخلی به عنوان ورودی» توسط آقای / خانم محمدامین قاسم‌زاده صحت و کفایت تحقیق انجام شده را برای اخذ درجه‌ی کارشناسی ارشد در رشته‌ی مهندسی کامپیوتر در تاریخ پاییز ۱۴۰۵مورد تأیید قرار دادند.

۱. استاد راهنما: دکتر بهروز نصیحت کن . . . . . امضا

۲. استاد داور داخلی: دکتر حمید ابریشمی مقدم. . . . . امضا

۳. استاد مدعو: دکتر محمدرضا محمدی . . . . . امضا

دانشگاه صنعتی خواجه نصیرالدین طوسی

اظهارنامه دانشجو

اینجانب محمدامین قاسم‌زاده به شماره دانشجویی ۴۰۲۰۹۶۴۴ دانشجوی کارشناسی ارشد رشته‌ی مهندسی کامپیوتر دانشکده دانشکده مهندسی کامپیوتر دانشگاه‌خواجه نصیرالدین طوسی گواهی می‌نمایم که تحقیقات ارائه شده در این پایان‌نامه با عنوان:

تخمین عمق بدون نظارت با استفاده از پارامترهای کالیبراسیون داخلی به عنوان ورودی

توسط اینجانب انجام و بدون هرگونه دخل و تصرف است و موارد نسخه برداری شده از آثار دیگران را با ذکر کامل مشخصات منبع ذکر کرده ام. در صورت اثبات خلاف مندرجات فوق، به تشخیص دانشگاه مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انضباطی و غیره) با اینجانب رفتار خواهد شد. در ضمن، مسئولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذی صلاح (اعم از اداری و قضایی) به عهده ی اینجانب خواهد بود و دانشگاه هیچ گونه مسئولیتی در این خصوص نخواهد داشت.

نام و نام خانوادگی دانشجو: محمدامین قاسم‌زاده

تاریخ و امضای دانشجو:



حق طبع، نشر و مالکیت نتایج

حق چاپ و تکثیر این پایان نامه متعلق به نویسندگان آن می باشد. بهره برداری از این پایان نامه در چهارچوب مقررات کتابخانه و با توجه به محدودیتی که توسط استاد راهنما به شرح زیر تعیین می گردد، بلامانع است:

☐ بهره‌برداری از این پایان‌نامه برای همگان و با ذکر منبع، بلامانع است.

☐ بهره‌برداری از این پایان‌نامه با اخذ مجوز از استاد راهنما و با ذکر منبع، بلامانع است.

☐ بهره‌برداری از این پایان‌نامه تا تاریخ _____ ممنوع است.

استاد راهنما: دکتر بهروز نصیحت کن . . . . . امضا

قدردانی

اکنون که به یاری پروردگار و یاری و راهنمایی اساتید بزرگ موفق به پایان این پایان‌نامه شده‌ام وظیفه خود دانشته که نهایت سپاسگزاری را از تمامی عزیزانی که در این راه به من کمک کرده‌اند را به عمل آورم: در آغاز از استاد بزرگ و دانشمند جناب آقادکتر نصیحت‌کن که راهنمایی این پایان‌نامه را به عهده داشته‌اند کمال تشکر را دارم. از داوران گرامی دکتر حمید ابریشمی مقدم و دکتر محمدرضا محمدی که زحمت داوری و تصحیح این پایان‌نامه را به عهده داشتند کمال سپاس را دارم. خالصانه از تمامی اساتید و معلمان و مدرسانی که در مقاطع مختلف تحصیلی به من علم آموخته و مرا از سرچشمه دانایی سیراب کرده‌اند متشکرم. از کلیه هم دانشگاهیان و همراهان عزیز، دوستان خوبم نهایت سپاس را دارم.

و در پایان این پایان‌نامه را تقدیم می‌کنم به مادر و پدر مهربانم که با حضور و همراهی شان در دوران تحصیل، همیشه راه را به من نشان داده و مرا در این راه استوار و ثابت قدم نموده است.

محمدامین قاسم‌زاده

پاییز ۱۴۰۵

چکیده

تخمین عمق تک‌دوربینه (MDE) یکی از مسائل اساسی بینایی ماشین و پایه بسیاری از کاربردهای رباتیک، رانندگی خودکار و بازسازی سه‌بعدی است. بااین‌حال، تعیین مقیاس واقعی صحنه از یک تصویر منفرد همچنان چالش‌برانگیز است و بسیاری از مدل‌های کنونی عمدتاً عمق نسبی را تخمین می‌زنند که برای اندازه‌گیری فواصل واقعی کافی نیست. از سوی دیگر، تغییر پارامترهای درونی دوربین، مانند فاصله کانونی، می‌تواند دقت تخمین عمق را کاهش دهد. اگرچه پژوهش‌های پیشین با تخمین پارامترهای کالیبراسیون یا بهره‌گیری از آن‌ها تلاش کرده‌اند این مشکل را برطرف کنند، دستیابی به مدلی که با استفاده مستقیم از ماتریس کالیبراسیون بتواند عمق مطلق را برای تصاویر دوربین‌های مختلف و با وضوح‌های متفاوت به‌دقت تخمین بزند، همچنان یک چالش مهم محسوب می‌شود.

در این پایان‌نامه، توصیف‌گر نه‌بعدی و نرمال‌شده‌ای از ماتریس کالیبراسیون معلوم دوربین با یک انکودر ترنسفورمری به توکن تبدیل و با گیت یادگیری‌پذیر به انکودر DINOv2 مدل Depth Anything V2 تزریق شد و «مدل پیشنهادی» با «مدل کنترل» مقایسه گردید که تنها در دسترسی به ماتریس کالیبراسیون با آن تفاوت دارد. در ارزیابی نسبی بر مجموعه آزمون NYUv2، تراز مقیاس هر تصویر بیشتر اطلاعات فاصله کانونی را حذف می‌کند و سهم ماتریس کالیبراسیون تنها در نسخه ViT-S معنادار است؛ اما در ارزیابی مطلق، مدل پیشنهادی به‌طور پایدار بهتر عمل می‌کند و برتری آن با تنوع میدان دید افزایش می‌یابد. با افزونه‌سازی «لرزش کانونی»، خطای AbsRel از ۰٫۱۰۳۰ به ۰٫۰۸۴۹ (حدود ۱۸ درصد) کاهش می‌یابد، شیب لگاریتمی پاسخ عمق به مقیاس فاصله کانونی از ۰٫۰۶ به ۰٫۹۳ تا ۰٫۹۷ (مقدار ایده‌آل: یک) می‌رسد و حذف ماتریس کالیبراسیون خطا را ۵۹ درصد افزایش می‌دهد. بنابراین پارامترهای درونی دوربین سیگنال مقیاسی معنادار و از نظر علی ضروری فراهم می‌کنند، هرچند حساسیت مدل به دقت کالیبراسیون را بالا می‌برند.

در گام پایانی، یک مدل ViT-L به‌صورت هم‌زمان بر چهار مجموعه‌داده NYUv2، KITTI، Virtual KITTI 2 و Cityscapes با دوربین‌های متفاوت آموزش داده شد. این مدل بر NYUv2، Cityscapes و دو حسگر دیده‌نشده Kinect v1 و Kinect v2 از SUN RGB-D در هر دو معیار AbsRel و δ_1 از مدل کنترل و نسخه مطلق منتشرشده Depth Anything V2 دقیق‌تر بود؛ برای نمونه، AbsRel بر NYUv2 به ۰٫۰۸۸ در برابر ۰٫۱۳۳ و ۰٫۲۰۷ رسید.

واژگان کلیدی MDE، یادگیری عمیق بدون نظارت، عمق مطلق، پارامترهای درونی دوربین، هندسه تصویربرداری، Depth Anything V2

فهرست مطالب

فصل ۱: مقدمه ۱

۱.۱ مقدمه ۲

۲.۱ ضرورت انجام تحقیق ۲

۳.۱ تعریف موضوع تحقیق ۵

۴.۱ سوالات تحقیق ۶

۵.۱ اهداف آرمانی تحقیق ۶

۶.۱ فرضیات پژوهش ۶

۷.۱ روش انجام تحقیق ۷

۸.۱ کاربرد تحقیق ۷

۹.۱ ساختار پایان‌نامه ۹

فصل ۲: مبانی نظری، مرور ادبیات، شکاف و نوآوری تحقیق ۱۱

۱.۲ مبانی نظری ۱۲

۱.۱.۲ مساله MDE ۱۲

۲.۱.۲ مدل سوراخ‌سوزنی و ماتریس کالیبراسیون دوربین ۱۳

۳.۱.۲ پارادایم‌های نظارتی و تابع‌های هزینه ۱۳

۲.۲ مرور ادبیات گذشته ۱۴

۱.۲.۲ دسته‌بندی کلی بر اساس حسگر و نوع نما ۱۴

۲.۲.۲ روش‌های کلاسیک و نظارت‌شده اولیه ۱۵

۳.۲.۲ سیر خودنظارتی: از استریو تا ویدیو ۱۵

۴.۲.۲ مدل‌های نسبی، معماری‌های ترنسفورمری و مدل‌های سبک ۱۶
۵.۲.۲ مدل‌های بنیادین و تقطیر در مقیاس بزرگ ۱۶
۶.۲.۲ مدل‌های مطلق و شرطی‌سازی دوربین ۱۷
۷.۲.۲ مقاله پایه برای مدل پیشنهادی ۱۸
۳.۲ شکاف تحقیقاتی ۲۳
۴.۲ نوآوری‌های تحقیق ۲۵
۵.۲ جمع‌بندی فصل ۲۵

فصل ۳: روش تحقیق ۲۷
۱.۳ مقدمه ۲۸
۲.۳ تحلیل مدل پایه ۲۸
۳.۳ صورت‌بندی مساله MDE ۲۹
۴.۳ هندسه دوربین و نقش پارامترهای درونی ۳۱
۱.۴.۳ مدل دوربین سوراخ‌سوزنی ۳۱
۲.۴.۳ ماتریس کالیبراسیون دوربین ۳۲
۳.۴.۳ نقش پارامترهای درونی در تخمین عمق ۳۳
۵.۳ طراحی روش پیشنهادی: ادغام صریح ماتریس کالیبراسیون دوربین ۳۴
۱.۵.۳ اصل طراحی: تفکیک اطلاعات تصویری و هندسی ۳۵
۲.۵.۳ نمایش و پیش‌پردازش ماتریس کالیبراسیون دوربین ۳۵
۳.۵.۳ راهبرد ادغام اطلاعات دوربین با معماری Depth Anything V2 . . . . . ۳۷
۴.۵.۳ مزایای مورد انتظار از ادغام صریح پارامترهای درونی ۴۰
۶.۳ داده‌ها، پیش‌پردازش و نرمال‌سازی ورودی ۴۰
۱.۶.۳ مجموعه‌داده‌های مورد استفاده ۴۰
۲.۶.۳ پیکربندی محل تزریق توکن دوربین ۴۴
۳.۶.۳ پیش‌پردازش داده‌ها ۴۵
۴.۶.۳ مدیریت و نرمال‌سازی پارامترهای درونی دوربین ۴۵

۷.۳ راهبرد آموزش مدل پیشنهادی ۴۶
۱.۷.۳ پروتکل تقسیم مجموعه‌های آموزش و آزمون در NYUv2 . . . . . ۴۷
۲.۷.۳ مدل پایه Depth Anything V2 و راهبرد تنظیم دقیق‌پارامترها ۴۷
۳.۷.۳ فعال‌سازی پشتیبانی از پارامترهای دوربین ۴۸
۴.۷.۳ تنظیمات آموزش و بهینه‌سازی ۴۸
۵.۷.۳ فضای هدف آموزش برای مدل‌های نسبی: عمق معکوس ۴۹
۶.۷.۳ افزونه‌سازی هندسی آگاه از پارامترهای دوربین ۵۰
۷.۷.۳ افزونه‌سازی لرزش کانونی: غیرقابل‌حل‌کردن مقیاس بدون ماتریس کالیبراسیون دوربین ۵۱
۸.۷.۳ آموزش چندمجموعه‌ای با دوربین‌های واقعی ۵۳
۹.۷.۳ جمع‌بندی فرآیند آموزش ۵۴
۸.۳ معیارهای ارزیابی عملکرد ۵۴
۱.۸.۳ خطای نسبی مطلق ۵۵
۲.۸.۳ ریشه میانگین مربعات خطا و حساسیت آن به پارامترهای دوربین ۵۶
۳.۸.۳ معیارهای دقت آستانه‌ای ۵۶
۴.۸.۳ کاربرد معیارها برای مدل‌های مطلق و نسبی ۵۷
۹.۳ توابع هزینه و معیارهای بهینه‌سازی ۵۷
۱.۹.۳ هزینه SiLog برای مدل‌های مطلق ۵۷
۲.۹.۳ هزینه تغییرناپذیر نسبت به مقیاس و جابجایی برای مدل‌های نسبی ۵۸
۳.۹.۳ تمایز میان توابع هزینه آموزش و معیارهای ارزیابی ۵۹
۴.۹.۳ پروتکل ارزیابی و سناریوهای مقایسه ۶۰
۵.۹.۳ آزمون‌های آماری و برآورد عدم‌قطعیت ۶۱
۶.۹.۳ نقش پارامترهای درونی دوربین در آموزش ۶۱
۱۰.۳ جمع‌بندی فصل ۶۲

فصل ۴: نتایج ۶۳

۱.۴ مقدمه ۶۴
۲.۴ جزئیات پیاده‌سازی ۶۴
۱.۲.۴ چارچوب نرم‌افزاری و زیرساخت محاسباتی ۶۴
۲.۲.۴ تنظیمات آموزش و راهبرد بهینه‌سازی ۶۵
۳.۲.۴ ساختار کد و اسکریپت‌های اصلی ۶۶
۴.۲.۴ اشکال‌زدایی و درس‌های پیاده‌سازی ۶۸
۳.۴ نتایج کمی: مقایسه عددی مدل‌ها ۶۹
۱.۳.۴ عملکرد مدل پایه Depth Anything V2 در دیتاست‌های مختلف ۶۹
۲.۳.۴ مقایسه مدل پایه Depth Anything V2 و مدل پیشنهادی ۷۰
۳.۳.۴ تحلیل پایداری بین‌دیتاستی مدل پیشنهادی ۷۱
۴.۴ مطالعه کنترل‌شده بر روی پروتکل استاندارد NYUv2 . . . . . ۷۲
۱.۴.۴ ممیزی نقاط وارسی و مسیر رسیدن به آزمایش نهایی ۷۳
۲.۴.۴ راستی‌آزمایی زنجیره ارزیابی: بازتولید نتایج مدل پایه Depth Anything V2 . . ۷۶
۳.۴.۴ ناکارآمدی تنظیم دقیق‌پارامترها برای ارزیابی برون‌دامنه‌ای ۷۷
۴.۴.۴ نتایج پروتکل نسبی: مقایسه چهارگانه ۷۷
۵.۴.۴ اثر افزونه‌سازی هندسی و یک نتیجه منفی آموزنده ۷۸
۶.۴.۴ ارزیابی مطلق: آشکارشدن سهم پارامترهای درونی دوربین ۷۹
۷.۴.۴ پیکربندی لرزش کانونی: جهش سهم پارامترهای دوربین ۸۰
۸.۴.۴ تفکیک اثر افزونه‌سازی لرزش کانونی از ضریب λ ۸۳
۹.۴.۴ نمای یکپارچه پیکربندی‌های آموزشی و الگوی پاسخ به دوز ۸۳
۱۰.۴.۴ جمع‌بندی مطالعه کنترل‌شده و گزارش کوشش‌های تجربی ۸۵
۱۱.۴.۴ نمای اندازه اثر: مقایسه همه معیارها در یک نگاه ۸۵
۵.۴ تحلیل حساسیت نسبت به پارامترهای دوربین ۸۵
۱.۵.۴ آزمون پیمایش فاصله کانونی: آیا مدل واقعا فاصله کانونی را می‌خواند؟ ۸۶
۲.۵.۴ آزمون حذف و تحریف ماتریس کالیبراسیون: اثبات اتکای علی ۸۸
۳.۵.۴ رفتار متفاوت معیارهای AbsRel و RMSE ۸۹

۴.۵.۴ ارتباط با تحلیل هندسی فصل سوم ۸۹
۶.۴ تعمیم بین‌دامنه‌ای با آموزش چندمجموعه‌ای ۹۰
۷.۴ ملاحظات کیفی و حدود شواهد بصری ۹۲
۸.۴ تحلیل موردی دیتاست CityScapes ۹۴
۱.۸.۴ ماهیت و ویژگی‌های خاص دیتاست CityScapes ۹۴
۲.۸.۴ تحلیل کیفیت عمق مرجع ۹۵
۳.۸.۴ دلیل رفتار متفاوت خطاها ۹۵
۴.۸.۴ محدودیت همسان‌سازی نتایج با سایر دیتاست‌ها ۹۵
۹.۴ بحث و تفسیر نتایج ۹۶
۱.۹.۴ جمع‌بندی تحلیلی نتایج کمی و کیفی ۹۶
۲.۹.۴ پاسخ به سوالات تحقیق ۹۶
۳.۹.۴ وابستگی سهم پارامترهای دوربین به پروتکل ارزیابی و ظرفیت مدل ۹۸
۴.۹.۴ مقایسه غیرمستقیم با ادبیات موضوع ۹۹
۵.۹.۴ تفسیر نتایج در چارچوب هندسه تصویربرداری ۱۰۰
۱۰.۴ جمع‌بندی فصل نتایج ۱۰۰

فصل ۵: بحث و نتیجه‌گیری ۱۰۳
۱.۵ مقدمه ۱۰۴
۲.۵ جمع‌بندی یافته‌های اصلی پژوهش ۱۰۵
۳.۵ پاسخ نهایی به سوالات تحقیق ۱۰۷
۴.۵ تفسیر نهایی نتایج در چارچوب هندسه تصویربرداری ۱۰۸
۵.۵ نوآوری‌های تحقیق ۱۰۹
۱.۵.۵ نوآوری تئوریک ۱۰۹
۲.۵.۵ نوآوری عملی ۱۱۰
۳.۵.۵ دستاوردهای روش‌شناختی و تشخیصی ۱۱۱
۶.۵ محدودیت‌ها و چالش‌های پژوهش ۱۱۳

۱.۶.۵ ملاحظات عملی و محدودیت‌های پیاده‌سازی ۱۱۵
۷.۵ پیشنهادهایی برای تحقیقات آینده ۱۱۶
۸.۵ جمع‌بندی نهایی فصل ۱۱۸

فهرست تصاویر ۱۲۱

فهرست جداول ۱۲۲

فهرست اختصارات ۱۲۳

کتاب‌نامه ۱۲۷

واژه‌نامه فارسی به انگلیسی **اول**

واژه‌نامه انگلیسی به فارسی **سوم**

فصل ۱

مقدمه

۱.۱ مقدمه

تخمین عمق صحنه از روی یک تصویر تک‌دوربینه یکی از مسایل بنیادی و در عین حال چالش‌برانگیز در بینایی ماشین (CV)[۱] به شمار می‌رود [۱، ۲]. برخلاف روش‌های مبتنی بر چنددوربینه یا حسگرهای فعال، تخمین عمق تک‌دوربینه (MDE)[۲] تنها بر اطلاعات یک تصویر دوبعدی متکی است و از این‌رو ذاتا با ابهام‌های هندسی متعددی مواجه می‌شود؛ یک تصویر منفرد تنها پرتو نگاه هر پیکسل را معین می‌کند و نه فاصله آن را [۳، ۲].

با پیشرفت روش‌های یادگیری عمیق، به‌ویژه شبکه‌های عصبی کانولوشنی (CNN)[۳] و مدل‌های مبتنی بر ترنسفورمر، دقت MDE در آزمون صفرنمونه[۴]، یعنی ارزیابی روی مجموعه‌داده‌هایی که مدل در آموزش ندیده است، به‌طور چشمگیری افزایش یافته است؛ برای نمونه، Depth Anything V2 با انکودر ViT-L[۵] روی NYU به خطای نسبی مطلق (AbsRel) حدود ۰٫۰۴۵ می‌رسد [۴]. بسیاری از مدل‌های مدرن قادرند ساختار نسبی صحنه را با دقت بالا بازسازی کنند و ترتیب نزدیک‌تر و دورتر بودن اجسام را درست پیش‌بینی کنند. با این حال، خروجی این مدل‌ها در اغلب موارد فاقد مقیاس فیزیکی واقعی بوده و به‌صورت تخمین عمق نسبی[۶] بیان می‌شود. این محدودیت باعث می‌شود که استفاده مستقیم از چنین مدل‌هایی در کاربردهایی که نیازمند اندازه‌گیری‌های مطلق دقیق هستند، با چالش مواجه شود [۵، ۶].

۲.۱ ضرورت انجام تحقیق

دستیابی به تخمین عمق مطلق[۷] پایدار (یعنی خطایی که با تغییر دیتاست یا دوربین به‌طور محسوس افزایش نیابد) و قابل تعمیم (یعنی معتبر ماندن روی دوربین‌های دیده‌نشده)، همچنان یکی از چالش‌های باز در حوزه بینایی ماشین محسوب می‌شود. پرداختن به این مساله نه‌تنها از دیدگاه نظری اهمیت دارد، بلکه از منظر عملی نیز برای توسعه سیستم‌های قابل اعتماد در محیط‌های واقعی ضروری است. این پژوهش با تمرکز بر این چالش اساسی، به بررسی راهکارهایی برای ارتقای مدل‌های MDE از خروجی‌های نسبی به عمق مطلق پایدار می‌پردازد.

[۱] Computer Vision
[۲] Monocular Depth Estimation
[۳] Convolutional Neural Network
[۴] Zero-shot
[۵] Vision Transformer-Large
[۶] Relative Depth Estimation
[۷] Absolute Depth Estimation

اگرچه مدل‌های یادگیری عمیق در سال‌های اخیر پیشرفت چشمگیری در MDE داشته‌اند، اما تابع هزینه بسیاری از این مدل‌ها نسبت به مقیاس و جابه‌جایی عمق ناوردا است و از این‌رو مقیاس فیزیکی در آموزش جریمه نمی‌شود. بسیاری از معیارهای ارزیابی رایج نیز بر سنجش خطاهای نرمال‌شده یا نسبی تمرکز دارند و به‌جای مقیاس فیزیکی مطلق، همبستگی ساختاری عمق را مورد توجه قرار می‌دهند. این موضوع سبب شده است که بهبود عملکرد در این معیارها لزوما به معنای دستیابی به عمق مطلق دقیق نباشد [۲، ۷، ۶].

یکی از چالش‌های مهم در این زمینه، وابستگی مدل‌ها به توزیع داده‌های آموزشی است. مدل‌هایی که بر روی یک یا چند دیتاست خاص آموزش داده می‌شوند، چون همه تصاویر آموزشی با دوربین‌هایی مشابه گرفته شده‌اند، ممکن است رابطه‌ای ثابت میان اندازه ظاهری اجسام و فاصله آن‌ها بیاموزند که برای دوربین دیگر درست نیست. در عمل، تغییر نوع دوربین، فاصله کانونی یا میدان دید (FoV)[۱] این رابطه را عوض می‌کند: با دو برابر شدن فاصله کانونی، جسمی در همان فاصله دو برابر بزرگ‌تر دیده می‌شود و مدلی که فقط اندازه ظاهری را دیده باشد، عمق را کمتر از مقدار واقعی برآورد می‌کند. این امر باعث افت عملکرد مدل می‌شود. این مساله به‌ویژه در معیارهای مطلق که نسبت به مقیاس فیزیکی حساس هستند، نمود بیشتری پیدا می‌کند [۸، ۹].

چالش دیگر، فقدان استفاده صریح از اطلاعات هندسی دوربین در بسیاری از مدل‌های موجود است. در حالی که فرآیند تصویربرداری به‌طور مستقیم تحت تاثیر پارامترهای درونی دوربین[۲] قرار دارد، اغلب روش‌های یادگیری عمیق این اطلاعات را نادیده می‌گیرند یا فرض می‌کنند شبکه می‌تواند فاصله کانونی را از محتوای تصویر حدس بزند. نتیجه آن است که مدل برای دوربین‌هایی غیر از دوربین‌های آموزش، مقیاس را نادرست برآورد می‌کند [۸، ۹].

در مجموع، این چالش‌ها نشان می‌دهند که برای دستیابی به تخمین عمق مطلق پایدار، صرف بهبود معماری شبکه یا افزایش حجم داده‌های آموزشی کافی نیست. بلکه لازم است پارامترهای درونی دوربین به‌عنوان ورودی صریح در اختیار مدل قرار گیرند. این ضرورت، انگیزه اصلی پژوهش حاضر را شکل می‌دهد و زمینه را برای ارایه رویکردی فراهم می‌کند که بتواند پایداری عمق مطلق را در مواجهه با تغییرات شرایط تصویربرداری بهبود بخشد.

بخش عمده‌ای از پژوهش‌های پیشین بر بهبود دقت تخمین عمق نسبی تمرکز داشته‌اند و موفق شده‌اند ساختار کلی صحنه و روابط عمقی میان اجسام را با خطای نسبی کم در بنچمارک‌های استاندارد (مانند NYU و KITTI) بازسازی کنند. با این حال، در بسیاری از این مطالعات، مساله مقیاس فیزیکی عمق یا به‌صورت ضمنی نادیده

[۱] Field of View
[۲] Camera Intrinsics

گرفته شده و یا به‌عنوان یک چالش ثانویه تلقی شده است [۲، ۱۰].

از سوی دیگر، روش‌هایی که به تخمین عمق مطلق پرداخته‌اند، غالبا متکی بر فرض‌های محدودکننده‌ای نظیر ثبات نوع دوربین یا شرایط تصویربرداری کنترل‌شده یا دسترسی به داده‌های کالیبره‌شده خاص بوده‌اند. این فرض‌ها موجب می‌شود که قابلیت تعمیم چنین مدل‌هایی به سناریوهای واقعی و متنوع کاهش یابد. به‌ویژه، تاثیر تغییر پارامترهای درونی دوربین بر عملکرد مدل‌ها در بسیاری از این کارها به‌صورت نظام‌مند مورد مطالعه قرار نگرفته است [۶، ۱۱].

نکته قابل توجه دیگر آن است که در اغلب پژوهش‌های موجود، ارزیابی مدل‌ها عمدتا بر اساس معیارهای نسبی[۱] یا نرمال‌شده انجام شده است. این معیارها اگرچه برای سنجش کیفیت نسبی عمق مناسب هستند، اما قادر به آشکارسازی ناپایداری‌های مرتبط با مقیاس فیزیکی و تغییر شرایط تصویربرداری نیستند. در نتیجه، ممکن است مدلی از نظر این معیارها عملکرد مطلوبی داشته باشد، در حالی که در کاربردهای مطلق و واقعی دچار خطای قابل توجه شود [۵].

علاوه بر این، اگرچه نقش هندسه دوربین در فرآیند تصویربرداری از دیرباز در هندسه چندنمایی صورت‌بندی شده است، در بدنه اصلی مدل‌های یادگیری عمیق تخمین عمق، این اطلاعات یا کاملا نادیده گرفته می‌شوند یا فرض می‌شود که شبکه می‌تواند اثر آن‌ها را به‌طور ضمنی از داده‌ها بیاموزد. در برابر این جریان غالب، خطی از پژوهش‌ها پارامترهای درونی دوربین را به‌صورت صریح وارد مدل کرده‌اند: CAM-Convs این پارامترها را به‌شکل کانال‌های مختصاتی به کانولوشن‌ها می‌افزاید، Metric3D تصویر یا برچسب عمق را به یک «فضای دوربین متعارف» نگاشت می‌کند، برخی روش‌ها مدل انتشاری را بر میدان دید شرطی می‌کنند، و UniDepth یک شاخه دوربین را در کنار شاخه عمق آموزش می‌دهد. بنابراین ادعای این پژوهش آن نیست که استفاده از ماتریس کالیبراسیون دوربین[۲] ایده تازه‌ای است؛ تمایز در شیوه ورود آن به مدل است. در کارهای پیشین، ماتریس کالیبراسیون یا از مسیر کانولوشنی وارد شبکه شده است (CAM-Convs و هسته انتشاری شرطی بر میدان دید)، یا تنها در پیش‌پردازش و تبدیل برچسب‌ها به‌کار رفته است (Metric3D)، یا از خود تصویر حدس زده شده و دوربین معلوم در ورودی مدل نیست (UniDepth). در پژوهش حاضر، برعکس، ماتریس کالیبراسیون معلوم به یک انکودر ترنسفورمری داده می‌شود. این انکودر آن را به توکنی هم‌بعد با فضای نهان انکودر تبدیل می‌کند و این توکن در لایه‌های خودتوجهی انکودر DINOv2 مدل بنیادین Depth Anything V2، کنار توکن‌های تصویر

[۱] Relative-Depth Metrics
[۲] Camera Calibration Matrix

قرار می‌گیرد. از آنجا که تصویر به‌صورت وصله‌های ثابت‌اندازه توکن‌سازی می‌شود و پارامترهای دوربین نیز بر ابعاد تصویر نرمال می‌شوند، مدل برای تصاویر با اندازه‌های مختلف کار می‌کند و دوربین‌های متفاوت را از راه همین ورودی هندسی از هم تشخیص می‌دهد. افزون بر این، در این کارها ماتریس کالیبراسیون همیشه همراه با تغییر هم‌زمان معماری، مجموعه آموزشی و برنامه آموزش وارد شده است. از این‌رو معلوم نیست بهبود حاصل چقدر به خود ماتریس کالیبراسیون دوربین مربوط است و چقدر به این تغییرات [۳، ۲، ۱۲، ۶، ۸، ۹، ۱۳، ۱۴]. بنابراین، سهم این پژوهش دوگانه است: طراحی معماری ترنسفورمری برای ورود صریح ماتریس کالیبراسیون به مدل بنیادین، و اندازه‌گیری اثر همین ورودی در شرایطی که بقیه عوامل ثابت نگه داشته شده‌اند.

۳.۱ تعریف موضوع تحقیق

مساله اصلی در این میان، ابهام مقیاس ذاتی در MDE است. در غیاب اطلاعات هندسی صریح درباره دوربین تصویربرداری، بازیابی عمق مطلق تنها بر اساس شدت پیکسل‌ها ذاتا نامعین است. اگرچه برخی روش‌ها با اعمال نرمال‌سازی یا استفاده از معیارهای نسبی، عملکرد مناسبی در سنجش‌های نسبی نشان می‌دهند، اما این رویکردها تضمینی برای پایداری مقیاس فیزیکی عمق فراهم نمی‌کنند. در نتیجه، تغییر شرایط تصویربرداری، از جمله تفاوت در نوع دوربین یا پارامترهای آن، می‌تواند خطای AbsRel و RMSE را افزایش دهد [۳].

با توجه به این مساله و فقدان تفکیک سهم علی ماتریس کالیبراسیون دوربین در پژوهش‌های پیشین، خلا مورد هدف این پژوهش را می‌توان به‌صورت مشخص چنین بیان کرد: یک مطالعه کنترل‌شده زوجی که در آن انکودر DINOv2 مدل بنیادین فریز شود و در هر دو بازوی آزمایش یکسان بماند؛ هر دو بازو داده، برنامه آموزشی و بذر تصادفی یکسانی دریافت کنند؛ و تنها متغیر دست‌کاری‌شده، دسترسی شبکه به ماتریس کالیبراسیون دوربین باشد. چنین طرحی امکان می‌دهد سهم ماتریس کالیبراسیون دوربین با معیارهای مطلق و بدون تراز مقیاس اندازه‌گیری شود و با آزمون‌های حذف و تحریف ماتریس کالیبراسیون راستی‌آزمایی گردد. پژوهش حاضر با تمرکز بر همین خلا، چارچوبی برای تحلیل و اندازه‌گیری سهم اطلاعات هندسی دوربین در پایداری عمق مطلق ارایه می‌دهد.

۴.۱ سوالات تحقیق

۱. آیا خطای مدل پایه Depth Anything V2 با تغییر دیتاست و شرایط تصویربرداری به‌طور معنادار تغییر می‌کند و آیا مقیاس مطلق آن به دامنه‌ای غیر از دامنه آموزش منتقل می‌شود؟

۲. آیا ارزیابی نسبی، که مقیاس و جابه‌جایی را برای هر تصویر جداگانه تراز می‌کند، تفاوت مدل‌ها در مقیاس فیزیکی عمق و سهم اطلاعات هندسی دوربین را پنهان می‌کند؟

۳. آیا ورودی صریح ماتریس کالیبراسیون دوربین، در ارزیابی مطلق، خطای مدل را نسبت به مدل کنترل هم‌داده کاهش می‌دهد و مقیاس خروجی را در برابر تغییر فاصله کانونی پایدارتر می‌کند؟

۵.۱ اهداف آرمانی تحقیق

- بررسی میزان وابستگی مدل‌های MDE به نوع دیتاست و پارامترهای دوربین؛
- تحلیل تفاوت رفتار معیارهای ارزیابی نسبی و مطلق در مواجهه با تغییرات شرایط تصویربرداری؛
- ارزیابی امکان بهبود دقت و پایداری تخمین عمق مطلق با استفاده از اطلاعات هندسی صریح.

۶.۱ فرضیات پژوهش

به‌منظور پاسخ‌گویی نظام‌مند به سوالات فوق، فرضیات تجربی زیر در این پژوهش تعریف و مورد آزمون قرار گرفته‌اند:

- فرضیه اول: مدل پایه Depth Anything V2 در معیارهای مطلق (AbsRel و RMSE)، نسبت به نوع دیتاست و پارامترهای دوربین حساس است؛ یعنی میانگین خطای آن بین دیتاست‌های مختلف تفاوت معنادار دارد (آزمون t دو نمونه‌ای، سطح معناداری ۰٫۰۵).

- فرضیه دوم: ادغام صریح ماتریس کالیبراسیون دوربین در مدل پیشنهادی، منجر به کاهش معنادار خطا در معیارهای مطلق (AbsRel و RMSE) و بهبود پایداری مقیاس فیزیکی خروجی عمق می‌شود (آزمون t زوجی و ویلکاکسون، سطح معناداری ۰٫۰۵).
- فرضیه سوم: بهبود عملکرد مطلق مدل پیشنهادی، بدون افت معنادار آماری نسبت به مدل کنترل در معیارهای نسبی (AbsRel پس از تراز مقیاس و جابه‌جایی در هر تصویر) و ساختار نسبی نقشه عمق حاصل می‌شود.

۷.۱ روش انجام تحقیق

۸.۱ کاربرد تحقیق

ارزش عملی این پژوهش از آنجا ناشی می‌شود که بسیاری از تصمیم‌های هندسی در سامانه‌های هوشمند، به دانستن «فاصله» در واحد فیزیکی نیاز دارند، نه صرفا دانستن ترتیب نزدیک و دور بودن اجسام. برای مثال، تشخیص وجود مانع کافی نیست و سامانه باید بداند مانع در چه فاصله‌ای قرار دارد، آیا فضای عبور یا توقف کافی است و جسم مورد نظر در چه مقیاسی قرار گرفته است. در تخمین عمق نسبی، ممکن است ساختار کلی صحنه درست بازسازی شود، اما مقیاس خروجی از تصویری به تصویر دیگر یا با تغییر دوربین جابه‌جا شود؛ بنابراین این خروجی به‌تنهایی برای اندازه‌گیری، کنترل حرکت یا جانمایی دقیق قابل اتکا نیست. ادغام صریح ماتریس کالیبراسیون دوربین در مدل، با در اختیار گذاشتن اطلاعاتی مانند فاصلهٔ کانونی و نقطهٔ اصلی که همراه با ابعاد تصویر میدان دید را تعیین می‌کنند، رابطه روزنه‌ای $X = (u - c_x)\, Z / f_x$ را میان مختصات پیکسل و مختصات فیزیکی در اختیار مدل می‌گذارد [۳، ۸، ۹].

نخستین حوزهٔ بهره‌برداری، رباتیک متحرک و سامانه‌های انبارداری و تولید است. ربات‌های سیار، ربات‌های جمع‌آوری کالا و بازوهای رباتیک برای برنامه‌ریزی مسیر، تشخیص مانع، تعیین فاصلهٔ قفسه یا میز و گرفتن اشیا به عمق مطلق نیاز دارند. در چنین سامانه‌هایی، استفاده از یک دوربین RGB به همراه پارامترهای درونی معتبر می‌تواند، در سناریوهایی که دقت مورد نیاز با دقت مدل سازگار است، نیاز به حسگر عمق فعال یا چیدمان استریوی چندحسگری را کاهش دهد. پیامد این کاهش، سبک‌تر شدن سخت‌افزار، مصرف توان کمتر، ساده‌تر

شدن هم‌زمان‌سازی حسگرها و کاهش نقاطی است که باید در زمان نصب و نگهداری کالیبره شوند. این مزیت به‌معنای جایگزینی قطعی لایدار یا حسگرهای ایمنی نیست؛ بلکه نشان می‌دهد در وظایفی که دقت مورد نیاز با توان یک دوربین مطلق سازگار است، می‌توان سامانه‌ای کم‌هزینه‌تر و ساده‌تر طراحی کرد [۱۵].

کاربرد مهم دیگر به خودروهای هوشمند، سامانه‌های کمک‌راننده (ADAS) و پارک خودکار مربوط است. برآورد فاصلهٔ خودروهای اطراف، تشخیص فضای آزاد، تخمین فاصله تا جدول یا مانع و کمک به کنترل سرعت، همگی به مقیاس فیزیکی وابسته‌اند. خودروها معمولا از چند دوربین با رزولوشن، فاصلهٔ کانونی و میدان دید متفاوت استفاده می‌کنند؛ در نتیجه مدلی که فقط الگوی تصویری یک دوربین را آموخته باشد، هنگام انتقال به دوربین دیگر ممکن است مقیاس عمق را نادرست برآورد کند. استفاده از ماتریس کالیبراسیون به‌عنوان فرادادهٔ هر دوربین، امکان می‌دهد این تفاوت به‌صورت صریح در مدل لحاظ و انتقال بین دوربین‌ها به‌صورت قابل آزمون ارزیابی شود. کاهش خطای مقیاس می‌تواند نیاز به تنظیم دستی مقیاس و بازآموزی جداگانه برای هر دوربین را کاهش دهد، هرچند برای کاربردهای ایمنی‌بحرانی همچنان اعتبارسنجی مستقل، افزونگی و ترکیب با حسگرهای تأییدشده لازم است.

در بازرسی صنعتی، اندازه‌گیری ابعاد و ساخت دوقلوی دیجیتال نیز عمق مطلق نقش مستقیم دارد. خروجی عمق را می‌توان به ابرنقاط، مدل سطحی یا اندازه‌گیری فاصلهٔ میان قطعات تبدیل کرد؛ در این صورت، خطای مقیاس فقط یک خطای تصویری نیست و مستقیما به تصمیم دربارهٔ کیفیت، هم‌ترازی یا وضعیت تجهیز منتقل می‌شود. یک دوربین قابل حمل که کالیبراسیون آن همراه تصویر ثبت شود، می‌تواند نیاز به اندازه‌گیری دستی یا تجهیزات حجیم را در برخی خطوط کاهش دهد. همچنین اگر مدل نسبت به تفاوت پارامترهای دوربین پایدارتر باشد، تغییر دوربین یا جایگزینی یک نمونهٔ معیوب لزوما به طراحی کامل یک زنجیرهٔ پردازش جدید منجر نمی‌شود. این موضوع هزینهٔ راه‌اندازی، توقف خط و نیروی مهندسی برای تنظیم مجدد را ممکن است کاهش دهد؛ مقدار واقعی این صرفه‌جویی به نوع خط تولید و سطح دقت مورد نیاز وابسته است و در این پژوهش به‌صورت مالی اندازه‌گیری نشده است.

در بازسازی سه‌بعدی، نقشه‌برداری متحرک، واقعیت افزوده و ربات‌های تعاملی، خروجی مطلق برای جای‌گذاری اشیا، تخمین سطح تماس، حذف پوشیدگی و ساخت هندسهٔ قابل استفاده اهمیت دارد. در واقعیت افزوده، اگر مقیاس عمق ناپایدار باشد، شیء مجازی روی سطح واقعی جابه‌جا می‌شود یا با اجسام برخورد نادرست دارد؛ در بازسازی سه‌بعدی نیز ابهام مقیاس، مقایسهٔ اندازه‌ها و اتصال چند برداشت را دشوار می‌کند. دوربین‌های تلفن همراه، دوربین‌های صنعتی و دوربین‌های روی پهپاد معمولا مشخصات یکسانی ندارند، اما

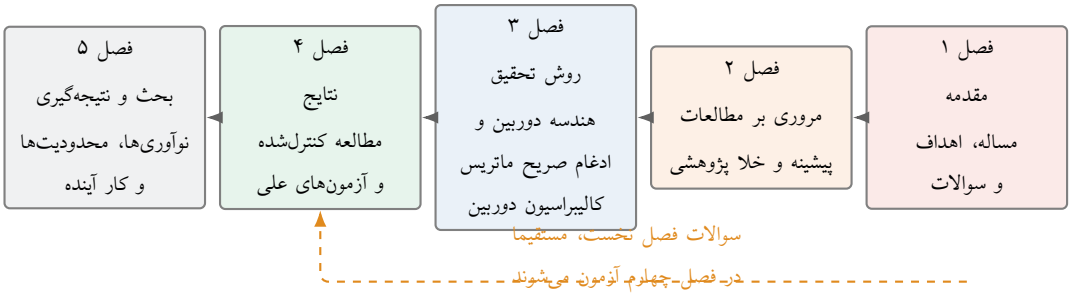
می‌توانند ماتریس کالیبراسیون خود را همراه داده ارائه کنند. بنابراین روش مورد مطالعه این امکان را بررسی می‌کند که به‌جای وابستگی کامل به یک پیکربندی ثابت، از یک مدل واحد برای دوربین‌های گوشی همراه، صنعتی و پهپاد استفاده شود و هزینهٔ جمع‌آوری نمونه، برچسب‌گذاری عمق و نگهداری چند مدل تخصصی کاهش یابد [۷، ۱۴].

این کاربردها یک نتیجهٔ مشترک دارند: هرچه تصمیم سامانه بیشتر به فاصلهٔ واقعی وابسته باشد، ارزیابی مطلق و بررسی پایداری در برابر تغییر دوربین اهمیت بیشتری پیدا می‌کند. دستاورد عملی پژوهش حاضر، ارائهٔ یک مسیر هندسی و تجربی برای سنجش همین پایداری است؛ یعنی می‌توان پیش از استقرار، اثر تغییر فاصلهٔ کانونی، میدان دید یا سایر اجزای ماتریس کالیبراسیون را آزمود و دربارهٔ محدودهٔ قابل اعتماد مدل تصمیم گرفت. در نتیجه، کاهش هزینه در اینجا فقط به قیمت حسگر محدود نمی‌شود و می‌تواند هزینهٔ انتقال مدل، کالیبراسیون مجدد، جمع‌آوری داده و نگهداری نرم‌افزار را نیز دربرگیرد. البته این مزایا مشروط به معتبر بودن ماتریس کالیبراسیون و ثبت درست آن همراه تصویر هستند. اعوجاج[۱] لنز، شاتر غلتان، نور نامناسب، سطوح شفاف یا بازتابنده و صحنه‌های بسیار پویا می‌توانند خطا ایجاد کنند؛ ازاین‌رو برای استقرار صنعتی یا ایمنی‌بحرانی باید روش با دادهٔ همان محیط، آزمون‌های خرابی و در صورت نیاز با حسگرهای دیگر اعتبارسنجی شود.

۹.۱ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل سازمان‌دهی شده است. پس از فصل اول، فصل دوم به مبانی نظری و پیشینهٔ پژوهش، فصل سوم به روش پیشنهادی، فصل چهارم به تنظیمات و نتایج آزمایش‌ها، و فصل پنجم به بحث و نتیجه‌گیری اختصاص دارد. نمای کلی این ساختار در شکل ۱.۱ نشان داده شده است.

[۱] Distortion



شکل ۱.۱: ساختار پایان‌نامه

فصل ۲

مبانی نظری، مرور ادبیات، شکاف و نوآوری تحقیق

۱.۲ مبانی نظری

۱.۱.۲ مساله MDE

تخمین عمق تک‌دوربینه (MDE) به معنای پیش‌بینی عمق هر پیکسل از یک تصویر رنگی $I \in \mathbb{R}^{H\times W\times ۳}$ است. مدل یادگیری را می‌توان به‌صورت

$$D = f_\theta(I), \tag{۱.۲}$$

نوشت که $D \in \mathbb{R}^{H\times W}$ نگاشت عمق و θ پارامترهای مدل است. این نگاشت از تصویر به صحنه سه‌بعدی یکتا نیست: تغییر هم‌زمان اندازه صحنه، فاصله کانونی و عمق می‌تواند تصویر یکسانی بسازد. بنابراین، مساله ذاتا بدحال است و مدل باید ابهام را با داده، فرض‌های صحنه یا قیدهای هندسی کاهش دهد [۳، ۲].

در عمق نسبی، تنها ترتیب یا نسبت عمق‌ها اهمیت دارد. اگر $\hat{D}$ پیش‌بینی مدل باشد، دو خروجی $\hat{D}$ و $s\hat{D}+t$ (برای $s > ۰$) از دید معیارهای تغییرناپذیر نسبت به مقیاس و انتقال معادل‌اند. در عمق مطلق، خروجی باید در واحد فیزیکی، معمولا متر، تفسیر شود؛ ازاین‌رو تغییر مقیاس مجاز نیست و خطاهایی مانند

$$\mathrm{AbsRel} = \frac{۱}{N}\sum_i \frac{|D_i - \hat{D}_i|}{D_i}, \qquad \mathrm{RMSE} = \sqrt{\frac{۱}{N}\sum_i (D_i - \hat{D}_i)^۲} \tag{۲.۲}$$

به مقیاس مطلق حساس‌اند؛ در اینجا خطای نسبی مطلق[۱] (AbsRel) و RMSE[۲] به‌کار می‌روند. این تمایز در ادامه برای جدا کردن دستاوردهای مدل‌های نسبی از مدل‌های مطلق ضروری است.

[۱] Absolute Relative Error
[۲] Root Mean Squared Error

۲.۱.۲ مدل سوراخ‌سوزنی و ماتریس کالیبراسیون دوربین

رابطه تصویربرداری یک نقطه سه‌بعدی $\mathbf{X} = (X, Y, Z)^{\mathsf{T}}$ را با مدل سوراخ‌سوزنی می‌توان چنین نوشت:

$$s \begin{bmatrix} u \\ v \\ ۱ \end{bmatrix} = K \left[R \mid \mathbf{t} \right] \begin{bmatrix} X \\ Y \\ Z \\ ۱ \end{bmatrix}, \qquad K = \begin{bmatrix} f_x & \gamma & c_x \\ ۰ & f_y & c_y \\ ۰ & ۰ & ۱ \end{bmatrix}. \tag{۳.۲}$$

در این رابطه f_x, f_y فاصله‌های کانونی بر حسب پیکسل، (c_x, c_y) نقطه اصلی و γ کجی محورهای تصویر است. برای دوربین مستطیلی معمولا $\gamma = ۰$. پارامترهای درونی ماتریس کالیبراسیون دوربین نگاشت پیکسل و شعاع دید را تعیین می‌کنند؛ پارامترهای بیرونی $(R, \mathbf{t})$ وضعیت دوربین نسبت به صحنه را تعیین می‌کنند. در نگاشت یک نقطه تصویری به پرتو سه‌بعدی، عبارت $K^{-۱}[u, v, ۱]^{\mathsf{T}}$ نشان می‌دهد که یک پیکسل بدون دانستن ماتریس کالیبراسیون دوربین تنها جهت تقریبی را مشخص می‌کند، نه مقیاس عمق را.

در خودنظارتی ویدیویی، اگر π عمل فرافکنی باشد، بازسازی دیدگاه به‌صورت

$$\hat{I}_{t+۱}(p) = I_t \left(\pi \left(K T_{t \to t+۱} D_{t+۱}(p) K^{-۱} \tilde{p} \right) \right) \tag{۴.۲}$$

انجام می‌شود. این معادله نشان می‌دهد که ماتریس کالیبراسیون دوربین ممکن است در تابع هزینه بازسازی حضور داشته باشد، بی‌آنکه شبکه عمق آن را به‌عنوان ورودی دریافت کند. این دو حالت در این فصل از یکدیگر تفکیک می‌شوند.

۳.۱.۲ پارادایم‌های نظارتی و تابع‌های هزینه

در روش نظارت‌شده، نقشه مرجع D^{gt} مستقیما به مدل سیگنال می‌دهد. در روش خودنظارتی استریو، زوج چپ راست و خط پایه b برای بازسازی تصویر به‌کار می‌رود و رابطه ایده‌آل $Z = fb/d$ مقیاس را به تنظیم استریو وابسته می‌کند. در روش خودنظارتی ویدیویی، شبکه عمق و شبکه ژست با کمینه‌کردن خطای بازسازی فریم‌های زمانی آموزش می‌بینند. در آموزش نیمه‌نظارتی، عمق حسگر و قید سازگاری استریو هم‌زمان استفاده می‌شوند.

این تفاوت‌ها بعدا در مقایسه مقالات تاریخی به‌کار می‌آیند.

برای خروجی نسبی، یک هزینه رایج در فضای معکوس عمق، خطای تغییرناپذیر نسبت به مقیاس و انتقال[۱] است. برای خروجی مطلق، تابع هزینهٔ SiLog[۲] به‌صورت

$$L_{\text{SiLog}} = \frac{1}{N}\sum_i g_i^2 - \frac{\lambda}{N^2}\left(\sum_i g_i\right)^2, \qquad g_i = \log \hat{D}_i - \log D_i \qquad (۵.۲)$$

تعریف می‌شود. انتخاب فضای هدف و تابع هزینه باید با معنای خروجی سر مدل سازگار باشد.

۲.۲ مرور ادبیات گذشته

۱.۲.۲ دسته‌بندی کلی بر اساس حسگر و نوع نما

ادبیات را می‌توان بر اساس منبع هندسه به چهار گروه تقسیم کرد:

۱. چندنما و چنددوربینه: روش‌های استریو و چندنمایی با تطبیق نقاط متناظر و پارامترهای کالیبراسیون، عمق مطلق را از چند تصویر استخراج می‌کنند. MVSNet نمونه‌ای از این دسته است؛ ماتریس کالیبراسیون دوربین و وضعیت دوربین در ساخت حجم هزینه مستقیما استفاده می‌شوند [۱۶]. این روش‌ها دقیق‌اند، اما به چند نمای هم‌زمان و کالیبراسیون نیاز دارند.

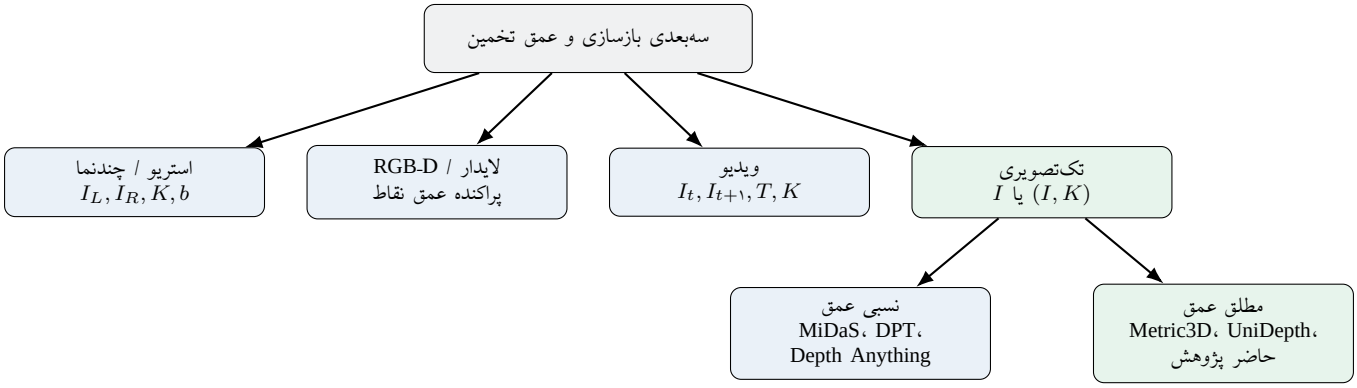
۲. لایدار یا عمق حسگر: نقاط پراکنده لایدار یا نقشه عمق رنگی عمق (RGB-D)[۳] با تصویر ترکیب می‌شوند. این گروه برای آموزش مطلق مناسب است، اما میدان دید محدود، پراکندگی و هزینه حسگر، استفاده مستقل از تصویر قرمز سبز آبی (RGB) را محدود می‌کند.

۳. تک‌دوربینه با ویدیو یا استریو در آموزش: فقط یک تصویر در آزمون داده می‌شود، ولی آموزش از زوج استریو یا فریم‌های زمانی و هندسه بازسازی استفاده می‌کند. این دسته مسیر اصلی خودنظارتی را شکل داده است.

[۱] Scale-Shift Invariant Loss
[۲] Scale-Invariant Logarithmic Loss تابع هزینهٔ لگاریتمی تغییرناپذیر نسبت به مقیاس؛
[۳] Red–Green–Blue–Depth

۴. تک‌تصویری بنیادین: شبکه از یک تصویر RGB خروجی نسبی یا مطلق می‌سازد و با آموزش چندمجموعه‌ای، تقطیر یا مدل‌های انتشاری به تعمیم صفرنمونه می‌رسد. این دسته، محور اصلی مرور حاضر است.

این چهار دسته و جایگاه عمق مطلق تک‌تصویری در شکل ۱.۲ خلاصه شده‌اند.



شکل ۱.۲: طبقه‌بندی روش‌های تخمین عمق بر اساس منبع اطلاعات هندسی و جایگاه تخمین عمق مطلق تک‌تصویری.

۲.۲.۲ روش‌های کلاسیک و نظارت‌شده اولیه

پیش از شبکه‌های عمیق، روش‌های Hoiem و Make3D از خطوط همگرا، افق، سطوح، اندازه نسبی اشیا و ویژگی‌های دستی برای برآورد ساختار صحنه استفاده می‌کردند [۱۷، ۱]. این روش‌ها رابطه میان نشانه دیداری و عمق را روشن کردند، اما به فرض‌های صحنه و دامنه آموزش حساس بودند. Eigen و همکاران یادگیری چندمقیاسی (Multi-scale) عمق را با شبکه عمیق مطرح کردند و Eigen–Fergus آن را به پیش‌بینی چندوظیفه‌ای (Multi-task) گسترش دادند [۲، ۵]. خروجی این مدل‌ها درون‌دامنه مطلق بود، اما تغییر دوربین و محیط، مقیاس آموخته‌شده را ناپایدار می‌کرد.

۳.۲.۲ سیر خودنظارتی: از استریو تا ویدیو

Godard و همکاران با جایگزین‌کردن عمق مرجع با زوج استریو، تابع بازسازی تصویر و سازگاری چپ راست را معرفی کردند [۱۰]. اگر d_L, d_R دیسپاریتی‌های دو نما باشند، قید سازگاری به‌صورت کلی $L_{lr} =$

$\|d_L - \mathcal{W}(d_R)\|$ نوشته می‌شود. این ایده آموزش RGB را ممکن کرد، ولی مقیاس آن به خط پایه و کالیبراسیون استریوی داده گره خورد. Zhou و همکاران عمق و حرکت دوربین را از ویدیوی بدون برچسب با بازسازی دیدگاه هم‌زمان آموختند [۱۸]. Zhan و همکاران با بازسازی ویژگی‌های عمیق در کنار خطای پیکسلی، پایداری بازسازی و تخمین ژست را بهبود دادند [۱۹]. مطالعه نیمه‌نظارتی Amiri و همکاران نیز ترکیب لایدار و سازگاری چپ راست را بررسی کرد [۲۰]. Monodepth2 با ماسک‌کردن خودکار پیکسل‌های نامعتبر و انتخاب حداقل بازسازی، خطاهای پویایی و انسداد را کاهش داد [۱۲].

این خط پژوهش نشان داد که از یک تصویر می‌توان مدل عمق ساخت، اما برای خروجی مطلق یا باید خط پایه/حرکت و ماتریس کالیبراسیون دوربین در حلقه بازسازی معلوم باشند، یا مقیاس از داده آموزش به‌طور ضمنی آموخته شود. هیچ‌کدام به‌تنهایی تضمین نمی‌کند که شبکه برای هر دوربین جدید، مقیاس را به‌درستی تغییر دهد.

۴.۲.۲ مدل‌های نسبی، معماری‌های ترنسفورمری و مدل‌های سبک

MiDaS با ترکیب مجموعه‌داده‌های ناهمگون و هزینه تغییرناپذیر نسبت به مقیاس و انتقال، عمق نسبی را به شکل قابل توجهی تعمیم داد [۷]. MiDaS v3.1 همین ایده را با ستون‌فقرات‌های BEiT، Swin، SwinV2، Next-ViT و LeViT در طیف دقت سرعت گسترش داد؛ بهترین مدل آن بهبود گزارش‌شده ۲۸ درصدی داشت، ولی خروجی همچنان نسبی است [۲۱]. Lite-Mono ترکیب CNN و ترنسفورمر را با بلوک‌های CDC و LGFI برای خودنظارتی سبک ارایه کرد و با حدود ۸۰ درصد پارامتر کمتر از Monodepth2 رقابت‌پذیر ماند [۲۲]. این کارها نشان می‌دهند که معماری قوی‌تر دقت نسبی را بالا می‌برد، اما ظرفیت بیشتر به‌تنهایی ابهام مقیاس ناشی از دوربین را حل نمی‌کند.

۵.۲.۲ مدل‌های بنیادین و تقطیر در مقیاس بزرگ

Depth Anything با استفاده از تصاویر مصنوعی برچسب‌دار، تصاویر واقعی بدون برچسب و معلم‌های قوی، یادگیری عمق نسبی را از محدودیت مجموعه‌داده‌های کوچک جدا کرد [۲۳]. نسخه دوم این مدل، که مدل پایه این پژوهش است، در بخش ۷.۲.۲ شرح داده می‌شود.

اگر z_T خروجی معلم و z_S خروجی دانش‌آموز باشند، یک قید معمول تقطیر مانند L_{dist} =

$\|\mathcal{N}(z_S) - \mathcal{N}(z_T)\|$ پیش‌بینی دانش‌آموز را با بازنمایی نرمال‌شده معلم هم‌راستا می‌کند. نرمال‌سازی، تفاوت مقیاس مجموعه‌داده‌ها را کاهش می‌دهد، ولی خود آن اطلاعات ماتریس کالیبراسیون دوربین هر تصویر را ایجاد نمی‌کند.

Distill Any Depth نشان می‌دهد که نرمال‌سازی سراسری شبه‌برچسب‌های پرنویز می‌تواند تقطیر را محدود کند؛ این کار با تقطیر متقاطع محلی سراسری و چندمعلمه کیفیت را افزایش می‌دهد [۲۴]. این نتیجه برای فصل حاضر مهم است، زیرا بهبود تقطیر و آگاهی از دوربین دو مساله متفاوت‌اند و نباید یکی به‌جای دیگری تفسیر شود.

۶.۲.۲ مدل‌های مطلق و شرطی‌سازی دوربین

CAM-Convs پارامترهای کالیبراسیون را به کانال‌های مختصاتی و میدان دید در کانولوشن وارد کرد و افت انتقال میان دوربین‌ها را کاهش داد [۸]. این نخستین شاهد مستقیم در فهرست حاضر است که شبکه تک‌تصویری از دانستن دوربین سود می‌برد.

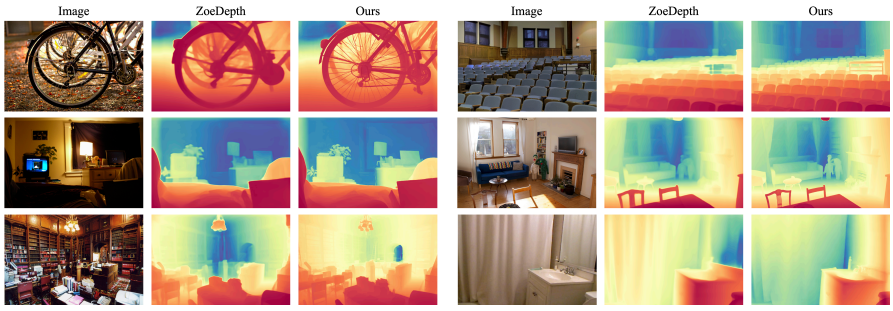
ZoeDepth یک ستون فقرات نسبی را با سرهای مطلق دامنه‌ای ترکیب می‌کند [۱۱]. این راهبرد مقیاس را در دامنه‌های شناخته‌شده می‌آموزد، اما برای دوربین یا دامنه خارج از تقسیم‌بندی، کالیبراسیون صریحی ندارد. Metric3D ابهام را با نگاشت ورودی‌ها به فضای دوربین متعارف و آموزش روی داده‌های متنوع کاهش می‌دهد [۹]. Metric3D v2 این ایده را با «تبدیل فضای دوربین متعارف» و آموزش بیش از ۱۶ میلیون تصویر از هزاران مدل دوربین برای پیش‌بینی هم‌زمان عمق مطلق و نرمال سطح گسترش می‌دهد [۲۵]. مزیت آن تعمیم صفرنمونه است؛ بااین‌حال اثر خالص دسترسی شبکه به ماتریس کالیبراسیون دوربین در برابر اثر تبدیل، داده و وظیفه نرمال به‌طور جداگانه سنجیده نشده است.

مدل عمق مطلق صفرنمونه (DMD) با شرط میدان دید، از پارامترسازی لگاریتمی عمق، تنوع مصنوعی میدان دید و مدل انتشار برای ترکیب صحنه‌های داخلی و بیرونی استفاده می‌کند [۱۳]. این کار نشان می‌دهد حتی یک اسکالر FoV می‌تواند ابهام مقیاس را کاهش دهد، اما هزینه استنتاج انتشار بالاست. UniDepth بازنمایی دوربین را از تصویر پیش‌بینی و ویژگی‌های عمق را با آن شرطی می‌کند؛ خروجی شبه‌کروی و زیان ناوردایی هندسی، جداسازی دوربین و عمق را تقویت می‌کنند [۱۴]. این روش به دوربین معلوم در زمان آزمون وابسته نیست، ولی چون هم‌زمان ماژول دوربین، داده و زیان جدید را تغییر می‌دهد، سهم علی یک ورودی ماتریس

کالیبراسیون دوربین معلوم را مشخص نمی‌کند.

از منظر معماری، این روش‌ها ماتریس کالیبراسیون را از مسیرهای متفاوتی به‌کار می‌برند: کانال‌های مختصاتی در کانولوشن‌ها (CAM-Convs)، شرط‌کردن شبکه انتشار بر اسکالر میدان دید (DMD)، نگاشت ورودی و برچسب‌ها به فضای متعارف در بیرون از شبکه (Metric3D)، یا تخمین دوربین از روی تصویر (Depth Pro ،UniDepth).

نمونه کیفی مقایسه مدل‌های مطلق در شکل ۲.۲ آمده است.



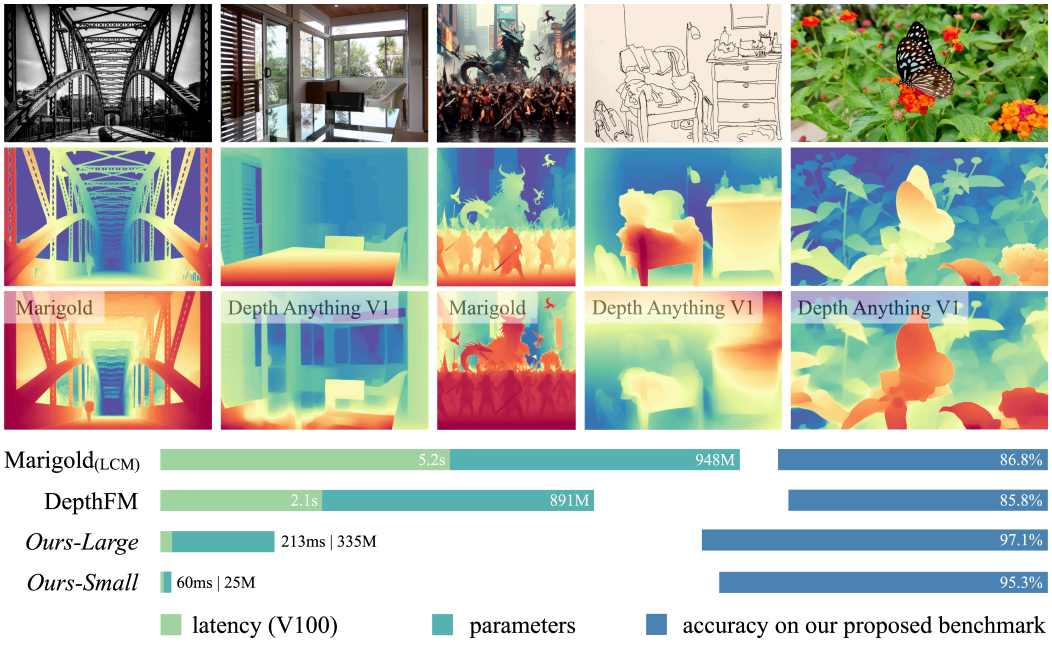
شکل ۲.۲: مقایسه کیفی چند مدل عمق مطلق؛ این شکل برای توضیح تفاوت خروجی مطلق و نسبی است و جایگزین ارزیابی عددی فصل چهارم نیست.

Marigold یک مدل انتشاری است که دانش ازپیش‌آموخته مدل تولید تصویر Stable Diffusion را برای تخمین عمق نسبی به کار می‌گیرد؛ یعنی عمقی که مقیاس و جابه‌جایی آن مشخص نیست [۲۶]. Marigold-DC مساله دیگری را هدف می‌گیرد: تکمیل عمق با راهنمایی اندازه‌گیری‌های پراکنده در زمان آزمون [۲۷]. بنابراین این دو کار شاهد قدرت priorهای مولدند، اما مقایسه مستقیم آن‌ها با مدل مطلق تک‌تصویری بدون اندازه‌گیری اضافی باید با احتیاط انجام شود.

۷.۲.۲ مقاله پایه برای مدل پیشنهادی

مدل پایه این پایان‌نامه Depth Anything V2 [۴] است و مدل پیشنهادی با افزودن مسیری برای ورود ماتریس کالیبراسیون دوربین به همین مدل ساخته می‌شود. این مدل از تقطیر دانش در مقیاس بزرگ برای ساخت مدل عمق نسبی با تعمیم بالا استفاده می‌کند و نسبت به نسخه نخست Depth Anything [۲۳] سه تغییر کلیدی دارد: جایگزینی تصاویر واقعی برچسب‌دار با تصاویر مصنوعی، افزایش ظرفیت معلم و آموزش دانش‌آموز با واسطه تصاویر واقعی شبه‌برچسب‌خورده. در جزییات گزارش‌شده مقاله، معلم ابتدا روی پنج مجموعه مصنوعی

با مجموع حدود ۵۹۵ هزار تصویر آموزش می‌بینند؛ سپس خروجی معلم برای هشت مجموعه واقعی با مجموع حدود ۶۲ میلیون تصویر تولید و برای آموزش دانش‌آموزان استفاده می‌شود. بنابراین برچسب‌های واقعی پرهزینه، با شبه‌برچسب‌های معلم جایگزین می‌شوند و چند اندازه دانش‌آموز از حدود ۲۵ میلیون تا ۳٫۱ میلیارد پارامتر ارایه می‌گردد. این فرایند، پیش‌آموزش عمومی مدل پایه است و با تنظیم دقیق‌پارامترها[۱] مطلق پژوهش حاضر یکسان نیست. نمونه‌ای از خروجی و دامنه این مدل در شکل ۳.۲ دیده می‌شود.



شکل ۳.۲: نمونه‌ای از خروجی‌های کیفی مدل Depth Anything V2 برای نمایش دامنه صحنه‌ها و جزئیات ساختاری.

معماری Depth Anything V2 از دو بخش تشکیل شده است: یک انکودر بصری از خانواده DINOv2 [۲۸] که تصویر را به دنباله‌ای از توکن‌های ویژگی تبدیل می‌کند، و یک دیکودر به سبک ترنسفورمر پیش‌بینی چگال (DPT)[۲] [۶] که ویژگی‌های چند بلوک میانی انکودر را به نگاشت عمق با وضوح کامل برمی‌گرداند. در نسخه مطلق، نویسندگان همین مدل‌های نسبی را با برچسب‌های عمق مطلق تنظیم دقیق‌پارامترها می‌کنند. در این پژوهش، نقطه بازرسی منتشرشده همین مدل (هم نسخه پایه و هم نسخه مطلق تنظیم‌دقیق‌شده روی Hypersim و VKITTI) به‌عنوان وزن شروع برای هر دو مدل پیشنهادی و مدل کنترل استفاده می‌شود؛ این انتخاب تضمین می‌کند که تفاوت عملکرد دو مدل، ناشی از کیفیت پیش‌آموزش نباشد و فقط به دسترسی یا عدم دسترسی به ماتریس کالیبراسیون دوربین نسبت داده شود. در ادامه، این دو بخش مدل

[۱] Fine-tuning
[۲] Dense Prediction Transformer

پایه و نقش هرکدام در مدل پیشنهادی شرح داده می‌شود.

بخش نخست مدل پایه، انکودر DINOv2 است. معماری این انکودر، ترنسفورمر بینایی (ViT) است [۲۹]. در این معماری، تصویر ورودی $I \in \mathbb{R}^{H\times W\times ۳}$ به شبکه‌ای از وصله‌های ناهمپوشان با اندازه $P\times P$ تقسیم می‌شود و هر وصله $\mathbf{x}_p^i \in \mathbb{R}^{۳P^۲}$ با یک نگاشت خطی آموزش‌پذیر $\mathbf{E}$ به یک توکن dبعدی تبدیل می‌شود. با افزودن یک توکن کلاس $\mathbf{x}_{\text{cls}}$ و جاسازی مکانی $\mathbf{E}_{\text{pos}}$، دنباله ورودی انکودر به‌صورت

$$\mathbf{z}^{۰} = \left[\mathbf{x}_{\text{cls}};\, \mathbf{x}_p^{۱}\mathbf{E};\, \ldots;\, \mathbf{x}_p^{N}\mathbf{E}\right] + \mathbf{E}_{\text{pos}}, \qquad N = \frac{H}{P}\cdot\frac{W}{P}, \tag{۶.۲}$$

ساخته می‌شود. سپس L بلوک ترنسفورمر یکسان این دنباله را پالایش می‌کنند. هر بلوک شامل یک لایه خودتوجهی چندسری (MSA)[۱] و یک شبکه پیش‌خور (MLP) است که هرکدام با نرمال‌سازی لایه (LN)[۲] و اتصال باقیمانده همراه‌اند:

(۷.۲)

$$\mathbf{z}'^{l} = \mathbf{z}^{l-۱} + \mathrm{MSA}\big(\mathrm{LN}(\mathbf{z}^{l-۱})\big), \qquad \mathbf{z}^{l} = \mathbf{z}'^{l} + \mathrm{MLP}\big(\mathrm{LN}(\mathbf{z}'^{l})\big), \qquad l = ۱,\ldots,L.$$

هسته هر سر توجه، توجه ضرب نقطه‌ای مقیاس‌شده است:

$$\mathrm{Attn}(Q,K,V) = \mathrm{softmax}\Big(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\Big)V, \tag{۸.۲}$$

که در آن Q، K و V نگاشت‌های خطی دنباله توکن‌ها و d_k بعد هر سر است. چون هر توکن از همان لایه نخست به همه توکن‌های دیگر توجه می‌کند، میدان دریافت انکودر، برخلاف شبکه‌های کانولوشنی، از ابتدا سراسری است؛ در مقابل، هزینه محاسبه خودتوجهی با مربع طول دنباله، یعنی $\mathcal{O}(N^۲)$، رشد می‌کند. در DINOv2 و در نتیجه در مدل پایه، $P = ۱۴$ است؛ بنابراین ابعاد ورودی باید مضرب ۱۴ باشند. برای نمونه، ورودی ۵۱۸ × ۵۱۸ به ۳۷ × ۳۷ = ۱۳۶۹ توکن وصله و چارچوب ۶۸۶ × ۵۱۸ آزمایش‌های نهایی این پژوهش به ۴۹ × ۳۷ = ۱۸۱۳ توکن وصله تبدیل می‌شود. چهار اندازه انکودر ViT-S، ViT-B، ViT-L و ViT-G به‌ترتیب با بعد نهان ۳۸۴، ۷۶۸، ۱۰۲۴ و ۱۵۳۶ و با ۱۲، ۱۲، ۲۴ و ۴۰ بلوک در دسترس‌اند و پیکربندی اصلی

[۱] Multi-head Self-Attention
[۲] Layer Normalization

این پژوهش ViT-L (۲۴ بلوک و ۱۶ سر توجه) است. مهم‌ترین ویژگی ViT برای این پژوهش آن است که ورودی آن یک دنباله توکن است؛ ازاین‌رو اطلاعات غیرتصویری، مانند بازنمایی ماتریس کالیبراسیون دوربین، را می‌توان به‌صورت یک توکن هم‌بعد با توکن‌های وصله وارد دنباله کرد و سازوکار خودتوجهی، بدون تغییر ساختار بلوک‌ها، آن را در اختیار همه توکن‌های وصله قرار می‌دهد.

وزن‌های این انکودر از پیش‌آموزش DINOv2 به دست آمده‌اند. این انکودر بدون هیچ برچسب انسانی و با یادگیری خودنظارتی[1] روی مجموعه گزینش‌شده LVD-142M، شامل حدود ۱۴۲ میلیون تصویر، آموزش دیده است. آموزش در چارچوب خودتقطیری انجام می‌شود: یک شبکه دانش‌آموز و یک شبکه معلم، که وزن‌هایش میانگین متحرک نمایی وزن‌های دانش‌آموز است، نماهای متفاوتی از یک تصویر (برش‌های بزرگ و کوچک همراه با افزونه‌سازی رنگی) را می‌بینند. تابع هدف دو جزء دارد: در سطح تصویر، توزیع خروجی توکن کلاس دانش‌آموز باید با توزیع معلم برای نمای دیگر هم‌خوان شود (هدف DINO)؛ و در سطح وصله، دانش‌آموز باید ویژگی معلم را برای وصله‌هایی که در ورودی خودش پوشانده شده‌اند بازسازی کند (هدف iBOT). یک جمله تنظیم KoLeo نیز ویژگی‌ها را در فضای بازنمایی یکنواخت‌تر پخش می‌کند. بزرگ‌ترین مدل (ViT-g) مستقیما با این هدف آموزش دیده و مدل‌های کوچک‌تر از آن تقطیر شده‌اند. حاصل این فرایند، ویژگی‌های وصله‌ای است که هم اطلاعات معنایی و هم نشانه‌های هندسی محلی را کد می‌کنند و برای وظایف چگال مانند تخمین عمق و قطعه‌بندی معنایی، حتی با انکودر فریزشده، قابل استفاده‌اند؛ مقاله DINOv2 گزارش می‌کند که سرهای ساده روی ویژگی‌های فریزشده آن، روی NYU و KITTI نتایج رقابتی به دست می‌دهند. با این حال، این ویژگی‌ها تنها از محتوای بصری ساخته می‌شوند و پارامترهای دوربین را به‌صورت صریح دریافت نمی‌کنند؛ اگر دو صحنه با اندازه و فاصله متفاوت، با دو دوربین متفاوت به تصویر یکسانی منجر شوند، انکودر برای هر دو بازنمایی یکسانی تولید می‌کند. Depth Anything V2 از خروجی چهار بلوک میانی این انکودر استفاده می‌کند: بلوک‌های ۵، ۱۲، ۱۸ و ۲۴ برای ViT-L، بلوک‌های ۳، ۶، ۹ و ۱۲ برای ViT-S و ViT-B و بلوک‌های ۱۰، ۲۰، ۳۰ و ۴۰ برای ViT-G. در پیاده‌سازی این پژوهش، وزن‌های از پیش‌آموزش‌دیده این انکودر از طریق نقطه بازرسی Depth Anything V2 بارگذاری و طی آموزش نگه‌داشته می‌شوند؛ یعنی انکودر DINOv2 در تنظیم دقیق‌پارامترها عمدتا فریز است و فقط شاخه جدید دوربین و سر خروجی به‌روزرسانی می‌شوند. دلیل این انتخاب آن است که DINOv2 به تنهایی پارامترهای دوربین را دریافت نمی‌کند؛ بنابراین مسئولیت تزریق اطلاعات ماتریس کالیبراسیون باید در لایه‌ای جدا از این انکودر تعریف شود، نه با تغییر دادن خود DINOv2.

[1] Self-supervised Learning

بخش دوم مدل پایه، دیکودر DPT است که دنباله توکن‌های چهار بلوک میانی انکودر را به نگاشت عمق با وضوح کامل تبدیل می‌کند. برخلاف شبکه‌های کانولوشنی، وضوح مکانی توکن‌ها در طول انکودر کاهش نمی‌یابد و همه بلوک‌ها روی یک شبکه ثابت $\frac{W}{۱۴} \times \frac{H}{۱۴}$ کار می‌کنند؛ بنابراین دیکودر باید خود یک هرم چندوضوحی بسازد. این کار در سه مرحله انجام می‌شود:

- بازآرایی[۱]: از خروجی هر بلوک منتخب، توکن کلاس کنار گذاشته می‌شود (پیکربندی پیش‌فرض Depth Anything V2) و N توکن وصله به یک نگاشت ویژگی دوبعدی با ابعاد $\frac{W}{۱۴} \times \frac{H}{۱۴} \times d$ بازچینی می‌شوند. سپس یک کانولوشن ۱×۱ تعداد کانال‌ها را به C_i تغییر می‌دهد (برای ViT-L: ۲۵۶، ۵۱۲، ۱۰۲۴ و ۱۰۲۴) و یک لایه بازنمونه‌برداری، وضوح چهار سطح را به‌ترتیب چهار برابر و دو برابر (با کانولوشن ترانهاده)، بدون تغییر و نصف (با کانولوشن گام‌دار) می‌کند. به این ترتیب، ویژگی‌های بلوک‌های کم‌عمق‌تر، که جزئیات محلی بیشتری دارند، در وضوح بالاتر و ویژگی‌های بلوک‌های عمیق‌تر، که بافت سراسری‌تری دارند، در وضوح پایین‌تر قرار می‌گیرند.

- ادغام[۲]: هر سطح با یک کانولوشن ۳×۳ به ۲۵۶ کانال مشترک نگاشت می‌شود. سپس بلوک‌های ادغام به سبک RefineNet، از درشت‌ترین سطح به سمت ریزترین، خروجی مرحله قبل را با سطح جاری جمع می‌کنند؛ هر بلوک شامل دو واحد کانولوشنی باقیمانده، یک بزرگ‌نمایی دوبرابری با درون‌یابی دوخطی و یک کانولوشن ۱×۱ است.

- سر پیش‌بینی: یک کانولوشن ۳×۳ تعداد کانال‌ها را نصف می‌کند، خروجی با درون‌یابی دوخطی به وضوح ورودی (۱۴ برابر شبکه وصله‌ها) برده می‌شود و پس از یک کانولوشن ۳×۳ با ۳۲ کانال و ReLU، یک کانولوشن ۱×۱ نگاشت تک‌کاناله نهایی را تولید می‌کند. در نسخه نسبی، خروجی با ReLU نامنفی می‌شود و به‌صورت عمق معکوس نسبی تفسیر می‌شود. در نقاط بازرسی مطلق رسمی، تابع سیگموید جایگزین آن شده و خروجی در بیشینه عمق $d_{\max}$ ضرب می‌شود تا عمق مطلق در بازه $(۰, d_{\max})$ به دست آید.

اگر $l_۱, \ldots, l_۴$ شماره بلوک‌های منتخب، $\mathcal{R}_i$ عملگر بازآرایی، $\mathcal{F}_i$ بلوک ادغام و $\mathcal{H}$ سر پیش‌بینی باشند، کل

[۱] Reassemble
[۲] Fusion

دیکودر را می‌توان به‌صورت

(۹.۲)

$$\mathbf{F}_i = \mathcal{R}_i(\mathbf{z}^{l_i}), \qquad \mathbf{P}_4 = \mathcal{F}_4(\mathbf{F}_4), \qquad \mathbf{P}_i = \mathcal{F}_i(\mathbf{P}_{i+1}, \mathbf{F}_i) \quad (i = 3, 2, 1), \qquad \hat{D} = \mathcal{H}(\mathbf{P}_1)$$

نوشت. در نتیجه، هم میدان دید سراسری ترنسفورمر و هم مرزهای مکانی لازم برای پیش‌بینی چگال حفظ می‌شوند. از آنجا که مرحله بازآرایی فقط توکن‌های وصله را به نگاشت مکانی تبدیل می‌کند، اطلاعات دوربین در مدل پیشنهادی به‌طور مستقیم وارد دیکودر نمی‌شود، بلکه از طریق اثری که در لایه‌های خودتوجهی انکودر بر توکن‌های وصله گذاشته است به آن می‌رسد. در این پژوهش، همین دیکودر بدون تغییر ساختاری از Depth Anything V2 به ارث رسیده است؛ تنها ورودی آن، یعنی توکن‌های انکودر، با افزودن بازنمایی ماتریس کالیبراسیون دوربین غنی‌تر می‌شود (شرح کامل در فصل سوم). به‌عبارت دیگر، DPT همان دیکودر مرجع است و نوآوری این پژوهش در مسیر ورودی به آن قرار دارد، نه در خود دیکودر.

نکته روش‌شناختی مهم درباره مدل پایه آن است که هیچ‌یک از دو بخش آن، در نسخه منتشرشده، ماتریس کالیبراسیون دوربین را به‌صورت ورودی صریح دریافت نمی‌کند؛ انکودر DINOv2 فقط تصویر را می‌بیند، دیکودر DPT فقط ویژگی‌های بصری را به نگاشت عمق تبدیل می‌کند و راهبرد تقطیر Depth Anything V2 نیز روی تعمیم بصری متمرکز است، نه روی هندسه دوربین. ازاین‌رو، سهم این پژوهش دقیقا در محل اتصال این دو بخش، یعنی مسیر ورودی انکودر، تعریف می‌شود (جزئیات در فصل سوم) و انتقال مدل بنیادین به عمق مطلق دوربین‌متغیر، پرسشی مستقل از کیفیت بازنمایی بصری مدل پایه باقی می‌ماند.

۳.۲ شکاف تحقیقاتی

با توجه به مرور بالا، شکاف‌ها به‌صورت شماره‌دار زیر صورت‌بندی می‌شوند. در این بخش فقط مساله باقی‌مانده و اهمیت آن بیان می‌شود؛ پاسخ‌های اجرایی در بخش بعد آمده‌اند.

۱. نبود اتصال صریح میان هندسه دوربین و مدل بنیادین نسبی. DPT، MiDaS و Depth Anything V2 عمدتا از I استفاده می‌کنند. حتی در روش‌های خودنظارتی که ماتریس کالیبراسیون دوربین در بازسازی حضور دارد، شبکه عمق لزوما آن را نمی‌بیند. بنابراین تغییر f_x, f_y, c_x, c_y می‌تواند به تغییر مقیاس

واقعی نیاز داشته باشد، بی‌آنکه مسیر صریحی برای اعمال این تغییر وجود داشته باشد. به‌ویژه، در انکودر ترنسفورمری مدل‌های بنیادین عمق تک‌تصویری، ماتریس کالیبراسیون معلوم از مسیر توکن وارد نمی‌شود.

۲. فاصله میان عمق نسبی بسیار تعمیم‌پذیر و عمق مطلق وابسته به دامنه. MiDaS و Depth Anything در خروجی نسبی قوی‌اند؛ ZoeDepth و مدل‌های مطلق درون‌دامنه مقیاس را بازیابی می‌کنند؛ Metric3D، DMD و UniDepth تعمیم را با تغییر هم‌زمان فضا، داده یا ماژول دوربین دنبال می‌کنند. هنوز روشن نیست آیا یک مدل بنیادین موجود با افزودن اطلاعات هندسی کم‌بعد می‌تواند در رژیم تنظیم دقیق‌پارامترهای محدود، مطلق و قابل انتقال شود.

۳. نبود آزمایش عامل‌محور برای سهم خالص ماتریس کالیبراسیون دوربین. در CAM-Convs، Metric3D، DMD و UniDepth، معماری، داده، پیش‌پردازش یا هدف آموزش هم‌زمان تغییر می‌کند. بهبود نهایی بنابراین اثر مشترک چند تصمیم است و نمی‌گوید چه مقدار از آن مستقیما از دریافت ماتریس کالیبراسیون دوربین آمده است.

۴. کمبود آزمون سازوکاری برای تشخیص مصرف واقعی ماتریس کالیبراسیون دوربین. بهبود AbsRel به‌تنهایی ممکن است از هم‌بستگی داده‌ای یا افزایش ظرفیت ناشی شود. ادبیات کمتر می‌سنجد که آیا با تغییر کنترل‌شده f، خروجی با قانون هندسی $Z \propto f$ حرکت می‌کند و آیا حذف یا تحریف ماتریس کالیبراسیون دوربین دقت را به‌صورت قابل پیش‌بینی کاهش می‌دهد.

۵. آمیختگی ارزیابی نسبی و مطلق. تراز مقیاس در معیارهای نسبی می‌تواند خطایی را پنهان کند که برای کاربردهای فیزیکی مهم است. بدون گزارش هم‌زمان ارزیابی بدون تراز و ارزیابی ترازشده، نقش ماتریس کالیبراسیون دوربین در مقیاس مطلق قابل تشخیص نیست.

۶. خطرهای بازتولیدپذیری در زنجیره انتقال مدل. تغییر ماتریس کالیبراسیون دوربین در برش تصویر، یا ناهم‌خوانی سر مطلق می‌تواند نتیجه‌ای ظاهرا معتبر بسازد و نسبت‌دادن اثر به هندسه را مخدوش کند. ادبیات معمولا این کنترل‌های زیرساختی را به‌صورت یک آزمایش مستقل گزارش نمی‌کند.

۴.۲ نوآوری‌های تحقیق

نوآوری‌های زیر به‌ترتیب با شماره‌های بخش پیشین متناظرند و جزییات فرمولی و پیاده‌سازی آن‌ها در فصل سوم می‌آید:

۱. پارامترهای نرمال‌شده ماتریس کالیبراسیون دوربین به یک نمایش هندسی مستقل تبدیل و به جریان توکن‌های انکودر Depth Anything V2 افزوده شدند تا مدل تصویر و هندسه تصویربرداری را هم‌زمان ببیند. برخلاف مسیرهای کانولوشنی، پیش‌پردازشی یا حدس‌زننده، ماتریس کالیبراسیون معلوم از راه خودتوجهی در بازنمایی‌های انکودر ترنسفورمری سهیم می‌شود.

۲. همان ستون فقرات بنیادین در دو حالت نسبی و مطلق بررسی و با تنظیم دقیق‌پارامترهای کنترل‌شده به مساله عمق مطلق متصل شد؛ بدین ترتیب مقایسه تعمیم بازنمایی پایه با بازیابی مقیاس ممکن شد.

۳. مدل پیشنهادی و مدل کنترل با داده، تقسیم، ابرپارامتر و بذر یکسان به‌صورت زوجی آموزش داده شدند و دسترسی به ماتریس کالیبراسیون دوربین تنها عامل طراحی‌شده متفاوت بود.

۴. آزمون پیمایش فاصله کانونی[۱] و آزمون حذف و تحریف ماتریس کالیبراسیون به‌عنوان سنجه سازوکاری اجرا شدند تا پاسخ خروجی و افت دقت مستقیما به مصرف اطلاعات دوربین نسبت داده شود.

۵. معیارهای نسبی ترازشده و معیارهای مطلق بدون تراز هم‌زمان گزارش شدند تا اثر حذف مقیاس در ارزیابی نسبی از نتیجه پنهان نشود.

۶. پروتکل تقسیم داده، به‌روزرسانی هندسی ماتریس کالیبراسیون دوربین پس از برش و تطبیق سر خروجی در زنجیره آموزش و ارزیابی کنترل شدند.

۵.۲ جمع‌بندی فصل

مرور تاریخی از روش‌های هندسی و چندنما، خودنظارتی استریو و ویدیویی، مدل‌های نسبی DPT/MiDaS، مدل‌های بنیادین Depth Anything و روش‌های مطلق CAM-Convs، Metric3D،

[۱] Focal Length Sweep Test (K-Sweep)

DMD و UniDepth نشان داد که آگاهی از دوربین یک ایده تثبیت‌شده اما هنوز از نظر انتساب علی و انتقال به مدل‌های بنیادین حل‌نشده است. فصل سوم اکنون فقط صورت‌بندی و اجرای روش پیشنهادی، انتخاب نمایش ماتریس کالیبراسیون دوربین، آموزش زوج کنترل و آزمایش‌های طراحی‌شده را شرح می‌دهد.

فصل ۳

روش تحقیق

۱.۳ مقدمه

در این فصل، روش پیشنهادی برای شرطی‌سازی یک مدل بنیادین تخمین عمق تک‌چشمی با پارامترهای درونی دوربین تشریح می‌شود. تمرکز اصلی بر معماری، نحوه ادغام اطلاعات هندسی و فرآیند واقعی آموزش و ارزیابی است. مدل پایه Depth Anything V2 ازپیش‌آموزش دیده است، اما مرحله نهایی تنظیم دقیق‌پارامترها در این پژوهش با عمق مرجع انجام شده است.

بر این اساس، در روش پیشنهادی این پژوهش، ماتریس کالیبراسیون دوربین به‌عنوان یک ورودی اضافی و ساختاریافته به بخش encoder مدل افزوده شده است. هدف از این کار، فراهم‌کردن امکان استفاده مستقیم از اطلاعات هندسی دوربین در فرآیند یادگیری و تاثیرگذاری آن بر مکانیزم attention در لایه‌های Transformer است. بدین ترتیب، مدل قادر خواهد بود نگاشت تصویر به عمق را نه‌تنها بر اساس محتوای بصری صحنه، بلکه با درنظرگرفتن ویژگی‌های تصویربرداری دوربین انجام دهد.

در ادامه این فصل، ابتدا فرمول‌بندی دقیق مساله و مدل هندسی دوربین ارایه می‌شود. سپس تغییرات اعمال‌شده برای ادغام ماتریس کالیبراسیون دوربین در مدل پایه توضیح داده می‌شود. جزییات عمومی مدل پایه در فصل دوم آمده است؛ پس از معرفی مدل پیشنهادی، داده‌ها و پیش‌پردازش ورودی توضیح داده می‌شوند و سپس فرآیند آموزش و توابع هزینه پژوهش حاضر ارایه می‌گردند. جزئیات نرم‌افزار و زیرساخت اجرایی در فصل چهارم، همراه با تنظیمات آزمایش، گزارش می‌شوند.

۲.۳ تحلیل مدل پایه

مدل پایه Depth Anything V2 یک معماری encoder–decoder مبتنی بر Vision Transformer را برای تخمین عمق چگال از تصاویر تک‌چشمی ارایه می‌دهد [۴]. اگرچه این مدل در حالت پایه عملکرد قابل‌توجهی در سناریوهای مختلف نشان می‌دهد، اما همانند بسیاری از روش‌های موجود، اطلاعات درونی دوربین به‌صورت صریح در ورودی مدل لحاظ نمی‌شود [۲، ۱۰، ۶]. این موضوع می‌تواند منجر به ناپایداری تخمین عمق در مواجهه با تغییر پارامترهای دوربین، به‌ویژه در داده‌های چندمنبعه یا تنظیمات دنیای واقعی، شود.

۳.۳ صورت‌بندی مساله MDE

مساله MDE به فرایند برآورد فاصله هر نقطه از صحنه نسبت به مرکز دوربین، تنها با استفاده از یک تصویر دوبعدی اطلاق می‌شود. در این مساله، ورودی سیستم یک تصویر رنگی دوبعدی تعریف می‌شود و خروجی آن یک نگاشت عمق چگال است که به هر پیکسل تصویر، یک مقدار اسکالر متناظر با عمق نسبت داده می‌شود. با وجود ظاهر ساده این تعریف، MDE ذاتا یک مساله بدوضعیت محسوب می‌شود [۳، ۱] زیرا نگاشت از فضای دوبعدی تصویر به فضای سه‌بعدی صحنه، یکتا نبوده و چندین پیکربندی هندسی متفاوت می‌توانند تصویر یکسانی را ایجاد کنند.

در چارچوب یادگیری عمیق، این مساله به‌صورت یادگیری یک تابع غیرخطی با پارامتر θ مدل‌سازی می‌شود که نگاشت زیر را تقریب می‌زند:

$$f_\theta : \mathbb{R}^{H\times W\times ۳} \rightarrow \mathbb{R}^{H\times W}, \tag{۱.۳}$$

که در آن، H و W به‌ترتیب ارتفاع و عرض تصویر ورودی بوده و خروجی، نگاشت عمق چگال متناظر با تصویر ورودی است. مقدار عمق پیش‌بینی‌شده در هر پیکسل، فاصله آن نقطه از مرکز اپتیکی دوربین را در راستای محور دید نمایش می‌دهد.

در روش‌های خودنظارتی (که در ادبیات پیشین غالبا «بدون نظارت» نامیده می‌شوند)، برخلاف روش‌های نظارت‌شده، برچسب عمق صریح در دسترس نیست و یادگیری معمولا بر قیود هندسی، سازگاری تصویری و بازسازی میان نماهای متوالی تکیه دارد [۱۸، ۱۰]. این پیشینه انگیزه عنوان و صورت‌بندی هندسی پژوهش است. بااین‌حال، آزمایش کنترل‌شده نهایی برای اندازه‌گیری دقیق سهم ماتریس کالیبراسیون دوربین، از عمق مرجع استفاده می‌کند و بنابراین باید یک مرحله تنظیم دقیق‌پارامترهای نظارتی تلقی شود.

به‌صورت صوری، اگر I_t تصویر ورودی در زمان t باشد، هدف یادگیری تابعی است که نگاشت عمق D_t را به‌گونه‌ای تولید کند که با استفاده از آن و با در نظر گرفتن حرکت دوربین، تصویر $I_{t+۱}$ قابل بازسازی از I_t باشد. این بازسازی مبتنی بر هندسه تصویربرداری و مدل دوربین بوده و به‌طور مستقیم به پارامترهای درونی دوربین وابسته است [۳]. با این حال، بخش قابل‌توجهی از روش‌های موجود، یا به‌صورت ضمنی این پارامترها را نادیده می‌گیرند یا فرض می‌کنند که تمامی تصاویر با یک دوربین ایده‌آل و یکسان ثبت شده‌اند.

یکی از تمایزهای اساسی در مساله MDE، تفاوت میان عمق نسبی و عمق مطلق است. بسیاری از روش‌های خودنظارتی و روش‌های عمق نسبی قادر به پیش‌بینی عمق تنها تا یک ضریب مقیاس نامشخص هستند؛ بدین معنا که ساختار نسبی صحنه حفظ می‌شود، اما مقادیر عمق از نظر مطلق معنا ندارند [۱۸، ۱۲، ۷]. این مساله به‌ویژه در کاربردهایی که نیازمند دقت عددی در واحدهای فیزیکی هستند، نظیر ناوبری رباتیک یا بازسازی سه‌بعدی، یک محدودیت جدی محسوب می‌شود.

در مقابل، تخمین عمق مطلق یا مطلق مستلزم آن است که نگاشت عمق خروجی، مستقیما قابل تفسیر در واحدهای فیزیکی نظیر متر باشد. تحقق این هدف بدون در نظر گرفتن مشخصات هندسی دوربین عملا امکان‌پذیر نیست، زیرا تبدیل میان مختصات تصویری و مختصات سه‌بعدی جهان، به‌طور مستقیم به پارامترهای درونی دوربین وابسته است. این وابستگی از طریق ماتریس کالیبراسیون دوربین مدل‌سازی می‌شود که نقش کلیدی در تعیین مقیاس و اعوجاج هندسی تصویر دارد.

در این پژوهش، مساله به‌صورت زیر تعریف می‌شود: هدف، یادگیری تابعی است که علاوه بر تصویر ورودی، پارامترهای درونی دوربین را نیز دریافت کرده و نگاشت عمقی سازگار با هندسه تصویربرداری تولید کند. این تعریف به نوع سیگنال نظارتی وابسته نیست و می‌تواند در آموزش‌های مختلف به‌کار رود؛ پیاده‌سازی نهایی حاضر از حالت نظارتی استفاده می‌کند. به‌صورت نمادین:

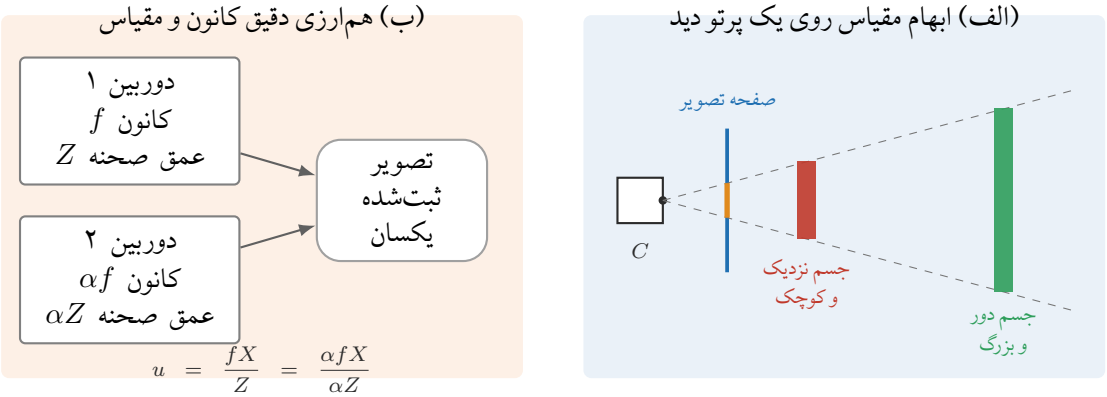
$$f_\theta : (I, K) \rightarrow D, \tag{۲.۳}$$

که در آن، I تصویر ورودی، ماتریس کالیبراسیون دوربین، و D نگاشت عمق خروجی است. در این صورت‌بندی، ماتریس کالیبراسیون دوربین به‌عنوان بخشی از ورودی مدل در نظر گرفته می‌شود و مدل می‌آموزد که چگونه اطلاعات هندسی دوربین را در فرآیند استنتاج عمق لحاظ کند.

این بازفرمول‌بندی، امکان تحلیل صریح اثر تغییرات دوربین بر خروجی مدل را فراهم می‌سازد و زمینه را برای تبیین تفاوت رفتار معیارهای ارزیابی مطلق و نسبی مهیا می‌کند. به‌ویژه، معیار RMSE که به مقیاس فیزیکی حساس است، مستقیما از نحوه مدل‌سازی پارامترهای دوربین تاثیر می‌پذیرند، در حالی که معیارهای نسبی‌تر نظیر AbsRel کمتر به این تغییرات واکنش نشان می‌دهند. این تمایز، در فصول بعدی و به‌ویژه در تحلیل نتایج تجربی، نقش محوری ایفا خواهد کرد.

شکل ۱.۳ ابهام مقیاس در تخمین عمق و نیاز به ماتریس مشخصه (کالیبراسیون) دوربین برای تشخیص عمق

واقعی را در همین صورت‌بندی مسئله نشان می‌دهد.



شکل ۳.۱: ابهام مقیاس در تخمین عمق تک‌دوربینه

۴.۳ هندسه دوربین و نقش پارامترهای درونی

مساله تخمین عمق، به‌طور بنیادین ریشه در هندسه تصویربرداری دارد و هرگونه نگاشت میان فضای دوبعدی تصویر و ساختار سه‌بعدی صحنه، ناگزیر وابسته به مدل دوربین مورد استفاده است. در MDE، این وابستگی حتی پررنگ‌تر می‌شود، زیرا تمام اطلاعات مربوط به ساختار فضایی صحنه باید از روی یک تصویر و با اتکا به قیود هندسی استنتاج شود. از این رو، درک دقیق هندسه دوربین و نقش پارامترهای درونی آن، برای تحلیل رفتار مدل‌های تخمین عمق، به‌ویژه در تنظیمات خودنظارتی، ضروری است.

در این بخش، ابتدا مدل هندسی دوربین مورد استفاده معرفی می‌شود، سپس ماتریس کالیبراسیون دوربین به‌صورت صوری تعریف شده و در ادامه، تاثیر مستقیم پارامترهای درونی بر مقیاس و پایداری تخمین عمق مورد بررسی قرار می‌گیرد.

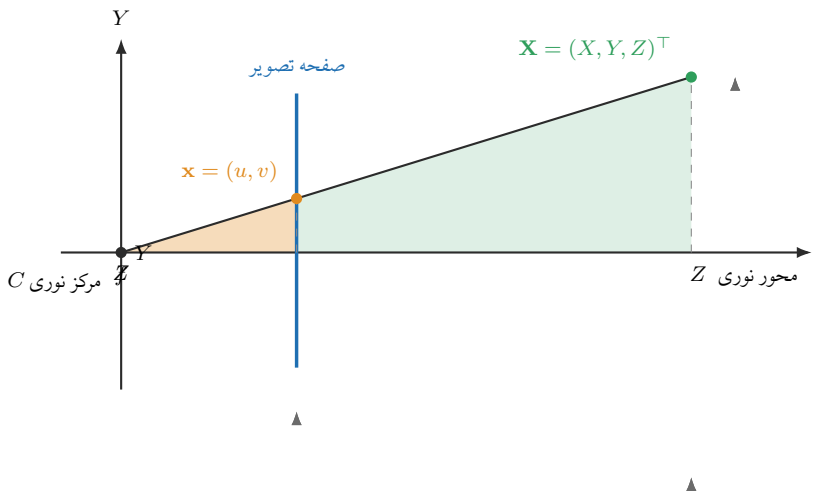
۱.۴.۳ مدل دوربین سوراخ‌سوزنی

در اغلب روش‌های بینایی ماشین، از مدل دوربین سوراخ‌سوزنی به‌عنوان یک تقریب هندسی استاندارد برای فرآیند تصویربرداری استفاده می‌شود [۳]. در این مدل، فرض می‌شود که تمام پرتوهای نوری از یک نقطه واحد،

موسوم به مرکز اپتیکی، عبور کرده و بر روی صفحه تصویر نگاشت می‌شوند. اگرچه این مدل بسیاری از پدیده‌های فیزیکی نظیر اعوجاج لنز را نادیده می‌گیرد، اما برای تحلیل هندسی و فرمول‌بندی ریاضی مساله تخمین عمق، کفایت لازم را دارد.

در چارچوب این مدل، یک نقطه سه‌بعدی در مختصات جهان به‌صورت $\mathbf{X} = (X, Y, Z)^\top$ نمایش داده می‌شود. این نقطه پس از تبدیل به دستگاه مختصات دوربین و انجام عمل تصویرسازی، به یک نقطه دوبعدی روی صفحه تصویر با مختصات پیکسلی (u, v) نگاشت می‌شود. این نگاشت، تحت فرضیات مدل سوراخ‌سوزنی، یک نگاشت پرسپکتیو بوده و ذاتا غیرخطی است.

این نگاشت پرسپکتیو در شکل ۲.۳ نمایش داده شده است.



$$\frac{u}{f} = \frac{X}{Z}, \qquad \frac{v}{f} = \frac{Y}{Z}$$

شکل ۲.۳: مدل هندسی دوربین سوراخ‌سوزنی و نگاشت مختصات سه‌بعدی به صفحه تصویر.

۲.۴.۳ ماتریس کالیبراسیون دوربین

رابطه میان مختصات سه‌بعدی یک نقطه در دستگاه مختصات دوربین و مختصات دوبعدی آن روی تصویر، به‌وسیله ماتریس کالیبراسیون دوربین مدل‌سازی می‌شود. این ماتریس پارامترهای درونی دوربین را در بر می‌گیرد

و به‌صورت زیر تعریف می‌شود:

$$K = \begin{bmatrix} f_x & ۰ & c_x \\ ۰ & f_y & c_y \\ ۰ & ۰ & ۱ \end{bmatrix}, \tag{۳.۳}$$

که در آن، f_x و f_y فاصله کانونی موثر دوربین در راستاهای افقی و عمودی بر حسب پیکسل هستند و (c_x, c_y) مختصات نقطه اصلی تصویر را مشخص می‌کنند. این پارامترها به ویژگی‌های فیزیکی دوربین، نظیر فاصله کانونی لنز، اندازه سنسور، و رزولوشن تصویر وابسته‌اند.

با استفاده از این ماتریس، رابطه میان یک نقطه سه‌بعدی $\mathbf{X}$ و تصویر دوبعدی آن را می‌توان به‌شکل زیر نوشت:

$$\lambda \begin{bmatrix} u \\ v \\ ۱ \end{bmatrix} = K \begin{bmatrix} X \\ Y \\ Z \end{bmatrix}, \tag{۴.۳}$$

که در آن، λ یک ضریب مقیاس است که به عمق نقطه، یعنی مولفه Z، وابسته است. این رابطه به‌وضوح نشان می‌دهد که مختصات تصویری هر پیکسل، نه‌تنها به موقعیت سه‌بعدی نقطه، بلکه به پارامترهای درونی دوربین نیز وابسته است [۳].

۳.۴.۳ نقش پارامترهای درونی در تخمین عمق

در مساله تخمین عمق، هدف اصلی برآورد مولفه Z برای هر پیکسل تصویر است. با توجه به رابطه هندسی فوق، روشن است که تبدیل میان مختصات تصویری و عمق واقعی صحنه، بدون اطلاع از ماتریس کالیبراسیون دوربین، به‌طور کامل قابل تعیین نیست. در غیاب این اطلاعات، مدل تنها قادر به یادگیری روابط نسبی میان پیکسل‌ها خواهد بود و عمق به‌دست‌آمده فاقد مقیاس مطلق مشخص خواهد بود.

این مساله در روش‌های خودنظارتی، که یادگیری بر پایه بازسازی تصویری انجام می‌شود، اهمیت دوچندان می‌یابد. در این روش‌ها، بازسازی یک تصویر از روی تصویر دیگر مستلزم انجام عملیات نگاشت معکوس و

نگاشت نقاط از یک نما به نمای دیگر است. این عملیات به‌طور مستقیم از ماتریس کالیبراسیون دوربین استفاده می‌کند و هرگونه خطا یا فرض نادرست درباره پارامترهای درونی، منجر به بازسازی نادرست و در نتیجه یادگیری عمق ناپایدار می‌شود.

در بسیاری از روش‌های پیشین، یا فرض شده است که تمام تصاویر با یک دوربین ثابت و با پارامترهای درونی یکسان ثبت شده‌اند، یا اطلاعات مربوط به دوربین به‌صورت ضمنی در وزن‌های شبکه جذب شده است [۲، ۱۲، ۴]. این فرضیات، در عمل و به‌ویژه در تنظیمات چنددوربینه یا داده‌های جمع‌آوری‌شده در شرایط واقعی، معتبر نیستند: Metric3D نشان می‌دهد که در چنین شرایطی برچسب‌های مطلق میان دوربین‌های مختلف با یکدیگر متناقض می‌شوند [۹]. تغییر در فاصله کانونی یا نقطه اصلی تصویر می‌تواند نگاشت میان پیکسل و عمق را به‌طور معناداری تغییر دهد، حتی اگر محتوای صحنه ثابت باقی بماند [۸].

پیامد مستقیم این موضوع، ناپایداری تخمین عمق مطلق در مواجهه با داده‌های ناهمگن از نظر مشخصات دوربین است. معیارهایی که به مقیاس فیزیکی عمق حساس هستند، نظیر RMSE، بیش از سایر معیارها تحت تاثیر این ناپایداری قرار می‌گیرند. در مقابل، معیارهای مبتنی بر روابط نسبی میان پیکسل‌ها، که به مقیاس مطلق وابسته نیستند، رفتار پایدارتری از خود نشان می‌دهند.

بر این اساس، لحاظ صریح پارامترهای درونی دوربین در فرآیند تخمین عمق، نه‌تنها از منظر هندسی موجه است، بلکه برای دستیابی به عمق مطلق پایدار و قابل تعمیم، امری ضروری به نظر می‌رسد. این مشاهده، مبنای نظری روش پیشنهادی این پژوهش را تشکیل می‌دهد که در آن، ماتریس کالیبراسیون دوربین به‌عنوان بخشی از ورودی مدل در نظر گرفته شده و نقش آن در فرآیند استنتاج عمق به‌صورت ساخت‌یافته مدل‌سازی می‌شود.

۵.۳ طراحی روش پیشنهادی: ادغام صریح ماتریس کالیبراسیون دوربین

در این پژوهش روشی برای ادغام صریح ماتریس کالیبراسیون دوربین در معماری Depth Anything V2 پیشنهاد می‌شود. ایده اصلی این روش، فراهم‌کردن امکان دسترسی مستقیم مدل به اطلاعات هندسی فرآیند تصویربرداری است، به‌گونه‌ای که شبکه به‌جای استنتاج ضمنی و ناپایدار این اطلاعات از روی داده، بتواند از قیود فیزیکی دوربین به‌صورت ساخت‌یافته بهره‌مند شود.

در این بخش، ابتدا اصول کلی طراحی روش پیشنهادی تشریح می‌شود، سپس نحوه نمایش و نرمال‌سازی ماتریس کالیبراسیون دوربین توضیح داده شده و در ادامه، راهبرد ادغام این اطلاعات با معماری encoder–decoder مدل پایه Depth Anything V2 مورد بررسی قرار می‌گیرد.

۱.۵.۳ اصل طراحی: تفکیک اطلاعات تصویری و هندسی

در اغلب مدل‌های MDE خودنظارتی، تصویر ورودی تنها منبع اطلاعاتی شبکه محسوب می‌شود و تمام قیود هندسی، اعم از فاصله کانونی یا میدان دید، به‌صورت ضمنی در وزن‌های مدل جذب می‌شوند [۱۸، ۱۲]. این رویکرد باعث می‌شود که مدل به توزیع دوربین‌های موجود در داده آموزشی وابسته شود و در مواجهه با داده‌هایی که از نظر پارامترهای درونی تفاوت دارند، عملکرد ناپایداری از خود نشان دهد.

روش پیشنهادی این پژوهش بر اصل تفکیک میان اطلاعات تصویری و اطلاعات هندسی استوار است. در این چارچوب، تصویر ورودی همچنان به‌عنوان منبع اطلاعات ظاهری و معنایی صحنه مورد استفاده قرار می‌گیرد، در حالی که ماتریس کالیبراسیون دوربین به‌عنوان توصیف‌گر هندسه تصویربرداری، به‌صورت یک ورودی مستقل و مکمل در اختیار مدل قرار داده می‌شود. این تفکیک، به مدل اجازه می‌دهد تا نگاشت میان پیکسل و عمق را نه‌تنها بر اساس الگوهای بصری، بلکه با در نظر گرفتن مقیاس و هندسه واقعی دوربین انجام دهد [۸، ۹].

۲.۵.۳ نمایش و پیش‌پردازش ماتریس کالیبراسیون دوربین

ماتریس کالیبراسیون دوربین به‌صورت زیر تعریف می‌شود:

$$K = \begin{bmatrix} f_x & ۰ & c_x \\ ۰ & f_y & c_y \\ ۰ & ۰ & ۱ \end{bmatrix}. \qquad (۵.۳)$$

از آنجا که مقادیر این ماتریس به رزولوشن تصویر و تنظیمات فیزیکی دوربین وابسته‌اند، استفاده مستقیم از مقادیر خام می‌تواند موجب ناپایداری عددی در فرآیند یادگیری شود. لزوم بازنمایی مستقل از تفکیک‌پذیری در ادبیات نیز شناخته شده است؛ برای نمونه، CAM-Convs به‌جای دادن فاصله کانونی خام بر حسب پیکسل، آن را

در قالب کانال‌های میدان دید به‌صورت $\arctan(\cdot/f)$ به شبکه می‌دهد [۸]. به همین دلیل، در روش پیشنهادی، پارامترهای درونی دوربین پیش از ورود به شبکه نرمال‌سازی می‌شوند. به‌طور خاص، مولفه‌های فاصله کانونی و مختصات نقطه اصلی بر حسب ابعاد تصویری که ماتریس کالیبراسیون دوربین در آن بیان شده است نرمال می‌شوند:

$$\tilde{f}_x = \frac{f_x}{W}, \quad \tilde{f}_y = \frac{f_y}{H}, \quad \tilde{c}_x = \frac{c_x}{W}, \quad \tilde{c}_y = \frac{c_y}{H}, \tag{۶.۳}$$

که در آن W و H به‌ترتیب عرض و ارتفاع چارچوب مرجع پارامترهای دوربین هستند. این بازنمایی نرمال‌شده، امکان استفاده پایدار از اطلاعات دوربین در مجموعه‌داده‌هایی با رزولوشن‌های متفاوت را فراهم می‌کند [۸، ۱۴].

افزون بر مولفه‌های نرمال‌شده فوق، برای آنکه بازنمایی ورودی به‌صورت مستقیم دربردارنده مفهوم فیزیکی میدان دید (FoV) باشد، زوایای میدان دید افقی و عمودی نیز به‌صورت

$$\mathrm{fov}_w = ۲ \arctan\left(\frac{W}{۲ f_x}\right), \qquad \mathrm{fov}_h = ۲ \arctan\left(\frac{H}{۲ f_y}\right) \tag{۷.۳}$$

محاسبه می‌شوند. مطابق پیاده‌سازی نهایی، زاویه‌ها بر π، میانگین فاصله کانونی بر بزرگ‌ترین بعد تصویر و مساحت تصویر بر مساحت مرجع ۱۰۸۰ × ۱۹۲۰ تقسیم می‌شوند. بنابراین، بردار توصیف‌گر هندسی دوربین دقیقا به‌صورت

$$\mathbf{d}_{\mathrm{cam}} = \left[\frac{f_x}{W}, \frac{f_y}{H}, \frac{c_x}{W}, \frac{c_y}{H}, \frac{\mathrm{fov}_h}{\pi}, \frac{\mathrm{fov}_w}{\pi}, \frac{W}{H}, \frac{f_x + f_y}{۲ \max(H, W)}, \frac{HW}{۱۹۲۰ \times ۱۰۸۰}\right] \tag{۸.۳}$$

تعریف می‌شود و به‌عنوان ورودی هندسی مدل مورد استفاده قرار می‌گیرد. جدول ۱.۳ معنای هندسی هر یک از نه مولفه این بردار را تشریح می‌کند.

نکته اساسی در این بازنمایی آن است که ماتریس کالیبراسیون دوربین و ابعاد (H, W) باید هر دو در یک چارچوب مختصات یکسان بیان شوند؛ در غیر این صورت، کدگذاری حاصل از منظر هندسی نادرست خواهد بود. اهمیت عملی این نکته در بخش جزییات پیاده‌سازی و در تحلیل اشکال‌زدایی فصل چهارم آشکار می‌شود.

جدول ۱.۳: بردار توصیف‌گر پارامترهای دوربین

شماره مولفه	تعریف	نقش هندسی
۱	f_x/W	فاصله کانونی افقی، مستقل از رزولوشن
۲	f_y/H	فاصله کانونی عمودی، مستقل از رزولوشن
۳	c_x/W	موقعیت افقی نقطه اصلی؛ به جابه‌جایی مرکز تصویر در برش حساس است
۴	c_y/H	موقعیت عمودی نقطه اصلی
۵	fov_h/π	میدان دید عمودی به‌صورت زاویه‌ای و نرمال‌شده
۶	fov_w/π	میدان دید افقی به‌صورت زاویه‌ای و نرمال‌شده
۷	W/H	نسبت ابعاد قاب تصویر
۸	$\frac{f_x + f_y}{۲\max(H,W)}$	کانون میانگین نسبت به بزرگ‌ترین بعد؛ سنجه‌ای فشرده از «تنگی» میدان دید
۹	$\frac{HW}{۱۹۲۰ \times ۱۰۸۰}$	مساحت قاب نسبت به یک چارچوب مرجع ثابت

۳.۵.۳ راهبرد ادغام اطلاعات دوربین با معماری Depth Anything V2

برای ادغام بردار پارامترهای درونی دوربین با معماری پایه، در این پژوهش از یک واحد انکودر دوربین[۱] استفاده می‌شود که وظیفه آن، تبدیل بردار کم‌بعد $\mathbf{d}_{\mathrm{cam}}$ به یک توکن دوربین سازگار با فضای بازنمایی ترنسفورمر است. این واحد شامل یک شبکه تمام‌متصل دولایه (MLP)[۲] برای نگاشت اولیه و سپس چند بلوک ترنسفورمر برای پالایش بازنمایی است که خروجی آن یک توکن با ابعاد برابر با بعد نهان انکودر بینایی است:

$$\mathbf{z}_{\mathrm{cam}} = \phi(\mathbf{d}_{\mathrm{cam}}), \tag{۹.۳}$$

که در آن $\phi(\cdot)$ تابع نگاشت پارامتری قابل یادگیری است.

توکن دوربین $\mathbf{z}_{\mathrm{cam}}$ سپس در کنار توکن‌های تصویری، به دنباله توکن‌های انکودر مبتنی بر DINOv2 تزریق می‌شود؛ به‌گونه‌ای که سازوکار خودتوجهی بتواند در تمامی لایه‌های پس از نقطه تزریق، اطلاعات هندسی دوربین را با بازنمایی‌های بصری ترکیب کند. در تنظیمات پیش‌فرض، تزریق از نخستین لایه انکودر انجام می‌گیرد. این راهبرد با روش‌های شرطی‌سازی مبتنی بر توکن در معماری‌های ترنسفورمری و نیز رویکردهای تعدیل خطی در سطح ویژگی (FiLM)[۳] هم‌خانواده است [۳۰]؛ با این تفاوت که در اینجا، شرطی‌سازی از طریق سازوکار توجه

[۱] Camera Encoder
[۲] Multi-Layer Perceptron
[۳] Feature-wise Linear Modulation

انجام می‌شود و نیازی به دستکاری مستقیم نگاشت‌های ویژگی نیست.

این طراحی با راهکارهای پیشین تفاوت ساختاری دارد. در CAM-Convs ماتریس کالیبراسیون به‌صورت کانال‌های مختصاتی وارد کانولوشن‌ها می‌شود؛ در Metric3D تنها در نگاشت ورودی و برچسب‌ها به فضای دوربین متعارف به‌کار می‌رود و خود شبکه آن را نمی‌بیند؛ و در UniDepth و Depth Pro دوربین از روی تصویر تخمین زده می‌شود. در روش حاضر، برعکس، تمام ماتریس کالیبراسیون معلوم به یک انکودر ترنسفورمری داده می‌شود و توکن حاصل با سازوکار خودتوجهی انکودر ترکیب می‌شود. ساختار این انکودر از CameraEnc در Depth Anything 3 [۳۱] اقتباس و برای ورودی تنها پارامترهای درونی ساده شده است؛ در اینجا این مسیر به یک مدل عمق تک‌تصویری بنیادین افزوده شده است.

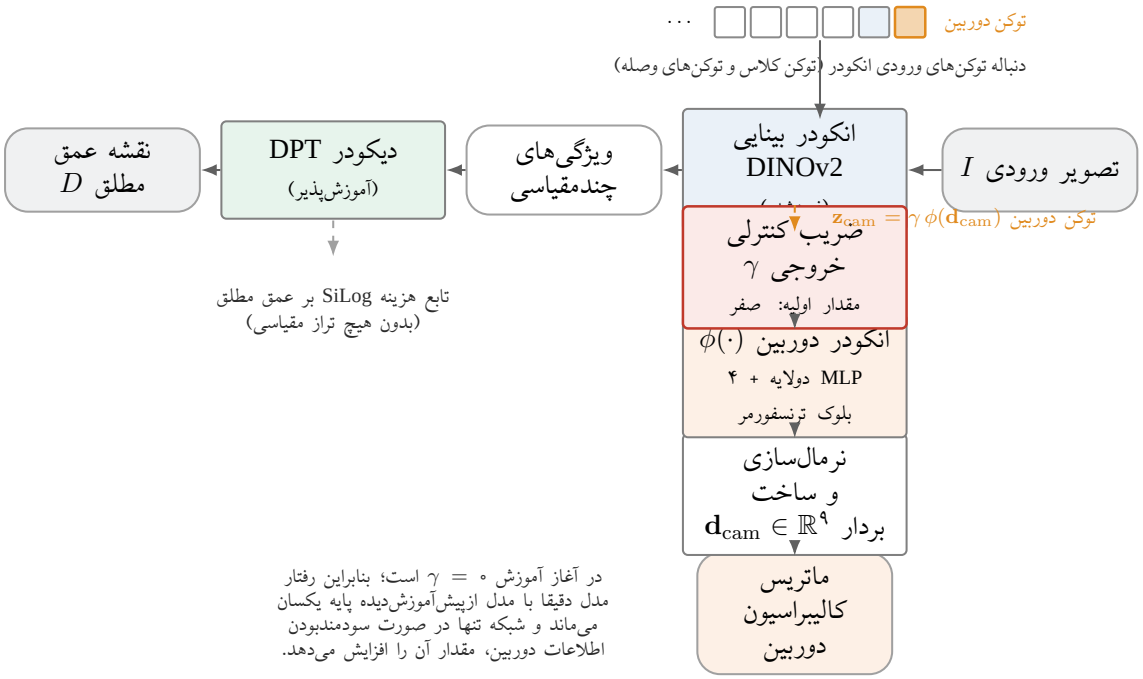
این معماری با اندازه تصویر نیز سازگار است. تصویر به وصله‌های ۱۴ × ۱۴ توکن‌سازی می‌شود، پس طول دنباله توکن‌های تصویری با اندازه ورودی تغییر می‌کند بی‌آنکه ساختار شبکه عوض شود؛ توکن دوربین نیز همواره یک توکن واحد با بعد ثابت است و مولفه‌های آن بر W و H نرمال می‌شوند. توجه شود که دو مولفه نسبت ابعاد و مساحت قاب، اندازه قاب را صریحا در بردار توصیف‌گر قرار می‌دهند.

نکته طراحی مهم در این ادغام، استفاده از یک ضریب کنترلی خروجی با مقداردهی اولیه صفر[۱] است: خروجی انکودر دوربین در ابتدای آموزش در یک ضریب قابل یادگیری با مقدار اولیه صفر ضرب می‌شود. در نتیجه، در گام‌های نخست آموزش، توکن دوربین عملا برداری صفر است و رفتار مدل دقیقا با مدل ازپیش‌آموزش‌دیده پایه یکسان باقی می‌ماند؛ سپس در طول آموزش، شبکه به‌تدریج و تنها در صورتی که اطلاعات دوربین برای کاهش خطا مفید باشد، مقدار این ضریب را از صفر افزایش می‌دهد. ضریب یادگیری‌پذیر با مقدار اولیه صفر در اینجا نقش یک گیت را دارد و توکن حاصل از این سازوکار را «توکن با گیت یادگیری‌پذیر»[۲] می‌نامیم. این سازوکار، از آسیب رساندن به بازنمایی‌های ازپیش‌آموخته در آغاز تنظیم دقیق‌پارامترها جلوگیری کرده و پایداری فرآیند آموزش را افزایش می‌دهد.

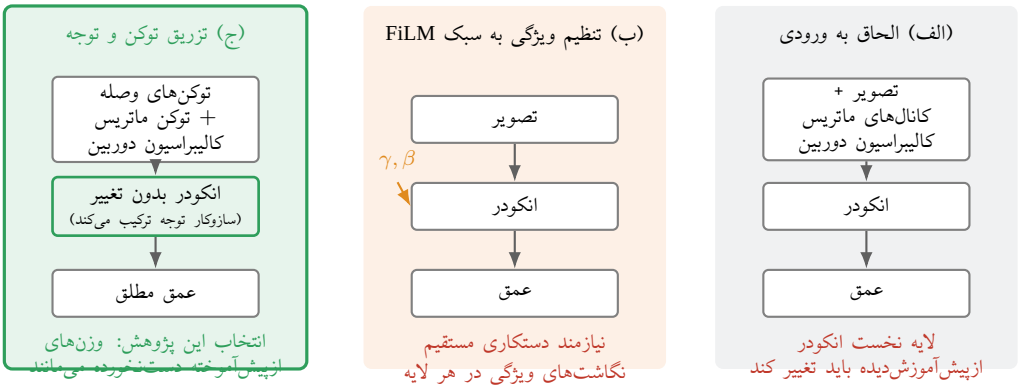
جریان کامل این ادغام در شکل ۳.۳ خلاصه شده است.

شکل ۴.۳ این انتخاب طراحی را در برابر دو گزینه متداول دیگر قرار می‌دهد.

[۱] Zero-initialized Output Control Coefficient
[۲] Learnable-gated Token



شکل ۳.۳: معماری مدل پیشنهادی و مسیر تزریق بردار دوربین به انکودر؛ ضریب کنترلی صفرمقدار اولیه مسیر اصلی را در آغاز آموزش حفظ می‌کند.



شکل ۴.۳: مقایسه سه سازوکار شرطی‌سازی دوربین و دلیل انتخاب تزریق توکن با وزن‌های ازپیش‌آموخته دست‌نخورده.

۴.۵.۳ مزایای مورد انتظار از ادغام صریح پارامترهای درونی

ادغام صریح ماتریس کالیبراسیون دوربین، چند مزیت کلیدی را به همراه دارد. نخست آنکه مدل قادر خواهد بود نگاشت میان پیکسل و عمق را با در نظر گرفتن مقیاس واقعی دوربین انجام دهد و از این طریق، دقت تخمین عمق مطلق افزایش یابد. دوم آنکه وابستگی مدل به توزیع خاصی از دوربین‌ها در داده آموزشی کاهش می‌یابد و تعمیم‌پذیری آن در مواجهه با داده‌های چنددوربینه بهبود پیدا می‌کند. این موضوع به‌ویژه با توجه به نتایج تجربی ارایه‌شده در تحلیل RMSE در بخش پیشین، اهمیت ویژه‌ای دارد. در نهایت، این طراحی امکان توسعه مدل به سناریوهای پیشرفته‌تر، نظیر یادگیری انتقالی میان مجموعه‌داده‌های با میدان دید متفاوت، را نیز فراهم می‌کند.

در بخش‌های بعدی، نحوه آموزش این مدل، تابع هزینه مورد استفاده، و تنظیمات تجربی برای ارزیابی اثر ادغام پارامترهای درونی دوربین به‌تفصیل تشریح خواهد شد.

۶.۳ داده‌ها، پیش‌پردازش و نرمال‌سازی ورودی

پس از معرفی مدل پایه و روش پیشنهادی، داده‌ها و زنجیره آماده‌سازی ورودی به‌صورت زیر تعریف می‌شوند. در این بخش، پیش‌پردازش تصویر، نرمال‌سازی مقادیر پیکسل و نرمال‌سازی پارامترهای درونی دوربین پیش از ورود هر نمونه به شبکه مشخص می‌شود؛ سپس در بخش بعد، فرآیند آموزش بر همین ورودی‌های آماده‌شده توضیح داده می‌شود.

۱.۶.۳ مجموعه‌داده‌های مورد استفاده

در مرحله اکتشافی، ترکیب‌هایی از Virtual KITTI، NYUv2، DIODE، Cityscapes و Middlebury آزموده شد. این داده‌ها از نظر نوع صحنه، شرایط تصویربرداری و مشخصات دوربین متنوع‌اند [۳۲، ۳۳، ۳۴، ۳۵، ۳۶]؛ بااین‌حال، نتایج فصل چهارم نشان داد که تنظیم دقیق‌پارامترهای چندمجموعه‌ای محدود، تعمیم صفرنمونه مدل بنیادین را تخریب می‌کند. ازاین‌رو، مطالعه نهایی برای جداسازی علی سهم ماتریس کالیبراسیون دوربین به NYUv2 محدود شد و هر زوج مدل پیشنهادی/مدل کنترل دقیقا داده‌ها و برنامه آموزشی یکسانی دریافت کرد.

در گام پایانی پژوهش، برای سنجش تعمیم مدل پیشنهادی به دامنه‌ها و دوربین‌های واقعی متفاوت، آموزشی چندمجموعه‌ای طراحی شد که در آن یک مدل واحد هم‌زمان بر چهار مجموعه‌داده آموزش می‌بیند: NYUv2 با صحنه‌های داخلی واقعی [۳۳]، KITTI با صحنه‌های جاده‌ای واقعی [۳۷]، Virtual KITTI 2 با صحنه‌های جاده‌ای مصنوعی [۳۲، ۳۸] و Cityscapes با صحنه‌های شهری واقعی [۳۵]. این مدل بر بخش آزمون نگه‌داشته‌شده NYUv2 و Cityscapes و نیز بر دو حسگر Kinect v1 و Kinect v2 از مجموعه‌داده SUN RGB-D [۳۹] ارزیابی شد که هیچ تصویری از آن‌ها در آموزش به‌کار نرفته است. اندازه هر بخش و مشخصات دوربین هر مجموعه‌داده در جدول ۳.۳ آمده است.

این ترکیب به پنج دلیل انتخاب شد:

- تنوع واقعی دوربین: نسبت f_y/H در چهار دوربین آموزشی از ۱٫۰۸ تا ۲٫۲۱ و میدان دید افقی آن‌ها از حدود ۴۹ تا ۸۲ درجه تغییر می‌کند. بنابراین بردار توصیف‌گر دوربین، برخلاف آموزش تک‌دوربینه NYUv2، مقادیر واقعا متفاوتی می‌گیرد و تنوع هندسی فقط از راه افزونه‌سازی شبیه‌سازی نمی‌شود.
- پوشش هم‌زمان صحنه‌های داخلی و بیرونی: NYUv2 صحنه‌های داخلی را با عمق ارزیابی تا ۱۰ متر و سه مجموعه دیگر صحنه‌های جاده‌ای و شهری را با عمق ارزیابی تا ۸۰ متر پوشش می‌دهند.
- مکمل‌بودن منابع عمق مرجع: حسگر Kinect در NYUv2، لایدار در KITTI، تطبیق استریو در Cityscapes و عمق رندرشده دقیق و چگال در Virtual KITTI 2؛ حجم بالای داده مصنوعی (۳۷۸۶۰ تصویر) کم‌بودن برچسب چگال در داده‌های واقعی بیرونی را جبران می‌کند.
- امکان مقایسه با ادبیات: بخش آزمون ۶۵۴ تصویری NYUv2 همان پروتکل استاندارد مقاله مرجع است [۲، ۴] و تصاویر آموزشی KITTI از درایوهایی برداشته شدند که با هیچ‌یک از ۲۸ درایو بخش آزمون استاندارد آن هم‌پوشانی ندارند.
- آزمون صفرنمونه بر حسگرهای تازه: تصاویر Kinect v1 از بخش B3DO مجموعه‌داده SUN RGB-D برداشته شدند و تصاویری که این مجموعه از NYUv2 وام گرفته است کنار گذاشته شدند تا هیچ هم‌پوشانی با داده آموزش پیش نیاید. حسگر Kinect v2 با $f_y/H \approx$ ۱٫۰۰ میدان دید عمودی حدود ۵۳ درجه دارد که از همه دوربین‌های آموزشی (حداکثر حدود ۵۰ درجه در NYUv2) بازتر است.

جدول ۲.۳ مشخصات این مجموعه‌داده‌ها و نقش هر یک در مراحل مختلف پژوهش را خلاصه می‌کند.

جدول ۲.۳: مجموعه‌داده‌های پژوهش

مجموعه‌داده	نوع محیط	منبع عمق مرجع	دسترسی به ماتریس کالیبراسیون دوربین	نقش در این پژوهش
NYUv2 [۳۳]	داخلی، واقعی	حسگر Kinect	دارد، ثابت برای کل مجموعه	بستر مطالعه کنترل‌شده نهایی؛ پروتکل استاندارد ارزیابی؛ آموزش و آزمون چندمجموعه‌ای
Virtual KITTI [۳۲]	بیرونی، مصنوعی	رندر دقیق موتور گرافیکی	دارد، دقیق	مرحله اکتشافی؛ سنجش پایداری بین‌دیتاستی؛ آموزش چندمجموعه‌ای با نسخه Virtual KITTI 2 [۳۸]
KITTI [۳۷]	بیرونی، واقعی	لایدار، پراکنده	دارد، از فایل کالیبراسیون	مجموعه‌داده ارزیابی صفرنمونه و راستی‌آزمایی زنجیره ارزیابی؛ آموزش چندمجموعه‌ای
DIODE [۳۴]	داخلی و بیرونی	اسکنر لیزری	دارد	مرحله اکتشافی؛ تنوع بالای صحنه
Cityscapes [۳۵]	شهری، واقعی	تطبیق استریو	دارد	مطالعه موردی رفتار خطا در دامنه عمق بزرگ؛ آموزش و آزمون چندمجموعه‌ای
Middlebury [۳۶]	داخلی، واقعی	استریوی دقت‌بالا	دارد، دو نمای کالیبره‌شده	ارزیابی تکمیلی در دامنهٔ صحنه‌های متنوع
Hypersim [۴۰]	داخلی، مصنوعی	رندر دقیق	دارد	نقطهٔ وارسی[۳] مطلق مرجع مدل پایه Depth Anything V2
SUN RGB-D [۳۹]	داخلی، واقعی	حسگرهای Kinect v1 و Kinect v2	دارد، برای هر تصویر	آزمون صفرنمونه حسگرهای دیده‌نشده در آموزش چندمجموعه‌ای

در جدول ۳.۳، تصاویر آموزشی NYUv2، ۶۳۶ تصویر از ۷۹۵ تصویر بیرون از بخش آزمون استاندارد هستند که مانند زیربخش ۱.۷.۳ با نسبت ۲۰/۸۰ میان آموزش و اعتبارسنجی تقسیم شده‌اند؛ تصاویر KITTI از درایوهای جدا از بخش آزمون، تصاویر Virtual KITTI 2 از صحنه‌های Scene01، Scene06، Scene18 و Scene20، و تصاویر Cityscapes از شهرهای بخش آموزش رسمی به‌جز زوریخ برداشته شده‌اند. داده اعتبارسنجی هر دامنه، ۵۰ تصویر از بخشی کنار گذاشته‌شده است: بخش اعتبارسنجی NYUv2، دو درایو جداگانه از KITTI، صحنه Scene02 از Virtual KITTI 2 و شهر زوریخ از Cityscapes. مجموعه‌های آزمون عبارت‌اند از بخش آزمون استاندارد NYUv2 با نقشه‌های عمق خام و برش استاندارد، بخش اعتبارسنجی

[۳] Checkpoint

جدول ۳.۳: مجموعه‌داده‌های آموزش چندمجموعه‌ای و مجموعه‌های آزمون گزارش‌شده

مجموعه‌داده	محیط و منبع عمق مرجع	f_y/H	میدان دید افقی (درجه)	آموزش	اعتبارسنجی	آزمون گزارش‌شده
NYUv2	داخلی، واقعی؛ حسگر Kinect	۱٫۰۸	۶۳	۶۳۶	۵۰	۶۵۴
KITTI	بیرونی، واقعی؛ لایدار	۱٫۹۲-۱٫۹۱	۸۲	۹۱۴۸	۵۰	
Virtual KITTI 2	بیرونی، مصنوعی؛ رندر	۱٫۹۳	۸۱	۳۷۸۶۰	۵۰	
Cityscapes	شهری، واقعی؛ تطبیق استریو	۲٫۲۱	۴۹	۲۸۵۲	۵۰	۵۰۰
SUN RGB-D Kinect v1	داخلی، واقعی؛ حسگر Kinect v1	۱٫۲۲	۵۷			۲۰۰
SUN RGB-D Kinect v2	داخلی، واقعی؛ حسگر Kinect v2	۱٫۰۰	۶۹			۲۰۰

رسمی Cityscapes و دو زیرمجموعه تصادفی ۲۰۰ تصویری از حسگرهای Kinect v1 و Kinect v2 در SUN RGB-D. عمق مرجع Cityscapes از نقشه‌های دیسپاریتی همان مجموعه‌داده و با خط پایه استریوی آن به‌دست می‌آید و ناحیه کاپوت خودرو از ارزیابی حذف می‌شود.

داده‌های مورد استفاده عمدتا به‌صورت تک‌تصویر یا توالی‌های کوتاه از تصاویر ثبت‌شده‌اند، با این تفاوت که در فرآیند آموزش حاضر، هر تصویر به‌صورت مستقل پردازش شده و هیچ‌گونه قید زمانی یا وابستگی صریح میان فریم‌های متوالی اعمال نشده است. این انتخاب، با هدف تمرکز بر مساله تخمین عمق تک‌تصویر و حذف اثرات جانبی ناشی از حرکت دوربین یا برآورد ژست صورت گرفته است.

در مواردی که اطلاعات ماتریس کالیبراسیون دوربین به‌صورت صریح در داده‌ها موجود بوده، این اطلاعات مستقیما مورد استفاده قرار گرفته و در سایر موارد، پارامترهای دوربین مطابق با تنظیمات مرجع هر مجموعه‌داده استخراج یا بازسازی شده‌اند.

جزئیات معیارهای ارزیابی، پروتکل مقایسه و آزمون‌های آماری در بخش‌های ۴.۹.۳ و ۵.۹.۳ تعریف شده‌اند. در اینجا فقط مشخصات دیتاست‌ها و سناریوهای اجرای آزمایش‌ها یادآوری می‌شود و نتایج فصل چهارم بر اساس همان پروتکل گزارش می‌گردند.



NYUv2 داخلی، عمق از حسگر نوری، میدان دید $\approx 63°$



Middlebury داخلی، دو نمای کالیبره، وضوح بالا



Cityscapes شهری، عمق از تطبیق استریو



KITTI جاده‌ای، عمق پراکنده لایدار

شکل ۵.۳: نمونه‌ای از تنوع شرایط تصویربرداری در مجموعه‌داده‌های به‌کاررفته. تفاوت این صحنه‌ها تنها در محتوا نیست: میدان دید، نسبت ابعاد، دامنه عمق و سازوکار تولید عمق مرجع در آن‌ها اساسا متفاوت است (جدول ۲.۳). تصاویر با نسبت ابعاد اصلی خود نمایش داده شده‌اند تا همین تفاوت دیده شود؛ برای نمونه، تصویر KITTI با نسبت ابعاد حدود ۳٫۵ به ۱ و میدان دید افقی باز دوربین جاده‌ای، در برابر قاب ۴ به ۳ و صحنه بسته NYUv2 قرار می‌گیرد. همین ناهمگونی است که ارزیابی با یک مقیاس مطلق ثابت را دشوار می‌کند و انگیزه لحاظ صریح پارامترهای درونی دوربین را شکل می‌دهد. هر چهار تصویر مستقیما از خود مجموعه‌داده‌ها برداشته شده‌اند (نه از مقالات)؛ KITTI با مجوز CC BY-NC-SA 3.0 و سه مجموعه دیگر با مجوز استفاده پژوهشی منتشر شده‌اند.

۲.۶.۳ پیکربندی محل تزریق توکن دوربین

در آزمایش‌های فصل چهارم، فعال‌سازی مسیر اطلاعات دوربین با گزینه `--use-camera-intrinsics` انجام شده است و محل ورود توکن دوربین به انکودر DINOv2 با پارامتر `--cam-token-inject-layer` کنترل می‌شود. این پارامتر شماره لایه‌ای را تعیین می‌کند که در آن توکن دوربین به دنباله توکن‌های تصویری افزوده می‌شود؛ بنابراین، از آن نقطه به بعد، لایه‌های انکودر می‌توانند اطلاعات هندسی دوربین را همراه با بازنمایی تصویری پردازش کنند. در تمام آزمایش‌های گزارش‌شده در فصل چهارم، مقدار پیش‌فرض پارامتر، یعنی تزریق در نخستین لایه انکودر، ثابت نگه داشته شده است تا مقایسه مدل‌ها تحت یک پیکربندی یکسان انجام شود. حساسیت عملکرد نسبت به محل تزریق و امکان تزریق در چند لایه در دامنه آزمایش‌های این پژوهش بررسی نشده و به‌عنوان مسیر پژوهشی آینده باقی می‌ماند.

۳.۶.۳ پیش‌پردازش داده‌ها

تمامی تصاویر ورودی پیش از ورود به شبکه، به‌صورت یکنواخت پیش‌پردازش می‌شوند. در تنظیم پایه، تصاویر با حفظ نسبت ابعاد به کران پایین ۵۱۸[۱] پیکسل تغییر اندازه داده شده و سپس برش‌های تصادفی $\times$ ۵۱۸ ۵۱۸ برای یکسان‌سازی ابعاد دسته در مرحله آموزش اعمال می‌گردد؛ راهبردی مطابق با تنظیمات مدل پایه Depth Anything V2 [۴]. در آزمایش‌های نهایی مبتنی بر افزونه‌سازی هندسی (بخش ۶.۷.۳)، این برش تصادفی ساده ناآگاه از ماتریس کالیبراسیون دوربین کنار گذاشته شده و کل زنجیره برش و تغییر اندازه به‌صورت آگاه از پارامترهای دوربین و با به‌روزرسانی دقیق ماتریس کالیبراسیون دوربین انجام می‌شود؛ در این حالت، چارچوب ورودی شبکه به‌صورت ثابت ۶۸۶ $\times$ ۵۱۸ (قاب کامل ۳:۴ در کران پایین ۵۱۸ و مضرب ۱۴) انتخاب شده است.

مقادیر پیکسل تصاویر به بازه $[۰, ۱]$ نرمال‌سازی شده و سپس با استفاده از میانگین و واریانس داده‌های ImageNet استانداردسازی می‌شوند:

$$I_{norm} = \frac{I - \mu_{ImageNet}}{\sigma_{ImageNet}}, \tag{۱۰.۳}$$

که در آن $\mu_{ImageNet} = [۰/۴۸۵, ۰/۴۵۶, ۰/۴۰۶]$ و $\sigma_{ImageNet} = [۰/۲۲۹, ۰/۲۲۴, ۰/۲۲۵]$ هستند. این مرحله به‌ویژه برای سازگاری با وزن‌های ازپیش‌آموزش‌دیده انکودر DINOv2 ضروری است.

۴.۶.۳ مدیریت و نرمال‌سازی پارامترهای درونی دوربین

برای هر تصویر ورودی، ماتریس کالیبراسیون دوربین استخراج شده و پارامترهای اصلی آن شامل فاصله کانونی در راستاهای افقی و عمودی (f_x, f_y) و مختصات نقطه اصلی (c_x, c_y) مورد استفاده قرار می‌گیرند.

به‌منظور جلوگیری از ناپایداری عددی و تسهیل فرآیند یادگیری، این پارامترها پیش از ورود به شبکه نرمال‌سازی می‌شوند:

[۱] مقاله Depth Anything V2، بخش ۱/۷، بند نخست («Details»): همه تصاویر با تفکیک‌پذیری ۵۱۸ $\times$ ۵۱۸ آموزش داده می‌شوند؛ اندازه کوتاه‌تر به ۵۱۸ تغییر می‌کند و سپس برش تصادفی انجام می‌شود.

$$\tilde{f}_x = \frac{f_x}{W}, \quad \tilde{f}_y = \frac{f_y}{H}, \quad \tilde{c}_x = \frac{c_x}{W}, \quad \tilde{c}_y = \frac{c_y}{H}, \tag{۱۱.۳}$$

که در آن W و H به‌ترتیب عرض و ارتفاع تصویر ورودی هستند.

بردار نهایی پارامترهای دوربین به‌صورت

$$\mathbf{d}_{\text{cam}} = [\tilde{f}_x, \tilde{f}_y, \tilde{c}_x, \tilde{c}_y] \tag{۱۲.۳}$$

تعریف شده و همراه با مولفه‌های میدان دید و نسبت ابعاد (مطابق بخش ۲.۵.۳)، یک بردار توصیف‌گر نه‌بعدی را تشکیل می‌دهد. این بردار از طریق یک شبکه تمام‌متصل دولایه (با تابع فعال‌سازی واحد خطی خطای گاوسی (GELU)[۱]) به فضایی هم‌بعد با بازنمایی نهان انکودر (برای ViT-L برابر ۱۰۲۴) نگاشت شده و سپس توسط چهار بلوک ترنسفورمر پالایش می‌شود. خروجی این واحد، پس از اعمال ضریب کنترلی خروجی صفرمقدار اولیه، به‌عنوان توکن دوربین $\mathbf{z}_{\text{cam}}$ به دنباله توکن‌های انکودر تزریق می‌گردد.

۷.۳ راهبرد آموزش مدل پیشنهادی

در این پژوهش، آموزش مدل پیشنهادی به‌صورت تنظیم دقیق‌پارامترها یک مدل از پیش‌آموزش‌یافته انجام شده است. به‌طور خاص، از مدل پایه Depth Anything V2، نسخه نسبی با وزن‌های اولیه مدل Large به‌عنوان نقطه شروع استفاده شده و فرآیند آموزش با هدف تبدیل آن به یک مدل مطلق پایدار، با لحاظ صریح پارامترهای درونی دوربین، طراحی شده است. این راهبرد، ضمن بهره‌گیری از بازنمایی‌های غنی مدل پایه، امکان انطباق مدل با تنظیمات هندسی جدید را بدون نیاز به آموزش از ابتدا فراهم می‌کند.

برای رفع ابهام اصطلاح‌شناختی، عبارت «بدون نظارت» در عنوان پژوهش به‌معنای دقیق یادگیری بدون هیچ برچسب عمقی به‌کار نرفته است. مدل مدل پایه Depth Anything V2 خود با تقطیر دانش و شبه‌برچسب‌های

[۱] Gaussian Error Linear Unit

تصاویر واقعی آموزش دیده است و روشی نیمه‌نظارتی محسوب می‌شود، و مرحله نهایی تنظیم دقیق‌پارامترهای کنترل‌شده در این پایان‌نامه نظارتی است و از نگاشت‌های عمق مرجع NYUv2 استفاده می‌کند. این تفکیک ضروری است تا بهبود مشاهده‌شده به ورودی ماتریس کالیبراسیون دوربین و برنامه تنظیم دقیق‌پارامترها نسبت داده شود.

۱.۷.۳ پروتکل تقسیم مجموعه‌های آموزش و آزمون در NYUv2

پروتکل استاندارد ارزیابی در ادبیات این حوزه، زیرمجموعه آزمون ۶۵۴ تصویری استاندارد NYUv2 است [۲] که مدل Depth Anything V2 نیز نتایج خود را بر همین مبنا گزارش می‌کند [۴]. در مطالعه کنترل‌شده این پژوهش، این ۶۵۴ تصویر به‌عنوان مجموعه آزمون در نظر گرفته شدند و ۷۹۵ تصویر باقی‌مانده با نسبت ۲۰/۸۰ به مجموعه‌های آموزش و اعتبارسنجی تقسیم شدند؛ بنابراین مجموعه آموزش شامل ۶۳۶ تصویر و مجموعه اعتبارسنجی شامل ۱۵۹ تصویر است. تمام نتایج نهایی گزارش‌شده در فصل چهارم بر همین پروتکل استاندارد استوارند.

سهم نگه‌داشت آزمون دقیقا برابر ٪۴۵٫۱ = ۶۵۴/۱۴۴۹ است. چون افزونه‌سازی به‌صورت برخط انجام می‌شود، در هر دوره از مجموعه آموزش ۶۳۶ نمای تصادفی تولید می‌شود و در ۴۰ دوره در مجموع = ۴۰ × ۶۳۶ ۲۵,۴۴۰ نمای آموزشی نمونه‌برداری می‌گردد؛ این عدد شمار برداشت‌هاست، نه تعداد صحنه‌های یکتای جدید.

۲.۷.۳ مدل پایه Depth Anything V2 و راهبرد تنظیم دقیق‌پارامترها

نسخه نسبی مدل پایه Depth Anything V2 به‌عنوان نقطه شروع انتخاب شده و دارای توانایی بالایی در استخراج ویژگی‌های معنایی و هندسی تصویر است. در این پژوهش، این مدل به‌عنوان دانش اولیه در نظر گرفته شده و فرآیند تنظیم دقیق‌پارامترها با هدف افزودن قابلیت تخمین عمق مطلق و تطبیق با اطلاعات دوربین انجام شده است.

برای حفظ پایداری آموزش و جلوگیری از بیش‌برازش[۱]، بخش encoder مبتنی بر DINOv2 در طول آموزش فریز شده است. این تصمیم مبتنی بر این فرض است که ویژگی‌های استخراج‌شده توسط DINOv2، پیشاپیش از

[۱] Overfitting

غنای کافی برای نمایش محتوای تصویری برخوردارند و نیازی به بازآموزی در این مرحله ندارند [۲۸]. در مقابل، بخش decoder و همچنین ماژول‌های مرتبط با تخمین عمق و پردازش پارامترهای دوربین، به‌صورت کامل قابل یادگیری باقی مانده‌اند.

۳.۷.۳ فعال‌سازی پشتیبانی از پارامترهای دوربین

گزینه `--use-camera-intrinsics` در اسکریپت آموزش، استفاده از ماتریس کالیبراسیون دوربین را در فرآیند آموزش فعال می‌کند. با فعال‌سازی این گزینه، بردار نرمال‌سازی‌شده پارامترهای دوربین مطابق با توضیحات بخش ۶.۳ استخراج شده و از طریق یک encoder اختصاصی به فضای نهان مدل نگاشت می‌شود.

علاوه بر این، امکان کنترل محل تزریق اطلاعات دوربین در معماری شبکه از طریق پارامتر `--cam-token-inject-layer` فراهم شده است. این پارامتر لایه تزریق توکن به انکودر DINOv2 را تعیین می‌کند. در تمام آزمایش‌های گزارش‌شده مقدار پیش‌فرض، یعنی لایه نخست انکودر، استفاده شده است؛ حساسیت نسبت به محل تزریق و تزریق چندلایه در این پژوهش پیمایش نشده و به‌عنوان مسیر کار آینده گزارش می‌شود.

۴.۷.۳ تنظیمات آموزش و بهینه‌سازی

فرآیند آموزش با اسکریپت `train.py` و در دو حالت انجام شده است: `--model-type releative` برای خروجی نسبی در فضای عمق معکوس، و `--model-type absolute` برای عمق مطلق بر حسب متر. حالت نسبی برای بازتولید پروتکل استاندارد و تشخیص محدودیت تراز مقیاس به‌کار رفت؛ حالت مطلق، بستر اصلی آزمون فرضیه نقش ماتریس کالیبراسیون دوربین در بازیابی مقیاس بود.

آموزش با بهینه‌ساز AdamW [۴۱] انجام شده است؛ این بهینه‌ساز کاهش وزن را از به‌روزرسانی مبتنی بر گرادیان جدا می‌کند و به همین دلیل برای تنظیم دقیق‌پارامترهای شبکه‌های مبتنی بر ترنسفورمر مناسب‌تر از Adam است. ضرایب تکانه $\beta_1 = ۰/۹$ و $\beta_2 = ۰/۹۹۹$، ضریب کاهش وزن ۰/۰۱ و پارامتر پایداری عددی $\epsilon = ۱۰^{-۸}$ در نظر گرفته شده‌اند.

به‌منظور سازگاری بهتر تنظیم دقیق‌پارامترها با وزن‌های ازپیش‌آموزش‌یافته، نرخ یادگیری بخش‌های مختلف

شبکه ناهمسان تعیین شده است. نرخ یادگیری پایه ۵×۱۰^{-۶} است و برای دیکودر و لایه‌های افزوده‌شده (انکودر دوربین و سر تخمین عمق) با ضریب تقویت `--head-lr-multiplier` برابر ۱۰ به ۵×۱۰^{-۵} می‌رسد. این راهبرد باعث می‌شود لایه‌های جدید یا تغییریافته سریع‌تر با هدف آموزش تطبیق یابند، بی‌آنکه بخش‌های ازپیش‌آموزش‌یافته دچار نوسان شدید شوند. نرخ یادگیری با گرم‌سازی[۱] خطی در ابتدای آموزش و سپس کاهش چندجمله‌ای با توان ۰٫۹ زمان‌بندی می‌شود.

برای پایداری عددی نیز از برش گرادیان[۲] با آستانه ۱٫۰ و در صورت محدودیت حافظه، از تجمع گرادیان[۳] برای افزایش اندازه دسته موثر استفاده شده است. فهرست کامل ابرپارامترها در جدول ۱.۴ آمده است.

۵.۷.۳ فضای هدف آموزش برای مدل‌های نسبی: عمق معکوس

مدل پایه Depth Anything V2، نسخه نسبی، مطابق با سنت روش‌های خانواده MiDaS [۷]، در فضای عمق معکوس (دیسپاریتی)[۴] آموزش دیده و خروجی آن با عمق رابطه وارون دارد: نقاط نزدیک مقادیر بزرگ و نقاط دور مقادیر کوچک دریافت می‌کنند.

بر این اساس، هدف مدل‌های نسبی مطابق پروتکل مقاله مرجع در فضای عمق معکوس تعریف می‌شود:

$$T_{\text{disp}} = \frac{۱}{\max(D^{GT}, d_{\min})}, \tag{۱۳.۳}$$

که در آن $d_{\min}$ کران پایین عمق معتبر است. به این ترتیب، فضای هدف با فضای خروجی مدل ازپیش‌آموزش‌دیده هم‌راستا است. متناظر با آن، ارزیابی اعتبارسنجی حین آموزش نیز با ترازکردن مقیاس و جابجایی در فضای عمق معکوس و سپس وارون‌سازی به فضای عمق انجام می‌شود و نوع فضای هدف در فرادادههای ذخیره‌شده هر نقطهٔ وارسی ثبت می‌گردد تا زنجیره ارزیابی به‌صورت خودکار رفتار صحیح را اتخاذ کند.

[۱] Learning Rate Warm-up
[۲] Gradient Clipping
[۳] Gradient Accumulation
[۴] Inverse Depth / Disparity

۶.۷.۳ افزونه‌سازی هندسی آگاه از پارامترهای دوربین

چالش بنیادی در آموزش مدل پیشنهادی بر روی یک مجموعه‌داده تک‌دوربینه (نظیر NYUv2 که تمامی تصاویر آن با یک حسگر Kinect ثبت شده‌اند) آن است که بردار $\mathbf{d}_{\text{cam}}$ برای تمامی نمونه‌ها ثابت است و در نتیجه هیچ سیگنال تمایزبخشی برای واحد انکودر دوربین فراهم نمی‌کند. افزون بر این، بررسی زیرساخت اولیه آموزش نشان داد که برش تصادفی[۱] متداول در خط لوله پیش‌پردازش، مرکز تصویر موثر را جابه‌جا می‌کند بدون آنکه ماتریس کالیبراسیون دوربین متناظرا به‌روزرسانی شود؛ در نتیجه، انکودر دوربین در عمل اطلاعاتی ثابت و از منظر هندسی نادرست دریافت می‌کرد.

برای رفع هم‌زمان هر دو مشکل، در این پژوهش یک راهبرد افزونه‌سازی هندسی دقیق طراحی و پیاده‌سازی شد که در آن، برای هر نمونه آموزشی، پنجره‌ای تصادفی با نسبت ابعادی ثابت ۳:۴ و ضریب بزرگ‌نمایی s (در بازه ۱ تا ۲٫۲، و با احتمال ۲۰ درصد دقیقا قاب کامل) از تصویر بریده می‌شود و ماتریس کالیبراسیون دوربین به‌صورت دقیق در تمامی مراحل هندسی به‌روزرسانی می‌گردد: جابه‌جایی نقطه اصلی متناسب با مبدا پنجره برش،

$$c'_x = c_x - x_\circ, \qquad c'_y = c_y - y_\circ, \tag{۱۴.۳}$$

و مقیاس‌دهی فاصله کانونی و نقطه اصلی متناسب با تغییر اندازه پنجره به چارچوب ثابت ورودی شبکه:

$$\begin{aligned} f'_x &= f_x \frac{W_{\text{net}}}{w_{\text{win}}}, \quad c'_x = (c_x - x_\circ)\frac{W_{\text{net}}}{w_{\text{win}}}, \\ f'_y &= f_y \frac{H_{\text{net}}}{h_{\text{win}}}, \quad c'_y = (c_y - y_\circ)\frac{H_{\text{net}}}{h_{\text{win}}}. \end{aligned} \tag{۱۵.۳}$$

که در آن $(H_{\text{net}}, W_{\text{net}})$ ابعاد ثابت چارچوب ورودی شبکه (در پیاده‌سازی حاضر ۶۸۶ × ۵۱۸، مضرب اندازه وصله‌های ترنسفورمر) است. مقادیر عمق در این تبدیل تغییر نمی‌کنند، زیرا نقاط صحنه همان نقاط پیشین هستند.

این زنجیره به‌صورت شماتیک تشریح می‌شود.

وارونه‌سازی افقی نیز هم‌زمان بر تصویر، نگاشت عمق، ماسک اعتبار و ماتریس کالیبراسیون دوربین اعمال می‌شود. در این حالت، مختصه افقی نقطه اصلی مطابق $c'_x = W - c_x$ اصلاح می‌گردد. همچنین ابعاد چارچوبی که ماتریس کالیبراسیون دوربین در آن تعریف شده است همراه هر نمونه نگهداری می‌شود تا نرمال‌سازی

[۱] Random Crop

مولفه‌های دوربین در آموزش و استنتاج دقیقا در یک دستگاه مختصات انجام شود. این کنترل‌ها ضروری‌اند، زیرا تغییر تصویر بدون تبدیل متناظر ماتریس کالیبراسیون دوربین، حتی در صورت اجرای بی‌خطای برنامه، ورودی هندسی ناسازگار تولید می‌کند.

از منظر هندسی، این افزونه‌سازی معادل شبیه‌سازی دوربین‌هایی با میدان دید متفاوت از یک صحنه واحد است: بزرگ‌نمایی s میدان دید موثر را از حدود ۶۳ درجه (قاب کامل NYUv2) تا حدود ۳۳ درجه تغییر می‌دهد. بدین ترتیب، مدل پیشنهادی در طول آموزش با زوج‌های (تصویر، ماتریس کالیبراسیون دوربین) مواجه می‌شود که در آن‌ها ابهام میان مقیاس صحنه و میدان دید به‌صورت واقعی وجود دارد و تنها از طریق اطلاعات ماتریس کالیبراسیون دوربین قابل رفع است؛ در حالی که مدل کنترل، دقیقا همین تصاویر افزونه‌سازی‌شده را بدون اطلاعات ماتریس کالیبراسیون دوربین دریافت می‌کند. این طراحی، مبنای مطالعه کنترل‌شده فصل چهارم برای سنجش سهم واقعی پارامترهای درونی دوربین است.

۷.۷.۳ افزونه‌سازی لرزش کانونی: غیرقابل‌حل‌کردن مقیاس بدون ماتریس کالیبراسیون دوربین

افزونه‌سازی زوم‌ـبرش زیربخش قبل، میدان دید را متنوع می‌کند، اما یک محدودیت بنیادی دارد: در تصاویر معمولی، نشانه‌های معنایی صحنه (ابعاد آشنای اشیا، مبلمان، درها) به‌تنهایی برای بازیابی مقیاس تقریبی کافی‌اند و شبکه می‌تواند بدون مراجعه به ماتریس کالیبراسیون دوربین نیز پاسخ قابل قبولی بدهد. برای آنکه اتکای مدل به پارامترهای درونی دوربین به یک ضرورت تبدیل شود، در این پژوهش افزونه‌سازی مکملی با عنوان «افزونه‌سازی لرزش کانونی»[۱] طراحی شد که مستقیما از معادله تصویربرداری روزنه‌ای الهام می‌گیرد. طبق این معادله، $u = f \cdot X/Z$، اگر فاصله کانونی در ضریب α و هم‌زمان تمام عمق‌های صحنه نیز در همان α ضرب شوند، تصویر حاصل دقیقا یکسان باقی می‌ماند. بر همین اساس، برای هر نمونه آموزشی ضریبی به‌صورت لگاریتمی‌ـیکنواخت از بازه

$$\alpha \sim \exp\big(\mathcal{U}(-\ln m, +\ln m)\big), \qquad m = ۱/۶, \tag{۱۶.۳}$$

[۱] Focal Jitter

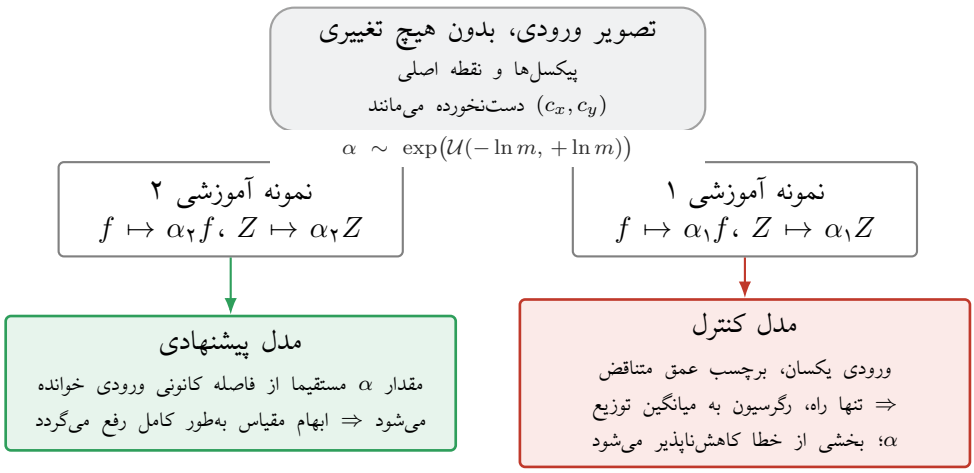
نمونه‌برداری شده و تبدیل

$$f_x \mapsto \alpha f_x, \qquad f_y \mapsto \alpha f_y, \qquad Z \mapsto \alpha Z \tag{۱۷.۳}$$

اعمال می‌شود؛ پیکسل‌های تصویر و مختصات نقطه اصلی (c_x, c_y) دست‌نخورده می‌مانند. این تبدیل از منظر هندسی دقیق است (برخلاف بازنمونه‌برداری، هیچ خطای درون‌یابی ایجاد نمی‌کند) و تصویر ورودی را تغییر نمی‌دهد.

پیامد این طراحی برای دو بازوی مطالعه کنترل‌شده متقارن نیست: مدل کنترل با تصاویری مواجه می‌شود که پیکسل‌های یکسان دارند اما برچسب‌های عمق متناقض؛ بهترین کاری که از آن برمی‌آید رگرسیون به میانگین توزیع α است و بخشی از خطا برای آن کاهش‌ناپذیر می‌شود. در مقابل، مدل پیشنهادی می‌تواند α را مستقیما از مقدار فاصله کانونی بخواند و ابهام را به‌طور کامل رفع کند. به بیان دیگر، افزونه‌سازی لرزش کانونی مساله بازیابی مقیاس را برای مدل کنترل به مساله‌ای بدساخت[۱] تبدیل می‌کند و بدین ترتیب فشار آموزشی صریحی برای بهره‌گیری از ورودی ماتریس کالیبراسیون دوربین ایجاد می‌نماید.

شکل ۶.۳ عدم تقارن این طراحی را میان دو بازوی مطالعه نشان می‌دهد.



شکل ۶.۳: افزونه‌سازی لرزش کانونی و تفاوت مسیر آموزشی مدل پیشنهادی و کنترل در حضور تغییر مقیاس صحنه.

[۱] Ill-posed

۸.۷.۳ آموزش چندمجموعه‌ای با دوربین‌های واقعی

افزونه‌سازی‌های زیربخش‌های پیشین، تنوع دوربین را از روی تصاویر یک حسگر واحد شبیه‌سازی می‌کنند. گام پایانی این پژوهش، آموزش مدل پیشنهادی بر داده‌هایی است که خود از دوربین‌های واقعی متفاوت آمده‌اند. در این تنظیم، یک مدل واحد هم‌زمان بر چهار مجموعه‌داده NYUv2، KITTI، Virtual KITTI 2 و Cityscapes آموزش می‌بیند (جدول ۳.۳) و هر نمونه، ماتریس کالیبراسیون دوربین واقعی خود را همراه دارد. پیاده‌سازی این آموزش چهار جزء دارد:

۱. نمونه‌برداری متوازن میان دامنه‌ها: اندازه مجموعه‌ها بسیار نابرابر است (از ۶۳۶ تصویر NYUv2 تا ۳۷۸۶۰ تصویر Virtual KITTI 2)؛ با نمونه‌برداری یکنواخت از کل تصاویر، داده مصنوعی بر آموزش غالب می‌شد. ازاین‌رو در هر دوره از هر مجموعه‌داده دقیقا ۱۵۰۰ نمونه برداشته می‌شود و مجموعه‌های کوچک‌تر با برداشت‌های تازه افزونه‌سازی تکرار می‌شوند. هر نمونه با یک زوج (شماره تصویر، بذر افزونه‌سازی) مشخص می‌شود که از بذر اصلی و شماره دوره ساخته می‌شود؛ بنابراین مدل پیشنهادی و مدل کنترل دقیقا همان تصاویر، همان برش‌ها و همان ضرایب افزونه‌سازی را می‌بینند.

۲. توصیف‌گر دوربین ویژه هر نمونه: در دسته‌های آموزشی مختلط، ابعاد قاب و ماتریس کالیبراسیون دوربین از نمونه‌ای به نمونه دیگر تغییر می‌کند. ازاین‌رو بردار $\mathbf{d}_{\text{cam}}$ برای هر نمونه با ابعاد قاب همان نمونه محاسبه می‌شود، یعنی با ابعاد چارچوبی که ماتریس کالیبراسیون دوربین آن پس از افزونه‌سازی در آن بیان شده است.

۳. زنجیره افزونه‌سازی مشترک و دقیق: این زنجیره برای همه مجموعه‌داده‌ها و هر دو بازو یکسان است و هر گام آن ماتریس کالیبراسیون دوربین را به‌طور دقیق به‌روز می‌کند. گام‌ها عبارت‌اند از برش پنجره‌ای با ضریب بزرگ‌نمایی ۱ تا ۲ (با احتمال ۲۰ درصد قاب کامل) همراه با جابه‌جایی نقطه اصلی؛ وارونه‌سازی افقی همراه با قرینه‌کردن c_x؛ تغییر اندازه با کران پایین ۵۱۸ پیکسل و سپس برش تصادفی ۵۱۸ × ۵۱۸؛ و افزونه‌سازی لرزش کانونی با $m = ۱/۶$ (زیربخش ۷.۷.۳).

۴. انتخاب نقطهٔ وارسی بر داده اعتبارسنجی: از هر دامنه ۵۰ تصویر اعتبارسنجی از بخش‌های کنار

گذاشته‌شده برداشته می‌شود و نقطهٔ وارسی با کمترین میانگین AbsRel میان چهار دامنه انتخاب می‌شود؛ هیچ تصویر آزمونی در این انتخاب به‌کار نمی‌رود.

سایر تنظیمات با مطالعه کنترل‌شده NYUv2 هم‌خوان است. نقطه شروع، مدل پایه Depth Anything V2، نسخه نسبی ViT-L است و انکودر DINOv2 فریز می‌ماند. هدف آموزش، عمق مطلق بر حسب متر با هزینه SiLog و $\lambda = ۰/۵$ است. نرخ یادگیری پایه ۵×۱۰^{-۶} با ضریب تقویت ۱۰ برای دیکودر و انکودر دوربین به‌کار می‌رود و با کاهش چندجمله‌ای با توان ۰/۹ و بدون گرم‌سازی زمان‌بندی می‌شود. آموزش ۱۲ دوره طول می‌کشد و هر دوره ۶۰۰۰ نمونه دارد؛ با اندازه دسته ۴، این برنامه در مجموع ۷۲۰۰۰ نمونه و ۱۸۰۰۰ گام بهینه‌سازی است. مدل کنترل همین داده‌ها و همین برداشت‌های افزونه‌سازی را بدون ماتریس کالیبراسیون دوربین دریافت می‌کند و برابری بیت‌به‌بیت هزینه گام صفر دو بازو، یکسان‌بودن ورودی‌ها را تایید کرد.

۹.۷.۳ جمع‌بندی فرآیند آموزش

در مجموع، راهبرد نهایی بر تنظیم دقیق‌پارامترهای نظارتی و کنترل‌شده یک مدل قدرتمند ازپیش‌آموزش‌یافته، فریزکردن انکودر، آموزش سر عمق و انکودر دوربین، و زوج‌سازی کامل مدل پیشنهادی با مدل کنترل استوار است.

در بخش بعدی، توابع هزینه مورد استفاده در این فرآیند آموزش و نقش هر یک در هدایت مدل به‌سوی تخمین عمق مطلق دقیق، به‌صورت رسمی و ریاضی تشریح خواهد شد.

۸.۳ معیارهای ارزیابی عملکرد

ارزیابی کمی مدل‌های تخمین عمق نیازمند معیارهایی است که اختلاف میان نگاشت عمق پیش‌بینی‌شده و عمق مرجع را به‌صورت عددی بیان کنند. در این پژوهش، از مجموعه معیارهایی استفاده شده که در پیشینه پژوهشی تخمین عمق تک‌چشمی، از کار Eigen و همکاران به‌عنوان پروتکل استاندارد مطرح شده و از آن پس به‌طور گسترده در مقایسه مدل‌های مطلق و نسبی به‌کار رفته‌اند [۲، ۵]. این معیارها در ادامه به‌صورت کامل معرفی می‌شوند؛ نحوه کاربرد هر یک برای مدل‌های مطلق و نسبی، و تمایز آن‌ها با تابع هزینه آموزش، در بخش ۹.۳ بحث خواهد شد.

الگوریتم ۱.۳ روند آموزش مدل با پارامترهای هندسی

Require: مجموعه داده آموزش $D = \{(I_i, K_i, D_i^{GT})\}_{i=1}^{N}$، مدل پایه Depth Anything V2 با وزن‌های θ_{enc} (فریز شده)، θ_{dec} (قابل آموزش)، θ_{cam} (شبکه انکودر دوربین)
Ensure: مدل نهایی آموزش‌دیده

for هر epoch از آموزش do
  for هر دسته داده (batch) از D do
    تصویر $\leftarrow I$
    ماتریس کالیبراسیون دوربین $\leftarrow K$
    نقشه عمق مرجع $\leftarrow D^{GT}$
    { پیش‌پردازش و کدگذاری پارامترهای دوربین }
    $\mathbf{d}_{\text{cam}} \leftarrow$ نرمال‌سازی(K, W, H)
    $\mathbf{z}_{\text{cam}} \leftarrow MLP(\mathbf{d}_{\text{cam}}, \theta_{cam})$
    { استخراج ویژگی‌های بصری با تزریق توکن دوربین در انکودر }
    $F \leftarrow Encoder(I, \mathbf{z}_{\text{cam}}, \theta_{enc})$
    { تخمین عمق }
    $D^{pred} \leftarrow Decoder(F, \theta_{dec})$
    { محاسبه تابع هزینه مطلق }
    $\mathcal{L} \leftarrow \mathcal{L}_{SiLog}(D^{pred}, D^{GT})$
    { به‌روزرسانی وزن‌ها }
    $\theta_{dec}, \theta_{cam} \leftarrow Optimizer.step(\nabla\mathcal{L})$
  endfor
endfor

۱.۸.۳ خطای نسبی مطلق

معیار AbsRel میانگین قدر مطلق اختلاف پیش‌بینی و مقدار مرجع را نسبت به مقدار مرجع می‌سنجد:

$$\text{AbsRel} = \frac{1}{N} \sum_{i=1}^{N} \frac{|D_i^{pred} - D_i^{GT}|}{D_i^{GT}}, \tag{۱۸.۳}$$

که در آن N تعداد پیکسل‌های دارای عمق مرجع معتبر، D_i^{pred} عمق پیش‌بینی‌شده و D_i^{GT} عمق مرجع در پیکسل i-ام است. نرمال‌سازی نسبت به D_i^{GT} باعث می‌شود این معیار به مقیاس مطلق صحنه حساسیت کمتری داشته باشد و خطا در نواحی نزدیک و دور به‌صورت نسبی و قابل‌مقایسه بیان شود.

۲.۸.۳ ریشه میانگین مربعات خطا و حساسیت آن به پارامترهای دوربین

ریشه میانگین مربعات خطا[۱]، یا RMSE، اختلاف پیش‌بینی و مقدار مرجع را بدون نرمال‌سازی نسبت به مقدار مرجع می‌سنجد:

$$\text{RMSE} = \sqrt{\frac{۱}{N}\sum_{i=۱}^{N}(D_i^{pred} - D_i^{GT})^۲}. \qquad (۱۹.۳)$$

به دلیل آنکه مجذور اختلاف در این معیار به‌کار رفته، خطاهای بزرگ وزن بیشتری در مقدار نهایی می‌یابند و RMSE نسبت به دورافت‌ها حساس‌تر از AbsRel عمل می‌کند.

از سوی دیگر، چون این معیار بدون نرمال‌سازی نسبت به D_i^{GT} تعریف شده، مقدار آن مستقیما به مقیاس فیزیکی عمق بستگی دارد و در نتیجه نسبت به تغییر پارامترهای درونی دوربین، به‌ویژه فاصله کانونی، حساس است. این ویژگی، هرچند در نگاه اول یک محدودیت به نظر می‌رسد، در واقع ابزار مناسبی برای آشکارسازی ناپایداری مطلق مدل‌های عمق محسوب می‌شود. در این پژوهش از این حساسیت به‌عنوان معیاری برای سنجش پایداری مدل استفاده شده است: مدلی که نسبت به تغییر پارامترهای دوربین پایدار باشد، باید تغییرات کمی در RMSE از خود نشان دهد، حتی زمانی که تصاویر با مشخصات هندسی متفاوت تصویربرداری شده باشند.

۳.۸.۳ معیارهای دقت آستانه‌ای

معیارهای دقت آستانه‌ای، که معمولا با نماد δ_i مشخص می‌شوند، درصد پیکسل‌هایی را اندازه می‌گیرند که نسبت پیش‌بینی به مقدار مرجع (یا برعکس) از یک آستانه معین کمتر باشد:

$$\delta_i : \quad \max\left(\frac{D_i^{pred}}{D_i^{GT}}, \frac{D_i^{GT}}{D_i^{pred}}\right) < ۱٫۲۵^i, \qquad i \in \{۱, ۲, ۳\}. \qquad (۲۰.۳)$$

مقدار $\delta_۱$ سخت‌گیرانه‌ترین آستانه را نشان می‌دهد و معمولا به‌عنوان شاخص اصلی دقت گزارش می‌شود، در

[۱] Root Mean Squared Error

حالی که δ_2 و δ_3 تصویری کلی‌تر از توزیع خطا در سطح پیکسل ارایه می‌دهند.

۴.۸.۳ کاربرد معیارها برای مدل‌های مطلق و نسبی

برای مدل‌های مطلق، که خروجی آن‌ها عمق مطلق بر حسب متر است، معیارهای فوق مستقیما و بدون هیچ ترازی میان پیش‌بینی و عمق مرجع محاسبه می‌شوند. برای مدل‌های نسبی که خروجی آن‌ها دارای ابهام مقیاس است، پیش از محاسبه معیارها یک تراز مقیاس (و در صورت نیاز جابجایی)، معمولا از طریق میانه یا کمترین مربعات، به‌ازای هر تصویر اعمال می‌شود تا ارزیابی به ساختار نسبی عمق محدود بماند. علاوه بر معیارهای فوق، معیار SiLog که در بخش ۱.۹.۳ به‌عنوان تابع هزینه مدل‌های مطلق معرفی می‌شود، به دلیل تغییرناپذیری ذاتی نسبت به مقیاس، برای ارزیابی مدل‌های نسبی نیز مناسب است و در این پژوهش به‌عنوان معیار مکمل برای این دسته از مدل‌ها گزارش می‌شود.

۹.۳ توابع هزینه و معیارهای بهینه‌سازی

طراحی تابع هزینه در مساله MDE، نقش تعیین‌کننده‌ای در نوع اطلاعاتی دارد که مدل در فرآیند آموزش فرا می‌گیرد. از آنجا که هدف این پژوهش، دستیابی به تخمین عمق مطلق پایدار و غیر وابسته به تغییر پارامترهای درونی دوربین است، انتخاب تابع هزینه به‌گونه‌ای انجام شده که مدل بتواند مقیاس مطلق عمق را یاد بگیرد و در عین حال نسبت به تغییرات پارامترهای دوربین پایدار باشد.

در این پژوهش، بسته به نوع مدل (مطلق یا نسبی)، از توابع هزینه مناسبی استفاده شده است که در ادامه تشریح می‌شوند.

۱.۹.۳ هزینه SiLog برای مدل‌های مطلق

برای آموزش مدل مطلق که هدف آن تولید تخمین عمق مطلق بر حسب متر است، از تابع هزینه SiLog استفاده می‌شود؛ این تابع نخستین‌بار توسط Eigen و همکاران معرفی شد [۲]. این تابع هزینه که به اختصار

SiLog نامیده می‌شود، به‌گونه‌ای طراحی شده که به‌جای تفاوت مستقیم مقادیر عمق، بر تفاوت لگاریتمی آن‌ها تمرکز دارد:

$$\mathcal{L}_{\text{SiLog}} = \sqrt{\frac{۱}{N}\sum_{i=۱}^{N} d_i^{۲} - \frac{\lambda}{N^{۲}}\left(\sum_{i=۱}^{N} d_i\right)^{۲}}, \tag{۲۱.۳}$$

که در آن N تعداد پیکسل‌های دارای برچسب معتبر، $d_i = \log D_i^{GT} - \log D_i^{pred}$ تفاوت لگاریتمی بین مقدار واقعی و مقدار پیش‌بینی‌شده در پیکسل i-ام است. ضریب λ معمولا برابر ۰٫۵ در نظر گرفته می‌شود تا تعادلی بین خطای مطلق و خطای نسبی برقرار گردد.

ویژگی مهم SiLog آن است که ضمن حفظ حساسیت به مقیاس مطلق عمق، باعث می‌شود خطا در فواصل دور و نزدیک به‌صورت متعادل‌تری در نظر گرفته شود. استفاده از فضای لگاریتمی، مدل را نسبت به خطاهای بزرگ در عمق‌های دور مقاوم‌تر می‌کند و از تمرکز بیش از حد بر خطاهای نقطه‌ای بسیار بزرگ جلوگیری می‌نماید.

۲.۹.۳ هزینه تغییرناپذیر نسبت به مقیاس و جابجایی برای مدل‌های نسبی

برای آموزش مدل در حالت نسبی که خروجی آن دارای ابهام مقیاس است، از تابع هزینه تغییرناپذیر نسبت به مقیاس و جابجایی استفاده می‌شود؛ این تابع، همان صورت‌بندی به‌کاررفته در خانواده MiDaS است [۷]. این تابع هزینه ابتدا پیش‌بینی مدل را با استفاده از روش کمترین مربعات بر مقدار واقعی منطبق می‌کند:

$$D_{pred}^{*} = s \cdot D_{pred} + t, \tag{۲۲.۳}$$

که در آن s و t مقیاس و جابجایی بهینه هستند که به‌صورت تحلیلی از طریق کمینه‌سازی خطای پیکسل‌به‌پیکسل محاسبه می‌شوند.

تابع هزینه نهایی ترکیبی از خطای مطلق پیکسل‌ها ($L_۱$) و خطای تطابق گرادیان است:

$$\mathcal{L}_{\text{SSI}} = (۱ - \alpha)\mathcal{L}_{\text{pixel}} + \alpha\mathcal{L}_{\text{grad}}, \quad (۲۳.۳)$$

که در آن $\mathcal{L}_{\text{pixel}}$ خطای $L_۱$ میان تخمین منطبق‌شده و عمق واقعی است و $\mathcal{L}_{\text{grad}}$ خطای تطابق گرادیان در چند مقیاس را اندازه می‌گیرد. پارامتر α (معمولا 0.5) وزن نسبی این دو مولفه را تعیین می‌کند. هزینه گرادیان باعث می‌شود که لبه‌های عمق و ناپیوستگی‌ها در تصویر با دقت بیشتری بازسازی شوند.

۳.۹.۳ تمایز میان توابع هزینه آموزش و معیارهای ارزیابی

نکته‌ای حایز اهمیت در این پژوهش، تمایز آگاهانه میان توابع هزینه مورد استفاده در آموزش و معیارهای به‌کاررفته در ارزیابی مدل است. این تمایز از آن جهت ضروری است که اهداف آموزش و ارزیابی لزوما یکسان نیستند.

- توابع هزینه در آموزش

در مرحله آموزش:

- برای مدل‌های مطلق از SiLog استفاده می‌شود
- برای مدل‌های نسبی از Scale-Shift Invariant Loss استفاده می‌شود
- معیارهای ارزیابی

در مرحله ارزیابی، از معیارهای متنوع‌تری بسته به نوع مدل استفاده می‌شود؛ تعریف کامل این معیارها (AbsRel، RMSE و معیارهای دقت آستانه‌ای δ_i) و نحوه کاربرد آن‌ها برای مدل‌های مطلق و نسبی، در بخش ۸.۳ ارایه شده است.

جدول ۴.۳ این تمایزها را در یک نما جمع‌بندی می‌کند.

جدول ۴.۳: توابع هزینه و پروتکل‌های ارزیابی

حالت مدل	فضای هدف آموزش	تابع هزینه	پروتکل ارزیابی و دلالت آن
نسبی (releative)	عمق معکوس نرمال‌شده $T_{\text{disp}} = 1/\max(D^{GT}, d_{\min})$	تغییرناپذیر نسبت به مقیاس و جابجایی: $\mathcal{L}_{\text{SSI}} = (1-\alpha)\mathcal{L}_{\text{pixel}} + \alpha\mathcal{L}_{\text{grad}}$	تراز مقیاس و جابجایی به‌ازای هر تصویر پیش از محاسبه معیارها؛ این تراز، اطلاعات مقیاس مطلق را حذف می‌کند
مطلق (absolute)	عمق مطلق بر حسب متر	لگاریتمی تغییرناپذیر نسبت به مقیاس: λ با ضریب $\mathcal{L}_{\text{SiLog}}$	بدون هیچ ترازی؛ تنها پروتکلی که سهم اطلاعات هندسی دوربین در آن قابل مشاهده است

۴.۹.۳ پروتکل ارزیابی و سناریوهای مقایسه

در ارزیابی مدل‌ها، معیارها بر اساس نوع خروجی مدل و هدف مقایسه انتخاب می‌شوند. برای مدل‌های مطلق، عمق پیش‌بینی‌شده بدون تراز مقیاس با عمق مرجع بر حسب متر مقایسه می‌شود؛ بنابراین AbsRel، RMSE، SiLog و معیارهای دقت آستانه‌ای، عملکرد عددی و حساسیت به مقیاس فیزیکی را نشان می‌دهند. برای مدل‌های نسبی، پیش از محاسبه معیارها تراز مقیاس و جابجایی در سطح هر تصویر انجام می‌شود تا ارزیابی به ساختار نسبی عمق محدود بماند. در گزارش‌های تجربی فصل چهارم، AbsRel به‌عنوان معیار خطای اصلی و RMSE و SiLog به‌عنوان معیارهای مکمل گزارش می‌شوند؛ معیارهای آستانه‌ای نیز برای سنجش درصد پیکسل‌های نزدیک به مقدار مرجع به‌کار می‌روند.

پروتکل نهایی بر تقسیم‌بندی استاندارد NYUv2 مبتنی بر ۶۵۴ تصویر آزمون است که در بخش ۱.۷.۳ توضیح داده شد. در مقایسه‌های زوجی، همه مدل‌ها روی همان تصاویر، با ماسک اعتبار یکسان و با ترتیب ثابت نمونه‌ها ارزیابی می‌شوند. در ارزیابی‌های بین‌دیتاستی، هر دیتاست با پروتکل معتبر و پارامترهای دوربین متناظر خودش پردازش می‌شود و نتایج با توجه به تفاوت دامنه‌ها تفسیر می‌گردند.

۵.۹.۳ آزمون‌های آماری و برآورد عدم‌قطعیت

برای بررسی معناداری تفاوت‌های مشاهده‌شده بین مدل‌ها و دیتاست‌ها، آزمون آماری متناسب با طرح مقایسه انتخاب می‌شود. در مقایسه‌های بین‌دیتاستی، آزمون t دو نمونه‌ای[۱] برای مقایسه میانگین خطاها به‌کار می‌رود و سطح معناداری برابر با ۰/۰۵ در نظر گرفته می‌شود.

در مطالعه کنترل‌شده، که مدل‌های مختلف روی مجموعه آزمون یکسان ارزیابی می‌شوند، خطای هر مدل برای هر تصویر به‌صورت زوجی محاسبه می‌شود. معناداری تفاوت میانگین خطاها با آزمون t زوجی[۲] سنجیده می‌شود و، چون توزیع خطاهای تک‌تصویری لزوما نرمال نیست، آزمون ناپارامتری علامت‌دار ویلکاکسون[۳] [۴۲] نیز به‌عنوان تحلیل استحکام گزارش می‌شود. طرح زوجی اثر دشواری متفاوت تصاویر را کنترل می‌کند.

برای برآورد عدم‌قطعیت و کاهش وابستگی به فرضیات توزیعی، از بازنمونه‌گیری بوت‌استرپ[۴] [۴۳] با ده‌هزار بازنمونه از تفاضل‌های زوجی خطا استفاده می‌شود و بازه اطمینان ٪۹۵ گزارش می‌گردد. این آزمون‌ها برای استنباط درباره تفاوت عملکرد در نمونه‌های ارزیابی به‌کار می‌روند؛ آموزش با چند بذر مستقل در این پژوهش تکرار نشده است و بنابراین پراکندگی میان اجراهای آموزشی برآورد نمی‌شود.

۶.۹.۳ نقش پارامترهای درونی دوربین در آموزش

نقش ماتریس کالیبراسیون دوربین در این چارچوب، نه از طریق افزودن یک مولفه مستقیم به تابع هزینه، بلکه از طریق تزریق اطلاعات هندسی به معماری مدل ایفا می‌شود. با در اختیار داشتن اطلاعات صریح پارامترهای درونی، مدل قادر است تخمین‌های مطلق خود را با هندسه واقعی تصویربرداری تطبیق دهد.

در مدل پیشنهادی، پارامترهای درونی دوربین از طریق یک واحد انکودر مجزا پردازش شده و به‌صورت توکن دوربین به لایه‌های میانی Vision Transformer تزریق می‌شوند. این اطلاعات به مدل امکان می‌دهد تا در فرآیند یادگیری، رابطه میان ویژگی‌های تصویری و مقیاس واقعی عمق را با در نظر گرفتن مشخصات هندسی دوربین یاد بگیرد.

به این ترتیب، تابع هزینه SiLog که ذاتا به مقیاس مطلق عمق حساس است، می‌تواند به‌درستی مدل را

[۱] Two-sample t-test
[۲] Paired t-test
[۳] Wilcoxon Signed-rank Test
[۴] Bootstrap Resampling

برای تولید تخمین‌های مطلق پایدار هدایت کند. این پایداری در مواجهه با داده‌هایی که تنها در پارامترهای درونی دوربین تفاوت دارند، در آزمایش‌های تجربی به‌وضوح مشاهده می‌شود. حساسیت معیار RMSE به این پارامترها و کاربرد آن در ارزیابی پایداری مدل، در بخش ۲.۸.۳ توضیح داده شده است.

۱۰.۳ جمع‌بندی فصل

در این فصل، چارچوب نظری و عملی پژوهش برای تبدیل مدل بنیادین تخمین عمق تک‌تصویری به سامانه‌ای با عمق مطلق پایدار ارائه شد. پس از بررسی نقش مدل سوراخ‌سوزنی و پارامترهای درونی دوربین در تعیین مقیاس فیزیکی، معماری Depth Anything V2 و روش پیشنهادی برای نرمال‌سازی، کدگذاری و تزریق ماتریس کالیبراسیون دوربین به‌صورت توکن هندسی در انکودر تشریح شد؛ ضریب کنترلی خروجی صفرمقدار اولیه نیز امکان افزودن تدریجی اطلاعات هندسی را بدون اختلال در مدل ازپیش‌آموزش‌دیده فراهم می‌کند. همچنین، توابع هزینه، معیارهای ارزیابی، داده‌ها، تنظیمات آموزش و ملاحظات تکرارپذیری بیان شد؛ به‌ویژه SiLog برای یادگیری مطلق و RMSE برای سنجش حساسیت به مقیاس به‌کار می‌روند، در حالی‌که AbsRel و معیارهای مشابه برای مقایسهٔ نرمال‌شده استفاده می‌شوند. فصل چهارم بر پایهٔ این چارچوب، اثر اطلاعات درونی دوربین را بر مقیاس مطلق، دقت عددی و پایداری مدل بررسی می‌کند.

در گام پایانی، همین چارچوب به آموزش چندمجموعه‌ای بر NYUv2، KITTI، Virtual KITTI 2 و Cityscapes با دوربین‌های واقعی متفاوت گسترش یافت (زیربخش ۸.۷.۳). نمونه‌برداری متوازن میان دامنه‌ها، توصیف‌گر دوربین ویژه هر نمونه و زنجیره افزونه‌سازی دقیق مشترک، مقایسه زوجی مدل پیشنهادی و مدل کنترل را در این تنظیم نیز ممکن می‌کنند.

فصل ۴

نتایج

۱.۴ مقدمه

این فصل به ارزیابی تجربی مدل پیشنهادی در برابر مدل پایه Depth Anything V2 می‌پردازد تا مشخص شود آیا تزریق صریح اطلاعات هندسی دوربین به فرآیند تخمین عمق، ناپایداری مقیاس و وابستگی به نوع دوربین را کاهش می‌دهد یا خیر. بدین منظور، دو مدل روی دیتاست‌های متنوعی شامل محیط‌های داخلی و خارجی و داده‌های واقعی و مصنوعی با معیارهای نسبی و مطلق مقایسه می‌شوند. سپس با آزمون‌های آماری و بازه‌های اطمینان بررسی می‌شود که آیا این تفاوت‌ها از نظر آماری معنادار هستند.

۲.۴ جزئیات پیاده‌سازی

در این بخش، تنظیمات اجرایی، داده‌های مورد استفاده، ساختار کد و فرآیندهای اشکال‌زدایی پژوهش ارائه می‌شود تا نتایج فصل حاضر قابل بازتولید و ارزیابی باشند.

۱.۲.۴ چارچوب نرم‌افزاری و زیرساخت محاسباتی

تمامی پیاده‌سازی‌ها در چارچوب PyTorch (نسخه 1.12 و بالاتر) [۴۴] انجام شده و کد پایه بر اساس مخزن رسمی Depth Anything V2 [۴] توسعه داده شده است. معماری کلی شامل یک انکودر مبتنی بر DINOv2 Vision Transformer [۲۸، ۲۹] و یک دیکودر از خانواده Dense Prediction Transformer (DPT) [۶] است.

آموزش مدل‌ها بر روی واحدهای پردازش گرافیکی (GPU)[۱] NVIDIA با معماری Ampere یا جدیدتر انجام شده و تمامی آزمایش‌ها به‌صورت تک‌کارت گرافیک و با دقت ممیز شناور ۳۲ بیتی اجرا شده‌اند. برای افزایش تکرارپذیری، بذر تصادفی[۲] برای کتابخانه‌های PyTorch، NumPy و Python در ابتدای هر آزمایش روی مقدار ثابت ۴۲ تنظیم شده است.

[۱] Graphics Processing Unit
[۲] Random Seed

آزمایش چندمجموعه‌ای بخش ۶.۴ از این قاعده مستثناست: این آزمایش بر یک کارت NVIDIA RTX 4090 با حافظه ۲۴ گیگابایت و با دقت ممیز شناور ترکیبی bfloat16 اجرا شد و لایه‌های توجه انکودر در آن با پیاده‌سازی ادغام‌شده scaled dot-product attention در PyTorch محاسبه شدند. این پیاده‌سازی از نظر عددی با محاسبه صریح توجه معادل است، اما ماتریس‌های توجه را در حافظه نگه نمی‌دارد.

۲.۲.۴ تنظیمات آموزش و راهبرد بهینه‌سازی

مدل پیشنهادی با استفاده از بهینه‌ساز AdamW [۴۱] آموزش داده شده است. نرخ یادگیری پایه برابر با ۵×۱۰^{-۶} تنظیم شده و برای دیکودر و لایه‌های افزوده‌شده (شامل انکودر دوربین و سر تخمین عمق) در ضریب تقویت ۱۰ ضرب می‌شود؛ بنابراین نرخ یادگیری موثر این بخش‌ها ۵×۱۰^{-۵} است. از آنجا که وزن‌های انکودر DINOv2 در این پژوهش ثابت نگه داشته می‌شوند، نرخ پایه به‌طور مستقیم به هیچ پارامتری اعمال نمی‌شود و تنها مبنای محاسبه نرخ موثر است؛ این نرخ فقط در صورت آموزش انکودر برای وزن‌های آن به کار می‌رفت.

پارامترهای بهینه‌ساز به‌صورت زیر تنظیم شده‌اند:

- ضرایب تکانه: $\beta_۱ = ۰/۹$، $\beta_۲ = ۰/۹۹۹$
- ضریب کاهش وزن (Weight Decay): ۰/۰۱
- پارامتر ϵ برای پایداری عددی: $۱۰^{-۸}$

برای جلوگیری از بیش‌برازش و حفظ ویژگی‌هایی که مدل DINOv2 پیش‌تر آموخته است، وزن‌های انکودر در طول آموزش ثابت نگه داشته شدند. این کار با استفاده از گزینه پیش‌فرض `--freeze-dinov2` در اسکریپت آموزش انجام شد. در نتیجه، تنها لایه‌های خروجی شبکه[۱] و بخش انکودر اطلاعات دوربین آموزش می‌بینند و وزن‌های انکودر تغییر نمی‌کنند. به این ترتیب، ویژگی‌های آموخته‌شده در DINOv2 حفظ می‌شوند و مدل می‌تواند از آن‌ها برای تخمین عمق استفاده کند. این روش در آزمایش‌های پژوهش حاضر به همگرایی سریع‌تر مدل نیز کمک کرد. دلیل انتخاب این روش آن است که طبق پژوهش اصلی DINOv2، ویژگی‌های استخراج‌شده

[۱] Head Layers

توسط این مدل حتی بدون نیاز به آموزش مجدد انکودر نیز برای انجام وظایف مختلف، از جمله وظایف بینایی ماشین، کارآمد هستند [۲۸].

برای زمان‌بندی نرخ یادگیری، از یک استراتژی ترکیبی شامل warmup خطی در ابتدای آموزش و سپس کاهش چندجمله‌ای با توان ۰٫۹ استفاده شده است. مدل‌ها به مدت ۴۰ دوره[۱] آموزش داده شده‌اند. به دلیل محدودیت حافظه، اندازه دسته برابر با ۲ تنظیم شده و با تجمع گرادیان[۲] در ۲ گام، اندازه دسته موثر به ۴ رسیده است.

جدول ۱.۴ تمامی ابرپارامترهای آموزش را در یک نما گرد آورده است. تاکید می‌شود که این مقادیر برای هر دو بازوی مدل پیشنهادی و مدل کنترل کاملا یکسان‌اند؛ تنها تفاوت دو بازو، وجود یا نبود ورودی ماتریس کالیبراسیون دوربین است.

۳.۲.۴ ساختار کد و اسکریپت‌های اصلی

اسکریپت `train.py` مسئول اجرای فرآیند آموزش بوده و از طریق آرگومان‌های ورودی، امکان تنظیم پارامترهای زیر را فراهم می‌کند:

- `--use-camera-intrinsics`: فعال‌سازی استفاده از پارامترهای دوربین
- `--model-type`: انتخاب نوع مدل (absolute یا releative)
- `--encoder`: انتخاب اندازه انکودر (vits, vitb, vitl, vitg)
- `--freeze-dinov2`: فریز کردن وزن‌های انکودر
- `--focal-jitter` و `--silog-lambda`: تنظیم افزونه‌سازی لرزش کانونی و ضریب مقیاس در هزینه SiLog
- `--seed`: قفل‌کردن ترتیب داده و جریان‌های تصادفی برای زوج‌های کنترل‌شده
- `--accumulate-grad`: تجمع گرادیان برای دستیابی به اندازه دسته موثر بزرگ‌تر

[۱] Epoch
[۲] Gradient Accumulation

جدول ۱.۴: ابرپارامترهای آموزش (یکسان برای هر دو بازوی مدل پیشنهادی و مدل کنترل)

مولفه	مقدار	توضیح
بهینه‌سازی		
بهینه‌ساز	AdamW [۴۱]	$\beta_1 = ۰/۹$، $\beta_2 = ۰/۹۹۹$، $\epsilon = ۱۰^{-۸}$
ضریب کاهش وزن	۰/۰۱	
نرخ یادگیری پایه	۵×۱۰^{-۶}	مبنای محاسبه؛ به دلیل فریز انکودر مستقیما اعمال نمی‌شود
ضریب تقویت نرخ یادگیری سر شبکه	۱۰	نرخ موثر دیکودر و انکودر دوربین: ۵×۱۰^{-۵}
زمان‌بندی نرخ یادگیری	گرم‌سازی خطی + کاهش چندجمله‌ای	توان کاهش برابر ۰/۹
برش گرادیان	۱/۰	برای پایداری عددی
مدل و اجرا		
انکودر	ViT-L، فریزشده	گزینه `--freeze-dinov2`
تعداد دوره‌ها	۴۰	
اندازه دسته	۲، با تجمع گرادیان ۲	اندازه دسته موثر: ۴
دقت عددی	ممیز شناور ۳۲ بیتی	تک‌کارت گرافیک
بذر تصادفی	۴۲	قفل‌شده میان دو بازو؛ راستی‌آزمایی با برابری بیت‌به‌بیت هزینه گام صفر
داده و تابع هزینه		
چارچوب ورودی شبکه	۵۱۸×۶۸۶	قاب کامل ۳:۴، مضرب اندازه وصله
افزونه‌سازی هندسی	برش ۳:۴	با به‌روزرسانی دقیق ماتریس کالیبراسیون دوربین
افزونه‌سازی لرزش کانونی	$m = ۱/۶$	شکل ۶.۳
ضریب λ در SiLog	۰/۵ (و ۰/۳ در پیکربندی لرزش کانونی، زیربخش ۷.۴.۴)	آزمایش تفکیک اثر بخش ۸.۴.۴

علاوه بر اسکریپت آموزش، ابزارهای اصلی به شرح زیر هستند:

- `evaluate_paper.py` برای بازتولید پروتکل ارزیابی مقاله؛
- `tools/paired_stats.py` برای آزمون زوجی، ویلکاکسون و بوت‌استرپ؛
- `tools/k_sweep.py` و `tools/k_knockout.py` برای آزمون‌های سازوکاری و علی؛
- `tools/eval_fov_varied.py` برای سنجش تعمیم به میدان دیدهای متفاوت.

صحت تبدیل افزونه‌سازی لرزش کانونی، منطق ماسک اعتبار و اعتبارسنجی آرگومان‌ها نیز با ده آزمون واحد در

فایل tests/test_focal_jitter.py پوشش داده شده است.

دستورالعمل مدل نهایی آزمایش تفکیک اثر (آزمایشی که در آن تنها یک عامل تغییر می‌کند تا اثر همان عامل به‌تنهایی سنجیده شود؛ زیربخش ۸.۴.۴) به‌صورت زیر است. برای بازوی مدل کنترل، دو گزینه پایانی با --model-variant base -- جایگزین می‌شوند؛ سایر آرگومان‌ها بدون تغییر می‌مانند.

```
python train.py --encoder vitl --datasets nyu --model-type absolute \
 --min-depth 0.001 --max-depth 20 --epochs 40 --bs 2 \
 --accumulate-grad 2 --lr 5e-6 --freeze-dinov2 \
 --head-lr-multiplier 10 --grad-clip 1 --focal-jitter 1.6 \
 --silog-lambda 0.5 --seed 42 --pretrained-from <basic_vitl.pth> \
 --save-path <output_dir> --model-variant revised \
 --use-camera-intrinsics
```

این مدل با AbsRel برابر ۰٫۰۸۳۴ و شیب پیمایش فاصله کانونی برابر ۰٫۰۳ ± ۰٫۹۷، بهترین مدل دارای افزونه‌سازی لرزش کانونی است.

۴.۲.۴ اشکال‌زدایی و درس‌های پیاده‌سازی

در مسیر رسیدن به پیکربندی نهایی، یک اشکال خاموش در زنجیره آموزش شناسایی و رفع شد. شرح این اشکال و راه‌حل آن، هم به تکرارپذیری نتایج کمک می‌کند و هم برای طراحی آزمایش‌های مشابه سودمند است.

برش تصادفی متداول در پیش‌پردازش، نقطه اصلی موثر تصویر را جابه‌جا می‌کرد، اما ماتریس کالیبراسیون دوربین متناظر با آن به‌روزرسانی نمی‌شد. در نتیجه، انکودر دوربین ورودی هندسی نادرستی دریافت می‌کرد، بی‌آنکه خطایی در اجرای برنامه رخ دهد یا منحنی هزینه رفتار غیرعادی نشان دهد. برای رفع این اشکال، زنجیره افزونه‌سازی هندسی دقیق بخش ۶.۷.۳ طراحی شد که در آن هر تبدیل هندسی تصویر با تبدیل متناظر ماتریس کالیبراسیون دوربین همراه است؛ صحت این زنجیره با راستی‌آزمایی عددی میدان دید نمونه‌های تولیدشده تایید شد.

این تجربه نشان می‌دهد که در زنجیره‌های یادگیری عمیق، برخی شکست‌ها کاملا خاموش‌اند و تنها با راستی‌آزمایی مستقل آشکار می‌شوند. به همین دلیل، پیش از اجرای آزمایش‌های اصلی، صحت زنجیره

ارزیابی نیز با بازتولید نتایج گزارش‌شده مقاله Depth Anything V2 بر روی پروتکل استاندارد بررسی شد (بخش ۲.۴.۴).

در آماده‌سازی آموزش چندمجموعه‌ای، اشکال خاموش دیگری نیز آشکار شد: فایل‌های ماتریس کالیبراسیون دوربین که پیش‌تر برای Virtual KITTI 2 تولید شده بودند، همگی مقدار صفر داشتند و تنها جای مقدار واقعی را پر می‌کردند. بنابراین در اجراهای پیشینی که از این فایل‌ها استفاده می‌کردند، نمونه‌های Virtual KITTI 2 اطلاعات دوربین معتبری نداشتند. در زنجیره چندمجموعه‌ای، ماتریس کالیبراسیون دوربین هر مجموعه‌داده مستقیما از فراداده خود آن خوانده می‌شود؛ برای Virtual KITTI 2 این مقادیر $f_x = f_y = ۷۲۵٫۰۰۸۷$، $c_x = ۶۲۰٫۵$ و $c_y = ۱۸۷$ پیکسل هستند و برای KITTI ماتریس تصویر اصلاح‌شده دوربین چپ از فایل کالیبراسیون هر روز ضبط خوانده می‌شود.

۳.۴ نتایج کمی: مقایسه عددی مدل‌ها

در این بخش، نتایج کمی حاصل از ارزیابی مدل‌ها ارایه و تحلیل می‌شود. هدف اصلی، بررسی پایداری مدل پایه Depth Anything V2 در دیتاست‌های مختلف و مقایسه آن با مدل پیشنهادی از منظر معیارهای مطلق و نسبی است. تمامی نتایج گزارش‌شده در این بخش بر اساس اجرای یکسان پروتکل ارزیابی و با استفاده از آزمون‌های آماری ارایه‌شده در بخش ۵.۹.۳ به‌دست آمده‌اند.

۱.۳.۴ عملکرد مدل پایه Depth Anything V2 در دیتاست‌های مختلف

در گام نخست، عملکرد مدل پایه Depth Anything V2 در دیتاست‌های مختلف مورد بررسی قرار می‌گیرد تا میزان پایداری آن نسبت به نوع دیتاست و پارامترهای دوربین ارزیابی شود. برای این منظور، معیار SiLog به‌عنوان معیار مطلق اصلی استفاده شده است.

نتایج مقایسه بین‌دیتاستی مدل پایه Depth Anything V2 در جدول ۲.۴ ارایه شده است.

همان‌طور که مشاهده می‌شود، مدل پایه Depth Anything V2 در تمامی مقایسه‌های انجام‌شده تفاوت

جدول ۲.۴: مقایسه معیار SiLog مدل پایه Depth Anything V2، نسخه منتشرشده در دیتاست‌های مختلف

مقایسه دیتاست‌ها	اختلاف میانگین	p-value	نتیجه
VKITTI vs DrivingStereo	۰٫۰۳۹	$< ۰٫۰۵$	معنادار
NYUv2 vs DrivingStereo	۰٫۱۰۱	$< ۰٫۰۵$	معنادار
NYUv2 vs DIODE	۰٫۴۵۰	$< ۰٫۰۵$	معنادار

عملکرد معنادار آماری بین دیتاست‌ها نشان می‌دهد ($p < ۰٫۰۵$). این رفتار بیانگر آن است که خروجی عمق مدل پایه Depth Anything V2 به نوع دیتاست و در نتیجه به پارامترهای دوربین و شرایط تصویربرداری وابسته است. در نتیجه، می‌توان نتیجه گرفت که مدل پایه Depth Anything V2 قادر به تولید عمق مطلق پایدار در شرایط مختلف نیست.

این ناپایداری، حتی در مواردی که مدل از نظر ساختار نسبی عمق عملکرد مناسبی دارد، در معیارهای مطلق به‌صورت اختلاف‌های قابل توجه در مقدار خطا ظاهر می‌شود.

۲.۳.۴ مقایسه مدل پایه Depth Anything V2 و مدل پیشنهادی

در ادامه، عملکرد مدل پایه Depth Anything V2 با مدل پیشنهادی که در آن ماتریس کالیبراسیون دوربین به‌صورت صریح در فرآیند تخمین عمق ادغام شده است، مقایسه می‌شود. تمرکز اصلی این مقایسه بر معیارهای مطلق و به‌ویژه SiLog است.

جدول ۳.۴ نتایج مقایسه مستقیم دو مدل در دیتاست‌های مختلف را نشان می‌دهد.

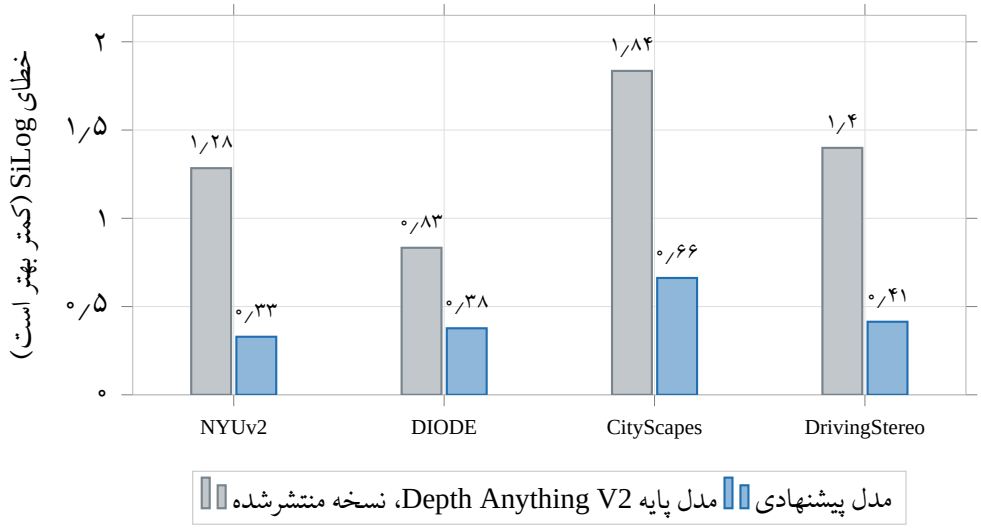
جدول ۳.۴: مقایسه تاریخی و موقت عملکرد مدل پایه Depth Anything V2، نسخه منتشرشده و مدل پیشنهادی بر اساس معیار SiLog

دیتاست	پایه منتشرشده	پیشنهادی	بهبود (%)	p-value
NYUv2	۱٫۲۸۴	۰٫۳۲۹	۷۴٫۳۸	$\ll ۰٫۰۵$
DIODE	۰٫۸۳۳	۰٫۳۷۷	۵۴٫۷۸	$\ll ۰٫۰۵$
CityScapes	۱٫۸۳۵	۰٫۶۶۲	۶۳٫۹۰	$\ll ۰٫۰۵$
DrivingStereo	۱٫۳۹۹	۰٫۴۱۴	۷۰٫۴۲	$\ll ۰٫۰۵$

این جدول از گزارش تاریخی پیش از ممیزی کامل تقسیم داده و منشا نقطهٔ وارسی نگه داشته شده است. ممیزی تازه نشان داد که میانگین‌های مدل پایه بازتولید می‌شوند، اما هر چهار میانگین مدل پیشنهادی و درصدهای بهبود چاپ‌شده بازتولید نمی‌شوند؛ برای نمونه، بازحسابی تاریخی NYUv2 مقدار ۰٫۳۳۴۶ → ۱٫۲۸۳۹ را به‌دست می‌دهد، نه ۰٫۳۲۹ → ۱٫۲۸۴. بنابراین این جدول فقط یک مقایسه تاریخی/اکتشافی است و نباید

برای ادعای اصلی پایان‌نامه یا خلاصه نتایج استفاده شود؛ پس از حل منشا نقطهٔ وارسی و واحدهای ارزیابی باید دوباره محاسبه و جایگزین شود.

نمای تصویری همین مقایسه تاریخی در شکل ۱.۴ آمده است.



شکل ۱.۴: مقایسه معیار SiLog مدل پایه و مدل پیشنهادی در چهار مجموعه‌داده

در گزارش تاریخی این مقایسه، برای مدل پیشنهادی در هر چهار دیتاست کاهش چاپ‌شده‌ای بین حدود ۵۵ تا ۷۴ درصد ثبت شده بود؛ بااین‌حال، چون مقادیر پیشنهادی در ممیزی تازه بازتولید نشدند، این درصدها و نتیجه معناداری آماری تاییدشده محسوب نمی‌شوند. بنابراین اثر ادغام هندسه دوربین بر پایداری بین‌دیتاستی باید فقط بر اساس پروتکل‌های کنترل‌شده و بازتولیدشده بخش ۴.۴ گزارش شود.

۳.۳.۴ تحلیل پایداری بین‌دیتاستی مدل پیشنهادی

در این بخش، پایداری مدل پیشنهادی نسبت به تغییر دیتاست و دوربین بررسی می‌شود. برای این منظور، عملکرد مدل پیشنهادی بین جفت دیتاست‌های مختلف با استفاده از آزمون t و بازه‌های اطمینان بوت‌استرپ مقایسه شده است.

این تحلیل تاریخی تا زمانی که نقاط وارسی، واحدها و پروتکل ارزیابی برای هر چهار دیتاست یکسان‌سازی و بازتولید نشوند، قابل داوری قطعی نیست. پس از تکمیل آن بازتولید، تفاوت عملکرد مدل پیشنهادی میان دیتاست‌ها باید با آزمون‌های از پیش تعیین‌شده و بازه‌های اطمینان بوت‌استرپ گزارش شود؛ در وضعیت فعلی،

ادعای کاهش وابستگی به پارامترهای دوربین و بهبود قطعی پایداری مقیاس از این جدول نتیجه‌گیری نمی‌شود.

ارزیابی بین‌دیتاستی بازتولیدپذیر مدل پیشنهادی، با زنجیره ارزیابی واحد، تصاویر یکسان برای همه مدل‌ها و آزمون‌های زوجی، پس از آموزش چندمجموعه‌ای در بخش ۶.۴ گزارش شده است.

۴.۴ مطالعه کنترل‌شده بر روی پروتکل استاندارد NYUv2

در مرحله دوم مطالعات تجربی این پژوهش، به‌منظور ارایه مقایسه‌ای کاملا منصفانه و قابل انطباق با ادبیات موضوع، مجموعه‌ای از آزمایش‌های کنترل‌شده بر روی پروتکل استاندارد ارزیابی NYUv2 طراحی و اجرا شد. در این پروتکل که در اغلب پژوهش‌های مرجع از جمله Depth Anything V2 به‌کار می‌رود [۲، ۴]، ارزیابی بر روی زیرمجموعه آزمون استاندارد با نقشه‌های عمق خام حسگر به‌عنوان مرجع، برش استاندارد، و محدوده عمق ۰٫۰۰۱ تا ۱۰ متر انجام می‌شود. برای مدل‌های نسبی، پیش از محاسبه معیارها، تراز مقیاس و جابجایی به‌ازای هر تصویر در فضای عمق معکوس اعمال می‌گردد و سپس پیش‌بینی ترازشده به بازه معتبر ارزیابی محدود می‌شود؛ برای مدل‌های مطلق، خروجی مدل بدون هیچ‌گونه ترازی مستقیما با مرجع مقایسه می‌شود. در بازتولید KITTI نیز مطابق جدول ۲ مقاله مرجع از ۶۵۲ تصویر تقسیم استاندارد و حالت بدون برش استفاده شد.

برای هر اندازه انکودر، چهار مدل در شرایط یکسان مقایسه می‌شوند:

۱. مقادیر گزارش‌شده در مقاله مرجع Depth Anything V2 (جدول ۲ مقاله)؛

۲. مدل پایه Depth Anything V2، نسخه منتشرشده، ارزیابی‌شده با زنجیره ارزیابی این پژوهش؛

۳. مدل کنترل: معماری پایه، که روی همان داده آموزشی تنظیم دقیق‌پارامترها شده است، با ابرپارامترها و برنامه آموزشی کاملا یکسان با مدل پیشنهادی؛

۴. مدل پیشنهادی: همان تنظیمات، با مسیر ورودی دوربین توضیح‌داده‌شده در فصل سوم.

مقایسه (۴) با (۲) میزان بهبود نسبت به مدل پایه Depth Anything V2، نسخه منتشرشده را می‌سنجد و مقایسه (۴) با (۳) سهم خالص پارامترهای درونی دوربین را جدا می‌کند.

۱.۴.۴ ممیزی نقاط وارسی و مسیر رسیدن به آزمایش نهایی

هدف این بخش گزارش رتبه یا عملکرد نهایی مدل‌ها نیست. هدف آن است که نشان دهد چرا پروتکل نهایی پژوهش به همین شکل طراحی شد. مسیر رسیدن به این طراحی هفت گام داشت. در هر گام ابتدا چیزی مشکوک یا غیرمنتظره مشاهده شد، سپس دلیل آن بررسی شد و در پایان، بر اساس همین برداشت، آزمایش بعدی تعیین شد.

جدول ۴.۴ این هفت گام را نشان می‌دهد. هر ردیف را به ترتیب ستون‌ها بخوانید: آنچه دیده شد، معنای آن، و کاری که پس از آن انجام شد.

جدول ۴.۴: مسیر تصمیم‌گیری آزمایش‌ها

گام	چه چیزی مشاهده شد؟	این مشاهده چه معنایی داشت؟	اقدام بعدی چه بود؟
۱. ممیزی اولیه	چند نقطه وارسی خروجی صفر یا نامعتبر تولید می‌کردند، اما منحنی اعتبارسنجی بعضی از آن‌ها ظاهرا عادی بود.	منحنی اعتبارسنجی به‌تنهایی نشان نمی‌دهد که مدل سالم است.	نتایج مقاله مرجع بازتولید شد و خروجی همه مدل‌ها جدا از فرایند آموزش بررسی شد.
۲. ارزیابی صفرنمونه	پس از تنظیم دقیق‌پارامترها روی چند مجموعه‌داده محدود، خطای KITTI تقریبا از ۰٫۰۸۳ به ۰٫۲۱۴ رسید. این افزایش در پیشنهادی و کنترل تقریبا یکسان بود.	تنظیم دقیق‌پارامترها روی داده محدود، توان تعمیم مدل بنیادین را کم کرده بود. چون افت در هر دو مدل دیده شد، افزودن ماتریس کالیبراسیون دوربین علت آن نبود.	ارزیابی صفرنمونه کنار گذاشته شد و مطالعه به پروتکل استاندارد درون‌دامنه‌ای منتقل شد.
۳. آزمایش نسبی ViT-S	در پروتکل درون‌دامنه‌ای، پیشنهادی از پایه منتشرشده و کنترل بهتر بود (نسخه نسبی، ViT-S).	این نخستین شاهد معتبر بهبود بود، اما هنوز معلوم نبود که در مدل بزرگ‌تر نیز تکرار می‌شود.	همین آزمایش برای ViT-L تکرار شد.

ادامه در صفحه بعد

ادامه جدول ۴.۴

گام	چه چیزی مشاهده شد؟	این مشاهده چه معنایی داشت؟	اقدام بعدی چه بود؟
۴. افزونه‌سازی هندسی (برش و بزرگ‌نمایی)	در برش معمولی، میدان دید تصویر عوض می‌شد ولی ماتریس کالیبراسیون ثابت می‌ماند و با تصویر ناسازگار می‌شد. پس از اصلاح ماتریس متناسب با برش، هر دو مدل بهتر شدند، اما پیشنهادی در ارزیابی نسبی برتری روشنی نداشت.	تنوع هندسی به هر دو مدل کمک کرد. اما ترازکردن نسبی هر تصویر می‌تواند اطلاعات مقیاسی را که ماتریس کالیبراسیون دوربین می‌دهد حذف کند.	ارزیابی به حالت مطلق و بدون تراز منتقل شد.
۵. ارزیابی مطلق	پس از حذف تراز نسبی، هرچه تنوع میدان دید در آموزش بیشتر بود، مدل منظم‌تر از اطلاعات دوربین استفاده می‌کرد.	اثر ماتریس کالیبراسیون دوربین بیشتر به بازیابی مقیاس مطلق مربوط بود و پروتکل نسبی آن را پنهان می‌کرد.	آزمایشی طراحی شد که در آن مقیاس بدون دانستن فاصله کانونی قابل بازیابی نباشد.
۶. افزونه‌سازی لرزش کانونی	در طراحی اولیه، شیب پیمایش فاصله کانونی (نسبت تغییر عمق پیش‌بینی‌شده به تغییر فاصله کانونی ورودی) فقط ۰٫۰۶ بود. پس از اعمال افزونه‌سازی لرزش کانونی بر داده آموزش، این شیب به بازه ۰٫۹۳ تا ۰٫۹۷ رسید. مقدار ایده‌آل شیب ۱ است.	شیب ۰٫۰۶ یعنی مدل تقریبا ماتریس کالیبراسیون دوربین را نادیده می‌گرفت. شیب نزدیک ۱ یعنی مقیاس خروجی تقریبا متناسب با کانون ورودی تغییر می‌کند.	افزونه‌سازی لرزش کانونی در طراحی نهایی حفظ شد و نیاز واقعی به ماتریس کالیبراسیون دوربین با آزمایش‌های علی بررسی شد.

ادامه در صفحه بعد

ادامه جدول ۴.۴

گام	چه چیزی مشاهده شد؟	این مشاهده چه معنایی داشت؟	اقدام بعدی چه بود؟
۷. تفکیک اثر و حذف ماتریس کالیبراسیون دوربین	در آزمایش قبل، هم افزونه‌سازی لرزش کانونی و هم وزن زیان λ تغییر کرده بودند؛ بنابراین نمی‌شد گفت کدام یک عامل اصلی بهبود است.	هم‌بستگی میان ماتریس کالیبراسیون دوربین و بهبود عملکرد برای ادعای رابطه علی کافی نبود.	با ثابت نگه‌داشتن سایر عوامل نشان داده شد که افزونه‌سازی لرزش کانونی عامل بهبود است. همچنین جایگزینی یا حذف ماتریس کالیبراسیون دوربین صحیح، مقیاس پیش‌بینی را مختل می‌کند.

جدول را می‌توان در سه فاز خلاصه کرد.

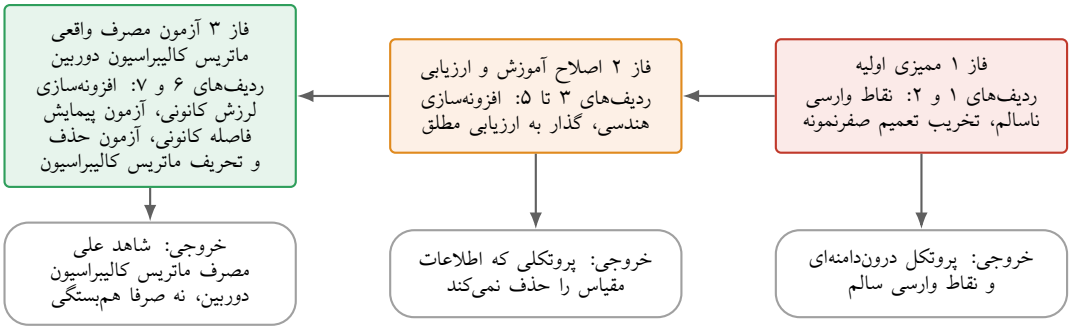
فاز نخست، ممیزی اولیه (ردیف‌های ۱ و ۲): در این فاز مشخص شد که بعضی نقاط وارسی ناسالم هستند و تنظیم دقیق‌پارامترها توان تعمیم صفرنمونه را کاهش داده است. حاصل این فاز یک پروتکل درون‌دامنه‌ای بود که در آن مقایسه مدل پیشنهادی و مدل کنترل معنادار است.

فاز دوم، اصلاح آموزش و ارزیابی (ردیف‌های ۳ تا ۵): ابتدا تایید شد که بهبود پایدار ممکن است. سپس روشن شد که ترازکردن جداگانه هر تصویر در ارزیابی نسبی، اطلاعات مقیاس را حذف می‌کند. به همین دلیل، اثر پارامترهای دوربین باید در حالت مطلق و بدون تراز سنجیده شود.

فاز سوم، آزمون استفاده واقعی از دوربین (ردیف‌های ۶ و ۷): با اعمال افزونه‌سازی لرزش کانونی، مقیاس صحنه دیگر از ظاهر تصویر به‌تنهایی قابل حدس نبود و مدل ناچار شد برای بازیابی مقیاس از ماتریس کالیبراسیون دوربین استفاده کند. شیب پیمایش از ۰٫۰۶ به بازه ۰٫۹۳ تا ۰٫۹۷ رسید؛ یعنی پاسخ مدل از حالت تقریبا بی‌تفاوت به حالتی نزدیک به پاسخ هندسی ایده‌آل تغییر کرد. آزمایش‌های تفکیک اثر و حذف نیز نشان دادند که این اثر صرفا هم‌بستگی نیست: وقتی ماتریس کالیبراسیون دوربین صحیح حذف یا با مقدار نادرست جایگزین شد، مقیاس خروجی به‌شکلی قابل پیش‌بینی مختل شد.

شکل ۲.۴ این سه فاز و شرط خروجی هر یک را نشان می‌دهد.

پیام اصلی جدول این نیست که هر ردیف یک مدل بهتر معرفی می‌کند. پیام آن است که اعتبار نتیجه نهایی به چهار شرط بستگی دارد:



شکل ۲.۴: سه فاز مسیر تجربی پژوهش: بازتولید، مطالعه کنترل‌شده و آزمون‌های علی آگاه از دوربین.

- داده و پروتکل ارزیابی به‌روشنی از هم جدا شده باشند؛
- نقطه وارسی سالم باشد؛
- ارزیابی به‌صورت مطلق و بدون تراز انجام شود؛
- آزمایش طوری طراحی شده باشد که مدل برای بازیابی مقیاس واقعا به ماتریس کالیبراسیون دوربین نیاز داشته باشد.

۲.۴.۴ راستی‌آزمایی زنجیره ارزیابی: بازتولید نتایج مدل پایه Depth Anything V2

پیش از هرگونه مقایسه، صحت زنجیره ارزیابی از طریق بازتولید نتایج گزارش‌شده مقاله مرجع راستی‌آزمایی شد. نسخه نسبی مدل پایه Depth Anything V2، نسخه منتشرشده با زنجیره ارزیابی این پژوهش بر NYUv2 به AbsRel برابر ۰٫۰۵۱ و δ_1 برابر ۰٫۹۷۳ با انکودر ViT-S، و به ۰٫۰۴۳ و ۰٫۹۷۹ با انکودر ViT-L رسید؛ مقادیر متناظر در جدول ۲ مقاله مرجع ۰٫۰۵۳ و ۰٫۹۷۳ و ۰٫۰۴۵ و ۰٫۹۷۹ هستند. بر KITTI نیز با انکودر ViT-S مقادیر ۰٫۰۸۳ و ۰٫۹۳۴ و با انکودر ViT-L مقادیر ۰٫۰۷۶ و ۰٫۹۴۸ به‌دست آمد، در برابر ۰٫۰۷۸ و ۰٫۹۳۶ و ۰٫۰۷۴ و ۰٫۹۴۶ در مقاله. بنابراین نتایج زنجیره ارزیابی این پژوهش با دقت مطلوبی بر مقادیر مقاله منطبق است و اختلاف‌های جزیی در محدوده تلورانس متعارف بازتولید نتایج این مجموعه‌داده‌ها قرار دارند. مقادیر خام بازتولید پیش از گردکردن نیز برای ممیزی ثبت شدند: در KITTI، مدل ViT-S برابر 0.9341/0.0829 و مدل ViT-L برابر 0.9477/0.0758 (δ_1/AbsRel) به‌دست آورد.

۳.۴.۴ ناکارآمدی تنظیم دقیق‌پارامترها برای ارزیابی برون‌دامنه‌ای

نخستین یافته این مرحله، نتیجه‌ای منفی اما تعیین‌کننده در طراحی ادامه آزمایش‌ها بود: تنظیم دقیق‌پارامترها مدل پایه Depth Anything V2 بر روی ترکیب مجموعه‌داده‌های محدود (نظیر VKITTI2، Cityscapes، DIODE و NYUv2)، توانایی تعمیم صفرنمونه مدل را به‌شدت تخریب می‌کند. نتایج دقیق در جدول ۵.۴ آمده است.

جدول ۵.۴: ارزیابی صفرنمونه پس از تنظیم دقیق‌پارامترها

مجموعه‌داده	مدل	داده تنظیم دقیق‌پارامترها	↓AbsRel	$\delta_1 \uparrow$
KITTI	پیشنهادی	چندمجموعه‌ای	۰٫۲۱۳۹	۰٫۶۱۸۹
KITTI	پایه منتشرشده		۰٫۰۸۲۹	۰٫۹۳۴۱
KITTI	کنترل	چندمجموعه‌ای	۰٫۲۱۳۲	۰٫۶۱۷۹
KITTI	پایه منتشرشده		۰٫۰۸۲۹	۰٫۹۳۴۱
NYUv2	پیشنهادی	چندمجموعه‌ای، بدون NYUv2	۰٫۰۶۵۷	۰٫۹۵۷۸
NYUv2	پایه منتشرشده		۰٫۰۵۰۸	۰٫۹۷۳۳

افزایش KITTI AbsRel از حدود ۰٫۰۸۳ به ۰٫۲۱۴ هم در مدل پیشنهادی و هم در مدل کنترل رخ می‌دهد؛ اختلاف ۰٫۲۱۳۹ و ۰٫۲۱۳۲ در حد نوفه است. بنابراین، پارامترهای دوربین نه علت این افت‌اند و نه راه‌حل آن. این مشاهده نشان می‌دهد که مدل بنیادین آموزش‌دیده بر ده‌ها میلیون تصویر، با تنظیم دقیق‌پارامترها بر چند هزار تصویر کوچک یا مصنوعی از بازنمایی عمومی خود فاصله می‌گیرد. بر همین اساس، مطابق رویه مقاله مرجع، ادامه مطالعه به تنظیم دقیق‌پارامترها بر بخش آموزشی یک مجموعه‌داده و ارزیابی بر بخش آزمون همان مجموعه‌داده منتقل شد.

۴.۴.۴ نتایج پروتکل نسبی: مقایسه چهارگانه

جدول‌های ۶.۴ و ۷.۴ نتایج مقایسه چهارگانه را برای دو اندازه انکودر نشان می‌دهند. هر دو مدل که با تنظیم دقیق‌پارامترها روی تقسیم استاندارد و با دستورالعمل یکسان (۴۰ دوره، نرخ یادگیری ۵×۱۰^{-۶}، انکودر فریزشده، هدف عمق معکوس مطابق بخش ۵.۷.۳) آموزش دیده‌اند.

نتایج ViT-L جدول بعد نیز با همین دستورالعمل آموزش و ارزیابی به‌دست آمده‌اند.

جدول ۶.۴: مقایسه مدل‌ها در پروتکل نسبی ViT-S

مدل	داده تنظیم دقیق‌پارامترها	↓AbsRel	$\delta_1 \uparrow$	↓RMSE	↓SqRel	$\log_{10} \downarrow$
مقاله مرجع (جدول ۲)		۰٫۰۵۳	۰٫۹۷۳			
پایه منتشرشده		۰٫۰۵۰۸	۰٫۹۷۳۳	۰٫۲۴۱۴	۰٫۰۲۴۵	۰٫۰۲۲۲
کنترل	NYUv2	۰٫۰۵۰۷	۰٫۹۷۴۱	۰٫۲۰۸۸	۰٫۰۱۸۶	۰٫۰۲۱۸
پیشنهادی	NYUv2	۰٫۰۵۰۱	۰٫۹۷۴۵	۰٫۲۰۶۴	۰٫۰۱۸۲	۰٫۰۲۱۶

جدول ۷.۴: مقایسه مدل‌ها در پروتکل نسبی ViT-L

مدل	داده تنظیم دقیق‌پارامترها	↓AbsRel	$\delta_1 \uparrow$	↓RMSE	↓SqRel
مقاله مرجع (جدول ۲)		۰٫۰۴۵	۰٫۹۷۹		
پایه منتشرشده		۰٫۰۴۲۵	۰٫۹۷۸۹	۰٫۲۱۱۹	۰٫۰۱۹۵
کنترل	NYUv2	۰٫۰۳۷۸	۰٫۹۸۶۲	۰٫۱۹۲۲	۰٫۰۱۴۲
پیشنهادی	NYUv2	۰٫۰۳۷۷	۰٫۹۸۶۱	۰٫۱۹۱۳	۰٫۰۱۴۳

۵.۴.۴ اثر افزونه‌سازی هندسی و یک نتیجه منفی آموزنده

فرضیه محتمل برای عدم مشاهده سهم پارامترهای دوربین در ViT-L، ثابت‌بودن بردار $\mathbf{d}_{\text{cam}}$ در مجموعه‌داده تک‌دوربینه NYUv2 بود. برای آزمون این فرضیه، زوج مدل ViT-L با افزونه‌سازی هندسی آگاه از دوربین (بخش ۶.۷.۳، بازه میدان دید ۴۰ تا ۶۳ درجه) بازآموزی شد. نتایج (جدول ۸.۴) دو یافته به همراه داشت: نخست، خود افزونه‌سازی هندسی برای هر دو مدل سودمندی چشمگیری دارد (کاهش AbsRel مدل کنترل از ۰٫۰۳۷۸ به ۰٫۰۳۵۹ و مدل پیشنهادی از ۰٫۰۳۷۷ به ۰٫۰۳۶۲) و بهترین نتایج این پژوهش در پروتکل نسبی را رقم می‌زند. دوم، حتی با وجود سیگنال هندسی متنوع و صحیح، مدل پیشنهادی در پروتکل نسبی بر مدل کنترل برتری نیافت (و در AbsRel با اختلاف بسیار جزیی ۰٫۰۰۰۳ ولی معنادار، $p = ۸٫۱ \times ۱۰^{-۳}$، پشت سر آن قرار گرفت؛ اختلاف RMSE برابر ۰٫۰۰۳۱ با $p \approx ۲٫۰ \times ۱۰^{-۵}$ بود).

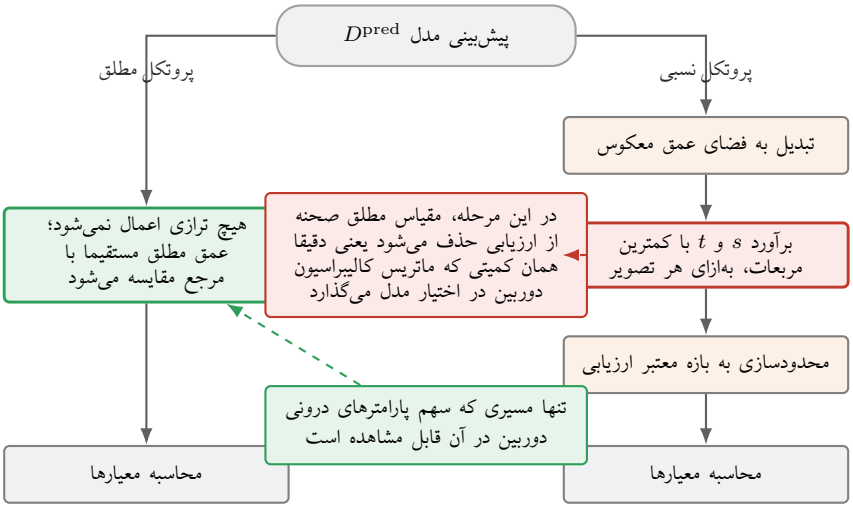
جدول ۸.۴: اثر افزونه‌سازی هندسی در پروتکل نسبی

مدل	↓AbsRel	$\delta_1 \uparrow$	↓RMSE
کنترل	۰٫۰۳۵۹	۰٫۹۸۷۲	۰٫۱۸۴۹
پیشنهادی	۰٫۰۳۶۲	۰٫۹۸۶۹	۰٫۱۸۸۱

این نتیجه منفی، تبیینی اصولی دارد که یکی از یافته‌های مفهومی این پژوهش محسوب می‌شود: در پروتکل ارزیابی نسبی، پیش از محاسبه هر معیار، یک تراز مقیاس و جابجایی به‌ازای هر تصویر میان پیش‌بینی و مرجع اعمال می‌شود. اطلاعات اصلی که میدان دید و فاصله کانونی در اختیار مدل قرار می‌دهند، دقیقا همان مقیاس مطلق صحنه است؛ کمیتی که سازوکار تراز، آن را از ارزیابی حذف می‌کند. به بیان دیگر، پروتکل نسبی به‌صورت

ساختاری نسبت به سهم اصلی پارامترهای درونی دوربین «کور» است. این تحلیل پیش‌بینی می‌کند که سهم پارامترهای دوربین باید در ارزیابی مطلق (بدون تراز) آشکار شود؛ پیش‌بینی‌ای که در زیربخش بعد به‌صورت تجربی آزموده می‌شود.

شکل ۳.۴ این استدلال را به‌صورت تصویری نشان می‌دهد: دو پروتکل ارزیابی، تنها در یک مرحله تفاوت دارند و دقیقا همان مرحله است که اطلاعات مورد بحث را از ارزیابی حذف می‌کند.



شکل ۳.۴: مقایسه دو پروتکل ارزیابی و مرحله‌ای که با تراز مقیاس حذف می‌شود؛ تنها پروتکل مطلق امکان مشاهده سهم پارامترهای درونی دوربین را فراهم می‌کند.

۶.۴.۴ ارزیابی مطلق: آشکارشدن سهم پارامترهای درونی دوربین

در این مرحله، زوج مدل ViT-L در حالت مطلق (تابع هزینه SiLog بر عمق مطلق، مطابق فصل سوم) با افزونه‌سازی هندسی زوم‌ـبرش (بخش ۶.۷.۳) در بازه میدان دید ۳۱ تا ۶۳ درجه (ضریب بزرگ‌نمایی ۱ تا ۲٫۲) آموزش دیده و بر روی مجموعه آزمون استاندارد، بدون هیچ‌گونه تراز مقیاس، ارزیابی شد. این زوج آموزشی در ادامه «پیکربندی زوم‌ـبرش» نامیده می‌شود.[۱] مرجع مقایسه در این حالت، مدل پایه Depth Anything V2، نسخه منتشرشده، نسخه مطلق (که با تنظیم دقیق‌پارامترها بر Hypersim برای صحنه‌های داخلی آموزش دیده است) است. در کوشش اولیه، همین زوج با بازه باریک‌تر میدان دید (۴۰ تا ۶۳ درجه) و بدون هیچ تفاوت دیگری

[۱] در این فصل، منظور از «پیکربندی آموزشی» (Training Configuration) مجموعه تنظیمات یک دستور آموزشی است، شامل نوع و شدت افزونه‌سازی، ضریب λ در تابع هزینه SiLog و قفل‌بودن یا نبودن بذر تصادفی. هر پیکربندی به یک زوج مدل اشاره دارد: مدل پیشنهادی و مدل کنترل که هر دو با همان تنظیمات آموزش دیده‌اند.

آموزش داده شده بود؛ گسترش بازه میدان دید، فاصله مدل پیشنهادی از مدل کنترل را در همه معیارها افزایش داد و به همین دلیل، نتایج با بازه وسیع‌تر به‌عنوان پیکربندی زوم‌ـبرش گزارش می‌شوند.

جدول ۹.۴: نتایج ارزیابی مطلق در پیکربندی زوم‌ـبرش

مدل	داده آموزش	↓AbsRel	$\delta_1 \uparrow$	↓RMSE
پایه منتشرشده (NYUv2 ارزیابی شده)	Hypersim	۰٫۲۰۷۳	۰٫۶۹۱۹	۰٫۶۰۶۳
کنترل	NYUv2	۰٫۰۸۲۶	۰٫۹۵۴۶	۰٫۲۹۹۸
پیشنهادی	NYUv2	۰٫۰۸۱۷	۰٫۹۵۶۹	۰٫۲۹۴۴

نتایج جدول ۹.۴ سه یافته کلیدی دارند:

نخست، هر دو مدلی که با تنظیم دقیق‌پارامترها آموزش دیده‌اند، مدل پایه Depth Anything V2، نسخه منتشرشده، نسخه مطلق را با فاصله بسیار زیاد پشت سر می‌گذارند (کاهش AbsRel از ۰٫۲۰۷ به حدود ۰٫۰۸، معادل بهبود ۲٫۵ برابری)؛ این نتیجه هم‌راستا با گزارش خود مقاله مرجع است که مقیاس مطلق مدل Hypersim به صحنه‌های واقعی به‌خوبی منتقل نمی‌شود. دوم، برخلاف پروتکل نسبی، در ارزیابی مطلق مدل پیشنهادی در تمامی معیارها از مدل کنترل هم‌داده پیشی می‌گیرد و بیشترین فاصله در معیار RMSE دیده می‌شود (۰٫۲۹۴۴ در برابر ۰٫۲۹۹۸). سوم، اختلاف دو مدل در AbsRel بسیار کوچک است (۰٫۰۰۰۹)؛ یعنی در پیکربندی زوم‌ـبرش سهم پارامترهای درونی دوربین واقعی اما مرزی است. زیربخش بعد نشان می‌دهد که با رساندن ابهام هندسی به حد نهایی خود، این سهم از یک برتری مرزی به یک اثر قاطع و همه‌جانبه تبدیل می‌شود.

۷.۴.۴ پیکربندی لرزش کانونی: جهش سهم پارامترهای دوربین

در پیاده‌سازی این روش، رعایت دو نکته اهمیت ویژه‌ای دارد. نخست، ماسک اعتبار پیکسل‌ها بر اساس محدوده اندازه‌گیری حسگر و مقادیر عمق پیش از مقیاس‌دهی تعریف می‌شود. بنابراین، هنگام اعمال ضریب مقیاس α به مقادیر عمق، لازم است آستانه بالای عمق معتبر نیز با همین ضریب تغییر کند. در غیر این صورت، برخی پیکسل‌های دارای عمق معتبر، به‌ویژه نقاط دورتر، به‌اشتباه از فرایند آموزش حذف می‌شوند و اطلاعات مربوط به تغییرات مقیاس در این نواحی از دست می‌رود. دوم، به‌منظور تضمین مقایسه‌ای منصفانه میان مدل پیشنهادی و مدل کنترل، سازوکاری برای ثابت نگه داشتن بذر تصادفی[1] به زیرساخت آموزش افزوده شد. این سازوکار تضمین می‌کند که ترتیب ارائه داده‌ها، عملیات وارونه‌سازی افقی، نواحی انتخاب‌شده برای بزرگ‌نمایی و

[1] Seed Locking

برش تصویر و مقادیر نمونه‌برداری‌شده α در هر دو اجرای آزمایشی یکسان باشند. صحت عملکرد این سازوکار نیز با بررسی برابری دقیق و بیت‌به‌بیت مقادیر تابع هزینه در گام ابتدایی آموزش دو مدل تأیید شد. افزون بر این، در آزمایش مربوطه، ضریب λ در تابع هزینه SiLog (بخش ۱.۹.۳) از ۰٫۵ به ۰٫۳ کاهش یافت تا حساسیت تابع هزینه نسبت به خطاهای مقیاس سراسری افزایش یابد و این خطاها با شدت بیشتری در فرایند بهینه‌سازی لحاظ شوند.

نقطه اوج الگوی پاسخ به دوز، به‌کارگیری افزونه‌سازی لرزش کانونی (بخش ۷.۷.۳) است که مقیاس مطلق صحنه را بدون دسترسی به ماتریس کالیبراسیون دوربین اساسا غیرقابل بازیابی می‌کند. زوج مدل ViT-L مطلق با دستور آموزشی یکسان با پیکربندی زوم‌ـبرش، به‌علاوه افزونه‌سازی لرزش کانونی ($m = ۱٫۶$)، ضریب $\lambda = ۰٫۳$ در هزینه SiLog، و قفل بذر تصادفی بازآموزی شد. این زوج آموزشی در ادامه «پیکربندی لرزش کانونی» نامیده می‌شود؛ قفل بذر تضمین می‌کند که هر دو بازو دقیقا همان دنباله‌ی داده، وارونه‌سازی و ضرایب α را دیده باشند (تابع هزینه گام صفر هر دو اجرا تا آخرین رقم اعشار برابر بود: ۱٫۷۲۵).

جدول ۱۰.۴: نتایج مطلق در پیکربندی لرزش کانونی

معیار	پیشنهادی	کنترل	تفاضل [بازه اطمینان ۹۵٪]
↓AbsRel	۰٫۰۸۴۹	۰٫۱۰۳۰	−۰٫۰۱۸۲ [−۰٫۰۲۱۰, −۰٫۰۱۵۳]
↓RMSE	۰٫۳۰۷۱	۰٫۳۴۳۱	−۰٫۰۳۶۱ [−۰٫۰۴۳۲, −۰٫۰۲۸۹]
$\delta_1 \uparrow$	۰٫۹۵۲۰	۰٫۹۲۲۶	+۰٫۰۲۹۴ [+۰٫۰۲۲۴, +۰٫۰۳۶۷]
↓SILog	۰٫۰۹۴۲	۰٫۱۰۴۵	−۰٫۰۱۰۲ [−۰٫۰۱۱۸, −۰٫۰۰۸۷]
$\log_{10} \downarrow$	۰٫۰۳۶۳	۰٫۰۴۲۷	−۰٫۰۰۶۵ [−۰٫۰۰۷۶, −۰٫۰۰۵۳]

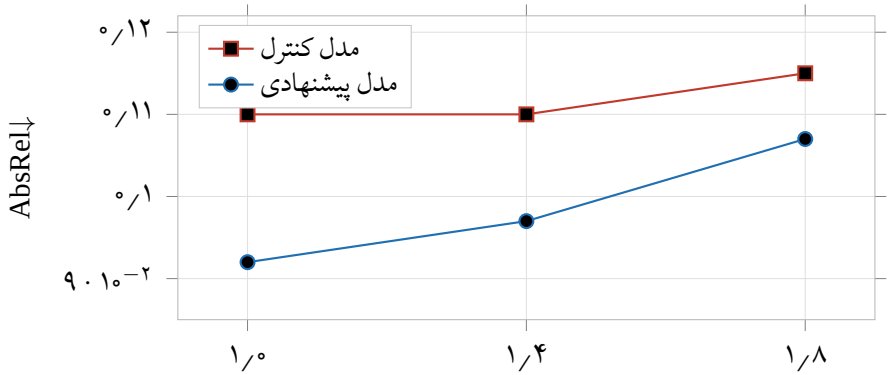
مقادیر خام این جدول پیش از گردکردن عبارت‌اند از: برای AbsRel، پیشنهادی 0.0849 و کنترل 0.1030 با تفاضل 0.0182-؛ برای RMSE، 0.3071 و 0.3431 با تفاضل 0.0361-؛ برای δ_1، 0.9520 و 0.9226 با تفاضل 0.0294+؛ برای SiLog، 0.0942 و 0.1045 با تفاضل 0.0102-؛ و برای $\log_{10}$، 0.0363 و 0.0427 با تفاضل 0.0065-. بازه‌های اطمینان خام در گزارش راستی‌آزمایی ثبت شده‌اند.

نتایج (جدول ۱۰.۴) جهشی کیفی نسبت به پیکربندی زوم‌ـبرش نشان می‌دهد: مدل پیشنهادی در تمامی معیارها از مدل کنترل هم‌داده و هم‌بذر پیشی می‌گیرد و بازه اطمینان ۹۵ درصدی تفاضل در هیچ معیاری صفر را در بر نمی‌گیرد؛ اختلاف AbsRel به ۰٫۰۱۸۲ می‌رسد، در حالی که این اختلاف در پیکربندی زوم‌ـبرش تنها ۰٫۰۰۰۹ بود. توزیع نسبت مقیاس هر تصویر (میانه پیش‌بینی تقسیم بر میانه مرجع) سازوکار این برتری را آشکار می‌کند: مدل پیشنهادی حول ۱٫۰۱۵ متمرکز است، در حالی که نوفه کاهش‌ناپذیر α مدل کنترل را اریب و پراکنده کرده است (میانه ۱٫۰۴۱؛ شکل ۱۰.۴). به بیان دیگر، مدل کنترل دقیقا همان رفتاری را نشان می‌دهد که تحلیل

بدساختی مساله در بخش ۷.۷.۳ پیش‌بینی می‌کرد. مقادیر خام این توزیع پیش از گردکردن نیز ثبت شده‌اند: میانه پیشنهادی 1.015 و کنترل 1.041، با انحراف معیارهای به‌ترتیب 0.078 و 0.094 روی کل مجموعه آزمون.

سنجش تعمیم به میدان دیدهای متفاوت نیز همین برتری را تایید می‌کند: در ارزیابی با برش‌های مرکزی قطعی (زوم ۱٫۰، ۱٫۴ و ۱٫۸ با به‌روزرسانی دقیق ماتریس کالیبراسیون دوربین، کل مجموعه آزمون)، مقادیر دقیق چهاررقمی AbsRel به‌صورت (پیشنهادی/کنترل/تفاضل) چنین‌اند: زوم ۱٫۰، ۰٫۰۹۲۴/۰٫۱۱۰۲/۰٫۰۱۷۸−؛ زوم ۱٫۴، ۰٫۰۹۷۴/۰٫۱۱۰۰/۰٫۰۱۲۷−؛ و زوم ۱٫۸، ۰٫۱۰۶۵/۰٫۱۱۴۸/۰٫۰۰۸۳−. بنابراین برتری در تمام سطوح زوم حفظ می‌شود. مقادیر خام پیش از گردکردن نیز به‌ترتیب چنین بودند: پیشنهادی 0.0924، 0.0974 و 0.1065؛ کنترل 0.1102، 0.1100 و 0.1148.

شکل ۴.۴ این ارزیابی را نشان می‌دهد.



شکل ۴.۴: تعمیم به میدان دیدهای متفاوت

دو ملاحظه صادقانه ضروری است. نخست، این برتری قاطع نسبت به کنترل، با بهای اندکی در کیفیت مطلق همراه است: AbsRel مدل پیشنهادی در پیکربندی لرزش کانونی (۰٫۰۸۴۹) اندکی بالاتر از پیکربندی زوم‌ـبرش (۰٫۰۸۱۷) است؛ همان مصالحه‌ای که با گسترش بازه میدان دید در افزونه‌سازی زوم‌ـبرش نیز مشاهده شد: وظیفه آموزشی دشوارتر، کیفیت مطلق را اندکی می‌کاهد اما شواهد سازوکاری را به‌شدت تقویت می‌کند. دوم، پیکربندی لرزش کانونی نسبت به پیکربندی زوم‌ـبرش دو متغیر را هم‌زمان تغییر می‌دهد (افزونه‌سازی لرزش کانونی و λ)؛ آزمایش تفکیک این دو عامل در زیربخش ۸.۴.۴ گزارش می‌شود.

۸.۴.۴ تفکیک اثر افزونه‌سازی لرزش کانونی از ضریب λ

برای انتساب دقیق اثر مشاهده‌شده در پیکربندی لرزش کانونی، زوج آموزشی دیگری با تنها یک متغیر تغییریافته نسبت به پیکربندی زوم‌ـبرش آموزش داده شد: افزونه‌سازی لرزش کانونی فعال ($m = ۱/۶$) اما $\lambda = ۰/۵$ بدون تغییر (به‌همراه همان قفل بذر تصادفی). این زوج آموزشی که با پیکربندی لرزش کانونی تنها در مقدار λ تفاوت دارد، در ادامه «پیکربندی تفکیک اثر» نامیده می‌شود.

جدول ۱۱.۴: نتایج مطلق در پیکربندی تفکیک اثر

معیار	پیشنهادی	کنترل	تفاضل [بازه اطمینان ۹۵٪]	p (ویلکاکسون)
↓AbsRel	۰/۰۸۳۴	۰/۱۰۶۵	$-۰/۰۲۳۱$ $[-۰/۰۲۶۰, -۰/۰۲۰۲]$	$۳/۴ \times ۱۰^{-۴۵}$
↓RMSE	۰/۲۹۸۷	۰/۳۴۹۷	$-۰/۰۵۱۰$ $[-۰/۰۵۸۳, -۰/۰۴۳۷]$	$۷/۵ \times ۱۰^{-۴۰}$
$\delta_۱ \uparrow$	۰/۹۵۵۴	۰/۹۱۷۳	$+۰/۰۳۸۱$ $[+۰/۰۳۱۰, +۰/۰۴۵۳]$	$۱/۲ \times ۱۰^{-۳۹}$
↓SILog	۰/۰۹۱۸	۰/۱۰۵۶	$-۰/۰۱۳۹$ $[-۰/۰۱۵۵, -۰/۰۱۲۳]$	$۲/۲ \times ۱۰^{-۵۰}$

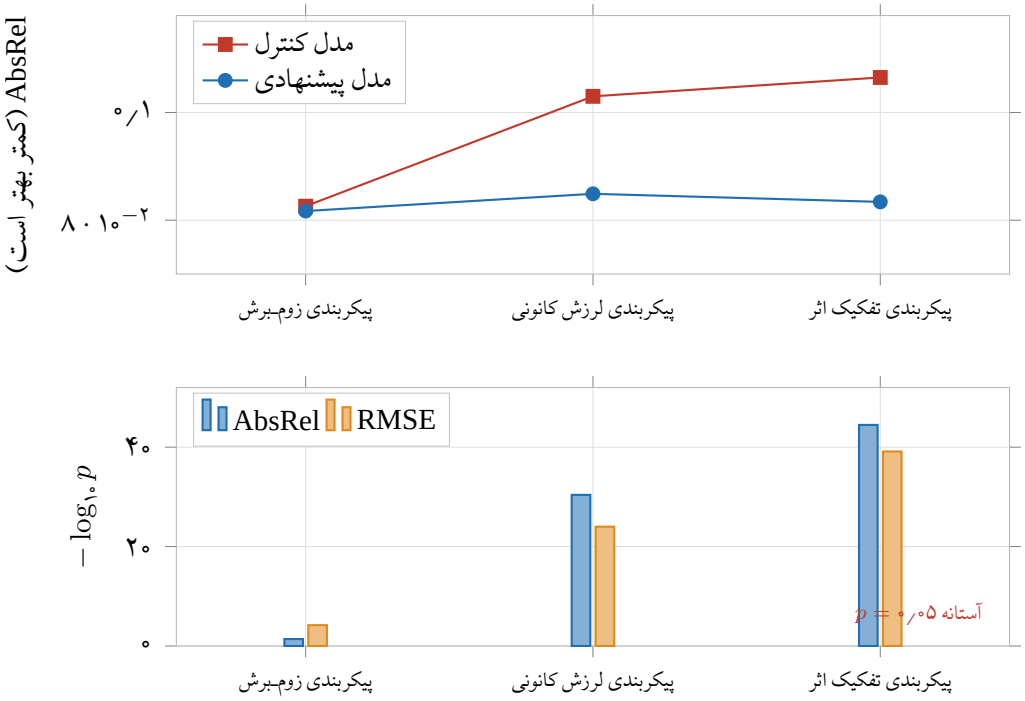
نتیجه این آزمایش (جدول ۱۱.۴) از دو جهت تعیین‌کننده است. نخست، کل اثر پیکربندی لرزش کانونی با افزونه‌سازی لرزش کانونی به‌تنهایی بازتولید می‌شود: برتری مدل پیشنهادی در تمامی معیارها به مرتبه $p \leq ۱۰^{-۳۹}$ می‌رسد و شیب پیمایش فاصله کانونی به $۰/۹۷ \pm ۰/۰۳$ می‌رسد که نسبت به پیکربندی لرزش کانونی به مقدار ایده‌آل ۱ نزدیک‌تر است. بنابراین عامل علی، خود افزونه‌سازی لرزش کانونی است و کاهش λ نه‌تنها ضروری نیست، بلکه اندکی هم زیان‌بار بوده است (AbsRel مدل پیشنهادی با $\lambda = ۰/۵$: ۰/۰۸۳۴ در برابر ۰/۰۸۴۹ با $\lambda = ۰/۳$). دوم، پیکربندی تفکیک اثر زوج آموزشی مستقل دیگری است که برتری مدل پیشنهادی را تکرار می‌کند و در کنار پیکربندی زوم‌ـبرش و پیکربندی لرزش کانونی، الگوی پاسخ به دوز را به‌صورت یکنواخت کامل می‌سازد: هرچه بازیابی مقیاس بدون ماتریس کالیبراسیون دوربین دشوارتر، سهم پارامترهای دوربین بزرگ‌تر و معنادارتر.

۹.۴.۴ نمای یکپارچه پیکربندی‌های آموزشی و الگوی پاسخ به دوز

سه پیکربندی آموزشی گزارش‌شده در زیربخش‌های پیشین، یعنی پیکربندی زوم‌ـبرش، پیکربندی لرزش کانونی و پیکربندی تفکیک اثر، در مجموع یک الگوی منظم می‌سازند که ارزش آن بیش از هر یک از نتایج منفرد است. جدول ۱۲.۴ این سه پیکربندی را در یک نما کنار هم می‌گذارد و شکل ۵.۴ همان داده‌ها را به‌صورت تصویری نمایش می‌دهد.

جدول ۱۲.۴: جمع‌بندی پیکربندی‌های آموزشی مطلق

پیکربندی آموزشی	افزونه‌سازی هندسی	λ	↓AbsRel		تفاضل	p (ویلکاکسون)	شیب پیمایش فاصله کانونی
			پیشنهادی	کنترل			
پیکربندی زوم‌برش	زوم‌برش، ۳۱ تا ۶۳ درجه	۰٫۵	۰٫۰۸۱۷	۰٫۰۸۲۶	−۰٫۰۰۰۹	۰٫۰۴۰	۰٫۰۶ ± ۰٫۰۱
پیکربندی لرزش کانونی	+ افزونه‌سازی لرزش کانونی ($m = ۱٫۶$)	۰٫۳	۰٫۰۸۴۹	۰٫۱۰۳۰	−۰٫۰۱۸۲	$۴٫۰ \times ۱۰^{-۳۱}$	۰٫۹۳ ± ۰٫۰۳
پیکربندی تفکیک اثر	+ افزونه‌سازی لرزش کانونی ($m = ۱٫۶$)	۰٫۵	۰٫۰۸۳۴	۰٫۱۰۶۵	−۰٫۰۲۳۱	$۳٫۴ \times ۱۰^{-۴۵}$	۰٫۹۷ ± ۰٫۰۳



شکل ۵.۴: الگوی پاسخ به دوز

مهم‌ترین ویژگی این الگو، یکنواختی آن است: هر سه پیکربندی، در جهت یکسانی حرکت می‌کنند و هیچ استثنایی در میان آن‌ها دیده نمی‌شود. چنین الگویی با فرض «نوسان تصادفی آموزش» سازگار نیست، زیرا نوسان تصادفی دلیلی ندارد که دقیقا متناسب با میزان ابهام هندسی تحمیل‌شده به داده رشد کند.

برای ثبت اندازه‌های خام مورد استفاده در نمودار، تفاضل RMSE کنترل منهای پیشنهادی در پیکربندی زوم‌برش، پیکربندی لرزش کانونی و پیکربندی تفکیک اثر به‌ترتیب 0.0054، 0.0361 و 0.0510 است؛ کاهش نسبی متناظر 1.82%، 10.51% و 14.58% به‌دست می‌آید. مقدار p معیار RMSE در پیکربندی زوم‌برش از آزمون t زوجی و سایر مقادیر از آزمون ویلکاکسون آمده‌اند؛ پیکربندی تفکیک اثر تغییر λ را با حفظ افزونه‌سازی لرزش کانونی ایزوله می‌کند و سطح دیگری از تنوع میدان دید نیست.

۱۰.۴.۴ جمع‌بندی مطالعه کنترل‌شده و گزارش کوشش‌های تجربی

برای شفافیت علمی، گستره کوشش‌های تجربی این مرحله به‌اختصار گزارش می‌شود. در مجموع بیش از بیست اجرای آموزش مستقل (شامل زوج‌های پیشنهادی/کنترل در دو اندازه انکودر، دو نوع مدل نسبی و مطلق، و دو شدت افزونه‌سازی) و ممیزی کامل نقاط وارسی پیشین پروژه انجام شد. در جریان این ممیزی، ممیزی نقاط وارسی و سازگاری زنجیرهٔ ارزیابی انجام شد و پروتکل نهایی آموزش و ارزیابی تثبیت گردید. تنظیم دقیق‌پارامترهای چندمجموعه‌ای برای ارزیابی صفرنمونه نیز به‌دلیل تخریب تعمیم کنار گذاشته شد.

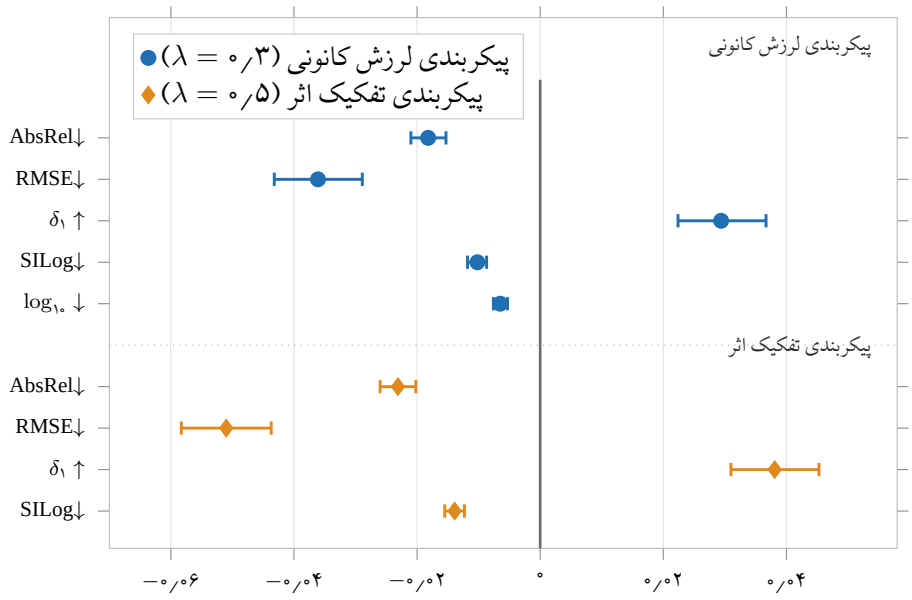
خلاصه یافته‌های این مطالعه کنترل‌شده چنین است: (۱) مدل پیشنهادی در هر دو اندازه انکودر و در هر دو پروتکل، از مدل پایه Depth Anything V2، نسخه منتشرشده به‌صورت معنادار بهتر است؛ (۲) سهم خالص پارامترهای درونی دوربین در پروتکل نسبی تنها در اندازه کوچک معنادار است، زیرا سازوکار تراز، اطلاعات مقیاس را حذف می‌کند؛ (۳) در ارزیابی مطلق سهم پارامترهای دوربین آشکار، معنادار و متناسب با میزان تنوع هندسی داده است؛ و (۴) هنگامی که افزونه‌سازی لرزش کانونی مقیاس را بدون ماتریس کالیبراسیون دوربین غیرقابل بازیابی می‌کند، این سهم به برتری قاطع در تمامی معیارها می‌رسد.

۱۱.۴.۴ نمای اندازه اثر: مقایسه همه معیارها در یک نگاه

جدول‌های ۱۰.۴ و ۱۱.۴ تفاضل زوجی و بازه اطمینان هر معیار را به‌صورت عددی گزارش کردند. شکل ۶.۴ همان مقادیر را در یک نمودار اندازه اثر گرد می‌آورد تا بتوان جهت، بزرگی و دقت برآورد هر معیار را هم‌زمان دید.

۵.۴ تحلیل حساسیت نسبت به پارامترهای دوربین

یکی از اهداف اصلی این پژوهش، کاهش حساسیت تخمین عمق نسبت به پارامترهای هندسی دوربین، به‌ویژه ماتریس کالیبراسیون دوربین، بوده است. در این بخش، رفتار مدل‌ها تحت تغییر این پارامترها به‌صورت کمی مورد تحلیل قرار می‌گیرد تا ارتباط عملی میان تحلیل‌های هندسی ارایه‌شده در فصل سوم و نتایج تجربی برقرار شود.



شکل ۴.۶: اندازه اثر زوجی معیارها با بازه اطمینان ۹۵ درصد؛ صفر به‌عنوان خط مبنای نبود تفاوت مشخص شده است.

۱.۵.۴ آزمون پیمایش فاصله کانونی: آیا مدل واقعا فاصله کانونی را می‌خواند؟

معیارهای تجمیعی مانند AbsRel نشان می‌دهند که ورودی ماتریس کالیبراسیون دوربین «سودمند» است، اما به این پرسش سازوکاری پاسخ نمی‌دهند که آیا مدل واقعا مقدار فاصله کانونی را می‌خواند و مطابق هندسه تصویربرداری از آن استفاده می‌کند یا خیر. برای پاسخ، آزمونی طراحی شد که در این پژوهش «آزمون پیمایش فاصله کانونی» نامیده می‌شود: تصویر ورودی ثابت نگه داشته می‌شود و تنها مولفه‌های f_x, f_y در ماتریس کالیبراسیون دوربین ورودی، در ضرایب $\{۰٫۶, ۰٫۸, ۱٫۰, ۱٫۲۵, ۱٫۶\}$ ضرب می‌شوند. طبق معادله روزنه‌ای $u = fX/Z$، تصویری یکسان با فاصله کانونی α برابر، تنها با صحنه‌ای α برابر دورتر سازگار است؛ بنابراین مدلی که ماتریس کالیبراسیون دوربین را به‌درستی مصرف می‌کند باید عمق پیش‌بینی‌شده خود را متناسب با f بازمقیاس کند. سنجه کمی این رفتار، شیب رگرسیون (عمق پیش‌بینی‌شده)$\log$ بر حسب $\log(f)$ است: مقدار ایده‌آل ۱ (پیروی کامل از هندسه) و مقدار ۰ به‌معنای نادیده‌گرفتن کامل ماتریس کالیبراسیون دوربین است.

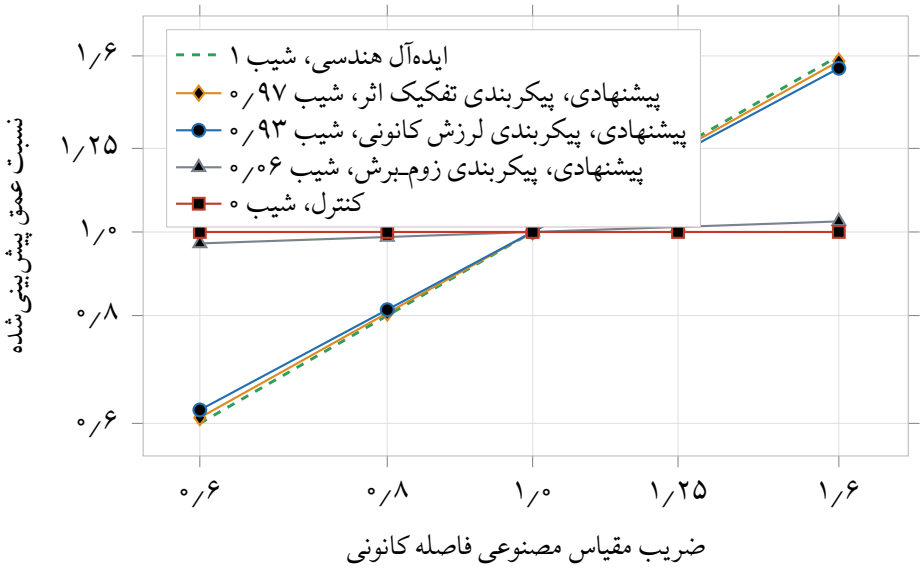
جدول ۱۳.۴: شیب پیمایش فاصله کانونی

پیکربندی آموزشی	پیشنهادی	کنترل
پیکربندی زوم‌برش	۰٫۰۶ ± ۰٫۰۱	۰٫۰۰
پیکربندی لرزش کانونی	۰٫۹۳ ± ۰٫۰۳	۰٫۰۰

برای پیکربندی لرزش کانونی، میانگین خام شیب پیمایش فاصله کانونی برابر 0.93 و انحراف معیار 0.03 روی ۲۰ تصویر است؛ مقدار کنترل پیش از گردکردن 0.00 با انحراف معیار 0.00 گزارش شده است.

نتیجه این آزمون (جدول ۱۳.۴ و شکل ۷.۴) صریح‌ترین یافته سازوکاری این پژوهش است. مدل پیشنهادی در پیکربندی زوم‌ـبرش شیب تنها ۰٫۰۶ دارد؛ یعنی عملا ماتریس کالیبراسیون دوربین را نمی‌خواند و برتری‌اش از نشانه‌های غیرمستقیم می‌آید. اما در پیکربندی لرزش کانونی، شیب به ۰٫۹۳ می‌جهد: خروجی مدل تقریبا دقیقا همان‌گونه با f مقیاس می‌شود که معادله $u = fX/Z$ ایجاب می‌کند. جالب آنکه پارامتر ضریب کنترلی اسکالر انکودر دوربین در همین مدل همچنان کوچک است (۰٫۰۲۴−)؛ یعنی اندازه ضریب کنترلی به‌تنهایی سنجه مناسبی برای میزان مصرف ماتریس کالیبراسیون دوربین نیست و بزرگی سیگنال آموخته‌شده در پشت این ضریب است که تعیین‌کننده است.

لازم است تاکید شود که تفسیر درست این رفتار برای مدل مطلق، «پاسخ‌گویی صحیح» به ماتریس کالیبراسیون دوربین است، نه «حساسیت نامطلوب»: هنگامی که فاصله کانونی واقعا تغییر کند (مثلا دوربینی با لنز متفاوت)، تصویر یکسان به‌واقع با صحنه‌ای در مقیاس متفاوت سازگار است و مدل باید پیش‌بینی خود را تغییر دهد؛ مدل کنترل که به هر ماتریس کالیبراسیون دوربین پاسخ یکسان می‌دهد، در چنین شرایطی به‌طور سیستماتیک خطا خواهد کرد. این همان پدیده‌ای است که در ارزیابی میدان دید متغیر زیربخش ۷.۴.۴ به‌صورت افت دقت مدل کنترل مشاهده شد.



شکل ۷.۴: پاسخ مقیاس خروجی به پیمایش فاصله کانونی ورودی؛ مدل پیشنهادی به رفتار هندسی ایده‌آل نزدیک می‌شود و کنترل تقریبا ثابت می‌ماند.

۲.۵.۴ آزمون حذف و تحریف ماتریس کالیبراسیون: اثبات اتکای علی

آزمون پیمایش فاصله کانونی نشان داد که خروجی مدل با ماتریس کالیبراسیون دوربین حرکت می‌کند؛ آزمون مکملی لازم است تا نشان دهد دقت مدل نیز به ماتریس کالیبراسیون دوربین وابسته است و اطلاعات درست دوربین، جزء ضروری عملکرد آن است. برای این منظور، مدل پیشنهادی در پیکربندی لرزش کانونی بر کل مجموعه آزمون در چهار شرایط ارزیابی شد: با ماتریس کالیبراسیون دوربین صحیح؛ با حذف کامل ورودی ماتریس کالیبراسیون دوربین؛ و با ماتریس کالیبراسیون دوربین عمدا تحریف‌شده (f_x, f_y در ۰٫۷ یا ۱٫۴ ضرب‌شده، تصویر بدون تغییر).

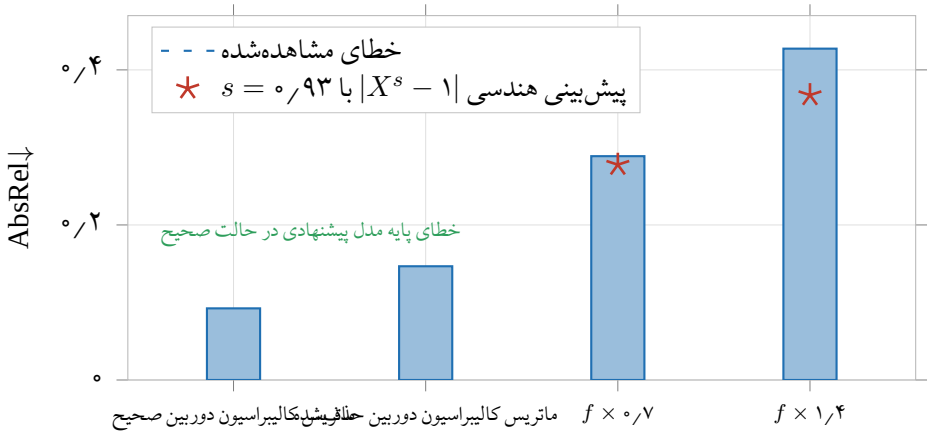
جدول ۱۴.۴: آزمون حذف و تحریف ماتریس دوربین

شرایط ورودی ماتریس کالیبراسیون دوربین	↓AbsRel	$\delta_1 \uparrow$	↓RMSE
ماتریس کالیبراسیون دوربین صحیح	۰٫۰۹۲۴	۰٫۹۳۳۹	۰٫۳۴۵۵
ماتریس کالیبراسیون دوربین حذف‌شده	۰٫۱۴۶۷	۰٫۸۴۴۹	۰٫۴۸۲۶
$f \times ۰٫۷$	۰٫۲۸۸۷	۰٫۱۳۱۰	۰٫۹۱۵۳
$f \times ۱٫۴$	۰٫۴۲۷۴	۰٫۱۲۰۹	۱٫۲۱۱۸

نتایج (جدول ۱۴.۴) اتکای علی را از دو جهت اثبات می‌کند. نخست، حذف ماتریس کالیبراسیون دوربین دقت را به‌شدت تخریب می‌کند (AbsRel از ۰٫۰۹۲ به ۰٫۱۴۷، افت ۵۹ درصدی): مسیر پارامترهای دوربین در این مدل تزئینی نیست و بخش اساسی محاسبه مقیاس از آن عبور می‌کند. دوم بزرگی خطا تحت تحریف f به‌صورت کمی با پیش‌بینی هندسی سازگار است: با شیب پیمایش فاصله کانونی ۰٫۹۳، انتظار می‌رود تحریف $f \times ۰٫۷$ خطای مقیاسی حدود $|۱ - ۰٫۷^{۰٫۹۳}| \approx ۰٫۲۸$ و تحریف $f \times ۱٫۴$ حدود $|۱ - ۱٫۴^{۰٫۹۳}| \approx ۰٫۳۷$ ایجاد کند؛ مقادیر مشاهده‌شده (۰٫۲۸۹ و ۰٫۴۲۷، شامل خطای پایه مدل) دقیقا در همین مرتبه‌اند و سقوط δ_1 به حدود ۰٫۱۳ نشان می‌دهد تقریبا تمام پیکسل‌ها به‌اندازه همین ضریب مقیاس جابه‌جا شده‌اند. به بیان دیگر، مدل نه‌تنها از ماتریس کالیبراسیون دوربین استفاده می‌کند، بلکه به همان شکلی استفاده می‌کند که معادله تصویربرداری روزنه‌ای تجویز می‌کند تصادف یا هم‌بستگی جانبی نمی‌تواند چنین انطباق کمی‌ای تولید کند.

شکل ۸.۴ این انطباق کمی را به‌صورت تصویری نشان می‌دهد: ستون‌ها خطای مشاهده‌شده و ستاره‌ها خطای مقیاسی پیش‌بینی‌شده از روی هندسه پیش از انجام آزمایش‌اند.

این یافته یک پیامد کاربردی نیز دارد که در بخش محدودیت‌ها (فصل پنجم) بازتاب یافته است: مدلی که به ماتریس کالیبراسیون دوربین اتکای علی دارد، به صحت ماتریس کالیبراسیون دوربین نیز حساس است؛ در کاربردهایی که کالیبراسیون نادقیق است، این حساسیت باید در طراحی سامانه لحاظ شود.



شکل ۸.۴: مقایسه حذف و تحریف ماتریس دوربین با خطای مشاهده‌شده و پیش‌بینی هندسی متناظر.

۳.۵.۴ رفتار متفاوت معیارهای AbsRel و RMSE

برای تحلیل دقیق‌تر حساسیت مدل‌ها، از دو معیار AbsRel و RMSE به‌صورت هم‌زمان استفاده شده است. نتایج نشان می‌دهد که این دو معیار رفتارهای متفاوتی نسبت به تغییر پارامترهای دوربین دارند.

معیار AbsRel، به‌دلیل نرمال‌سازی خطا نسبت به مقدار عمق مرجع، در بسیاری از موارد تغییرات ناشی از مقیاس را پنهان می‌کند. به‌عبارت دیگر، حتی در شرایطی که خروجی عمق دچار تغییر مقیاس قابل توجه شده است، مقدار AbsRel ممکن است تغییر اندکی را نشان دهد یا حتی تقریبا ثابت باقی بماند.

در مقابل، معیار RMSE به‌طور مستقیم به مقدار مطلق عمق حساس است و تغییرات مقیاس ناشی از تغییر ماتریس کالیبراسیون دوربین را به‌وضوح منعکس می‌کند. نتایج تجربی نشان می‌دهد که در شرایط تغییر پارامترهای دوربین، افزایش RMSE در مدل پایه Depth Anything V2 به‌مراتب شدیدتر از مدل پیشنهادی است، که این موضوع بیانگر پایداری بیشتر مدل پیشنهادی از منظر هندسی است.

۴.۵.۴ ارتباط با تحلیل هندسی فصل سوم

یافته‌های این بخش به‌صورت مستقیم با تحلیل‌های هندسی ارایه‌شده در فصل سوم هم‌راستا هستند. در فصل سوم نشان داده شد که عدم لحاظ صریح ماتریس کالیبراسیون دوربین در فرآیند تخمین عمق منجر به ابهام مقیاس و وابستگی خروجی به پارامترهای تصویربرداری می‌شود.

نتایج تجربی این فصل تایید می‌کنند که ادغام صریح ماتریس کالیبراسیون دوربین می‌تواند این ابهام را کاهش

دهد و تخمین عمق را از یک پیش‌بینی نسبی به تخمینی با مقیاس پایدار نزدیک کند. بدین ترتیب، تحلیل حساسیت انجام‌شده در این بخش نه‌تنها کارایی عملی مدل پیشنهادی را نشان می‌دهد، بلکه اعتبار تجربی چارچوب هندسی ارایه‌شده در فصل سوم را نیز تایید می‌کند.

۶.۴ تعمیم بین‌دامنه‌ای با آموزش چندمجموعه‌ای

مطالعه کنترل‌شده بخش ۴.۴ سهم ماتریس کالیبراسیون دوربین را با یک دوربین واحد (حسگر Kinect در NYUv2) و با تغییر شبیه‌سازی‌شده فاصله کانونی نشان داد. پرسش این بخش آن است که آیا این برتری، هنگامی که یک مدل واحد بر صحنه‌های داخلی و بیرونی چند دوربین واقعی آموزش می‌بینند، نیز باقی می‌ماند یا خیر. برای این منظور، زوج مدل پیشنهادی/مدل کنترل با انکودر ViT-L و مطابق زیربخش ۸.۷.۳ بر ترکیب NYUv2، KITTI، Virtual KITTI 2 و Cityscapes آموزش داده شد. دو بازو جز در دسترسی به ماتریس کالیبراسیون دوربین، در داده، ترتیب نمونه‌ها، افزونه‌سازی و بذر تصادفی یکسان بودند. با دقت ممیز شناور ترکیبی و ورودی ۵۱۸ × ۵۱۸، اندازه دسته ۴ بدون تجمع گرادیان در حافظه کارت جای گرفت و آموزش هر بازو حدود سه ساعت طول کشید.

مرجع سوم، مدل پایه Depth Anything V2، نسخه منتشرشده، نسخه مطلق ViT-L است؛ برای صحنه‌های داخلی نقطهٔ وارسی Hypersim و برای Cityscapes نقطهٔ وارسی Virtual KITTI 2 آن به‌کار رفت. هر سه مدل با یک زنجیره ارزیابی و بر تصاویر یکسان، به‌صورت مطلق و بدون هیچ ترازی ارزیابی شدند. این زنجیره همان AbsRel برابر ۰٫۲۰۷ را که در جدول ۹.۴ برای نقطهٔ وارسی Hypersim بر NYUv2 گزارش شد، بازتولید می‌کند.

جدول ۱۵.۴ نتایج را بر چهار مجموعه آزمون نشان می‌دهد: بخش آزمون استاندارد NYUv2 (۶۵۴ تصویر، داخلی)، بخش اعتبارسنجی رسمی Cityscapes (۵۰۰ تصویر، شهری) و دو حسگر Kinect v1 و Kinect v2 از SUN RGB-D (هر یک ۲۰۰ تصویر، داخلی) که در آموزش دیده نشده‌اند. مدل پیشنهادی در هر هشت ستون جدول بهترین مقدار را دارد، یعنی در هر چهار مجموعه آزمون کمترین AbsRel و بیشترین δ_1 را به‌دست می‌آورد.

جدول ۴.۱۵: مقایسه مدل‌ها با انکودر ViT-L پس از آموزش چندمجموعه‌ای

مدل	NYUv2		Cityscapes		SUN RGB-D Kinect v1		SUN RGB-D Kinect v2	
	↓AbsRel	$\delta_1 \uparrow$	↓AbsRel	$\delta_1 \uparrow$	↓AbsRel	$\delta_1 \uparrow$	↓AbsRel	$\delta_1 \uparrow$
پیشنهادی	۰٫۰۸۸	۰٫۹۴۵	۰٫۱۰۹	۰٫۸۹۴	۰٫۱۶۹	۰٫۷۶۶	۰٫۱۰۴	۰٫۹۰۶
کنترل	۰٫۱۳۳	۰٫۸۵۶	۰٫۱۳۶	۰٫۸۵۱	۰٫۳۱۴	۰٫۴۷۸	۰٫۲۰۹	۰٫۶۷۷
پایه منتشرشده	۰٫۲۰۷	۰٫۶۹۲	۰٫۲۴۳	۰٫۵۷۷	۰٫۱۹۶	۰٫۷۴۹	۰٫۲۴۶	۰٫۵۲۴

کاهش AbsRel مدل پیشنهادی نسبت به مدل کنترل بر NYUv2، Cityscapes، Kinect v1 و Kinect v2 به‌ترتیب ۳۴، ۲۰، ۴۶ و ۵۰ درصد است و نسبت به مدل پایه Depth Anything V2، نسخه منتشرشده به‌ترتیب ۵۸، ۵۵، ۱۴ و ۵۸ درصد. در آزمون زوجی ویلکاکسون، برتری بر مدل کنترل در هر هشت ستون معنادار است ($p < ۱۰^{-۲۱}$). برتری بر مدل پایه Depth Anything V2، نسخه منتشرشده نیز در هفت ستون از هشت ستون معنادار است ($p < ۱۰^{-۳}$) و تنها تفاوت δ_1 در Kinect v1 (۰٫۷۶۶ در برابر ۰٫۷۴۹) معنادار نیست.

این نتایج دو جنبه از تعمیم را هم‌زمان نشان می‌دهند. نخست، یک مدل واحد هم در صحنه‌های داخلی NYUv2 و هم در صحنه‌های شهری Cityscapes، که دوربین‌هایشان میدان دید افقی ۶۳ و ۴۹ درجه دارند، از هر دو مدل مرجع دقیق‌تر است. دوم، این برتری به دو حسگری که در آموزش دیده نشده‌اند نیز منتقل می‌شود. حسگر Kinect v2 با $f_y/H \approx ۱٫۰۰$ میدان دید عمودی بازتری از همه دوربین‌های آموزشی دارد و در همین حسگر، AbsRel از ۰٫۲۰۹ برای مدل کنترل و ۰٫۲۴۶ برای مدل پایه Depth Anything V2، نسخه منتشرشده به ۰٫۱۰۴ می‌رسد.

برتری مدل پیشنهادی با تغییر دوربین نیز حفظ می‌شود. در آزمون جابه‌جایی دوربین، از مرکز هر تصویر آزمون پنجره‌ای با ابعاد ۱/۱٫۵ تصویر برداشته و ماتریس کالیبراسیون دوربین متناظر با آن به‌روز شد؛ این کار همان صحنه‌ها را از نگاه دوربینی با فاصله کانونی ۱٫۵ برابر نشان می‌دهد. در این آزمون، AbsRel مدل پیشنهادی بر NYUv2، Cityscapes و Kinect v2 به‌ترتیب ۰٫۰۹۷، ۰٫۰۸۷ و ۰٫۱۰۶ است، در برابر ۰٫۱۱۸، ۰٫۱۰۸ و ۰٫۱۱۳ برای مدل کنترل و ۰٫۱۶۴، ۰٫۱۷۸ و ۰٫۱۴۲ برای مدل پایه Depth Anything V2، نسخه منتشرشده. بر NYUv2 و Cityscapes، برتری بر هر دو مدل مرجع معنادار است ($p < ۱۰^{-۲۸}$).

سرانجام، آزمون‌های سازوکاری بخش ۵.۴ نشان می‌دهند که این مدل نیز واقعا از ماتریس کالیبراسیون

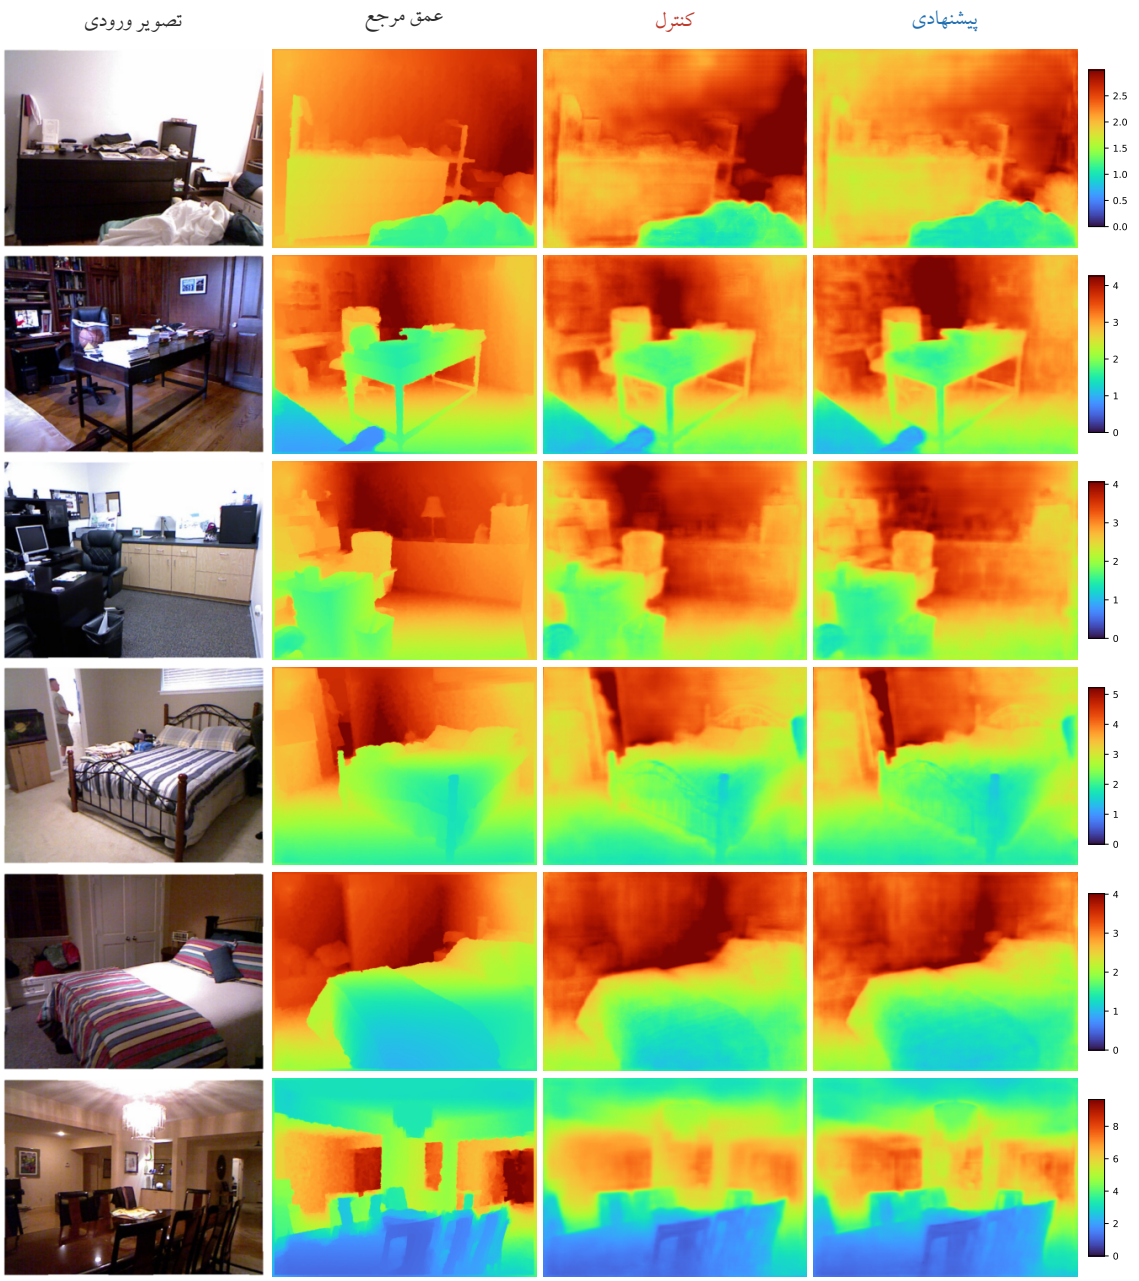
دوربین استفاده می‌کند. در آزمون پیمایش فاصله کانونی بر NYUv2، با ضرب f_x و f_y در ۰/۷ و ۱/۴، عمق پیش‌بینی‌شده هر تصویر نسبت به حالت ماتریس صحیح، با میانه ۰/۷۱۵ و ۱/۴۱۸ مقیاس می‌شود؛ یعنی شیب پیمایش ۰/۹۹ است که به مقدار ایده‌آل ۱ بسیار نزدیک است. حذف ماتریس کالیبراسیون دوربین نیز AbsRel را از ۰/۰۸۸ به ۱/۳۱ می‌رساند. بنابراین دقت گزارش‌شده در جدول ۱۵.۴ از مسیر ورودی دوربین به‌دست می‌آید.

۷.۴ ملاحظات کیفی و حدود شواهد بصری

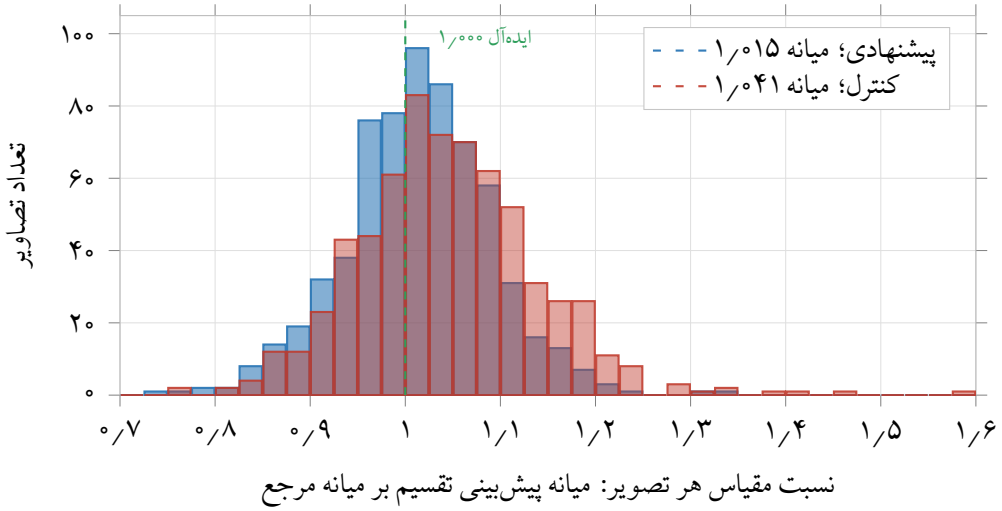
بازبینی نقشه‌های عمق در جریان توسعه برای یافتن خروجی صفر، پیکسل‌های مرده و شکست مقیاس به‌کار رفت؛ به‌ویژه همین بازرسی، فروپاشی دو اجرای اولیه ViT-L را آشکار کرد. بااین‌حال، شبکه تصویری همسان و قابل بازتولیدی از خروجی تمام نقاط وارسی در مصنوعات نهایی آزمایش‌ها نگهداری نشده است. ازاین‌رو، درج یک شکل نمونه یا ادعای برتری بصری می‌توانست گزینشی و غیرقابل ممیزی باشد و تا پیش از اجرای پروتکل پیش‌ثبت‌شده‌ای که در ادامه همین بخش توضیح داده می‌شود، آگاهانه کنار گذاشته شد.

شاهد اصلی برای تغییر رفتار خروجی، به‌جای قضاوت بصری، آزمون‌های عددی سطح تصویر است: آزمون پیمایش فاصله کانونی پاسخ تقریبا خطی مقیاس پیش‌بینی را نشان می‌دهد، آزمون حذف و تحریف ماتریس کالیبراسیون افت ۵۹ درصدی ایجاد می‌کند و مقایسه زوجی روی کل مجموعه آزمون، بهبود AbsRel و RMSE را اندازه‌گیری می‌کند. این شواهد مستقیما به فرضیه مصرف اطلاعات دوربین مربوط‌اند و از انتخاب چند تصویر مطلوب مصون‌تر هستند.

پروتکل پیش‌ثبت‌شده‌ای که پیش‌تر به‌عنوان کار آینده معرفی شده بود، اکنون اجرا شده است: شناسه تصاویر نمونه تنها از روی یک بذر تصادفی و پیش از هرگونه استنتاج انتخاب، و چکیده رمزنگاشتی آن پیش از رندر ثبت شد؛ سپس برای هر نمونه، تصویر ورودی، عمق مرجع، خروجی مدل کنترل و خروجی مدل پیشنهادی با یک نگاشت رنگ و بازه عمق یکسان ذخیره گردید. نتیجه در شکل ۹.۴ آمده است. از آنجا که انتخاب نمونه پیش از مشاهده خروجی‌ها قفل شده است، این شکل برخلاف یک نمایش گزینشی، قابل ممیزی است. افزون بر آن، شکل ۱۰.۴ توزیع کامل نسبت مقیاس هر تصویر را روی کل مجموعه آزمون نشان می‌دهد و سازوکار عددی برتری گزارش‌شده در جدول ۱۰.۴ را آشکار می‌سازد.



شکل ۹.۴: مقایسه کیفی خروجی مدل پیشنهادی و مدل کنترل روی نمونه‌ای که پیش از هرگونه استنتاج قفل شده است. شش تصویر تنها از روی بذر تصادفی ۲۰۲۶۰۸۲۱ از میان ۶۵۴ تصویر مجموعه آزمون انتخاب شدند و چکیده SHA-256 فهرست شناسه‌ها (8086cb124e40) پیش از بارگذاری هر مدل ثبت شد؛ بنابراین گزینش پس از مشاهده نتایج ممکن نبوده و شکل قابل ممیزی است. ستون‌ها از چپ به راست: تصویر ورودی، عمق مرجع، خروجی مدل کنترل و خروجی مدل پیشنهادی. در هر ردیف، نگاشت رنگ و بازه عمق برای مرجع و هر دو مدل یکسان است (نوار رنگ سمت راست همان ردیف، برحسب متر)، تا هیچ برتری بصری از نرمال‌سازی جداگانه هر تصویر ناشی نشود. تفاوت دو مدل عمدتا در مقیاس مطلق صحنه است، نه در جزییات ساختاری که با سازوکار پیش‌بینی‌شده در بخش ۷.۷.۳ هم‌خوان است.



شکل ۱۰.۴: توزیع نسبت مقیاس هر تصویر روی تمام ۶۵۴ تصویر مجموعه آزمون همان نمونه‌ای که آزمون‌های زوجی بخش ۷.۷.۳ روی آن انجام شده است. مقدار ایده‌آل ۱ است. این نمودار سازوکار عددی برتری گزارش‌شده در جدول ۱۰.۴ را آشکار می‌کند: توزیع مدل پیشنهادی هم نزدیک‌تر به مقدار ایده‌آل است (میانه ۱٫۰۱۵ در برابر ۱٫۰۴۱) و هم فشرده‌تر (انحراف معیار ۰٫۰۷۸ در برابر ۰٫۰۹۴؛ دامنه میان‌چارکی ۰٫۰۹۸ در برابر ۰٫۱۱۴). به بیان دیگر، مدل کنترل که ناچار است به میانگین توزیع α رگرسیون کند هم اریب است و هم پراکنده‌تر، دقیقا همان‌گونه که تحلیل بدساختی مساله پیش‌بینی می‌کرد. در سطح تک‌تصویر نیز، مدل پیشنهادی در ۳۹۹ تصویر از ۶۵۴ تصویر (۶۱ درصد) به مقیاس صحیح نزدیک‌تر است.

۸.۴ تحلیل موردی دیتاست CityScapes

در میان دیتاست‌های مورد استفاده در این پژوهش، دیتاست CityScapes دارای ویژگی‌هایی است که آن را از سایر مجموعه‌داده‌ها متمایز می‌کند. به همین دلیل، رفتار خطاها و نتایج حاصل از ارزیابی مدل‌ها بر روی این دیتاست نیازمند تحلیل مستقل و موردی است.

۱.۸.۴ ماهیت و ویژگی‌های خاص دیتاست CityScapes

CityScapes یک دیتاست واقعی شهری[۱] است که تصاویر آن در شرایط متنوع نوری، آب‌وهوایی و با سناریوهای پیچیده ترافیکی ثبت شده‌اند. صحنه‌ها شامل اجسام متعدد در فواصل بسیار متنوع از دوربین هستند، از خودروها و عابران نزدیک تا ساختمان‌ها و پس‌زمینه‌های بسیار دوردست.

برخلاف برخی دیتاست‌های دیگر، CityScapes به‌صورت ذاتی برای MDE طراحی نشده و عمق مرجع آن از طریق تطبیق استریو و بازسازی سه‌بعدی به‌دست آمده است. این موضوع منجر به تفاوت‌های ساختاری در

[۱] Real-world Urban Dataset

کیفیت و یکنواختی داده‌های عمق مرجع می‌شود.

۲.۸.۴ تحلیل کیفیت عمق مرجع

عمق مرجع در CityScapes دارای چگالی و دقت یکنواخت در سراسر تصویر نیست. در نواحی نزدیک به دوربین و بر روی اجسام برجسته، عمق مرجع از کیفیت نسبتا بالایی برخوردار است، اما در نواحی دوردست، لبه‌ها و سطوح با بافت ضعیف، خطاها و ناپیوستگی‌های قابل توجهی مشاهده می‌شود.

این ناهمگنی در کیفیت عمق مرجع باعث می‌شود که معیارهای مطلق، به‌ویژه RMSE و SiLog، نسبت به نویز و خطاهای محلی حساسیت بیشتری نشان دهند. در نتیجه، مقادیر خطای گزارش‌شده لزوما بازتاب‌دهنده صرف عملکرد واقعی مدل نیستند، بلکه تا حدی تحت تاثیر محدودیت‌های داده مرجع قرار دارند.

۳.۸.۴ دلیل رفتار متفاوت خطاها

نتایج تجربی نشان می‌دهد که رفتار خطاها در CityScapes با برخی دیتاست‌های دیگر مانند NYUv2 یا VKITTI تفاوت معناداری دارد. یکی از دلایل اصلی این تفاوت، دامنه بسیار وسیع عمق در صحنه‌های شهری است، که از چند متر تا ده‌ها متر متغیر است.

در چنین شرایطی، خطاهای کوچک نسبی می‌توانند به خطاهای مطلق بزرگ در معیارهای مطلق منجر شوند. از سوی دیگر، وجود نواحی دوردست با عمق نامطمئن باعث می‌شود که مدل‌هایی با رفتار پایدارتر از نظر مقیاس الزاما بهبود یکنواختی در تمامی معیارها نشان ندهند.

۴.۸.۴ محدودیت همسان‌سازی نتایج با سایر دیتاست‌ها

با توجه به ویژگی‌های ذکرشده، همسان‌سازی مستقیم مقادیر خطا بین CityScapes و سایر دیتاست‌ها دارای محدودیت‌های ذاتی است. تفاوت در نحوه تولید عمق مرجع، دامنه عمق صحنه، و کیفیت داده‌ها باعث می‌شود که مقایسه عددی ساده بدون در نظر گرفتن این عوامل می‌تواند منجر به برداشت نادرست شود.

از این رو، در این پژوهش، نتایج CityScapes بیشتر به‌عنوان یک مطالعه موردی برای بررسی رفتار مدل‌ها

در شرایط شهری واقعی و پیچیده مورد استفاده قرار گرفته است، نه به‌عنوان مرجع مطلق برای مقایسه کمی با سایر دیتاست‌ها. این رویکرد امکان تحلیل واقع‌بینانه‌تر و تفسیر دقیق‌تر نتایج را فراهم می‌کند.

۹.۴ بحث و تفسیر نتایج

در این بخش، نتایج کمی و کیفی ارایه‌شده در فصل حاضر به‌صورت یکپارچه مورد بحث و تفسیر قرار می‌گیرند. هدف اصلی این بخش، فراتر رفتن از گزارش صرف اعداد و نمودارها و پاسخ‌گویی صریح به سوالات تحقیق، تبیین رفتار مدل‌ها، و تفسیر یافته‌ها در چارچوب هندسه تصویربرداری و ادبیات موجود در حوزه MDE است.

۱.۹.۴ جمع‌بندی تحلیلی نتایج کمی و کیفی

نتایج کمی نشان دادند که مدل پایه Depth Anything V2، اگرچه در معیارهای نسبی عملکرد رقابتی و قابل قبولی دارد، اما در معیارهای مطلق، به‌ویژه SiLog و RMSE، رفتاری ناپایدار نسبت به تغییر دیتاست و پارامترهای دوربین از خود نشان می‌دهد. این ناپایداری به‌صورت اختلاف‌های معنادار آماری در مقایسه بین‌دیتاستی آشکار شد.

در مقابل، مدل پیشنهادی که در آن ماتریس کالیبراسیون دوربین به‌صورت صریح لحاظ شده است، بهبود قابل توجهی در معیارهای مطلق و کاهش معنادار حساسیت نسبت به تغییر دیتاست‌ها نشان داد. این بهبودها نه‌تنها از نظر آماری معنادار بودند، بلکه در تحلیل‌های کیفی نیز به‌صورت افزایش یکنواختی سطوح، پایداری مقیاس اجسام و بازنمایی واقع‌بینانه‌تر نواحی دوردست مشاهده شدند.

هم‌راستایی نتایج کمی و کیفی نشان می‌دهد که بهبودهای حاصل‌شده صرفا نتیجه بهینه‌سازی عددی معیارها نیستند، بلکه بیانگر تغییر معنادار در نحوه درک مدل از ساختار هندسی صحنه هستند.

۲.۹.۴ پاسخ به سوالات تحقیق

یافته‌های این فصل به هر سه سوال تحقیق مطرح‌شده در فصل اول (بخش ۴.۱) پاسخ می‌دهند.

سوال اول به حساسیت مدل پایه Depth Anything V2 نسبت به دیتاست و شرایط تصویربرداری مربوط است. اختلاف میانگین خطای SiLog این مدل در هر سه مقایسه بین‌دیتاستی معنادار است (جدول ۲.۴). مقیاس مطلق آن نیز به دامنه‌ای غیر از دامنه آموزش منتقل نمی‌شود: نسخه مطلق آموزش‌دیده بر Hypersim، روی NYUv2 به AbsRel برابر ۰٫۲۰۷ می‌رسد، در حالی که تنظیم دقیق‌پارامترها درون‌دامنه‌ای این مقدار را به حدود ۰٫۰۸ کاهش می‌دهد (جدول ۹.۴). پاسخ سوال اول برای مدل پایه Depth Anything V2 مثبت است. بااین‌حال، مقایسه‌های بین‌دیتاستی اثر دیتاست و اثر دوربین را از هم جدا نمی‌کنند؛ سهم جداگانه دوربین در مطالعه کنترل‌شده و با تغییر مصنوعی فاصله کانونی سنجیده شد.

سوال دوم به نقش پروتکل ارزیابی مربوط است و پاسخ آن نیز مثبت است. در پروتکل نسبی ViT-L، مدل پیشنهادی بر مدل کنترل برتری نمی‌یابد (جدول ۷.۴)، اما همین زوج در ارزیابی مطلق بدون تراز، در تمامی معیارها از مدل کنترل بهتر است و برتری آن در RMSE معنادار است (جدول ۹.۴). تراز مقیاس و جابه‌جایی برای هر تصویر، همان مولفه‌ای را حذف می‌کند که ماتریس کالیبراسیون دوربین در اختیار مدل می‌گذارد، یعنی مقیاس مطلق صحنه. از این رو، ارزیابی صرفا نسبی تفاوت مدل‌ها در مقیاس فیزیکی عمق و سهم اطلاعات هندسی دوربین را پنهان می‌کند. این وابستگی به پروتکل در زیربخش ۳.۹.۴ بررسی شده است.

سوال سوم به سهم ورودی صریح ماتریس کالیبراسیون دوربین مربوط است و پاسخ آن مثبت اما مشروط است. در ارزیابی مطلق، مدل پیشنهادی در هر سه پیکربندی آموزشی از مدل کنترل هم‌داده بهتر است و اندازه این برتری با میزان ابهام هندسی داده افزایش می‌یابد (شکل ۵.۴). در پیکربندی لرزش کانونی، AbsRel از ۰٫۱۰۳۰ برای مدل کنترل به ۰٫۰۸۴۹ برای مدل پیشنهادی می‌رسد (جدول ۱۰.۴). مقیاس خروجی نیز پایدارتر است: نسبت مقیاس هر تصویر برای مدل پیشنهادی میانه ۱٫۰۱۵ و انحراف معیار ۰٫۰۷۸ دارد و برای مدل کنترل میانه ۱٫۰۴۱ و انحراف معیار ۰٫۰۹۴ (شکل ۱۰.۴). شیب پیمایش فاصله کانونی در پیکربندی تفکیک اثر (۰٫۰۳ ± ۰٫۹۷) و آزمون حذف و تحریف ماتریس کالیبراسیون (شکل ۸.۴) نشان می‌دهند که مدل واقعا فاصله کانونی را می‌خواند و بر آن تکیه می‌کند. دو قید این پاسخ را محدود می‌کند. نخست، در پروتکل نسبی ViT-L این برتری دیده نمی‌شود. دوم، شواهد پایداری مقیاس از تغییر مصنوعی فاصله کانونی روی NYUv2 به‌دست آمده است، نه از دوربین‌های واقعی متفاوت؛ مقایسه بین‌دیتاستی مدل پیشنهادی هنوز بازتولید نشده است (زیربخش ۳.۳.۴). در آزمون زوم نیز فاصله دو مدل با افزایش زوم کم می‌شود (از ۰٫۰۱۷۸− به ۰٫۰۰۸۳−)؛ بنابراین ادعای کوچک‌ترشدن اختلاف خطا میان دوربین‌ها از این شواهد نتیجه نمی‌شود.

بخشی از قید دوم با آزمایش چندمجموعه‌ای بخش ۶.۴ برطرف شده است. مدل پیشنهادی آموزش‌دیده بر چهار دوربین واقعی و مصنوعی، بر NYUv2، Cityscapes و دو حسگر دیده‌نشده SUN RGB-D در هر دو معیار AbsRel و δ_1 از مدل کنترل و مدل پایه Depth Anything V2، نسخه منتشرشده دقیق‌تر است (جدول ۱۵.۴) و در آزمون جابه‌جایی دوربین نیز بر NYUv2، Cityscapes و Kinect v2 دقیق‌ترین مدل باقی می‌ماند. بنابراین سودمندی ماتریس کالیبراسیون دوربین به تغییر مصنوعی فاصله کانونی در یک مجموعه‌داده محدود نیست و بر دوربین‌های واقعی متفاوت نیز دیده می‌شود.

این داوری‌ها در جدول جمع‌بندی فصل پنجم (جدول ۱.۵) بر پایه شواهد فصل چهارم یک‌جا ارائه می‌شوند.

۳.۹.۴ وابستگی سهم پارامترهای دوربین به پروتکل ارزیابی و ظرفیت مدل

یافته‌های مطالعه کنترل‌شده بخش ۴.۴ تصویری دقیق‌تر و مشروط‌تر از سهم پارامترهای درونی دوربین ترسیم می‌کنند که شایسته بحث مستقل است.

نخست، سهم این پارامترها به پروتکل ارزیابی وابسته است. در پروتکل نسبی، تراز مقیاس و جابجایی به‌ازای هر تصویر، دقیقا همان مولفه اطلاعاتی را از ارزیابی حذف می‌کند که میدان دید و فاصله کانونی در اختیار مدل می‌گذارند؛ یعنی مقیاس مطلق صحنه. از این رو، مشاهده برتری‌نیافتن مدل پیشنهادی بر مدل کنترل در پروتکل نسبی ViT-L نه شاهدی علیه فرضیه پژوهش، بلکه پیامد ساختاری سازوکار ارزیابی است. در مقابل، در ارزیابی مطلق بدون تراز، برتری مدل پیشنهادی در تمامی معیارها ظاهر شده و در RMSE معنادار است. مهم‌تر آنکه الگوی پاسخ به دوز نشان می‌دهد که این برتری، پیوند علی با اطلاعات هندسی دارد و صرفا نوسان آماری نیست.

دوم، سهم پارامترهای دوربین به ظرفیت انکودر نیز وابسته است. در اندازه ViT-S، حتی در پروتکل نسبی، افزودن ماتریس کالیبراسیون دوربین بهبود کوچک اما معنادار ایجاد کرد؛ در حالی که در ViT-L چنین نبود. تبیین محتمل آن است که انکودر بزرگ‌تر، سرنخ‌های پرسپکتیوی و معنایی تصویر (نظیر اندازه ظاهری اجسام آشنا و هندسه خطوط گریز) را با دقتی استخراج می‌کند که برای بازسازی ساختار نسبی، اطلاعات مکمل چندانی از ماتریس کالیبراسیون دوربین باقی نمی‌ماند؛ حال آنکه انکودر کوچک‌تر از هر سیگنال کمکی بهره می‌برد. این تبیین، فرضیه‌ای برخاسته از داده‌های همین پژوهش است و نه یافته‌ای نقل‌شده از ادبیات؛ کارهایی که ماتریس کالیبراسیون دوربین یا میدان دید را به مدل می‌دهند، اثر ظرفیت انکودر را به‌صورت جداگانه گزارش نکرده‌اند [۸،

۱۳، ۱۴]. آزمون این فرضیه در چند اندازه انکودر، در بخش پیشنهادهای پژوهش آتی (بخش ۷.۵) مطرح شده است.

سوم، نتایج نشان دادند که بخش قابل توجهی از بهبود مطلق نسبت به مدل پایه Depth Anything V2، نسخه منتشرشده، حاصل ترکیب تنظیم دقیق‌پارامترها درون‌دامنه‌ای استاندارد و افزونه‌سازی هندسی صحیح است و سهم خالص ورودی ماتریس کالیبراسیون دوربین، افزایشی و در مرتبه کوچک‌تری قرار دارد. گزارش شفاف این تفکیک، برای جلوگیری از بیش‌برآورد سهم هر مولفه ضروری است و اعتبار علمی ادعاهای پژوهش را تضمین می‌کند.

۴.۹.۴ مقایسه غیرمستقیم با ادبیات موضوع

مقایسه مستقیم اعداد این فصل با اعداد منتشرشده در ادبیات ممکن نیست، زیرا مدل‌های مرجع بر داده و برنامه آموزشی متفاوتی آموزش دیده‌اند. آنچه در ادامه می‌آید، مقایسه جهت‌گیری یافته‌ها است، نه مقایسه کمی.

در جریان غالب مطالعات پیشین، تمرکز اصلی بر بهبود معیارهای نسبی یا استفاده از نرمال‌سازی‌های ضمنی برای کاهش اثر مقیاس بوده و اطلاعات دوربین یا نادیده گرفته شده یا به‌صورت ضمنی در داده‌ها نهفته فرض شده است [۲، ۱۲، ۷، ۴]. یافته این فصل مبنی بر اینکه پروتکل نسبی دارای تراز مقیاس، نسبت به سهم اصلی ماتریس کالیبراسیون دوربین نابیناست، همین نکته را از منظر ارزیابی تایید می‌کند.

در سوی دیگر، سه یافته اصلی این پژوهش با گزارش‌های موجود در خط پژوهشی شرطی‌سازی صریح بر هندسه دوربین هم‌جهت‌اند. نخست، افت عملکرد هنگام تغییر فاصله کانونی، همان پدیده‌ای است که CAM-Convs به‌صورت تجربی نشان داد [۸]. دوم، این تحلیل که ابهام مقیاس در آموزش چنددوربینه ریشه هندسی دارد و نه ریشه معماری، همان صورت‌بندی است که Metric3D برای انگیزه‌بخشی به فضای دوربین متعارف ارایه می‌کند [۹]. سوم، سودمندی شرطی‌سازی بر میدان دید در بازیابی مقیاس مطلق، پیش‌تر در چارچوب مدل‌های انتشاری [۱۳] و در UniDepth با یک شاخه دوربین درون‌مدلی [۱۴] گزارش شده است.

در عین حال، باید توجه داشت که این هم‌جهتی، ادعای «لزوم» ماتریس کالیبراسیون دوربین را اثبات نمی‌کند. Depth Pro نشان می‌دهد که با مقیاس داده و محاسبه به‌مراتب بزرگ‌تر، می‌توان بدون دریافت فراداده‌های دوربین نیز به عمق مطلق صفرنمونه رسید و فاصله کانونی را از خود تصویر تخمین زد [۴۵]. بنابراین برداشت قابل دفاع از نتایج این فصل چنین است: در رژیم داده محدود و ستون فقرات فریزشده، ورودی صریح ماتریس کالیبراسیون

دوربین سیگنالی است که مدل در غیاب آن باید با هزینه داده و ظرفیت بسیار بیشتری بازسازی کند.

۵.۹.۴ تفسیر نتایج در چارچوب هندسه تصویربرداری

از منظر هندسه تصویربرداری، عمق مطلق به‌صورت مستقیم به پارامترهای کانونی و هندسه پروجکشن وابسته است. بنابراین، مدلی که تنها بر اطلاعات تصویری تکیه دارد، در بهترین حالت می‌تواند یک بازنمایی نسبی از عمق را بیاموزد.

نتایج این پژوهش تایید می‌کنند که ادغام صریح ماتریس کالیبراسیون دوربین در فرآیند تخمین عمق، در واقع محدودیت‌های فیزیکی سیستم تصویربرداری را به فضای یادگیری تحمیل می‌کند. این محدودیت‌ها باعث می‌شوند که مدل به‌جای اتکا به هم‌بستگی‌های آماری ناپایدار، وابستگی‌های هندسی معنادار میان تصویر و عمق را یاد بگیرد.

در نتیجه، بهبود پایداری مطلق مشاهده‌شده را می‌توان به‌عنوان پیامد مستقیم هم‌راستا شدن معماری یادگیری با اصول هندسی مدل سوراخ‌سوزنی تفسیر کرد. این تفسیر نشان می‌دهد که ترکیب آگاهانه یادگیری عمیق و هندسه کلاسیک می‌تواند مسیر موثری برای پیشرفت در MDE فراهم کند.

۱۰.۴ جمع‌بندی فصل نتایج

در این فصل، نتایج حاصل از ارزیابی کمی و کیفی مدل پیشنهادی و مدل پایه Depth Anything V2 در چارچوبی منسجم ارایه و تحلیل شد. هدف اصلی این فصل، پاسخ‌گویی تجربی به سوالات تحقیق و بررسی میزان تحقق اهداف پژوهش بر اساس داده‌ها و آزمایش‌های انجام‌شده بود.

نتایج کمی نشان دادند که مدل پایه Depth Anything V2، علی‌رغم عملکرد مناسب در معیارهای نسبی، در معیارهای مطلق رفتاری ناپایدار نسبت به تغییر دیتاست و پارامترهای دوربین دارد. این ناپایداری به‌صورت اختلاف‌های معنادار آماری در مقایسه‌های بین‌دیتاستی و حساسیت بالا در معیارهایی مانند RMSE و SiLog مشاهده شد.

در مقابل، مدل پیشنهادی که در آن ماتریس کالیبراسیون دوربین به‌صورت صریح در فرآیند تخمین عمق لحاظ شده است، بهبود معناداری در معیارهای مطلق نشان داد و حساسیت آن نسبت به تغییر شرایط تصویربرداری به‌طور

محسوسی کاهش یافت. این بهبودها نه‌تنها از نظر آماری معنادار بودند، بلکه در تحلیل‌های کیفی نیز به‌صورت پایداری مقیاس، یکنواختی بهتر سطوح و بازنمایی واقع‌بینانه‌تر نواحی دوردست قابل مشاهده بودند.

تحلیل حساسیت نسبت به پارامترهای دوربین نشان داد که معیارهای نرمال‌شده‌ای مانند AbsRel توانایی محدودی در آشکارسازی خطاهای مقیاس دارند، در حالی که معیارهای مطلق رفتار هندسی واقعی مدل‌ها را بهتر منعکس می‌کنند. این یافته به‌طور مستقیم تحلیل‌های نظری فصل سوم در خصوص نقش ماتریس کالیبراسیون دوربین در بازیابی عمق مطلق را تایید می‌کند.

همچنین، تحلیل موردی دیتاست CityScapes نشان داد که تفاوت در ماهیت داده‌ها و کیفیت عمق مرجع می‌تواند بر رفتار معیارهای ارزیابی اثرگذار باشد و تفسیر نتایج نیازمند در نظر گرفتن محدودیت‌های ذاتی هر دیتاست است.

مطالعه کنترل‌شده بخش ۴.۴، که پس از اصلاح تقسیم آموزش/آزمون NYUv2 و راستی‌آزمایی زنجیره ارزیابی از طریق بازتولید نتایج مقاله مرجع انجام شد، دقیق‌ترین سنجش این پژوهش از سهم پارامترهای درونی دوربین را فراهم آورد. بر اساس این مطالعه، مدل پیشنهادی ViT-L در پروتکل استاندارد، از مدل پایه Depth Anything V2، نسخه منتشرشده در تمامی معیارها به‌صورت معنادار آماری بهتر است (کاهش AbsRel از ۰٫۰۴۲۵ به ۰٫۰۳۷۷ در پروتکل نسبی و از ۰٫۲۰۷ به ۰٫۰۸۲ در ارزیابی مطلق). سهم خالص ورودی ماتریس کالیبراسیون دوربین در برابر مدل کنترل هم‌داده، در پروتکل نسبی تنها برای انکودر کوچک معنادار بود، اما در ارزیابی مطلق بدون تراز، در هر سه پیکربندی آموزشی و به‌صورت فزاینده با شدت ابهام هندسی داده (الگوی پاسخ به دوز) آشکار شد. این نتایج، همراه با تحلیل توضیحی نقش سازوکار تراز در پنهان‌سازی اطلاعات مقیاس، درک دقیق‌تری از شرایط سودمندی اطلاعات هندسی دوربین به‌دست می‌دهند.

آزمایش چندمجموعه‌ای بخش ۶.۴ این یافته‌ها را از یک دوربین به چند دوربین و از صحنه‌های داخلی به صحنه‌های بیرونی گسترش داد. مدل پیشنهادی ViT-L که هم‌زمان بر NYUv2، KITTI، Virtual KITTI 2 و Cityscapes آموزش دید، بر NYUv2، Cityscapes و دو حسگر دیده‌نشده SUN RGB-D در هر دو معیار AbsRel و δ_1 از مدل کنترل هم‌داده و مدل پایه Depth Anything V2، نسخه منتشرشده بهتر بود. برای نمونه، AbsRel این مدل بر NYUv2 برابر ۰٫۰۸۸ است، در برابر ۰٫۱۳۳ برای مدل کنترل و ۰٫۲۰۷ برای مدل پایه Depth Anything V2، نسخه منتشرشده، و شیب پیمایش فاصله کانونی آن ۰٫۹۹ است.

در مجموع، نتایج این فصل نشان می‌دهد که ادغام آگاهانه اطلاعات هندسی دوربین در مدل‌های MDE می‌تواند گامی موثر در جهت دستیابی به عمق مطلق پایدار باشد. این فصل، با ارایه شواهد تجربی، زمینه را برای جمع‌بندی نهایی پژوهش و بیان دستاوردها، محدودیت‌ها و مسیرهای آینده تحقیق در فصل بعد فراهم می‌کند.

فصل ۵

بحث و نتیجه‌گیری

۱.۵ مقدمه

این فصل به جمع‌بندی نهایی پژوهش حاضر و تبیین برداشت‌های حاصل از یافته‌های آن اختصاص دارد. در فصل‌های پیشین، مساله پژوهش، پیشینه علمی مرتبط، روش پیشنهادی و نتایج تجربی به‌صورت گام‌به‌گام ارایه و تحلیل شدند. در این مرحله، هدف اصلی پاسخ‌گویی به این پرسش بنیادین است که یافته‌های به‌دست‌آمده چه معنایی دارند و چه ارزش علمی و عملی برای حوزه MDE ایجاد می‌کنند.

در فصل نخست، ضرورت پرداختن به مساله تخمین عمق مطلق و چالش‌های ذاتی آن، به‌ویژه ابهام مقیاس و وابستگی به پارامترهای دوربین، مطرح شد. در ادامه، مرور ادبیات (فصل دوم) نشان داد که جریان غالب روش‌های موجود، یا به عمق نسبی بسنده کرده‌اند و یا نقش هندسه تصویربرداری را به‌صورت ضمنی در نظر گرفته‌اند [۲، ۱۲، ۷، ۴]؛ در برابر آن، خط پژوهشی موازی‌ای وجود دارد که پارامترهای دوربین را صریحا وارد مدل می‌کند [۸، ۹، ۱۳، ۱۴]، اما در هیچ‌یک از آن‌ها ورود ماتریس کالیبراسیون دوربین از تغییر هم‌زمان معماری، داده و برنامه آموزش تفکیک نشده است. همین تفکیک، هدف پژوهش حاضر قرار گرفت؛ در کنار آن، ورود ماتریس کالیبراسیون معلوم از مسیر توکن به انکودر ترنسفورمری یک مدل بنیادین، به‌جای مسیرهای کانولوشنی، پیش‌پردازشی یا حدس‌زننده، طراحی شد. در فصل سوم، چارچوب روش‌شناختی پژوهش ارایه شد و نشان داده شد که چگونه می‌توان با ادغام صریح ماتریس کالیبراسیون دوربین در معماری یک مدل یادگیری عمیق، رابطه میان تصویر، هندسه دوربین و عمق مطلق را به‌صورت مستقیم مدل‌سازی کرد. در فصل چهارم نیز، نتایج کمی و کیفی حاصل از آزمایش‌ها برای ارزیابی صحت این رویکرد گزارش و تحلیل شدند.

اکنون در فصل حاضر، با تکیه بر نتایج عملی استخراج‌شده و بدون ارایه داده‌ها یا آزمایش‌های جدید، برداشت نهایی از یافته‌های پژوهش مطرح می‌شود. در این فصل، تلاش می‌شود ضمن جمع‌بندی دستاوردهای اصلی، میزان تحقق اهداف پژوهش مشخص شود، نوآوری‌های تئوریک و عملی کار تبیین گردد، و محدودیت‌ها و مسیرهای آتی پژوهش در چارچوب مساله مورد مطالعه بیان شوند. بدین ترتیب، این فصل نقش حلقه پایانی تز را ایفا می‌کند و ارتباط منطقی میان مساله اولیه، روش انجام تحقیق و نتایج به‌دست‌آمده را به‌صورت یکپارچه روشن می‌سازد.

۲.۵ جمع‌بندی یافته‌های اصلی پژوهش

هدف اصلی این پژوهش، بررسی امکان دستیابی به تخمین عمق مطلق پایدار با استفاده از یک مدل بنیادین MDE و تحلیل نقش اطلاعات هندسی دوربین در تحقق این هدف بود. یافته‌های به‌دست‌آمده در فصل‌های سوم و چهارم به‌صورت منسجم نشان می‌دهند که ابهام مقیاس، نه یک ضعف پیاده‌سازی، بلکه یک محدودیت هندسی در مدل‌هایی است که صرفا بر اطلاعات تصویری تکیه دارند محدودیتی که در رژیم داده محدود، عملا غیرقابل جبران است. لازم است تصریح شود که این محدودیت، مطلق نیست: مدل‌هایی نظیر Depth Pro نشان داده‌اند که با مقیاس داده به‌مراتب بزرگ‌تر می‌توان فاصله کانونی را از خود تصویر تخمین زد و بدون فراداده به عمق مطلق رسید [۴۵]. آنچه یافته‌های این پژوهش نشان می‌دهد، ناممکن‌بودن بازیابی مقیاس بدون ماتریس کالیبراسیون دوربین نیست، بلکه پرهزینه‌بودن آن است.

نتایج نشان داد که مدل‌های متداول MDE، از جمله مدل پایه Depth Anything V2 مورد بررسی در این پژوهش، توانایی یادگیری ساختار نسبی عمق صحنه را دارند، اما در غیاب اطلاعات صریح مربوط به هندسه دوربین، قادر به بازیابی مقیاس فیزیکی پایدار نیستند. این مساله به‌صورت ناپایداری خروجی عمق در برابر تغییر دیتاست و پارامترهای تصویربرداری در معیارهای مطلق آشکار شد، در حالی که معیارهای نرمال‌شده در بسیاری از موارد این ناپایداری را پنهان می‌کنند.

در مقابل، یافته‌های این پژوهش نشان می‌دهد که ادغام صریح ماتریس کالیبراسیون دوربین در فرآیند تخمین عمق می‌تواند این محدودیت ذاتی را تا حد قابل توجهی کاهش دهد. مدل پیشنهادی با بهره‌گیری از اطلاعات هندسی دوربین، وابستگی خروجی عمق به شرایط تصویربرداری را کاهش داده و به تخمینی پایدارتر از نظر مقیاس فیزیکی دست یافته است. این بهبود نه‌تنها در ارزیابی‌های کمی، بلکه در تحلیل‌های کیفی نیز به‌صورت یکنواختی بهتر سطوح، حفظ مقیاس اجسام و بازنمایی واقع‌بینانه‌تر نواحی دوردست مشاهده شد.

مطالعه کنترل‌شده نهایی بر روی پروتکل استاندارد NYUv2 (بخش ۴.۴)، این یافته‌ها را با دقت آماری مشخص‌تری صورت‌بندی کرد. مدل پیشنهادی در پیکربندی ViT-L، مدل پایه Depth Anything V2، نسخه منتشرشده را در تمامی معیارهای ارزیابی و با معناداری آماری بالا پشت سر گذاشت: در پروتکل نسبی، کاهش AbsRel از ۰٫۰۴۲۵ به ۰٫۰۳۷۷ و در ارزیابی مطلق بدون تراز، کاهش AbsRel از ۰٫۲۰۷ به ۰٫۰۸۲ (بهبود ۲٫۵ برابری). در عین حال، مقایسه با مدل کنترل هم‌داده نشان داد که سهم خالص ورودی پارامترهای دوربین، وابسته به پروتکل ارزیابی است: در ارزیابی نسبی که تراز مقیاس به‌ازای هر تصویر، اطلاعات مقیاس را حذف

می‌کند، این سهم تنها در انکودر کوچک معنادار بود؛ اما در ارزیابی مطلق، برتری مدل پیشنهادی آشکار شد و با افزایش ابهام هندسی در داده‌های آموزشی، به‌صورت نظام‌مند بزرگ‌تر گردید. نقطه اوج این الگوی پاسخ به دوز، پیکربندی لرزش کانونی، یعنی آموزش با افزونه‌سازی لرزش کانونی، بود (زیربخش ۷.۴.۴) که مقیاس مطلق را بدون ماتریس کالیبراسیون دوربین اساسا غیرقابل بازیابی می‌کند: در این پیکربندی، مدل پیشنهادی در تمامی معیارها از مدل کنترل هم‌داده و هم‌بذر پیشی گرفت (AbsRel: ۰٫۰۸۵ در برابر ۰٫۱۰۳) و آزمون سازوکاری پیمایش فاصله کانونی نشان داد که خروجی مدل تقریبا دقیقا مطابق معادله روزنه‌ای با فاصله کانونی مقیاس می‌شود (شیب لگاریتمی ۰٫۹۳ در برابر مقدار ایده‌آل ۱؛ مدل کنترل: صفر). آزمایش تفکیک اثر، عامل علی را به‌طور قطعی به خود افزونه‌سازی لرزش کانونی منتسب کرد (بازتولید کامل اثر با λ بدون تغییر: AbsRel ۰٫۰۸۳ در برابر ۰٫۱۰۷ برای مدل کنترل، شیب پیمایش فاصله کانونی ۰٫۹۷) و آزمون حذف و تحریف ماتریس کالیبراسیون نشان داد که این اتکا علی است: حذف ماتریس کالیبراسیون دوربین دقت را ۵۹ درصد تخریب می‌کند و تحریف عمدی فاصله کانونی، خطا را دقیقا به اندازه‌ای که هندسه روزنه‌ای پیش‌بینی می‌کند افزایش می‌دهد. مجموعه این شواهد، سودمندی علی اطلاعات هندسی دوربین را به‌صورت هم‌گرا اثبات می‌کند.

گام پایانی پژوهش نشان داد که این سودمندی به یک دوربین و یک دامنه محدود نیست (بخش ۶.۴). مدل پیشنهادی ViT-L پس از آموزش هم‌زمان بر NYUv2، KITTI، Virtual KITTI 2 و Cityscapes، یعنی چهار دوربین متفاوت در صحنه‌های داخلی و بیرونی، بر NYUv2، Cityscapes و دو حسگر دیده‌نشده Kinect v1 و Kinect v2 از SUN RGB-D در هر دو معیار AbsRel و δ_1 از مدل کنترل هم‌داده و مدل پایه Depth Anything V2، نسخه منتشرشده دقیق‌تر بود. کاهش AbsRel نسبت به مدل کنترل بین ۲۰ و ۵۰ درصد و نسبت به مدل پایه Depth Anything V2، نسخه منتشرشده بین ۱۴ و ۵۸ درصد بود و برتری بر مدل کنترل در همه این مقایسه‌ها معنادار بود ($p < ۱۰^{-۲۱}$). شیب پیمایش فاصله کانونی این مدل بر NYUv2 برابر ۰٫۹۹ بود؛ یعنی مدل چندمجموعه‌ای نیز مقیاس خروجی را تقریبا دقیقا مطابق معادله روزنه‌ای با فاصله کانونی تنظیم می‌کند.

همچنین، تحلیل بین‌دیتاستی نتایج نشان داد که پایداری مطلق مدل پیشنهادی در محیط‌های متنوع داخلی و خارجی حفظ می‌شود، هرچند کیفیت و ماهیت داده‌های عمق مرجع می‌تواند بر مقادیر مطلق خطا اثرگذار باشد. مطالعه موردی دیتاست CityScapes نشان داد که تفسیر نتایج باید با در نظر گرفتن محدودیت‌های ذاتی هر دیتاست انجام شود و مقایسه مستقیم خطاها بدون توجه به کیفیت داده‌های مرجع می‌تواند گمراه‌کننده باشد.

در مجموع، یافته‌های این پژوهش نشان می‌دهد که دستیابی به عمق مطلق پایدار در MDE نه از طریق پیچیده‌تر کردن معماری شبکه، بلکه از طریق هم‌راستا کردن مدل یادگیری با اصول هندسه تصویربرداری امکان‌پذیر است. این نتیجه، چارچوب نظری و عملی ارایه‌شده در این پژوهش را تایید می‌کند و مبنایی برای تفسیر نوآوری‌ها، محدودیت‌ها و مسیرهای آتی تحقیق در بخش‌های بعدی این فصل فراهم می‌سازد.

۳.۵ پاسخ نهایی به سوالات تحقیق

در این بخش، پاسخ نهایی به سوالات تحقیق و داوری فرضیه‌های تجربی بر اساس شواهد گزارش‌شده در فصل چهارم جمع‌بندی می‌شود. جدول ۱.۵ سه فرضیه تجربی را در کنار شاهد اصلی و داوری نهایی هر یک قرار می‌دهد.

جدول ۱.۵: پاسخ به سوالات تحقیق و داوری فرضیه‌های تجربی بر پایه شواهد فصل چهارم.

فرضیه	شاهد اصلی	داوری
فرضیه اول حساسیت مدل پایه به دیتاست و دوربین	تفاوت معنادار بین‌دیتاستی (جدول ۲.۴)؛ خطای AbsRel برابر ۰٫۲۰۷ برای نسخه مطلق Hypersim روی NYUv2	تایید می‌شود
فرضیه دوم کاهش معنادار خطای مطلق با ورودی صریح ماتریس کالیبراسیون دوربین	برتری مدل پیشنهادی در هر چهار زوج آموزشی مستقل و در تمامی معیارها؛ الگوی پاسخ به دوز (شکل ۵.۴)؛ اتکای علی اثبات‌شده با آزمون حذف و تحریف ماتریس کالیبراسیون (شکل ۸.۴)؛ برتری بر مدل کنترل و مدل پایه Depth Anything V2، نسخه منتشرشده پس از آموزش چندمجموعه‌ای، بر مجموعه‌های آزمون داخلی و شهری و دو حسگر دیده‌نشده (جدول ۱۵.۴)	تایید می‌شود، به‌صورت مشروط: در ارزیابی مطلق بدون تراز و متناسب با میزان ابهام هندسی داده
فرضیه سوم بهبود مطلق بدون افت ساختار نسبی	در پروتکل نسبی، مدل پیشنهادی از مدل پایه Depth Anything V2، نسخه منتشرشده بهتر و با مدل کنترل هم‌تراز است (جدول‌های ۶.۴ و ۷.۴)	تایید می‌شود: هیچ افت معناداری در ساختار نسبی مشاهده نشد

۴.۵ تفسیر نهایی نتایج در چارچوب هندسه تصویربرداری

یافته‌های این پژوهش را می‌توان به‌صورت منسجم در چارچوب هندسه تصویربرداری و مدل فیزیکی دوربین تفسیر کرد. در مدل سوراخ‌سوزنی، رابطه میان مختصات تصویر و عمق صحنه به‌صورت مستقیم به پارامترهای کانونی و هندسه پروجکشن وابسته است [۳]. از این رو، عمق مطلق ذاتا یک کمیت هندسی است و بازیابی آن تنها از روی هندسه یک تصویر و بدون اطلاع از پارامترهای دوربین، به‌صورت یکتا امکان‌پذیر نیست. آنچه مدل‌های داده‌محور در عمل انجام می‌دهند، جایگزین‌کردن این اطلاعات غایب با آمار سرنخ‌های تصویری (اندازه ظاهری اجسام آشنا، هندسه خطوط گریز و مانند آن) است؛ راهبردی که با مقیاس داده کافی تا حد قابل توجهی کارآمد است [۴۵] اما در رژیم داده محدود این پژوهش، ناپایدار می‌ماند.

نتایج تجربی این پژوهش نشان دادند که مدل‌هایی که تنها بر اطلاعات تصویری تکیه دارند، در بهترین حالت قادر به یادگیری ساختار نسبی عمق هستند. این رفتار با تحلیل‌های نظری فصل سوم هم‌خوانی دارد، زیرا در غیاب ماتریس کالیبراسیون دوربین، نگاشت تصویر به عمق دارای درجه‌ای از آزادی مقیاس است که شبکه یادگیری عمیق نمی‌تواند آن را صرفا از داده تصویری حذف کند. به همین دلیل، پایداری مشاهده‌شده در معیارهای نسبی لزوما به معنای بازیابی صحیح عمق فیزیکی نیست.

در مقابل، زمانی که اطلاعات هندسی دوربین به‌صورت صریح در فرآیند تخمین عمق لحاظ می‌شود، مدل یادگیری با محدودیت‌های فیزیکی سیستم تصویربرداری هم‌راستا می‌گردد. نتایج این پژوهش نشان می‌دهد که ادغام صریح ماتریس کالیبراسیون دوربین در عمل نقش یک قید هندسی را ایفا می‌کند که فضای پاسخ‌های ممکن شبکه را محدود می‌سازد. این محدودسازی باعث می‌شود که مدل به‌جای اتکا به هم‌بستگی‌های آماری ناپایدار، وابستگی‌های هندسی معنادار میان تصویر و عمق را بیاموزد.

تحلیل رفتار معیارهای ارزیابی نیز از این تفسیر هندسی پشتیبانی می‌کند. معیارهای نرمال‌شده، به‌دلیل حذف ضمنی اثر مقیاس، نمی‌توانند تغییرات ناشی از پارامترهای دوربین را به‌خوبی منعکس کنند، در حالی که معیارهای مطلق مستقیما به روابط پروجکشن وابسته‌اند و نسبت به خطاهای هندسی حساس هستند. بهبود پایداری در این معیارها نشان‌دهنده آن است که مدل پیشنهادی توانسته است وابستگی خروجی عمق به هندسه تصویربرداری را به‌صورت سازگارتر مدل‌سازی کند.

از منظر هندسی، یافته‌های این پژوهش نشان می‌دهند که در رژیم تنظیم دقیق‌پارامترها با داده محدود، یادگیری عمیق بدون لحاظ صریح مدل تصویربرداری، جایگزین کارآمدی برای قیود فیزیکی نیست؛ همان نتیجه‌ای که

کارهای شرطی‌شده بر هندسه دوربین نیز به آن رسیده‌اند [۸، ۹، ۱۴]. در عوض، ترکیب آگاهانه یادگیری داده‌محور با مدل‌های کلاسیک هندسی می‌تواند به تخمین‌هایی منجر شود که هم از نظر بصری معنادارند و هم از نظر فیزیکی پایدار. این تفسیر نشان می‌دهد که دستاورد اصلی پژوهش حاضر نه صرفا بهبود یک مدل خاص، بلکه ارایه شواهد تجربی برای اهمیت ادغام هندسه تصویربرداری در طراحی مدل‌های MDE است.

۵.۵ نوآوری‌های تحقیق

بر اساس یافته‌های نظری و تجربی ارایه‌شده در این پژوهش، نوآوری‌های تحقیق حاضر را می‌توان در دو سطح تئوریک و عملی دسته‌بندی کرد. این نوآوری‌ها نه بر مبنای ادعاهای کلی، بلکه بر اساس نتایج عملی استخراج‌شده و تحلیل‌های انجام‌شده در فصل‌های سوم و چهارم تشریح می‌شوند.

۱.۵.۵ نوآوری تئوریک

نوآوری تئوریک اصلی این پژوهش در بازتعریف مساله MDE در چارچوب هندسه تصویربرداری نهفته است. در جریان غالب کارهای پیشین، تخمین عمق به‌عنوان یک مساله صرفا داده‌محور مدل‌سازی شده و نقش پارامترهای هندسی دوربین یا نادیده گرفته شده یا به‌صورت ضمنی در داده‌ها فرض شده است [۲، ۱۲، ۶، ۴].

صورت‌بندی هندسی ابهام مقیاس، به‌خودی‌خود تازه نیست و پیش‌تر در Metric3D به‌عنوان انگیزه «فضای دوربین متعارف» ارایه شده است [۹]. سهم نظری پژوهش حاضر، اندازه‌گیری این ابهام است: با ثابت نگه‌داشتن همه عوامل جز دسترسی به ماتریس کالیبراسیون دوربین، نشان داده شد که بخشی از خطای مطلق که پیش‌تر به کمبود ظرفیت یا کمبود داده نسبت داده می‌شد، در واقع سهم اطلاعات هندسی غایب است، و این سهم با آزمون‌های پیمایش فاصله کانونی و حذف و تحریف ماتریس کالیبراسیون، به‌صورت کمی قابل ردیابی است.

بر این اساس، ادعای قابل دفاع این پژوهش چنین است: در رژیم تنظیم دقیق‌پارامترها با داده محدود و ستون فقرات فریزشده، بازیابی مقیاس مطلق پایدار بدون ورودی صریح هندسه دوربین به‌شدت پرهزینه و ناپایدار است. این ادعا با ادعای قوی‌تر «ناممکن‌بودن» یکسان نیست؛ کارهایی با مقیاس داده بسیار بزرگ‌تر نشان داده‌اند که فاصله کانونی را می‌توان از خود تصویر بازسازی کرد [۴۵].

افزون بر این، پژوهش حاضر با تفکیک روشن میان معیارهای مطلق و نسبی و تحلیل رفتار متفاوت آن‌ها نشان می‌دهد که ارزیابی‌های متداول مبتنی بر معیارهای نرمال‌شده که از پروتکل Eigen [۲] و تراز مقیاس و جابجایی خانواده MiDaS [۷] ریشه می‌گیرند و در ارزیابی مدل‌های بنیادین اخیر نیز رایج‌اند [۴] می‌توانند تصویری ناقص یا حتی گمراه‌کننده از عملکرد واقعی مدل‌ها ارایه دهند. این دیدگاه، چارچوبی مفهومی برای بازنگری در نحوه ارزیابی مدل‌های تخمین عمق در ادبیات موجود فراهم می‌کند.

۲.۵.۵ نوآوری عملی

در سطح عملی، نوآوری این پژوهش در ارایه یک راهکار ساده، قابل پیاده‌سازی و سازگار با معماری‌های موجود برای بهبود تخمین عمق مطلق است. برخلاف روش‌هایی که ماتریس کالیبراسیون را به کانولوشن‌ها می‌دهند (CAM-Convs [۸])، آن را تنها در پیش‌پردازش به‌کار می‌برند (Metric3D [۹]) یا دوربین را از تصویر حدس می‌زنند (UniDepth [۱۴]، Depth Pro [۴۵])، روش پیشنهادی (تا آنجا که نویسنده اطلاع دارد، برای نخستین‌بار در یک مدل بنیادین عمق تک‌تصویری) ماتریس کالیبراسیون معلوم را، بدون تخمین آن، با یک انکودر ترنسفورمری به توکن تبدیل و به‌صورت توکنی با گیت یادگیری‌پذیر به انکودر ترنسفورمری یک مدل بنیادین تزریق می‌کند، به‌طوری که خودتوجهی انکودر هندسه دوربین را در کنار محتوای تصویر پردازش کند. این مسیر، با حفظ هسته معماری و وزن‌های پایه، پایداری مطلق خروجی عمق را افزایش داده است. از آنجا که تصویر وصله‌بندی می‌شود و پارامترهای دوربین بر ابعاد تصویر نرمال می‌شوند، معماری به اندازه ورودی وابسته نیست، و پاسخ مدل به تغییر دوربین (در این پژوهش، تغییر شبیه‌سازی‌شده فاصله کانونی) با قانون روزنه‌ای هم‌خوان شد.

یافته‌های عملی این پژوهش نشان می‌دهد که حتی بدون تغییر انکودر و با ثابت نگه‌داشتن وزن‌های استخراج ویژگی، می‌توان با بهره‌گیری از اطلاعات هندسی مناسب، به بهبود معنادار در معیارهای مطلق دست یافت. این نتیجه، توصیه‌ای عملی برای پژوهشگران و کاربردهای صنعتی است که نشان می‌دهد نادیده گرفتن اطلاعات دوربین می‌تواند منجر به نتایج ناپایدار در کاربردهایی شود که به مقیاس فیزیکی دقیق نیاز دارند.

در مجموع، نوآوری عملی این پژوهش در ارایه شواهد تجربی است که نشان می‌دهد ادغام آگاهانه هندسه دوربین در مدل‌های یادگیری عمیق می‌تواند بدون افزایش قابل توجه پیچیدگی سیستم، کیفیت و پایداری تخمین عمق مطلق را بهبود بخشد.

۳.۵.۵ دستاوردهای روش‌شناختی و تشخیصی

در کنار نوآوری‌های فوق، این پژوهش مجموعه‌ای از دستاوردهای روش‌شناختی دارد که اعتبار نتایج را تقویت کرده و برای پژوهش‌های مشابه قابل استفاده‌اند:

- افزونه‌سازی هندسی آگاه از دوربین: راهبردی که با برش‌های مقیاس‌متغیر و به‌روزرسانی دقیق ماتریس کالیبراسیون دوربین، از یک مجموعه‌داده تک‌دوربینه، داده‌هایی با میدان دید متنوع و برچسب هندسی صحیح می‌سازد. این راهبرد به‌تنهایی بهترین نتایج پروتکل نسبی این پژوهش را رقم زد و بستر آزمون علی سهم پارامترهای دوربین را فراهم کرد.

- تحلیل وابستگی نتیجه‌گیری به پروتکل ارزیابی: نشان داده شد که پروتکل ارزیابی نسبی، به‌صورت ساختاری نسبت به سهم اصلی پارامترهای دوربین (مقیاس مطلق) نابیناست و سنجش منصفانه این سهم، مستلزم ارزیابی مطلق بدون تراز است. این یافته برای طراحی ارزیابی در پژوهش‌های آتی حوزه اهمیت دارد.

- افزونه‌سازی لرزش کانونی: تبدیل دقیق $(f, Z) \mapsto (\alpha f, \alpha Z)$ برگرفته از معادله روزنه‌ای که بدون هیچ بازنمونه‌برداری، بازیابی مقیاس را برای مدل فاقد ماتریس کالیبراسیون دوربین به مساله‌ای بدساخت تبدیل می‌کند و اتکای مدل به پارامترهای دوربین را از یک گزینه به یک ضرورت آموزشی ارتقا می‌دهد (زیربخش ۷.۷.۳).

- آزمون تشخیصی پیمایش فاصله کانونی: سنجه‌ای سازوکاری (شیب لگاریتمی پاسخ عمق به مقیاس‌دهی مصنوعی فاصله کانونی) که مستقیما اندازه می‌گیرد مدل چقدر ماتریس کالیبراسیون دوربین را «می‌خواند»، و نشان داد که معیارهای تجمیعی و حتی مقدار پارامتر ضریب کنترلی انکودر دوربین می‌توانند درباره میزان واقعی مصرف ماتریس کالیبراسیون دوربین گمراه‌کننده باشند (زیربخش ۱.۵.۴).

- زوج‌سازی کامل آزمایش‌ها با قفل بذر تصادفی: یکسان‌سازی ترتیب داده، وارونه‌سازی‌ها و نمونه‌های افزونه‌سازی میان بازوهای مدل پیشنهادی و مدل کنترل، به‌گونه‌ای که تفاوت نتایج تنها به متغیر مورد مطالعه (ورودی ماتریس کالیبراسیون دوربین) قابل انتساب باشد؛ صحت آن با برابری بیت‌به‌بیت هزینه گام صفر دو بازو راستی‌آزمایی شد.

- آموزش چندمجموعه‌ای زوجی با دوربین‌های واقعی: نمونه‌برداری متوازن میان دامنه‌ها، توصیف‌گر دوربین ویژه هر نمونه و زنجیره افزونه‌سازی دقیق مشترک، آموزش یک مدل واحد بر چهار دوربین داخلی و بیرونی را ممکن می‌کنند و مقایسه زوجی آن با مدل کنترل را حفظ می‌کنند (زیربخش ۸.۷.۳). مدل حاصل بر صحنه‌های داخلی، شهری و دو حسگر دیده‌نشده از مدل کنترل و مدل پایه Depth Anything V2، نسخه منتشرشده دقیق‌تر بود (جدول ۱۵.۴).

جدول ۲.۵ این نوآوری‌ها را در سه سطح تئوریک، عملی و روش‌شناختی جمع‌بندی می‌کند و برای هر مورد، شاهد پشتیبان و قابلیت استفاده مجدد آن در پژوهش‌های دیگر را مشخص می‌سازد.

جدول ۲.۵: جمع‌بندی نوآوری‌ها و دستاوردها

سطح	دستاورد	شرح	شاهد پشتیبان
تئوریک	بازتعریف ابهام مقیاس به‌عنوان محدودیت هندسی	ابهام مقیاس یک ویژگی ذاتی نگاشت تصویربرداری است، نه ضعف معماری یا کمبود داده؛ بنابراین با بزرگ‌ترکردن شبکه رفع نمی‌شود	شکل ۱.۳ و آزمون حذف و تحریف ماتریس کالیبراسیون (۲.۵.۴)
تئوریک	نابینایی ساختاری پروتکل نسبی	تراز مقیاس به‌ازای هر تصویر، دقیقا همان کمیتی را حذف می‌کند که ماتریس کالیبراسیون دوربین فراهم می‌آورد؛ پس ارزیابی نسبی نمی‌تواند سهم ماتریس کالیبراسیون دوربین را بسنجد	بخش ۵.۴.۴
عملی	شرطی‌سازی توکنی با ضریب کنترلی صفر مقدار	افزودن ماتریس کالیبراسیون دوربین بدون تغییر هسته معماری و بدون آسیب به وزن‌های ازپیش‌آموخته، حتی با انکودر کاملا فریزشده	شکل ۳.۳
روش‌شناختی	افزونه‌سازی هندسی آگاه از دوربین	ساخت داده‌های با میدان دید متنوع و برچسب هندسی صحیح از یک مجموعه‌داده تک‌دوربینه	بهترین نتایج پروتکل نسبی
روش‌شناختی	افزونه‌سازی لرزش کانونی	تبدیل دقیق $(f, Z) \mapsto (\alpha f, \alpha Z)$ که بازیابی مقیاس را برای مدل کنترل بدساخت می‌کند، بدون بازنمونه‌برداری و با حفظ هندسه	شکل ۶.۳ و جدول ۱۲.۴
روش‌شناختی	آزمون تشخیصی پیمایش فاصله کانونی	سنجه‌ای مستقیم برای اینکه مدل چقدر واقعا ماتریس کالیبراسیون دوربین را «می‌خواند»؛ نشان داد معیارهای تجمیعی و حتی مقدار ضریب کنترلی انکودر می‌توانند گمراه‌کننده باشند	شکل ۷.۴
روش‌شناختی	زوج‌سازی کامل با قفل بذر تصادفی	یکسان‌سازی ترتیب داده، وارونه‌سازی‌ها و نمونه‌های افزونه‌سازی میان دو بازو، تا تفاوت نتایج تنها به ورودی ماتریس کالیبراسیون دوربین قابل انتساب باشد	برابری بیت‌به‌بیت هزینه گام صفر دو بازو
روش‌شناختی	آموزش چندمجموعه‌ای زوجی با دوربین‌های واقعی	نمونه‌برداری متوازن میان دامنه‌ها و افزونه‌سازی دقیق مشترک برای آموزش یک مدل واحد بر چهار دوربین داخلی و بیرونی، با حفظ مقایسه زوجی با مدل کنترل	جدول ۱۵.۴

۶.۵ محدودیت‌ها و چالش‌های پژوهش

با وجود نتایج مثبت و معنادار حاصل از این پژوهش، لازم است محدودیت‌ها و چالش‌هایی که در مسیر انجام تحقیق وجود داشته‌اند به‌صورت شفاف بیان شوند. ذکر این موارد نه‌تنها به درک دقیق‌تر دامنه اعتبار یافته‌ها کمک می‌کند، بلکه مسیر توسعه و بهبود پژوهش‌های آتی در این حوزه را نیز روشن‌تر می‌سازد.

نخستین محدودیت این پژوهش به وابستگی روش پیشنهادی به صحت ماتریس کالیبراسیون دوربین بازمی‌گردد. در این تحقیق فرض شده است که پارامترهای درونی دوربین به‌صورت دقیق و بدون خطا در دسترس هستند. آزمون حذف و تحریف ماتریس کالیبراسیون (زیربخش ۲.۵.۴) ابعاد این وابستگی را کمی کرده است: حذف کامل ماتریس کالیبراسیون دوربین حدود ۵۹ درصد و تحریف ۳۰ تا ۴۰ درصدی فاصله کانونی، چند برابر خطای پایه به مدل تحمیل می‌کند. این رفتار، روی دیگر سکه اتکای علی مدل به ماتریس کالیبراسیون دوربین است: در عمل، به‌ویژه در کاربردهای واقعی که پارامترها ممکن است ناقص، تقریبی یا همراه با نویز باشند، حساسیت مدل به خطای کالیبراسیون باید در طراحی سامانه لحاظ شود؛ مطالعه نظام‌مند رفتار مدل تحت عدم قطعیت‌های واقع‌گرایانه کالیبراسیون (نه تحریف‌های عمدی بزرگ) موضوعی برای پژوهش‌های آتی است.

محدودیت دیگر به کیفیت و ماهیت داده‌های عمق مرجع در دیتاست‌های مختلف مربوط است. همان‌گونه که در فصل چهارم نشان داده شد، دیتاست‌ها از نظر نحوه تولید عمق مرجع، دامنه عمق و یکنواختی داده‌ها تفاوت‌های اساسی دارند. این ناهمگنی می‌تواند بر مقادیر مطلق خطاهای مطلق اثرگذار باشد و تفسیر نتایج را تحت تاثیر قرار دهد. هرچند در این پژوهش تلاش شده است این مساله از طریق تحلیل‌های آماری و بررسی‌های موردی کنترل شود، اما محدودیت‌های ذاتی داده‌های مرجع به‌طور کامل قابل حذف نیستند.

از منظر معماری، روش پیشنهادی بر پایه یک مدل خاص از خانواده Depth Anything V2 پیاده‌سازی و ارزیابی شده است. اگرچه چارچوب ارایه‌شده به‌صورت مفهومی مستقل از معماری خاص است، اما تعمیم تجربی نتایج به سایر معماری‌ها یا انکودرهای متفاوت در این پژوهش به‌صورت مستقیم بررسی نشده است. از این رو، نتایج ارایه‌شده بیشتر در چارچوب معماری مورد استفاده قابل تفسیر هستند.

در نهایت، این پژوهش تمرکز خود را بر MDE ایستا و تصاویر منفرد قرار داده است. اطلاعات زمانی یا چندنمایی که می‌توانند قیود هندسی مکملی فراهم کنند، در چارچوب این تحقیق مورد استفاده قرار نگرفته‌اند. این انتخاب آگاهانه، برای تمرکز بر نقش ماتریس کالیبراسیون دوربین در ساده‌ترین سناریوی ممکن انجام شده است، اما در عین حال دامنه کاربرد نتایج را به این سناریو محدود می‌کند.

سه محدودیت دیگر نیز که از مطالعه کنترل‌شده نهایی برمی‌خیزند باید به‌صراحت ذکر شوند. نخست، تنوع پارامترهای دوربین در آزمایش‌های نهایی از طریق افزونه‌سازی هندسی (برش‌های مقیاس‌متغیر با ماتریس کالیبراسیون دوربین اصلاح‌شده) شبیه‌سازی شده است، نه با داده‌های واقعی چنددوربینه؛ اگرچه این شبیه‌سازی از منظر هندسی دقیق است، اثرات ثانویه دوربین‌های واقعی (نظیر اعوجاج لنز، عمق میدان و نویز حسگر) را پوشش نمی‌دهد. دوم، در پیکربندی زوم‌برش، برتری مدل پیشنهادی در RMSE معنادار بود، اما AbsRel تنها در آستانه معناداری قرار گرفت. این محدودیت مربوط به پیکربندی زوم‌برش است؛ در پیکربندی لرزش کانونی و پیکربندی تفکیک اثر تمام معیارها به‌طور معنادار بهبود یافتند. بنابراین قدرت شواهد به میزان ابهام هندسی ایجادشده در داده وابسته است. سوم، مقایسه‌های کنترل‌شده نهایی بر یک مجموعه‌داده درون‌دامنه‌ای (NYUv2) متمرکز بوده‌اند؛ تعمیم سهم پارامترهای دوربین به تنظیم دقیق‌پارامترها بر مجموعه‌داده‌های دیگر (به‌ویژه صحنه‌های بیرونی با دامنه عمق بزرگ) نیازمند آزمایش‌های تکمیلی است. در صورت دسترسی به داده آموزشی واقعی KITTI، تکرار مطالعه کنترل‌شده مطلق بر روی آن می‌تواند تعمیم‌پذیری یافته‌ها را در محیط بیرونی و دامنه عمق بزرگ مستند کند.

محدودیت نخست و سوم در آزمایش چندمجموعه‌ای این پژوهش تا حدی برطرف شدند (بخش ۶.۴): یک مدل واحد با ۹۱۴۸ تصویر واقعی KITTI و نیز NYUv2، Virtual KITTI 2 و Cityscapes، یعنی چهار دوربین واقعی و مصنوعی، آموزش دید و برتری آن بر صحنه‌های داخلی، صحنه‌های شهری و دو حسگر دیده‌نشده نشان داده شد. بااین‌حال، در این آموزش NYUv2 تنها منبع صحنه‌های داخلی بود؛ ازاین‌رو تعمیم به دوربین‌های داخلی با میدان دیدی بسیار متفاوت از NYUv2 به داده آموزشی داخلی متنوع‌تری نیاز دارد.

چهارم، هر بازوی هر زوج آموزشی تنها یک بار آموزش داده شده است. قفل بذر، ترتیب داده و افزونه‌سازی را میان دو بازو یکسان می‌کند و آزمون‌های زوجی عدم قطعیت در سطح تصویر را می‌سنجند، اما جایگزین تکرار کامل آموزش با چند بذر مستقل نیست. ازاین‌رو، استنباط علی درون هر زوج قوی است، ولی برآورد واریانس ناشی از تصادفی‌بودن کل فرآیند آموزش همچنان به آزمایش تکمیلی نیاز دارد.

با در نظر گرفتن این موارد، می‌توان گفت که محدودیت‌های مطرح‌شده نتایج اصلی پژوهش را نقض نمی‌کنند، بلکه چارچوب اعتبار آن‌ها را مشخص می‌سازند و زمینه‌ای مناسب برای توسعه و تکمیل پژوهش در مطالعات آینده فراهم می‌کنند.

جدول ۳.۵ این محدودیت‌ها را در کنار اثر هر یک بر دامنه اعتبار یافته‌ها و مسیر پژوهشی متناظر برای رفع آن قرار می‌دهد.

جدول ۳.۵: محدودیت‌ها و مسیرهای پژوهشی آینده

محدودیت	اثر بر دامنه اعتبار یافته‌ها	مسیر پژوهشی پیشنهادی
وابستگی به صحت ماتریس کالیبراسیون دوربین	همان اتکای علی که مزیت مدل است، آن را به خطای کالیبراسیون حساس می‌کند	مطالعه رفتار مدل تحت عدم قطعیت‌های واقع‌گرایانه کالیبراسیون؛ طراحی سازوکار مقاوم به نویز ماتریس کالیبراسیون دوربین
شبیه‌سازی تنوع دوربین با افزونه‌سازی	اثرات ثانویه دوربین‌های واقعی مانند اعوجاج لنز، عمق میدان و نویز حسگر پوشش داده نشده است	آموزش بر داده‌های واقعا چنددوربینه؛ الگوی پاسخ به دوز پیش‌بینی می‌کند سهم ماتریس کالیبراسیون دوربین در این حالت بزرگ‌تر شود؛ گام نخست این مسیر با آموزش چندمجموعه‌ای بر چهار دوربین برداشته شد (بخش ۶.۴)
تمرکز بر یک مجموعه‌داده درون‌دامنه‌ای	تعمیم یافته‌ها به صحنه‌های بیرونی با دامنه عمق بزرگ در مطالعه کنترل‌شده NYUv2 آزموده نشده بود؛ آزمایش چندمجموعه‌ای این تعمیم را بر Cityscapes نشان داد	تکرار مطالعه کنترل‌شده مطلق روی KITTI یا مجموعه‌داده‌های بیرونی مشابه؛ افزودن مجموعه‌داده‌های داخلی بیشتر با دوربین‌های متنوع به ترکیب آموزشی
تک‌اجرا بودن هر بازو	استنباط علی درون هر زوج قوی است، اما واریانس ناشی از تصادفی‌بودن کل فرآیند آموزش برآورد نشده است	تکرار هر زوج با چند بذر مستقل و گزارش میانگین و انحراف معیار میان اجراها
تک‌معماری بودن ارزیابی	نتایج در چارچوب خانواده Depth Anything V2 تفسیرپذیرند	پیاده‌سازی همان چارچوب روی انکودرها و دیکودرهای متفاوت
نبود پروتکل کیفی قفل‌شده	نتیجه‌گیری به شواهد کمی و آزمون‌های علی محدود مانده است	قفل‌کردن شناسه تصاویر پیش از مشاهده و ذخیره خروجی هر دو بازو با نگاشت رنگ و بازه عمق یکسان

۱.۶.۵ ملاحظات عملی و محدودیت‌های پیاده‌سازی

در پیاده‌سازی عملی، برخی محدودیت‌ها و چالش‌ها شناسایی و مدیریت شده‌اند:

- محدودیت حافظه GPU: با توجه به حجم بالای مدل‌های Vision Transformer، از تجمع گرادیان استفاده شده است. به‌طور مشخص، آموزش ViT-L در چارچوب ورودی ۶۸۶ × ۵۱۸ با اندازه دسته ۴ از حافظه ۲۴ گیگابایتی کارت گرافیک فراتر می‌رفت؛ از این رو، اندازه دسته ۲ همراه با تجمع گرادیان با گام ۲ (اندازه دسته موثر ۴) به‌کار گرفته شد.

در آزمایش چندمجموعه‌ای، دقت ممیز شناور ترکیبی bfloat16، پیاده‌سازی ادغام‌شده توجه و ورودی ۵۱۸ × ۵۱۸ این محدودیت را برطرف کردند و اندازه دسته ۴ بدون تجمع گرادیان ممکن شد (بخش ۶.۴).

- عدم دسترسی به پارامترهای دقیق دوربین: برای برخی دیتاست‌ها، پارامترهای دوربین از روی فراداده تصویری تبادلی (EXIF)[۱] تصاویر یا مستندات دیتاست استخراج یا تخمین زده شده است. در مواردی که اطلاعات دقیق در دسترس نبوده، از مقادیر متعارف (مانند $f = W$ برای تصاویر با FoV استاندارد) استفاده شده است.

- تنوع در کیفیت ground truth: دیتاست‌های مختلف دارای سطوح متفاوتی از دقت در نقشه‌های عمق مرجع هستند. برای رفع این مساله، در فرآیند ارزیابی از masking برای حذف پیکسل‌های نامعتبر استفاده شده است. در ارزیابی استاندارد NYUv2، مطابق پروتکل مرجع، از نقشه‌های عمق خام ثبت‌شده[۲] (و نه نسخه‌های درون‌یابی‌شده) به‌عنوان مرجع استفاده شده است.

- تکرارپذیری و استنباط آماری: علی‌رغم ثابت نگه‌داشتن بذرهای تصادفی، برخی عملیات GPU ذاتا غیرقطعی هستند. برای استنباط آماری معتبر، به‌جای اتکا به مقایسه میانگین‌های کل، از آزمون‌های زوجی در سطح تک‌تصویر (آزمون t زوجی و آزمون علامت‌دار ویلکاکسون بر روی ۶۵۴ تصویر آزمون) به‌همراه بازه‌های اطمینان بوت‌استرپ استفاده شده است. آموزش با چند بذر مستقل تکرار نشده است؛ ازاین‌رو، برآورد و گزارش انحراف معیار میان اجراها یکی از محدودیت‌ها و پیشنهادهای پژوهش آینده است.

۷.۵ پیشنهادهایی برای تحقیقات آینده

یافته‌ها و محدودیت‌های مطرح‌شده در این پژوهش، زمینه‌های روشنی را برای ادامه و توسعه تحقیقات آینده در حوزه MDE فراهم می‌کنند. پیشنهادهای ارایه‌شده در این بخش به‌طور مستقیم بر چارچوب مفهومی و عملی تحقیق حاضر استوار هستند و از طرح موضوعات کلی و خارج از دامنه پژوهش اجتناب شده است.

[۱] Exchangeable Image File Format
[۲] Raw Depth

یکی از مسیرهای طبیعی برای توسعه این پژوهش، بررسی رفتار مدل پیشنهادی در شرایطی است که ماتریس کالیبراسیون دوربین به‌صورت دقیق در دسترس نیست. در بسیاری از کاربردهای واقعی، پارامترهای درونی دوربین ممکن است همراه با نویز یا به‌صورت تخمینی ارایه شوند. مطالعه پایداری مدل پیشنهادی در برابر خطاهای موجود در ماتریس کالیبراسیون دوربین و یا طراحی سازوکارهایی برای مقابله با این عدم قطعیت، می‌تواند گام مهمی در جهت کاربردپذیری عملی‌تر روش ارایه‌شده باشد.

مسیر پژوهشی دیگر، یادگیری هم‌زمان عمق و پارامترهای دوربین است. در چارچوب تحقیق حاضر، ماتریس کالیبراسیون دوربین به‌عنوان ورودی معلوم در نظر گرفته شده است. بررسی امکان تخمین یا اصلاح پارامترهای درونی دوربین به‌صورت هم‌زمان با تخمین عمق، می‌تواند منجر به مدل‌هایی شود که وابستگی کمتری به کالیبراسیون اولیه دارند و در سناریوهای متنوع‌تری قابل استفاده هستند. این مسیر پیشینه روشنی دارد: UniDepth یک شاخه دوربین را در کنار شاخه عمق آموزش می‌دهد [۱۴] و Depth Pro فاصله کانونی را مستقیما از تصویر تخمین می‌زند [۴۵]؛ مزیت طرح کنترل‌شده این پژوهش آن است که می‌توان سهم ماتریس کالیبراسیون دوربین تخمینی را در برابر ماتریس کالیبراسیون دوربین مرجع، با همان بازوی کنترل هم‌داده سنجید.

مسیر مهم دیگری که مستقیما از یافته‌های مطالعه کنترل‌شده برمی‌خیزد، آموزش بر روی داده‌های واقعا چنددوربینه است. الگوی پاسخ به دوز مشاهده‌شده نشان می‌دهد که سهم پارامترهای دوربین با میزان تنوع هندسی داده رشد می‌کند؛ بنابراین انتظار می‌رود آموزش بر ترکیبی از مجموعه‌داده‌هایی با دوربین‌ها و میدان‌های دید متفاوت (به‌جای شبیه‌سازی تنوع از طریق افزونه‌سازی) این سهم را بزرگ‌تر و پایدارتر آشکار کند؛ همان رژیمی که در آن، تناقض برچسب‌های مطلق میان دوربین‌های مختلف انگیزه اصلی طراحی فضای دوربین متعارف در Metric3D بوده است [۹].

نخستین گام این مسیر در همین پژوهش برداشته شد (بخش ۶.۴) و نتیجه آن با این پیش‌بینی هم‌خوان بود: پس از آموزش بر چهار دوربین، مدل پیشنهادی بر صحنه‌های داخلی، صحنه‌های شهری و دو حسگر دیده‌نشده از مدل کنترل و مدل پایه Depth Anything V2، نسخه منتشرشده دقیق‌تر شد. گام بعدی، افزودن مجموعه‌داده‌های داخلی با دوربین‌ها و میدان‌های دید متنوع‌تر، برای نمونه Hypersim [۴۰]، به ترکیب آموزشی است؛ زیرا در آزمایش حاضر NYUv2 تنها منبع صحنه‌های داخلی بود.

از منظر استحکام آماری، تکرار هر زوج مدل پیشنهادی/مدل کنترل با چند بذر مستقل و گزارش میانگین و

انحراف معیار میان اجراها ضروری است. این تکرار باید در کنار آزمون‌های زوجی سطح تصویر انجام شود تا دو منبع عدم قطعیت به‌صورت جداگانه اندازه‌گیری شوند.

همچنین، تعمیم چارچوب پیشنهادی به سناریوهای چندتصویری یا ویدیویی می‌تواند زمینه پژوهشی ارزشمندی باشد. اطلاعات زمانی یا چندنمایی، قیود هندسی مکملی نسبت به اطلاعات تک‌تصویری فراهم می‌کنند و ترکیب آن‌ها با ادغام صریح ماتریس کالیبراسیون دوربین می‌تواند به تخمین‌های پایدارتر و دقیق‌تر از عمق مطلق منجر شود.

از منظر معماری، بررسی پیاده‌سازی روش پیشنهادی بر روی انکودرها و دیکودرهای متفاوت و تحلیل میزان وابستگی نتایج به انتخاب معماری پایه می‌تواند به تعمیم‌پذیری بهتر چارچوب ارایه‌شده کمک کند. چنین بررسی‌هایی امکان ارزیابی این موضوع را فراهم می‌کنند که آیا مزایای مشاهده‌شده یک ویژگی عمومی رویکرد هندسی پیشنهادی هستند یا به معماری خاصی وابسته‌اند. این مسیر، آزمون مستقیم فرضیه‌ای است که در بخش ۳.۹.۴ مطرح شد: سهم ماتریس کالیبراسیون دوربین با افزایش ظرفیت انکودر کاهش می‌یابد. تا آنجا که بررسی شد، هیچ‌یک از کارهای شرطی‌شده بر هندسه دوربین [۸، ۹، ۱۴] این وابستگی را به‌صورت جداگانه گزارش نکرده‌اند.

در مجموع، پیشنهادهای مطرح‌شده در این بخش نشان می‌دهند که پژوهش حاضر می‌تواند به‌عنوان نقطه آغاز برای مجموعه‌ای از مطالعات عمیق‌تر در زمینه ترکیب هندسه تصویربرداری و یادگیری عمیق در MDE مورد استفاده قرار گیرد.

۸.۵ جمع‌بندی نهایی فصل

در این فصل، جمع‌بندی نهایی پژوهش حاضر با تمرکز بر برداشت‌های حاصل از یافته‌ها ارایه شد. بر اساس نتایج نظری و تجربی به‌دست‌آمده، نشان داده شد که تخمین عمق مطلق پایدار در چارچوب تک‌دوربینه بدون لحاظ صریح هندسه دوربین به‌صورت ذاتی با محدودیت مواجه است. این برداشت، ریشه در اصول هندسه تصویربرداری دارد و با نتایج عملی گزارش‌شده در فصل‌های پیشین هم‌راستا است.

یافته‌های این پژوهش نشان می‌دهد که ادغام آگاهانه ماتریس کالیبراسیون دوربین در فرآیند تخمین عمق می‌تواند نقش تعیین‌کننده‌ای در کاهش ابهام مقیاس و افزایش پایداری مطلق خروجی ایفا کند. این بهبودها نه‌تنها

در معیارهای ارزیابی، بلکه در کیفیت بصری نقشه‌های عمق و رفتار مدل در سناریوهای متنوع تصویربرداری قابل مشاهده بودند.

آزمایش چندمجموعه‌ای پایانی نشان داد که این سودمندی به یک دوربین محدود نیست: مدلی که بر چهار دوربین داخلی و بیرونی آموزش دید، بر NYUv2، Cityscapes و دو حسگر دیده‌نشده SUN RGB-D از مدل کنترل هم‌داده و مدل پایه Depth Anything V2، نسخه منتشرشده دقیق‌تر بود و همچنان مقیاس خروجی خود را مطابق فاصله کانونی ورودی تنظیم می‌کرد.

در مجموع، پژوهش حاضر نشان می‌دهد که ترکیب یادگیری عمیق با قیود هندسی کلاسیک، مسیر موثری برای ارتقای MDE است. نتایج ارایه‌شده می‌توانند به‌عنوان مبنایی برای توسعه مدل‌های آتی و بازنگری در شیوه ارزیابی روش‌های تخمین عمق مورد استفاده قرار گیرند. بدین ترتیب، این پایان‌نامه با ارایه یک چارچوب نظری و عملی منسجم، پاسخی روشن به مساله مطرح‌شده در ابتدای تحقیق ارایه می‌دهد و زمینه را برای پژوهش‌های تکمیلی در این حوزه فراهم می‌سازد.

فهرست تصاویر

۱.۱ ساختار پایان‌نامه ۱۰

۱.۲ دسته‌بندی روش‌های تخمین عمق ۱۵
۲.۲ مقایسه کیفی مدل‌های عمق مطلق ۱۸
۳.۲ نمونه خروجی مدل ۲V Anything Depth ۱۹

۱.۳ ابهام مقیاس در تخمین عمق تک‌دوربینه ۳۱
۲.۳ مدل هندسی دوربین سوراخ‌سوزنی ۳۲
۳.۳ معماری مدل پیشنهادی ۳۹
۴.۳ مقایسه سازوکارهای شرطی‌سازی دوربین ۳۹
۵.۳ نمونه‌ای از تنوع شرایط تصویربرداری مجموعه‌داده‌ها ۴۴
۶.۳ افزونه‌سازی لرزش کانونی ۵۲

۱.۴ مقایسه بین‌دیتاستی معیار SiLog ۷۱
۲.۴ فازهای مسیر تجربی پژوهش ۷۶
۳.۴ مقایسه پروتکل‌های ارزیابی ۷۹
۴.۴ تعمیم به میدان دیدهای متفاوت ۸۲
۵.۴ الگوی پاسخ به دوز ۸۴
۶.۴ اندازه اثر زوجی معیارها ۸۶
۷.۴ پاسخ خروجی به پیمایش فاصله کانونی ۸۷
۸.۴ مقایسه حذف و تحریف ماتریس دوربین ۸۹
۹.۴ مقایسه کیفی روی نمونه پیش‌ثبت‌شده ۹۳

۱۰.۴ توزیع نسبت مقیاس هر تصویر ۹۴

فهرست جداول

۱.۳ بردار توصیف‌گر پارامترهای دوربین ۳۷
۲.۳ مجموعه‌داده‌های پژوهش ۴۲
۳.۳ مجموعه‌داده‌های آموزش چندمجموعه‌ای و مجموعه‌های آزمون گزارش‌شده ۴۳
۴.۳ توابع هزینه و پروتکل‌های ارزیابی ۶۰

۱.۴ ابرپارامترهای آموزش (یکسان برای هر دو بازوی مدل پیشنهادی و مدل کنترل) ۶۷
۲.۴ مقایسه معیار SiLog مدل پایه Depth Anything V2، نسخه منتشرشده در دیتاست‌های مختلف ۷۰
۳.۴ مقایسه تاریخی و موقت عملکرد مدل پایه Depth Anything V2، نسخه منتشرشده و مدل پیشنهادی بر اساس معیار SiLog ۷۰
۴.۴ مسیر تصمیم‌گیری آزمایش‌ها ۷۳
۵.۴ ارزیابی صفرنمونه پس از تنظیم دقیق‌پارامترها ۷۷
۶.۴ مقایسه مدل‌ها در پروتکل نسبی ViT-S ۷۸
۷.۴ مقایسه مدل‌ها در پروتکل نسبی ViT-L ۷۸
۸.۴ اثر افزونه‌سازی هندسی در پروتکل نسبی ۷۸
۹.۴ نتایج ارزیابی مطلق در پیکربندی زوم‌برش ۸۰
۱۰.۴ نتایج مطلق در پیکربندی لرزش کانونی ۸۱
۱۱.۴ نتایج مطلق در پیکربندی تفکیک اثر ۸۳
۱۲.۴ جمع‌بندی پیکربندی‌های آموزشی مطلق ۸۴
۱۳.۴ شیب پیمایش فاصله کانونی ۸۶

۱۴.۴ آزمون حذف و تحریف ماتریس دوربین ۸۸
۱۵.۴ مقایسه مدل‌ها با انکودر ViT-L پس از آموزش چندمجموعه‌ای ۹۱

۱.۵ پاسخ به سوالات تحقیق و داوری فرضیه‌های تجربی ۱۰۷
۲.۵ جمع‌بندی نوآوری‌ها و دستاوردها ۱۱۲
۳.۵ محدودیت‌ها و مسیرهای پژوهشی آینده ۱۱۵

فهرست اختصارات

معادل فارسی	اختصار	صورت کامل انگلیسی
بینایی ماشین	CV	Computer Vision
تخمین عمق تک‌دوربینه	MDE	Monocular Depth Estimation
شبکه عصبی کانولوشنی	CNN	Convolutional Neural Network
میدان دید	FoV	Field of View
سیستم‌های کمک‌راننده پیشرفته	ADAS	Advanced Driver-Assistance Systems
ترنسفورمر بینایی	ViT	Vision Transformer
ترنسفورمر پیش‌بینی چگال	DPT	Dense Prediction Transformer
قرمز سبز آبی	RGB	Red–Green–Blue
قرمز سبز آبی و عمق	RGB-D	Red–Green–Blue–Depth
پرسپترون چندلایه	MLP	Multi-Layer Perceptron
تعدیل خطی در سطح ویژگی	FiLM	Feature-wise Linear Modulation
واحد خطی خطای گاوسی	GELU	Gaussian Error Linear Unit
واحد خطی یکسوشده	ReLU	Rectified Linear Unit
واحد پردازش گرافیکی	GPU	Graphics Processing Unit
قالب تبادل اطلاعات تصویری	EXIF	Exchangeable Image File Format
ریشه میانگین مربعات خطا	RMSE	Root Mean Squared Error
خطای نسبی مطلق	AbsRel	Absolute Relative Error
خطای نسبی مربعی	SqRel	Squared Relative Error
تابع هزینه لگاریتمی تغییرناپذیر نسبت به مقیاس	SiLog	Scale-Invariant Logarithmic Loss
عمق مطلق صفرنمونه	DMD	Zero-Shot Metric Depth

کتاب‌نامه

[1] Saxena, Ashutosh, Sun, Min, and Ng, Andrew Y. Make3d: Learning 3d scene structure from a single still image. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31(5):824–840, 2009.

[2] Eigen, David, Puhrsch, Christian, and Fergus, Rob. Depth map prediction from a single image using a multi-scale deep network. in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, pp. 2366–2374, 2014.

[3] Hartley, Richard and Zisserman, Andrew. *Multiple View Geometry in Computer Vision*. Cambridge University Press, Cambridge, UK, 2 ed. , 2004.

[4] Yang, Lihe, Kang, Bingyi, Huang, Zilong, Zhao, Zhen, Xu, Xiaogang, Feng, Jiashi, and Zhao, Hengshuang. Depth anything v2. in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 37, 2024. arXiv:2406.09414.

[5] Eigen, David and Fergus, Rob. Predicting depth, surface normals and semantic labels with a common multi-scale convolutional architecture. in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2650–2658, 2015.

[6] Ranftl, René, Bochkovskiy, Alexey, and Koltun, Vladlen. Vision transformers for dense prediction. in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 12179–12188, 2021.

[7] Ranftl, René, Lasinger, Katrin, Hafner, David, Schindler, Konrad, and Koltun, Vladlen. Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(3):1623–1637, 2022. نسخهٔ پیش‌چاپ: arXiv:1907.01341, 2019.

[8] Facíl, Jose M., Ummenhofer, Benjamin, Zhou, Huizhong, Montesano, Luis, Brox, Thomas, and Civera, Javier. Cam-convs: Camera-aware multi-scale convolutions for single-view depth. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11826–11835, 2019.

[9] Yin, Wei, Zhang, Chi, Chen, Hao, Cai, Zhipeng, Yu, Gang, Wang, Kaixuan, Chen, Xiaozhi, and Shen, Chunhua. Metric3d: Towards zero-shot metric 3d prediction from a single image. in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 9043–9053, 2023.

[10] Godard, Clément, Mac Aodha, Oisin, and Brostow, Gabriel J. Unsupervised monocular depth estimation with left-right consistency. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 270–279, 2017.

[11] Bhat, Shariq Farooq, Birkl, Reiner, Wofk, Diana, Wonka, Peter, and Müller, Matthias. Zoedepth: Zero-shot transfer by combining relative and metric depth. *arXiv preprint arXiv:2302.12288*, 2023.

[12] Godard, Clément, Mac Aodha, Oisin, Firman, Michael, and Brostow, Gabriel J. Digging into self-supervised monocular depth estimation. in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 3828–3838, 2019.

[13] Saxena, Saurabh, Hur, Junhwa, Herrmann, Charles, Sun, Deqing, and Fleet, David J. Zero-shot metric depth with a field-of-view conditioned diffusion model. *arXiv preprint arXiv:2312.13252*, 2023.

[14] Piccinelli, Luigi, Yang, Yung-Hsu, Sakaridis, Christos, Segu, Mattia, Li, Siyuan, Van Gool, Luc, and Yu, Fisher. Unidepth: Universal monocular metric depth estimation. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 10106–10116, 2024.

[15] Casser, Vincent, Pirk, Sören, Mahjourian, Reza, and Angelova, Anelia. Depth prediction without the sensors: Leveraging structure for unsupervised learning from monocular videos. in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, vol. 33, pp. 8001–8008, 2019.

[16] Yao, Yao, Luo, Zixin, Li, Shiwei, Fang, Tian, and Quan, Long. Mvsnet: Depth inference for unstructured multi-view stereo. in *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 767–783, 2018.

[17] Hoiem, Derek, Efros, Alexei A., and Hebert, Martial. Geometric context from a single image. in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 654–661, 2005.

[18] Zhou, Tinghui, Brown, Matthew, Snavely, Noah, and Lowe, David G. Unsupervised learning of depth and ego-motion from video. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1851–1858, 2017.

[19] Zhan, Huangying, Garg, Ravi, Weerasekera, Chamara Saroj, Li, Kejie, Agarwal, Harsh, and Reid, Ian. Unsupervised learning of monocular depth estimation and visual odometry with deep feature reconstruction. *arXiv preprint arXiv:1803.03893*, 2018.

[20] Amiri, Ali Jahani, Loo, Shing Yan, and Zhang, Hong. Semi-supervised monocular depth estimation with left-right consistency using deep neural network. *arXiv preprint arXiv:1905.07542*, 2019.

[21] Birkl, Reiner, Wofk, Diana, and M"uller, Matthias. Midas v3.1 – a model zoo for robust monocular relative depth estimation. *arXiv preprint arXiv:2307.14460*, 2023.

[22] Zhang, Ning, Nex, Francesco, Vosselman, George, and Kerle, Norman. Lite-mono: A lightweight cnn and transformer architecture for self-supervised monocular depth estimation. *arXiv preprint arXiv:2211.13202*, 2022.

[23] Yang, Lihe, Kang, Bingyi, Huang, Zilong, Xu, Xiaogang, Feng, Jiashi, and Zhao, Hengshuang. Depth anything: Unleashing the power of large-scale unlabeled data. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 10371–10381, 2024.

[24] He, Xiankang, Guo, Dongyan, Li, Hongji, Li, Ruibo, Cui, Ying, and Zhang, Chi. Distill any depth: Distillation creates a stronger monocular depth estimator. *arXiv preprint arXiv:2502.19204*, 2025.

[25] Hu, Mu, Yin, Wei, Zhang, Chi, Cai, Zhipeng, Long, Xiaoxiao, Wang, Kaixuan, Chen, Hao, Yu, Gang, Shen, Chunhua, and Shen, Shaojie. Metric3d v2: A versatile monocular geometric foundation model for zero-shot metric depth and surface normal estimation. *arXiv preprint arXiv:2404.15506*, 2024.

[26] Ke, Bingxin, Obukhov, Anton, Huang, Shengyu, Metzger, Nando, Daudt, Rodrigo Caye, and Schindler, Konrad. Repurposing diffusion-based image generators for monocular depth estimation. *arXiv preprint arXiv:2312.02145*, 2023.

[27] Viola, Massimiliano, Qu, Kevin, Metzger, Nando, Ke, Bingxin, Becker, Alexander, Schindler, Konrad, and Obukhov, Anton. Marigold-dc: Zero-shot monocular depth completion with guided diffusion. *arXiv preprint arXiv:2412.13389*, 2024.

[28] Oquab, Maxime, Darcet, Timothée, Moutakanni, Théo, Vo, Huy V., Szafraniec, Marc, Khalidov, Vasil, Fernandez, Pierre, Haziza, Daniel, Massa, Francisco, El-Nouby, Alaaeldin, Assran, Mahmoud, Ballas, Nicolas, Galuba, Wojciech, Howes, Russell, Huang, Po-Yao, Li, Shang-Wen, Misra, Ishan, Rabbat, Michael, Sharma, Vasu, Synnaeve, Gabriel, Xu, Hu, Jegou, Hervé, Mairal, Julien, Labatut, Patrick, Joulin, Armand, and Bojanowski, Piotr. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 2024. نسخهٔ پیش‌چاپ: arXiv:2304.07193, 2023.

[29] Dosovitskiy, Alexey, Beyer, Lucas, Kolesnikov, Alexander, Weissenborn, Dirk, Zhai, Xiaohua, Unterthiner, Thomas, Dehghani, Mostafa, Minderer, Matthias, Heigold, Georg, Gelly, Sylvain, Uszkoreit, Jakob, and Houlsby, Neil. An image is worth 16x16 words: Transformers for image recognition at scale. in *International Conference on Learning Representations (ICLR)*, 2021.

[30] Perez, Ethan, Strub, Florian, de Vries, Harm, Dumoulin, Vincent, and Courville, Aaron. Film: Visual reasoning with a general conditioning layer. in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, vol. 32, pp. 3942–3951, 2018.

[31] Lin, Haotong, Chen, Sili, Liew, Jun Hao, Chen, Donny Y., Li, Zhenyu, Shi, Guang, Feng, Jiashi, and Kang, Bingyi. Depth anything 3: Recovering the visual space from any views. *arXiv preprint arXiv:2511.10647*, 2025.

[32] Gaidon, Adrien, Wang, Qiao, Cabon, Yohann, and Vig, Eleonora. Virtual worlds as proxy for multi-object tracking analysis. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4340–4349, 2016.

[33] Silberman, Nathan, Hoiem, Derek, Kohli, Pushmeet, and Fergus, Rob. Indoor segmentation and support inference from rgbd images. in *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 746–760, 2012.

[34] Vasiljevic, Igor, Kolkin, Nick, Zhang, Shanyi, Luo, Ruotian, Wang, Haochen, Dai, Falcon Z., Daniele, Andrea F., Mostajabi, Mohammadreza, Basart, Steven, Walter, Matthew R., and Shakhnarovich, Gregory. Diode: A dense indoor and outdoor depth dataset. *arXiv preprint arXiv:1908.00463*, 2019.

[35] Cordts, Marius, Omran, Mohamed, Ramos, Sebastian, Rehfeld, Timo, Enzweiler, Markus, Benenson, Rodrigo, Franke, Uwe, Roth, Stefan, and Schiele, Bernt. The cityscapes dataset for semantic urban scene understanding. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 3213–3223, 2016.

[36] Scharstein, Daniel, Hirschmüller, Heiko, Kitajima, York, Krathwohl, Greg, Nešić, Nera, Wang, Xi, and Westling, Porter. High-resolution stereo datasets with subpixel-accurate ground truth. in *German Conference on Pattern Recognition (GCPR)*, pp. 31–42, 2014.

[37] Geiger, Andreas, Lenz, Philip, and Urtasun, Raquel. Are we ready for autonomous driving? the kitti vision benchmark suite. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 3354–3361, 2012.

[38] Cabon, Yohann, Murray, Naila, and Humenberger, Martin. Virtual KITTI 2. *arXiv preprint arXiv:2001.10773*, 2020.

[39] Song, Shuran, Lichtenberg, Samuel P., and Xiao, Jianxiong. SUN RGB-D: A RGB-D scene understanding benchmark suite. in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 567–576, 2015.

[40] Roberts, Mike, Ramapuram, Jason, Ranjan, Anurag, Kumar, Atulit, Bautista, Miguel Angel, Paczan, Nathan, Webb, Russ, and Susskind, Joshua M. Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding. in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 10912–10922, 2021.

[41] Loshchilov, Ilya and Hutter, Frank. Decoupled weight decay regularization. in *International Conference on Learning Representations (ICLR)*, 2019.

[42] Wilcoxon, Frank. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.

[43] Efron, Bradley and Tibshirani, Robert J. *An Introduction to the Bootstrap*. Chapman and Hall/CRC, New York, 1993.

[44] Paszke, Adam, Gross, Sam, Massa, Francisco, Lerer, Adam, Bradbury, James, Chanan, Gregory, Killeen, Trevor, Lin, Zeming, Gimelshein, Natalia, Antiga, Luca, Desmaison, Alban, Köpf, Andreas, Yang, Edward, DeVito, Zachary, Raison, Martin, Tejani, Alykhan, Chilamkurthy, Sasank, Steiner, Benoit, Fang, Lu, Bai, Junjie, and Chintala, Soumith. Pytorch: An imperative style, high-performance deep learning library. in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 8024–8035, 2019.

[45] Bochkovskii, Aleksei, Delaunoy, Amaël, Germain, Hugo, Santos, Marcel, Zhou, Yichao, Richter, Stephan R., and Koltun, Vladlen. Depth pro: Sharp monocular metric depth in less than a second. in *International Conference on Learning Representations (ICLR)*, 2025. arXiv:2410.02073.

واژه‌نامه فارسی به انگلیسی

معادل فارسی	معادل انگلیسی
آزمون ویلکاکسون	Wilcoxon Signed-rank Test
ابهام مقیاس	Scale Ambiguity
اعوجاج	Distortion
افزونه‌سازی	Augmentation
انکودر دوربین	Camera Encoder
بازنمونه‌گیری بوت‌استرپ	Bootstrap Resampling
بدساخت	Ill-posed
بذر تصادفی	Random Seed
برش تصادفی	Random Crop
بیش‌برازش	Overfitting
پارامترهای درونی دوربین	Camera Intrinsics
پیش‌آموزش	Pre-training
تابع هزینه	Loss Function
تجمع گرادیان	Gradient Accumulation
تخمین عمق تک‌دوربینه	Monocular Depth Estimation
ترنسفورمر	Transformer
تعمیم	Generalization
تنظیم دقیق	Fine-tuning
توکن	Token
توکن با گیت یادگیری‌پذیر	Learnable-gated Token
دوربین سوراخ‌سوزنی	Pinhole Camera
سر شبکه	Head Layers
صفرنمونه	Zero-shot
ضریب کنترلی	Control Coefficient
عمق مطلق	Absolute Depth
عمق معکوس (دیسپاریتی)	Inverse Depth (Disparity)
عمق نسبی	Relative Depth
فاصله کانونی	Focal Length
ماتریس کالیبراسیون دوربین	Camera Calibration Matrix
مجموعه‌داده مصنوعی	Synthetic Dataset
محدودسازی گرادیان	Gradient Clipping
محیط‌های بیرونی	Outdoor
محیط‌های داخلی	Indoor
مدل بنیادین	Foundation Model
مدل پیشنهادی	Proposed Model

معادل فارسی	معادل انگلیسی
مدل کنترل	Control Model
معادل فارسی	
میدان دید	Field of View
نرخ یادگیری	Learning Rate
نقشه عمق	Depth Map
نقطه اصلی	Principal Point
نقطهٔ وارسی	Checkpoint
یادگیری خودنظارتی	Self-supervised Learning

واژه‌نامه انگلیسی به فارسی

معادل انگلیسی	معادل فارسی
Absolute Depth	عمق مطلق
Augmentation	افزونه‌سازی
Bootstrap Resampling	بازنمونه‌گیری بوت‌استرپ
Camera Calibration Matrix	ماتریس کالیبراسیون دوربین
Camera Encoder	انکودر دوربین
Camera Intrinsics	پارامترهای درونی دوربین
Checkpoint	نقطهٔ وارسی
Control Coefficient	ضریب کنترلی
Control Model	مدل کنترل
Learnable-gated Token	توکن با گیت یادگیری‌پذیر
Depth Map	نقشه عمق
Distortion	اعوجاج
Field of View	میدان دید
Fine-tuning	تنظیم دقیق
Focal Length	فاصله کانونی
Foundation Model	مدل بنیادین
Generalization	تعمیم
Gradient Accumulation	تجمع گرادیان
Gradient Clipping	محدودسازی گرادیان
Head Layers	سر شبکه
Ill-posed	بدساخت
Indoor	محیط‌های داخلی
Inverse Depth (Disparity)	عمق معکوس (دیسپاریتی)
Learning Rate	نرخ یادگیری
Loss Function	تابع هزینه
Monocular Depth Estimation	تخمین عمق تک‌دوربینه
Outdoor	محیط‌های بیرونی
Overfitting	بیش‌برازش
Pinhole Camera	دوربین سوراخ‌سوزنی
Pre-training	پیش‌آموزش
Principal Point	نقطه اصلی
Proposed Model	مدل پیشنهادی
Random Crop	برش تصادفی
Random Seed	بذر تصادفی
Relative Depth	عمق نسبی

معادل انگلیسی	معادل فارسی
Scale Ambiguity	ابهام مقیاس
Self-supervised Learning	یادگیری خودنظارتی
Synthetic Dataset	مجموعه‌داده مصنوعی
Token	توکن
Transformer	ترنسفورمر
Wilcoxon Signed-rank Test	آزمون ویلکاکسون
Zero-shot	صفرنمونه
	معادل فارسی

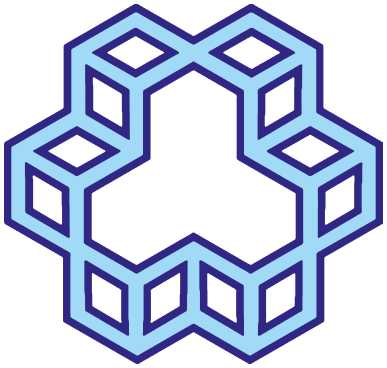
Abstract

Monocular depth estimation (MDE) underpins robotics, autonomous driving, augmented reality, and 3D reconstruction, yet a single image does not uniquely determine the absolute scale of a scene, and current foundation models mostly output relative depth that is insufficient for physical measurement. Methods such as CAM-Convs, Metric3D, and UniDepth mitigate this by feeding camera intrinsics to the network, but none of the existing methods feeds the known intrinsics, without estimating them, as a token into the transformer encoder of a single-image foundation model: CAM-Convs adds them as coordinate channels to convolutions, Metric3D maps the input to a canonical camera space outside the network, UniDepth and Depth Pro estimate the camera from the image itself, and Depth Anything 3 uses a camera token only for cross-view consistency with multi-view input. Moreover, in these methods the camera information was introduced together with changes in architecture, data, and training schedule, so the contribution of the camera calibration matrix itself has not been isolated.

In this thesis, a normalized nine-dimensional descriptor of the known camera calibration matrix is encoded by a transformer camera encoder and injected as a gated token into the transformer DINOv2 encoder of Depth Anything V2, and the proposed model is compared with a control model that shares the same data, split, hyperparameters, and random seed and differs only in its access to the calibration matrix. Evaluation uses the standard NYUv2 test split. Under relative evaluation, per-image scale-and-shift alignment removes most of the information carried by the focal length, and the contribution of the calibration matrix is significant only for the ViT-S encoder; under absolute evaluation without alignment, the proposed model consistently outperforms the control, and the margin grows with field-of-view diversity. With a geometrically exact focal-jitter augmentation that makes scale unrecoverable from pixels alone, AbsRel falls from 0.1030 for the control to 0.0849 for the proposed model (about an 18 percent reduction). The log–log slope of predicted depth versus focal scale rises from 0.06 to 0.93–0.97 (ideal value 1), and withholding the calibration matrix increases AbsRel by 59 percent. Camera intrinsics therefore provide a statistically significant and causally necessary scale signal, although this reliance increases sensitivity to calibration accuracy, and generalization to genuinely multi-camera and outdoor data requires further study.

As a first step in that direction, a single ViT-L model was trained jointly on NYUv2, KITTI, Virtual KITTI 2, and Cityscapes, covering four cameras and both indoor and outdoor scenes. On NYUv2, Cityscapes, and two SUN RGB-D sensors unseen in training (Kinect v1 and Kinect v2), the proposed model is more accurate than both the control model and the released metric Depth Anything V2 model in AbsRel and δ_1; on NYUv2, for example, AbsRel is 0.088, against 0.133 for the control and 0.207 for the released model.

Keywords Monocular Depth Estimation, Unsupervised Deep Learning, Absolute Depth, Camera Intrinsics, Imaging Geometry, Depth Anything V2



K. N. Toosi University of Technology
Faculty of Computer Engineering- Artificial Intelligence Group

Thesis Submitted in Partial Fulfillment of the
Requirements for the Degree of Master of Science (M.Sc.)
in Computer Engineering

Unsupervised Depth Estimation Using Internal Calibration Parameters as Input

By:

Mohammad Amin Ghasemzadeh

Supervisor:

Dr. Behrouz Nasihatkon

Autumn 2026